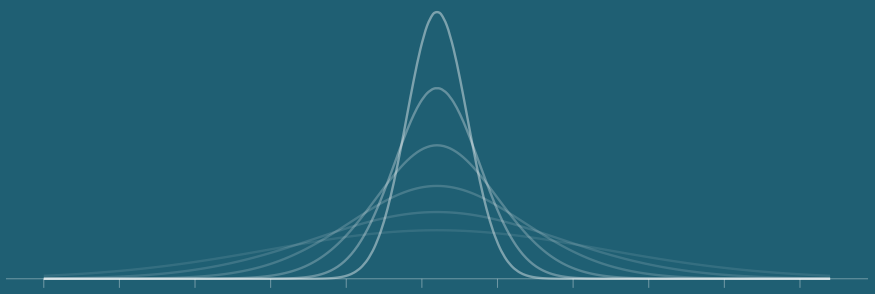
新领军计划 · 重构版

数理统计自学讲义

从数据到推断

抽样　估计　区间　检验　两样本　回归



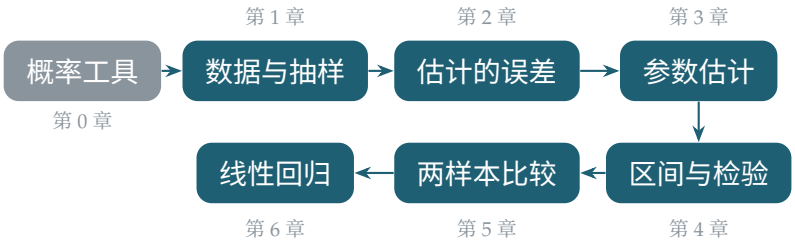
2026 年 10 月

写在前面

这份讲义想做什么

统计学回答的是一类特别的问题：只看到了一部分，怎样对整体说话，又怎样说清楚自己可能错多少。抛十次硬币得到七次正面，硬币偏不偏？测了十个病人，新药有没有效？量了十七次沸点和气压，能不能用沸点推算海拔？这些问题都有同一个结构：数据是随机的，我们关心的却是背后固定而未知的量。

这份讲义要带你走完一条完整的路：



每一站都先问为什么需要它，再给出定义和结论，然后用一个能算到底的例子把它落地，最后说清楚它什么时候不能用、不能用时该用什么。

和原讲义的关系

本讲义是在原《新领军计划数理统计自学讲义》（141 页）的基础上重新组织、重新写作的。原讲义的数学功底很扎实：对假设的精确性、取等条件和唯一性一丝不苟，不少题目（最优耦合、对称化、置换检验、回归的几何）很有深度。但它更像一本以统计为背景的高难度题集，作为自学教材有几处明显的问题。重写时针对它们做了如下改动：

原讲义的问题	本讲义的处理
数学技巧压过统计理解	主线按“数据与抽样 → 估计误差 → 参数估计 → 区间与检验 → 两样本 → 回归”的学习顺序展开；组合极值、最优耦合、构造与唯一性证明一律移到标有 ★ 的“深入讨论”和 C 级习题，第一遍可以跳过。
前置知识没交代	新增**第 0 章概率工具箱**：协方差与和的方差、切比雪夫不等式、两种收敛的区别、中心极限定理、Delta 方法，全部在第一次使用前讲清楚。
几乎没有图	全书配有二十余幅统计图与示意图：抽样分布随 n 集中、偏差与方差的靶图、似然曲线、置信区间的覆盖、p 值的尾部面积、功效函数、配对图与 QQ 图、最小二乘与残差、置信带与预测带、杠杆点、辛普森悖论……图是正文的一部分。
只说“不能用”，不说“该用什么”	合并方差 t 检验之后紧接着讲 **Welch 检验**，并用模拟展示合并方差检验在什么情形下失效；比例的 Wald 区间之后给出 Wilson 区间；每章都有“方法的适用条件”与选择建议。
缺少真实数据与模型检查	使用两份经典真实数据贯穿后半部分：Student（1908）的**睡眠药物数据**、Forbes（1857）的**沸点与气压数据**；讲解箱线图、QQ 图、残差图如何检查假设，以及发现异常点后怎么办。
习题跨度过大、缺少提示	每章习题分为 **A 基础**、**B 进阶**、**C 挑战**三级，C 级保留原讲义的精华题并附提示；附录 A 给出全部习题的解答。

原讲义中关于“只保存部分数据能确定什么”、随机化检验、标签置换等较专门的内容，这里做了取舍：保留其核心思想并放到合适的位置，删去了与主线关系较远、主要考验技巧的部分。

怎样使用这份讲义

需要的准备　一元微积分（求导、积分、泰勒展开），以及初等概率（事件、条件概率、随机变量、期望）。遇到不熟悉的概率工具，先翻第 0 章；第 0 章本身也可以作为复习单独读。

阅读节奏　建议的第一遍路线是：第 0 章快速浏览 → 第 1 至 6 章的正文与 A、B 级习题，跳过所有 ★ 内容。第二遍再读“深入讨论”并挑战 C 级习题。每章开头的“本章导引”说明了这一章要解决的问题和需要的预备知识；章末的“本章小结”列出必须掌握的要点，可以用来自测。

书中的标记

定义 示例　定义放在这样的浅色框里。

定理 （示例）

重要的定理和命题放在带标题栏的框里，后面一般紧跟证明。

◆ **直观理解**

“直观理解”用来解释一个结论为什么应该成立，或者应该怎样想到它。

常见误区

“常见误区”提醒初学者最容易犯的错误。

★ **深入讨论**

标有 ★ 的“深入讨论”内容更难，或离主线较远，第一遍可以跳过，不影响后续阅读。

记号约定

记号	含义
X, Y, X_i	随机变量（大写）；对应的观测值用小写 x, y, x_i
$\bar{X}$, S^2	样本均值 $\frac{1}{n}\sum X_i$，样本方差 $\frac{1}{n-1}\sum (X_i-\bar{X})^2$
θ, Θ	参数，参数空间
$\mathbb{P}_\theta$, $\mathbb{E}_\theta$, Var_θ	参数为 θ 时的概率、期望、方差（可省略下标）
$X_i \overset{\text{iid}}{\sim} F$	各 X_i 独立同分布，共同分布为 F
$\mathcal{N}(\mu,\sigma^2)$	均值 μ、方差 σ^2 的正态分布；Φ 为标准正态分布函数
z_q, $t_{\nu,q}$	标准正态分布、自由度 ν 的 t 分布的 q 分位数，如 $z_{0.975}\approx 1.96$
$\xrightarrow{\text{P}}$, $\xrightarrow{\text{d}}$	依概率收敛，依分布收敛（第 0 章）
$\mathbf{1}_A$	事件 A 的示性变量：A 发生取 1，否则取 0

本讲义的图中，标明“模拟”的结果均由固定随机种子的程序生成，其余均为精确计算。

目　录

写在前面 iii

第 0 章　概率工具箱 1

0.1　期望与方差：计算规则 . . . 1
0.2　协方差与和的方差 . . . 2
0.3　常用分布一览 . . . 3
0.4　两个不等式：只用均值和方差控制概率 . . . 4
0.5　大数定律与依概率收敛 . . . 5
0.6　中心极限定理与依分布收敛 . . . 6
0.7　Delta 方法：函数的误差怎样传递 . . . 8
习题 . . . 10

第 1 章　数据与抽样 11

1.1　总体、样本、参数与统计量 . . . 11
1.2　描述一组数据 . . . 12
1.3　抽样分布与标准误 . . . 14
1.4　样本方差：为什么除以 $n-1$ . . . 15
1.5　有限总体与不放回抽样 . . . 16
1.6　分层抽样 . . . 17
1.7　★ 深入讨论 . . . 19
习题 . . . 20

第 2 章　估计量及其误差 22

2.1　估计量是随机变量 . . . 22
2.2　偏差、方差与均方误差 . . . 23
2.3　案例：估计均匀分布的上界 . . . 23
2.4　无偏性的局限 . . . 24
2.5　合并几个估计：逆方差加权 . . . 26
2.6　相合性：样本越大，越接近真值 . . . 26

2.7 ★深入讨论 . . . 27
习题 . . . 28

第 3 章 构造估计量：矩估计与极大似然 30

3.1 矩估计 . . . 30
3.2 可识别性：数据能否区分参数 . . . 31
3.3 似然函数 . . . 31
3.4 极大似然估计 . . . 32
3.5 极大似然估计有多准：Fisher 信息 . . . 34
3.6 ★深入讨论 . . . 36
习题 . . . 37

第 4 章 置信区间与假设检验 39

4.1 从标准误到置信区间 . . . 39
4.2 正态样本的精确理论：t 分布 . . . 40
4.3 比例的区间：不要只会用 Wald 区间 . . . 42
4.4 假设检验的逻辑 . . . 43
4.5 p 值：用尾概率表示证据 . . . 44
4.6 检验与区间：一枚硬币的两面 . . . 46
4.7 常见的陷阱 . . . 46
4.8 ★深入讨论 . . . 47
习题 . . . 48

第 5 章 两个样本的比较 50

5.1 先问设计，再选方法 . . . 50
5.2 配对数据：先求差，再推断 . . . 51
5.3 两个独立正态样本：合并方差 t 检验 . . . 51
5.4 方差不等时：Welch 检验 . . . 52
5.5 两个比例 . . . 54
5.6 不依赖正态的精确检验 . . . 54
5.7 检查假设 . . . 56
5.8 ★深入讨论 . . . 57
习题 . . . 58

第 6 章 一元线性回归 60

6.1 最小二乘直线 . . . 61

6.2 几何视角：投影与平方和分解 62
6.3 统计模型与估计精度 63
6.4 正态误差下的推断 64
6.5 检查模型：残差图 65
6.6 异常点与强影响点 66
6.7 完整案例：Forbes 数据分析 68
6.8 ★深入讨论 68
习题 69

附录 A 习题解答 71

附录 B 分位数表与内容对照 80

预备

概率工具箱

为什么先读这一章　统计推断的每一步都要用到几件概率工具：期望和方差的计算规则、协方差（求和的方差时必不可少）、切比雪夫不等式、大数定律、中心极限定理，以及 Delta 方法。原讲义在用到它们时才突然引入，这里把它们集中讲清楚。

怎么读　学过概率论的读者可以只看 0.2、0.6、0.7 三节和章末习题；没学过的读者请完整读一遍。本章的结论后面会反复引用。

预备　事件与概率、离散与连续随机变量、密度函数、独立性。

0.1　期望与方差：计算规则

设 X 是随机变量。离散时 $\mathbb{E}X=\sum_x x\,\mathbb{P}(X=x)$，有密度 f 时 $\mathbb{E}X=\int x f(x)\,\mathrm{d}x$（要求级数或积分绝对收敛）。更一般地，对函数 g，$\mathbb{E}g(X)$ 用 $g(x)$ 代替 x 计算。

定理 0.1（期望的线性性）

对任意可积随机变量 $X_1,\dots,X_n$ 和常数 $a_1,\dots,a_n,b$，

$$\mathbb{E}\Big(\sum_{i=1}^{n} a_iX_i+b\Big)=\sum_{i=1}^{n} a_i\mathbb{E}X_i+b.$$

这里不需要任何独立性。

线性性看似平凡，却是全书最常用的工具。它最漂亮的用法是配合**示性变量**：若 A 是事件，$\mathbf{1}_A$ 在 A 发生时取 1、否则取 0，则 $\mathbb{E}\mathbf{1}_A=\mathbb{P}(A)$。

> **例 0.1（用示性变量求二项分布的均值）**　独立抛一枚正面概率为 p 的硬币 n 次，正面次数为 K。求 $\mathbb{E}K$。

解. 令 I_i 为“第 i 次是正面”的示性变量，则 $K=I_1+\cdots+I_n$。由线性性，$\mathbb{E}K=\sum_i \mathbb{E}I_i=np$。不需要对 $\binom{n}{k}p^k(1-p)^{n-k}$ 求和。 □

定义 0.2 方差与标准差　若 $\mathbb{E}X^2 < \infty$，记 $\mu = \mathbb{E}X$，称 $\operatorname{Var} X = \mathbb{E}(X-\mu)^2$ 为 X 的方差，$\sqrt{\operatorname{Var} X}$ 为标准差。

展开平方并用线性性，得到最常用的计算公式和平移、伸缩规则：

$$\operatorname{Var} X = \mathbb{E}X^2 - (\mathbb{E}X)^2, \qquad \operatorname{Var}(aX+b) = a^2 \operatorname{Var} X. \tag{0.1}$$

平移不改变分散程度，伸缩 a 倍使方差变为 a^2 倍、标准差变为 $|a|$ 倍。对示性变量，$\mathbf{1}_A^2 = \mathbf{1}_A$，所以 $\operatorname{Var}\mathbf{1}_A = \mathbb{P}(A) - \mathbb{P}(A)^2 = \mathbb{P}(A)(1-\mathbb{P}(A))$。

0.2　协方差与和的方差

统计里最常见的操作是求平均。平均 n 次测量为什么更准？要回答它，就要知道和的方差。先看两个变量：

$$\operatorname{Var}(X+Y) = \mathbb{E}\big[(X-\mathbb{E}X)+(Y-\mathbb{E}Y)\big]^2 = \operatorname{Var} X + \operatorname{Var} Y + 2\,\mathbb{E}\big[(X-\mathbb{E}X)(Y-\mathbb{E}Y)\big].$$

最后一项描述 X, Y 是否“同涨同落”，它有专门的名字。

定义 0.3 协方差与相关系数　设 X, Y 的二阶矩有限。称

$$\operatorname{Cov}(X,Y) = \mathbb{E}\big[(X-\mathbb{E}X)(Y-\mathbb{E}Y)\big] = \mathbb{E}(XY) - \mathbb{E}X\,\mathbb{E}Y$$

为 X 与 Y 的协方差。当两者方差都为正时，称 $\operatorname{Corr}(X,Y) = \operatorname{Cov}(X,Y)/\sqrt{\operatorname{Var} X \operatorname{Var} Y}$ 为相关系数。$\operatorname{Cov}(X,Y)=0$ 时称两者**不相关**。

协方差的性质与乘法完全类似：

- 对称：$\operatorname{Cov}(X,Y) = \operatorname{Cov}(Y,X)$；且 $\operatorname{Cov}(X,X) = \operatorname{Var} X$；
- 双线性：$\operatorname{Cov}(aX+bY+c,\, Z) = a\operatorname{Cov}(X,Z) + b\operatorname{Cov}(Y,Z)$，常数 c 不起作用。

定理 0.4 （和的方差）

若 $X_1, \dots, X_n$ 的二阶矩有限，则

$$\operatorname{Var}\Big(\sum_{i=1}^{n} a_i X_i\Big) = \sum_{i=1}^{n} a_i^2 \operatorname{Var} X_i + 2\sum_{1\le i<j\le n} a_i a_j \operatorname{Cov}(X_i, X_j).$$

特别地，若它们两两不相关（例如相互独立），则交叉项全部消失：$\operatorname{Var}(\sum a_i X_i) = \sum a_i^2 \operatorname{Var} X_i$。

证明. 由双线性，$\operatorname{Var}(\sum_i a_i X_i) = \operatorname{Cov}(\sum_i a_i X_i, \sum_j a_j X_j) = \sum_i \sum_j a_i a_j \operatorname{Cov}(X_i, X_j)$。$i = j$ 的项给出 $a_i^2 \operatorname{Var} X_i$，$i \neq j$ 的项两两成对，合起来是 $2\sum_{i<j}$。若 X_i, X_j 独立，则 $\mathbb{E}(X_i X_j) = \mathbb{E}X_i \, \mathbb{E}X_j$，协方差为零。 ■

> **例 0.2（二项分布的方差）** 接例 0.1。各 I_i 独立，$\operatorname{Var} I_i = p(1-p)$，所以 $\operatorname{Var} K = np(1-p)$。正面比例 $\bar{X} = K/n$ 的方差是 $p(1-p)/n$。

> **常见误区**
>
> **不相关不等于独立。**设 X 在 $\{-1, 0, 1\}$ 上等可能，$Y = X^2$。Y 完全由 X 决定，但 $\mathbb{E}(XY) = \mathbb{E}X^3 = 0 = \mathbb{E}X \, \mathbb{E}Y$，所以 $\operatorname{Cov}(X, Y) = 0$。协方差只度量线性的共同变化。不过，计算和的方差时只需要不相关，这比独立弱得多。

协方差为负的情形在抽样中很常见，下面这个例子在第 1 章会再次出现。

> **例 0.3（不放回抽取的负相关）** 袋中有 $N \geq 2$ 个球，其中 M 个红球。不放回地依次摸两个，I_1, I_2 分别表示第一、二个是红球。求 $\operatorname{Cov}(I_1, I_2)$。

解. 由对称性，每次摸到红球的概率都是 M/N。两次都是红球的概率为 $\frac{M}{N} \cdot \frac{M-1}{N-1}$。于是

$$\operatorname{Cov}(I_1, I_2) = \frac{M(M-1)}{N(N-1)} - \frac{M^2}{N^2} = -\frac{M(N-M)}{N^2(N-1)} \leq 0.$$

直观上，第一个是红球，袋里的红球就少了，第二个是红球的机会随之变小。 □

最后记下一个处处要用的不等式。

> **命题 0.5（柯西–施瓦茨不等式）**
>
> $|\operatorname{Cov}(X, Y)| \leq \sqrt{\operatorname{Var} X \, \operatorname{Var} Y}$，从而 $-1 \leq \operatorname{Corr}(X, Y) \leq 1$。当 $\operatorname{Var} Y > 0$ 时，取等号当且仅当 $X - \mathbb{E}X$ 以概率 1 等于 $Y - \mathbb{E}Y$ 的某个常数倍。

证明. 设 $\operatorname{Var} Y > 0$（否则两边都是 0）。对任意实数 t，$0 \leq \operatorname{Var}(X - tY) = \operatorname{Var} X - 2t \operatorname{Cov}(X, Y) + t^2 \operatorname{Var} Y$。取 $t = \operatorname{Cov}(X, Y)/\operatorname{Var} Y$ 即得 $\operatorname{Var} X - \operatorname{Cov}(X, Y)^2/\operatorname{Var} Y \geq 0$。等号成立当且仅当 $\operatorname{Var}(X - tY) = 0$，即 $X - tY$ 为常数。 ■

0.3 常用分布一览

下表列出本讲义用到的分布。Γ 函数、χ^2 分布与 t 分布在第 4 章再介绍。

表 0.1 常用分布

分布	取值	概率或密度	均值	方差
Bernoulli(p)	$\{0,1\}$	$\mathbb{P}(X=1)=p$	p	$p(1-p)$
Bin(n,p)	$\{0,\dots,n\}$	$\binom{n}{k}p^k(1-p)^{n-k}$	np	$np(1-p)$
Poisson(λ)	$\{0,1,\dots\}$	$e^{-\lambda}\lambda^k/k!$	λ	λ
U(a,b)	(a,b)	$1/(b-a)$	$(a+b)/2$	$(b-a)^2/12$
Exp(λ)	$(0,\infty)$	$\lambda e^{-\lambda x}$	$1/\lambda$	$1/\lambda^2$
$\mathcal{N}(\mu,\sigma^2)$	$\mathbb{R}$	$\frac{1}{\sqrt{2\pi}\sigma}e^{-(x-\mu)^2/(2\sigma^2)}$	μ	σ^2

关于正态分布，下面两条性质会反复使用：

(1) **标准化**：$X\sim\mathcal{N}(\mu,\sigma^2)$ 当且仅当 $Z=(X-\mu)/\sigma\sim\mathcal{N}(0,1)$。因此 $\mathbb{P}(X\le x)=\Phi((x-\mu)/\sigma)$，其中 Φ 是标准正态分布函数。

(2) **独立正态的线性组合仍是正态**：若 $X_i\sim\mathcal{N}(\mu_i,\sigma_i^2)$ 相互独立，则

$$\sum a_iX_i\sim\mathcal{N}\Big(\sum a_i\mu_i,\ \sum a_i^2\sigma_i^2\Big).$$

均值和方差由线性性和定理 0.4 给出，“仍是正态”这一点可用矩母函数证明。

几个需要记住的数：$\mathbb{P}(|Z|\le 1)\approx 0.683$，$\mathbb{P}(|Z|\le 1.96)\approx 0.95$，$\mathbb{P}(|Z|\le 2.576)\approx 0.99$。

0.4 两个不等式：只用均值和方差控制概率

很多时候我们只知道均值和方差，不知道完整分布。下面两个不等式说明，这已经足以控制“偏离很远”的概率。

定理 0.6 （马尔可夫与切比雪夫不等式）

(1)（马尔可夫）若 $Y\ge 0$，则对任意 $a>0$，$\mathbb{P}(Y\ge a)\le \mathbb{E}Y/a$。

(2)（切比雪夫）若 $\operatorname{Var}X<\infty$，则对任意 $\varepsilon>0$，

$$\mathbb{P}(|X-\mathbb{E}X|\ge\varepsilon)\le\frac{\operatorname{Var}X}{\varepsilon^2}.$$

证明. (1) 因为 $Y\ge a\mathbf{1}_{\{Y\ge a\}}$，取期望得 $\mathbb{E}Y\ge a\mathbb{P}(Y\ge a)$。(2) 对 $Y=(X-\mathbb{E}X)^2$ 和 $a=\varepsilon^2$ 应用 (1)。 ■

例 0.4（切比雪夫界有多粗） 公平硬币抛 100 次，正面比例 $\bar{X}$ 偏离 $1/2$ 至少 0.1 的概率是多少？

解. $\operatorname{Var}\bar{X} = \frac{1/4}{100} = \frac{1}{400}$，切比雪夫给出 $\mathbb{P}(|\bar{X} - \frac{1}{2}| \geq 0.1) \leq \frac{1/400}{0.01} = 0.25$。精确值是 $\mathbb{P}(|K - 50| \geq 10) \approx 0.057$。切比雪夫界对任何分布都成立，代价是它往往很保守。更精确的近似要靠 0.6 节的中心极限定理。 □

0.5 大数定律与依概率收敛

定义 0.7 依概率收敛 称随机变量序列 T_n **依概率收敛**到常数 c，记作 $T_n \xrightarrow{\mathrm{P}} c$，如果对每个 $\varepsilon > 0$，

$$\mathbb{P}(|T_n - c| > \varepsilon) \longrightarrow 0 \qquad (n \to \infty).$$

意思是：n 足够大时，T_n 落在 c 的任意小邻域之外的概率可以任意小。它不要求每一条样本路径都收敛，也不要求 $\mathbb{E}T_n \to c$（见习题 0.4）。

定理 0.8 （弱大数定律）

设 $X_1, X_2, \ldots$ 独立同分布，$\mathbb{E}X_1 = \mu$，$\operatorname{Var}X_1 = \sigma^2 < \infty$。则 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathrm{P}} \mu$。

证明. 由定理 0.4，$\operatorname{Var}\bar{X}_n = \sigma^2/n$。切比雪夫不等式给出 $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2) \to 0$。 ■

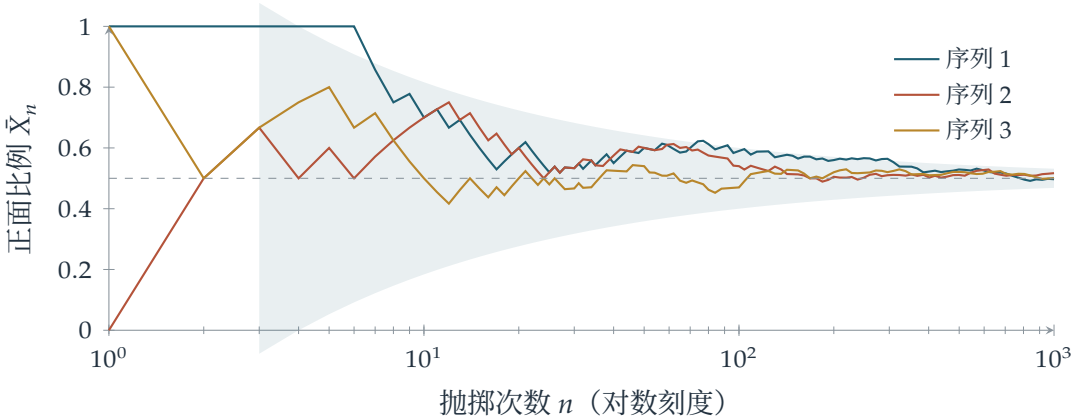


图 0.1 三条公平硬币序列的累计正面比例（模拟）。阴影是 $\frac{1}{2} \pm 2\sqrt{1/(4n)}$，宽度按 $1/\sqrt{n}$ 收窄。早期的波动很大，但三条曲线最终都被“挤”向 $1/2$——这就是大数定律。

依概率收敛与连续函数可以交换次序，这让我们能从简单的结论推出复杂的结论。

命题 0.9 （连续映射）

若 $T_n \xrightarrow{\mathrm{P}} c$，函数 g 在 c 处连续，则 $g(T_n) \xrightarrow{\mathrm{P}} g(c)$。对多个分量同样成立：若 $T_n \xrightarrow{\mathrm{P}} c$、$U_n \xrightarrow{\mathrm{P}} d$，$g$ 在 (c,d) 处连续，则 $g(T_n, U_n) \xrightarrow{\mathrm{P}} g(c,d)$。

证明. 给定 $\varepsilon > 0$，由连续性存在 $\delta > 0$，使 $|t-c| \le \delta$ 时 $|g(t)-g(c)| \le \varepsilon$。于是 $\{|g(T_n)-g(c)| > \varepsilon\} \subseteq \{|T_n - c| > \delta\}$，后者的概率趋于 0。多分量情形同理。 ■

例 0.5 （样本方差的收敛） 设 X_i 独立同分布且 $\mathbb{E}X_1^4 < \infty$，$\operatorname{Var} X_1 = \sigma^2$。记 $S_n^2 = \frac{1}{n-1}\sum (X_i - \bar X_n)^2$（第 1 章）。由于 $S_n^2 = \frac{n}{n-1}\left(\frac{1}{n}\sum X_i^2 - \bar X_n^2\right)$，大数定律给出 $\frac{1}{n}\sum X_i^2 \xrightarrow{\mathrm{P}} \mathbb{E}X_1^2$ 和 $\bar X_n \xrightarrow{\mathrm{P}} \mu$，连续映射给出 $S_n^2 \xrightarrow{\mathrm{P}} \mathbb{E}X_1^2 - \mu^2 = \sigma^2$，再由 $\sqrt{\cdot}$ 连续得 $S_n \xrightarrow{\mathrm{P}} \sigma$。（实际上只要 $\sigma^2 < \infty$ 就够了，但证明要用强一些的大数定律。）

0.6 中心极限定理与依分布收敛

大数定律说 $\bar X_n$ 会靠近 μ；但统计推断还要回答：偏离多少是正常的？偏离的量级是 $\sigma/\sqrt{n}$。把偏离放大 $\sqrt{n}$ 倍再看，它的分布会稳定下来，而且几乎总是正态的。

定义 0.10 依分布收敛 设 T_n 的分布函数为 F_n，T 的分布函数为 F。如果在 F 的每个连续点 t 都有 $F_n(t) \to F(t)$，就称 T_n **依分布收敛**到 T（或到 T 的分布），记作 $T_n \xrightarrow{\mathrm{d}} T$。

定理 0.11 （中心极限定理）

设 $X_1, X_2, \dots$ 独立同分布，$\mathbb{E}X_1 = \mu$，$0 < \operatorname{Var} X_1 = \sigma^2 < \infty$。则

$$\frac{\sqrt{n}\,(\bar X_n - \mu)}{\sigma} \xrightarrow{\mathrm{d}} \mathcal{N}(0,1), \qquad \text{即} \qquad \mathbb{P}\!\left(\frac{\sqrt{n}(\bar X_n - \mu)}{\sigma} \le z\right) \to \Phi(z) \text{ 对每个 } z.$$

证明需要特征函数，可在任何一本概率论教材中找到，这里从略。图 0.2 展示了它在说什么：即使单次观测的分布很偏（$p = 0.2$ 的伯努利分布只取 0, 1 且很不对称），标准化后的和也迅速接近钟形曲线。

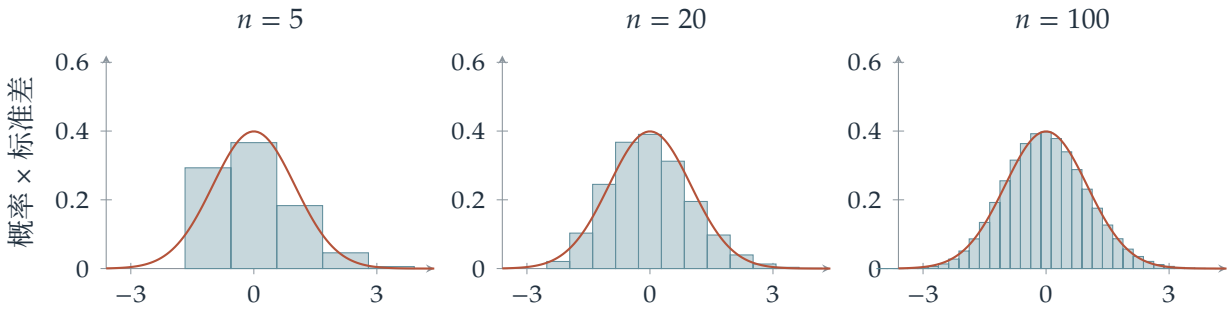


图 0.2 $K \sim \mathrm{Bin}(n, 0.2)$ 标准化为 $(K - np)/\sqrt{np(1-p)}$ 后的分布（精确计算；柱高为概率除以柱宽，以便与密度比较）。红线是 $\mathcal{N}(0,1)$ 的密度。$n = 5$ 时明显右偏，$n = 100$ 时已与正态曲线几乎重合。

> **例 0.6 （正态近似）** 公平硬币抛 100 次，求至少 60 次正面的概率。

解. K 的均值 50、标准差 5。K 只取整数，“$K \geq 60$”与“$K \geq 59.5$”是同一事件，用 59.5 做正态近似更准（**连续性修正**）：

$$\mathbb{P}(K \geq 60) \approx 1 - \Phi\Big(\frac{59.5 - 50}{5}\Big) = 1 - \Phi(1.9) \approx 0.0287.$$

精确值为 0.0284。不做修正得 $1 - \Phi(2) \approx 0.0228$，误差大得多。 □

0.6.1 两种收敛，别混为一谈

初学者最容易混淆的是：$\bar{X}_n$ 收敛到 μ，而 $\sqrt{n}(\bar{X}_n - \mu)$ 收敛到一个正态分布，两个结论有什么区别？

	依概率收敛 $T_n \xrightarrow{\mathrm{P}} c$	依分布收敛 $T_n \xrightarrow{\mathrm{d}} T$
说的是	T_n 本身越来越接近一个常数	T_n 的分布形状越来越像某个分布
典型例子	大数定律：$\bar{X}_n \xrightarrow{\mathrm{P}} \mu$	中心极限定理：$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{\mathrm{d}} \mathcal{N}(0, \sigma^2)$
统计用途	估计量是否相合（会不会估准）	误差有多大、怎样构造区间和检验
强弱关系	依概率收敛 $\Rightarrow$ 依分布收敛；极限是常数时两者等价	

两者在不同的尺度上看同一个误差 $\bar{X}_n - \mu$：不放大时它缩成一个点 0；放大 $\sqrt{n}$ 倍时它保持一个稳定的正态“形状”。放大得太少（例如乘 $n^{1/4}$），仍缩到 0；放大得太多（乘 n），则会发散。$\sqrt{n}$ 恰好是“刚刚好”的尺度。

> **常见误区**
>
> 依分布收敛只涉及分布，不涉及随机变量本身。例如 $X \sim \mathcal{N}(0,1)$，令 $X_n = -X$。

每个 X_n 都与 X 同分布，所以 $X_n \xrightarrow{\mathrm{d}} X$；但 $|X_n - X| = 2|X|$ 根本不变小，X_n 并不依概率收敛到 X。

0.6.2 把未知的 σ 换成估计值：Slutsky 定理

实际使用中心极限定理时，σ 通常未知，要用样本标准差 S_n 代替。下面的定理保证这样替换不改变极限。

定理 0.12 （Slutsky）

若 $T_n \xrightarrow{\mathrm{d}} T$，$U_n \xrightarrow{\mathrm{P}} c$（常数），则 $T_n + U_n \xrightarrow{\mathrm{d}} T + c$，$U_n T_n \xrightarrow{\mathrm{d}} cT$；当 $c \neq 0$ 时还有 $T_n / U_n \xrightarrow{\mathrm{d}} T/c$。

结合例 0.5（$S_n \xrightarrow{\mathrm{P}} \sigma$）与中心极限定理，得到第 4 章近似置信区间的基础：

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \cdot \frac{\sigma}{S_n} \xrightarrow{\mathrm{d}} \mathcal{N}(0,1). \tag{0.2}$$

0.7 Delta 方法：函数的误差怎样传递

估计了 μ，常常还要估计 $g(\mu)$，例如用 $1/\bar{X}$ 估计指数分布的参数 $\lambda = 1/\mu$。$\bar{X}$ 的误差约为 $\sigma/\sqrt{n}$，$g(\bar{X})$ 的误差是多少？答案是：在 μ 附近，g 近似是一条直线，斜率为 $g'(\mu)$，误差就被放大 $|g'(\mu)|$ 倍。

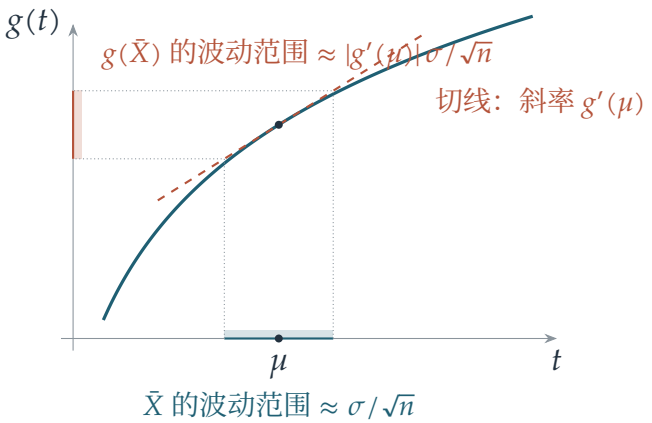


图 0.3　Delta 方法的几何意义：在 $\bar{X}$ 可能落入的小范围内，曲线 g 几乎与切线重合。

定理 0.13 （Delta 方法）

设 $\sqrt{n}(T_n - c) \xrightarrow{\mathrm{d}} \mathcal{N}(0, \tau^2)$，函数 g 在 c 处可导。则

$$\sqrt{n}(g(T_n) - g(c)) \xrightarrow{\mathrm{d}} \mathcal{N}(0,\ g'(c)^2\tau^2).$$

证明梗概. 由导数的定义，$g(T_n) - g(c) = (g'(c) + R_n)(T_n - c)$，其中 $T_n \to c$ 时余项 $R_n \to 0$。由 $\sqrt{n}(T_n - c) \xrightarrow{\mathrm{d}} \mathcal{N}(0, \tau^2)$ 可推出 $T_n \xrightarrow{\mathrm{P}} c$（误差是 $O(1/\sqrt{n})$ 量级），于是 $R_n \xrightarrow{\mathrm{P}} 0$。将等式乘以 $\sqrt{n}$ 并应用 Slutsky 定理即得。 ■

例 0.7 （指数分布的率参数） 设 X_i 独立服从 $\mathrm{Exp}(\lambda)$，用 $\hat{\lambda} = 1/\bar{X}$ 估计 λ。由表 0.1，$\mu = 1/\lambda$，$\sigma^2 = 1/\lambda^2$，中心极限定理给出 $\sqrt{n}(\bar{X} - 1/\lambda) \xrightarrow{\mathrm{d}} \mathcal{N}(0, 1/\lambda^2)$。取 $g(t) = 1/t$，$g'(1/\lambda) = -\lambda^2$，所以

$$\sqrt{n}\,(\hat{\lambda} - \lambda) \xrightarrow{\mathrm{d}} \mathcal{N}(0,\ \lambda^4 \cdot \lambda^{-2}) = \mathcal{N}(0, \lambda^2).$$

也就是说，$\hat{\lambda}$ 的标准误约为 $\lambda/\sqrt{n}$——相对误差约为 $1/\sqrt{n}$，与 λ 的大小无关。

常见误区

若 $g'(c) = 0$，定理给出的极限是退化的 $\mathcal{N}(0, 0)$，只说明误差比 $1/\sqrt{n}$ 小，不能用来构造区间。此时需要二阶展开，误差的量级变为 $1/n$（见习题 0.6）。

本章小结

- 期望总是线性的；方差只有在不相关时才“可加”，一般还要加上协方差项 $2\sum_{i<j} a_i a_j \operatorname{Cov}(X_i, X_j)$。
- 独立 $\Rightarrow$ 不相关，反之不然；不放回抽样会产生负相关。
- 切比雪夫：$\mathbb{P}(|X - \mathbb{E}X| \geq \varepsilon) \leq \operatorname{Var} X/\varepsilon^2$，普适但保守。
- 大数定律：$\bar{X}_n \xrightarrow{\mathrm{P}} \mu$；中心极限定理：$\sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{\mathrm{d}} \mathcal{N}(0,1)$。前者回答“会不会估准”，后者回答“误差多大”。
- Slutsky：可以把 σ 换成相合估计 S_n。Delta 方法：$g(T_n)$ 的渐近标准差是 $|g'(c)|$ 乘以 T_n 的渐近标准差。

习题

A 基础：熟悉概念与计算

习题 0.1 掷一颗均匀骰子，点数为 X。求 $\mathbb{E}X$ 与 $\operatorname{Var} X$；再求两颗独立骰子点数之和的方差，以及“两颗骰子点数之和”与“第一颗点数”的协方差。

习题 0.2 设 $\operatorname{Var} X = \operatorname{Var} Y$。证明 $X+Y$ 与 $X-Y$ 不相关。它们一定独立吗？

> 提示：考虑两颗骰子的点数之和与点数之差能否同时取到 12 与 1。

习题 0.3 公平硬币抛 400 次，正面比例为 $\bar{X}$。分别用切比雪夫不等式和中心极限定理（带连续性修正）估计 $\mathbb{P}(|\bar{X}-\frac{1}{2}|\geq 0.05)$，并与精确值 0.0510 比较。

B 进阶：推导与理解

习题 0.4 设 X_n 以概率 $1/n$ 取 n，以概率 $1-1/n$ 取 0。证明 $X_n \xrightarrow{\mathrm{P}} 0$，但 $\mathbb{E}X_n = 1$ 对每个 n 成立，而 $\operatorname{Var} X_n \to \infty$。这说明依概率收敛并不保证期望收敛。

习题 0.5 设 $X_1, \dots, X_n$ 的方差都是 $\sigma^2 > 0$，任意两个的相关系数都是 ρ。

(1) 证明 $\operatorname{Var}\bar{X} = \dfrac{\sigma^2}{n}\bigl(1+(n-1)\rho\bigr)$。

(2) 由此证明 $\rho \geq -1/(n-1)$。当 $\rho > 0$ 时，$n\to\infty$ 时 $\operatorname{Var}\bar{X}$ 趋于多少？这对“多测几次取平均”有什么启示？

习题 0.6 设 X_i 独立服从 Bernoulli(p)，用 $T_n = \bar{X}(1-\bar{X})$ 估计 $p(1-p)$。

(1) 当 $p \neq 1/2$ 时，求 $\sqrt{n}\bigl(T_n - p(1-p)\bigr)$ 的极限分布。

(2) 当 $p = 1/2$ 时，证明 $n\bigl(T_n - \frac{1}{4}\bigr) \xrightarrow{\mathrm{d}} -\frac{1}{4}\chi^2_1$，其中 χ^2_1 是一个标准正态变量的平方的分布。

> 提示：$x(1-x) - \frac{1}{4} = -(x-\frac{1}{2})^2$。

第 1 章

数据与抽样

本章要解决的问题　手里的一组数据怎样概括？如果再抽一次样，这些概括会变多少？本章引入统计学最核心的概念——**抽样分布**：把一个由样本算出的量看成随机变量，研究它的分布。样本均值的**标准误** $\sigma/\sqrt{n}$、样本方差的分母 $n-1$、不放回抽样的修正因子、分层抽样的好处，都由它导出。

预备　第 0 章的期望、方差、协方差（定理 0.4）。

贯穿全书的数据　本章首次出现 Student 的睡眠药物数据，第 4、5 章还会用到它。

1.1　总体、样本、参数与统计量

一枚硬币正面朝上的概率为 p，我们不知道 p 是多少。独立地抛 n 次，第 i 次正面记 $X_i=1$、反面记 $X_i=0$。给定 p，每一种结果序列的概率都能算出来——这是概率论的问题。统计学的问题方向相反：看到了结果，p 大概是多少？有多大把握？

定义 1.1 参数与统计模型　描述总体分布的未知常数称为**参数**，记为 θ（可以是一个数，也可以是一组数）；它的全部可能取值组成**参数空间** Θ。θ 遍历 Θ 时得到的一族分布 $\{P_\theta:\theta\in\Theta\}$ 称为**统计模型**。

抛币问题中参数是 p，$\Theta=[0,1]$；正态模型 $\mathcal{N}(\mu,\sigma^2)$ 中参数是 $\theta=(\mu,\sigma^2)$，$\Theta=\mathbb{R}\times(0,\infty)$。在本讲义中，参数是固定的未知常数，随机的是数据。

定义 1.2 随机样本与统计量　若 $X_1,\dots,X_n$ 相互独立且服从同一总体分布，称它们为容量（样本量）为 n 的**随机样本**。一次抽样实际得到的数 $x_1,\dots,x_n$ 称为**样本观测值**。只用样本计算、不含任何未知参数的量 $T=t(X_1,\dots,X_n)$ 称为**统计量**。用统计量估计某个未知量时，称它为**估计量**，代入观测值得到的数称为**估计值**。

样本均值 $\bar X$、样本最大值 $\max_i X_i$ 都是统计量；若 μ 未知，$\bar X-\mu$ 就不是统计量，因为算它还需要知道 μ。同一个估计量（例如“正面比例”）在不同次抽样中给出不同的估

计值，如 1/2 或 3/4。

> **◆ 直观理解**
>
> 大写字母是“还没抽之前”的随机变量，小写字母是“抽完之后”的具体数。统计学的大部分推理都在大写字母的层面进行：我们关心的不是这一次估计值是多少，而是这个估计方法在反复使用时表现如何。

1.2 描述一组数据

先把手中的一组实数 $x_1, \dots, x_n$ 当作确定的数来概括。下面这份数据将贯穿全书。

▣ 案例 Student 的睡眠药物数据

1908 年，W. S. Gosset 以笔名 “Student” 发表了 t 分布的论文，其中使用了 Cushny 与 Peebles（1905）的一项试验：10 名病人在不同的夜晚分别服用两种催眠药，记录服药后比不服药的夜晚多睡的小时数。

病人	1	2	3	4	5	6	7	8	9	10
药物 A	0.7	−1.6	−0.2	−1.2	−0.1	3.4	3.7	0.8	0.0	2.0
药物 B	1.9	0.8	1.1	0.1	−0.1	4.4	5.5	1.6	4.6	3.4
差值 $d = B - A$	1.2	2.4	1.3	1.3	0.0	1.0	1.8	0.8	4.6	1.4

关心的问题是：药物 B 是否比药物 A 让人多睡？每位病人都试了两种药，所以自然的做法是看每人的差值 d_i。本节先描述这 10 个差值；第 5 章再做正式的推断。

1.2.1 位置与分散：均值和方差

定义 1.3 数据的均值与方差 n 个实数的均值与（以 n 为分母的）数据方差为

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad v = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2.$$

第二个等号与 (0.1) 同理。若 $y_i = a + bx_i$，则 $\bar{y} = a + b\bar{x}$，方差变为 $b^2 v$。对睡眠数据的差值，$\bar{d} = 1.58$ 小时。

1.2.2　次序、中位数与箱线图

把数据从小到大排列为 $x_{(1)} \le x_{(2)} \le \dots \le x_{(n)}$，$x_{(j)}$ 称为第 j 个**次序统计量**。**中位数**在 n 为奇数时取正中间的一个，为偶数时取中间两个的平均。

定义 1.4 四分位数与五数概括　记中位数为 Q_2。n 为偶数时把排序后的数据分成前后两半；n 为奇数时去掉正中一个再分成两半。前一半的中位数记为 Q_1（下四分位数），后一半的中位数记为 Q_3（上四分位数），$I = Q_3 - Q_1$ 称为**四分位距**。$(x_{(1)}, Q_1, Q_2, Q_3, x_{(n)})$ 称为**五数概括**。

（四分位数有多种略有差别的约定，软件的默认值也不尽相同；样本较大时差别可以忽略。本讲义统一使用上面的约定。）

箱线图把五数概括画出来：箱体从 Q_1 到 Q_3，中间一条线标出 Q_2；两条“须”从箱体延伸到区间 $[Q_1 - 1.5I,\ Q_3 + 1.5I]$ 内最远的观测值；落在这个区间之外的点单独画出，作为可能的异常值提醒我们注意。

例 1.1（睡眠差值的箱线图）　差值排序后为 0, 0.8, 1.0, 1.2, 1.3, 1.3, 1.4, 1.8, 2.4, 4.6。前一半 $(0, 0.8, 1.0, 1.2, 1.3)$ 的中位数 $Q_1 = 1.0$，后一半 $(1.3, 1.4, 1.8, 2.4, 4.6)$ 的中位数 $Q_3 = 1.8$，$Q_2 = 1.3$，$I = 0.8$。区间 $[Q_1 - 1.5I, Q_3 + 1.5I] = [-0.2, 3.0]$，所以须延伸到 0 和 2.4，而第 9 号病人的 4.6 被单独标出（图 1.1）。

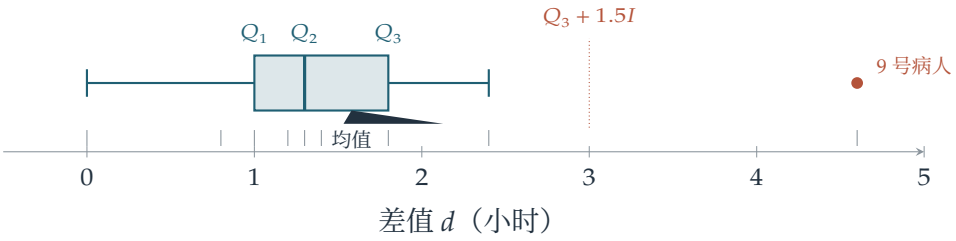


图 1.1　睡眠药物数据中 10 个差值的箱线图。下方的短竖线是原始数据（1.3 出现两次），三角形标出均值 1.58。

◆ 均值与中位数：谁更稳健

如果第 9 号病人的记录误写成 46 而不是 4.6，箱体和须完全不变，只有那个单独的点向右移；中位数仍是 1.3，均值却从 1.58 变成 5.72。一个极端值可以把均值拉到任意远，却拉不动中位数。描述数据时两者都要看；两者差别很大时，要回头检查数据。

1.3 抽样分布与标准误

现在回到随机的视角。同一个统计量，重复抽样会得到不同的值；它的分布就是统计推断的出发点。

定义 1.5 抽样分布 固定总体参数和抽样方式后，统计量的概率分布称为它的**抽样分布**。

例 1.2 （四次抛币） 公平硬币抛 4 次，正面比例 $\bar{X}$ 的抽样分布是

$\bar{X}$	0	1/4	1/2	3/4	1
概率	1/16	4/16	6/16	4/16	1/16

这里每个概率描述的是“整组 4 次试验”的结果；一般地，$n\bar{X} \sim \mathrm{Bin}(n, p)$。

图 1.2 画出了 $p = 0.3$ 时不同 n 下 $\bar{X}$ 的抽样分布。两件事一目了然：分布的中心始终在 0.3；分布的宽度随 n 增大而收窄——n 从 5 到 20 再到 80，每次乘 4，宽度每次减半。

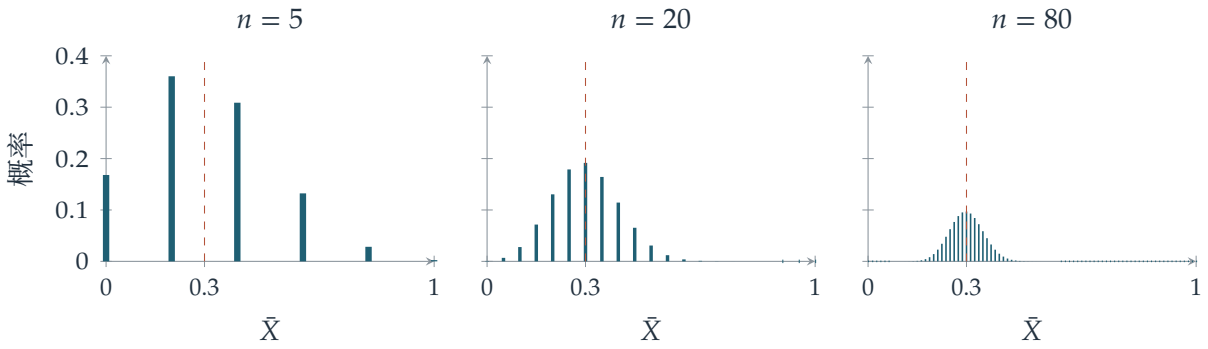


图 1.2 $p = 0.3$ 时正面比例 $\bar{X}$ 的精确抽样分布。样本量每增加到 4 倍，分布的宽度减半。

把这个观察写成定理，只需第 0 章的工具。

定理 1.6 （样本均值的均值与方差）

设 $X_1, \dots, X_n$ 两两不相关（例如独立），均值都是 μ，方差都是 $\sigma^2 < \infty$。则

$$\mathbb{E}\bar{X} = \mu, \qquad \operatorname{Var}\bar{X} = \frac{\sigma^2}{n}.$$

证明. 由线性性 $\mathbb{E}\bar{X} = \frac{1}{n}\sum \mathbb{E}X_i = \mu$；由定理 0.4，$\operatorname{Var}\bar{X} = \frac{1}{n^2}\sum \operatorname{Var}X_i = \frac{\sigma^2}{n}$。 ■

定义 1.7 标准误　统计量 T 的抽样分布的标准差 $\mathrm{SE}(T)=\sqrt{\operatorname{Var} T}$ 称为它的**标准误**。

于是 $\mathrm{SE}(\bar X)=\sigma/\sqrt{n}$。这是全书最重要的公式之一，它有两层含义：

- **平均确实有用**：单次测量的标准差是 σ，n 次的平均只有 $\sigma/\sqrt{n}$。
- **但收益递减**：精度只按 $\sqrt{n}$ 提高。想把标准误减半，样本量要变为 4 倍；想提高一位有效数字，要 100 倍。

常见误区

不要把“总体标准差 σ”和“均值的标准误 $\sigma/\sqrt{n}$”混为一谈。样本量增大时，单个观测的分散程度不变，变小的是平均值的波动。标准误也不是“这一次估计值的误差”——那个误差是未知的，标准误描述的是误差的典型大小。

1.4　样本方差：为什么除以 $n-1$

σ 通常未知，需要从数据估计。自然的想法是用数据方差 $V_n=\frac{1}{n}\sum(X_i-\bar X)^2$，但它系统性地偏小。

定义 1.8 样本方差　$n\ge 2$ 时，称 $S^2=\dfrac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar X)^2$ 为**样本方差**，$S=\sqrt{S^2}$ 为**样本标准差**。

定理 1.9 （样本方差的期望）

在定理 1.6 的条件下，若 $n\ge 2$，则 $\mathbb{E}V_n=\frac{n-1}{n}\sigma^2$，$\mathbb{E}S^2=\sigma^2$。

证明. 把 $X_i-\mu$ 写成 $(X_i-\bar X)+(\bar X-\mu)$，平方后求和。因为 $\sum_i(X_i-\bar X)=0$，交叉项消失：

$$\sum_{i=1}^{n}(X_i-\mu)^2=\sum_{i=1}^{n}(X_i-\bar X)^2+n(\bar X-\mu)^2. \tag{1.1}$$

取期望：左边是 $n\sigma^2$，右边第二项是 $n\operatorname{Var}\bar X=\sigma^2$。所以 $\mathbb{E}\sum(X_i-\bar X)^2=(n-1)\sigma^2$。∎

◆ **“自由度”从哪里来**

式 (1.1) 说明：以 $\bar X$ 为中心的平方和，总比以真正的 μ 为中心的平方和小——因为 $\bar X$ 恰好是使平方和最小的中心。少掉的部分平均恰为一个 σ^2。另一种说法是：

n 个离差 $X_i - \bar{X}$ 加起来必为零，只有 $n-1$ 个能“自由”变化，所以平均时应除以 $n-1$。

例 1.3 （S^2 无偏，S 却有偏） 设 X_1, X_2 独立服从 Bernoulli(1/2)，$\sigma = 1/2$。两数相同时 $S^2 = 0$，不同时 $S^2 = 1/2$，各占一半概率。于是 $\mathbb{E}S^2 = 1/4 = \sigma^2$，但 $\mathbb{E}S = \frac{1}{2}\cdot\frac{1}{\sqrt{2}} \approx 0.354 < \frac{1}{2} = \sigma$。一般地，只要 S 不是常数，$(\mathbb{E}S)^2 < \mathbb{E}S^2 = \sigma^2$（因为 $\operatorname{Var} S > 0$），所以 S 总是低估 σ。无偏性在非线性变换下不保持，第 2 章还会再谈。

把 σ 换成 S，就得到标准误的估计 $S/\sqrt{n}$。对睡眠差值，$s = 1.230$，估计的标准误为 $1.230/\sqrt{10} = 0.389$ 小时。

1.5 有限总体与不放回抽样

民意调查从一个城市的选民中抽人，质检从一批产品中抽件——总体是有限的，而且不会把同一个人问两次。这时各次观测不再独立。

定义 1.10 有限总体与简单随机抽样 有限总体由 N 个有编号的单位组成，数值为 $a_1, \dots, a_N$。总体均值与总体方差为

$$\mu = \frac{1}{N}\sum_{i=1}^{N} a_i, \qquad \sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(a_i - \mu)^2.$$

从中不放回地抽 n 个单位，若每个含 n 个单位的子集被抽中的概率都是 $1/\binom{N}{n}$，称为**简单随机抽样**。

例 1.4 （有放回与不放回） 总体为 $\{0,1,2\}$（$\mu = 1$，$\sigma^2 = 2/3$），抽两个求平均。有放回时 9 种有序结果等可能，均值的方差为 $\sigma^2/2 = 1/3$。不放回时只有 $\{0,1\},\{0,2\},\{1,2\}$ 三种，均值 $1/2, 1, 3/2$ 各占 $1/3$，方差为 $1/6$——只有前者的一半。

定理 1.11 （不放回抽样均值的方差）

从 $N \geq 2$ 个单位中简单随机抽取 n 个，样本均值 $\bar{X}$ 满足

$$\mathbb{E}\bar{X} = \mu, \qquad \operatorname{Var}\bar{X} = \frac{N-n}{N-1}\cdot\frac{\sigma^2}{n}.$$

因子 $\frac{N-n}{N-1}$ 称为**有限总体修正**。

证明. 把抽中的单位随机排序，依次记其数值为 $X_1,\dots,X_n$。由对称性，每个 X_r 都等可能是 $a_1,\dots,a_N$ 中的任一个，所以 $\mathbb{E}X_r=\mu$，$\operatorname{Var}X_r=\sigma^2$；任意两个位置 (X_r,X_s) 等可能是任一个有序的不同编号对 (a_i,a_j)，于是

$$\operatorname{Cov}(X_r,X_s)=\frac{1}{N(N-1)}\sum_{i\neq j}(a_i-\mu)(a_j-\mu)=\frac{\left(\sum_i(a_i-\mu)\right)^2-\sum_i(a_i-\mu)^2}{N(N-1)}=-\frac{\sigma^2}{N-1}.$$

这正是例 0.3 中负相关的一般形式。由定理 0.4，

$$\operatorname{Var}\bar X=\frac{1}{n^2}\Big[n\sigma^2-n(n-1)\frac{\sigma^2}{N-1}\Big]=\frac{N-n}{N-1}\cdot\frac{\sigma^2}{n}.$$

■

◆ **抽样精度取决于 n，几乎与 N 无关**

修正因子约为 $1-n/N$，即 1 减去**抽样比**。从一千万选民中抽 1000 人，修正因子是 0.9999，可以忽略；从一万人中抽 1000 人，修正因子是 0.90，标准误只小约 5%。所以一个全国性的民调和一个城市的民调，只要样本量相同，精度几乎一样。这与很多人的直觉相反：要紧的是抽了多少，而不是总体有多大。

1.6　分层抽样

如果事先知道总体由几个差别明显的部分组成（城市与农村、不同年级），可以在每一部分内分别抽样。

定义 1.12 分层抽样　把总体分成互不重叠的 k 层，第 h 层占总体的比例为 p_h，层均值为 μ_h，层方差为 σ_h^2。在各层内独立地简单随机抽样，第 h 层抽 n_h 个，层内样本均值为 $\bar X_h$。**分层估计量**为 $T=\sum_{h=1}^{k}p_h\bar X_h$。

先看总体方差怎样由各层组成。

命题 1.13 （方差分解：层内与层间）

总体均值 $\mu=\sum_h p_h\mu_h$，总体方差

$$\sigma^2=\underbrace{\sum_h p_h\sigma_h^2}_{\text{层内方差的平均}}+\underbrace{\sum_h p_h(\mu_h-\mu)^2}_{\text{层间方差}}.$$

证明. 在第 h 层内，$a-\mu=(a-\mu_h)+(\mu_h-\mu)$。平方后在层内平均，交叉项因 $a-\mu_h$ 的层内平均为零而消失，得层内平均平方离差为 $\sigma_h^2+(\mu_h-\mu)^2$。再按 p_h 加权平均即可。

■

定理 1.14 （分层估计量）

$\mathbb{E}T=\mu$，$\operatorname{Var}T=\sum_h p_h^2\operatorname{Var}\bar{X}_h$，其中 $\operatorname{Var}\bar{X}_h=\frac{N_h-n_h}{N_h-1}\frac{\sigma_h^2}{n_h}$（$N_h$ 为该层单位数）。

证明. 由定理 1.11，$\mathbb{E}\bar{X}_h=\mu_h$，故 $\mathbb{E}T=\sum p_h\mu_h=\mu$。各层独立，协方差为零，由定理 0.4 得方差公式。 ■

常见误区

各层抽样比例不同时，不能把全部样本直接平均。例如第一层占 3/4、第二层占 1/4，两层各抽 10 个，全部 20 个数的平均的期望是 $(\mu_1+\mu_2)/2$，一般不等于 μ。必须按总体比例 p_h 加权。

分层为什么有效 为看清本质，忽略有限总体修正（各层都很大）。总样本量为 n，按比例分配 $n_h=p_hn$ 时，

$$\operatorname{Var}T=\sum_h p_h^2\frac{\sigma_h^2}{p_hn}=\frac{1}{n}\sum_h p_h\sigma_h^2.$$

而不分层的简单随机抽样方差为 σ^2/n。对比命题 1.13，分层恰好消去了层间方差。层与层差别越大、层内越均匀，分层的好处越大。

例 1.5 （分得好与分得不好） 总体为 $\{-3,-1,1,3\}$（$\mu=0$，$\sigma^2=5$），抽两个求平均。

- 简单随机抽样：$\operatorname{Var}=\frac{4-2}{4-1}\cdot\frac{5}{2}=\frac{5}{3}$。
- 分为 $\{-3,-1\}$、$\{1,3\}$ 两层，各抽一个：层内方差都是 1，$\operatorname{Var}T=\frac{1}{4}+\frac{1}{4}=\frac{1}{2}$。
- 分为 $\{-3,3\}$、$\{-1,1\}$ 两层，各抽一个：层内方差为 9 和 1，$\operatorname{Var}T=\frac{9}{4}+\frac{1}{4}=\frac{5}{2}$，反而比不分层更差。

第二种分层把“相近的”放在一起，层间差别大；第三种恰好相反。

最优分配 样本量固定为 n 时，怎样分给各层最好？仍忽略有限总体修正，要使 $\sum_h p_h^2\sigma_h^2/n_h$ 最小。

命题 1.15 （Neyman 分配）

在 $\sum_h n_h=n$ 的约束下（允许 n_h 取实数），$\sum_h p_h^2\sigma_h^2/n_h$ 的最小值为 $\left(\sum_h p_h\sigma_h\right)^2/n$，在 $n_h\propto p_h\sigma_h$ 时取到。

证明. 由柯西–施瓦茨不等式，$\left(\sum_h p_h\sigma_h\right)^2 = \left(\sum_h \frac{p_h\sigma_h}{\sqrt{n_h}}\sqrt{n_h}\right)^2 \le \sum_h \frac{p_h^2\sigma_h^2}{n_h}\cdot\sum_h n_h$，等号成立当且仅当 $\sqrt{n_h} \propto p_h\sigma_h/\sqrt{n_h}$，即 $n_h \propto p_h\sigma_h$。 ■

直观上，人多的层、内部差异大的层，应该多抽。实际中 n_h 要取整数，σ_h 也只能用先验信息或预调查估计。

1.7　★ 深入讨论

★ 深入讨论：什么样的抽样规则能处处胜过简单随机抽样

设 $N \ge 3$。某规则从 N 个单位中抽两个，各二元子集的概率预先固定。若对任意实数总体，所抽两数的平均都无偏，且方差不超过简单随机抽样，那么它必是简单随机抽样。

证明思路：记 I_i 为单位 i 入选的示性变量，$T = \frac{1}{2}\sum a_i I_i$。取 $a_i = 1$、其余为 0，无偏性给出 $\mathbb{P}(I_i = 1) = 2/N$。再取 $a_i = u$、$a_j = v$、其余为 0，比较方差得

$$\operatorname{Var} T - \operatorname{Var} T_{\mathrm{SRS}} = uv\Big(\mathbb{P}(\text{抽中}\{i,j\}) - \tbinom{N}{2}^{-1}\Big)\Big/2.$$

取 $u = v = 1$ 与 $u = 1, v = -1$，两个方向的不等式迫使 $\mathbb{P}(\text{抽中}\{i,j\}) = 1/\binom{N}{2}$。

这个结论说明：没有一种固定的抽样设计能对所有总体都更好。分层抽样之所以能更好，是因为它利用了关于总体的额外信息（分层）。

★ 深入讨论：允许两层的抽取相互依赖

两层各有 m 个单位，数值为 $a_1 < \cdots < a_m$ 和 $b_1 < \cdots < b_m$，每层等概率抽一个，但允许两层的抽取相关。平均值 $(A+B)/2$ 的方差 $= \frac{1}{4}(\operatorname{Var}A + \operatorname{Var}B + 2\operatorname{Cov}(A,B))$，边缘分布固定，所以只需让 $\mathbb{E}(AB)$ 最小。用“交换”论证可以证明：唯一的最优方案是等概率选 i，同时抽 a_i 与 b_{m+1-i}——最小配最大，次小配次大。这是对偶抽样（antithetic sampling）的思想：人为制造负相关来减小方差，在随机模拟中很常用。关键步骤：若第一行（a_1）的概率没有全部集中在最后一列（b_m），则存在 $q_{1j} > 0$（$j < m$）和 $q_{km} > 0$（$k > 1$），把这两格的概率各减 δ、把 $(1,m)$ 和 (k,j) 两格各加 δ，$\mathbb{E}(AB)$ 减少 $\delta(a_k - a_1)(b_m - b_j) > 0$。

★ 深入讨论：只保存部分数据，能确定什么

若只保存了 n、$\sum x_i$ 和 $\sum x_i^2$，均值、方差、S^2 都能算出；但中位数不能：

$(0,0,0,3,3)$ 与 $(0,0,1,1,4)$ 的这三个量完全相同（$n=5$，和为 6，平方和为 18），中位数却分别是 0 和 1。

一般地，所求量 $t(x)$ 能由保存的量 $h(x)$ 唯一确定，当且仅当 $h(x)=h(y)$ 总蕴含 $t(x)=t(y)$。要证明不能确定，只需找到一对“保存的量相同、所求的量不同”的数据。这个思想在第 2 章讨论“数据中哪些部分包含参数的信息”时会再次出现。

本章小结

- 参数固定而未知，数据随机；统计量不含未知参数。
- 描述数据看位置（均值、中位数）与分散（方差、四分位距）；箱线图能一眼看出偏斜与可能的异常值，中位数对异常值稳健。
- 抽样分布是统计量在重复抽样下的分布。$\mathbb{E}\bar{X}=\mu$，$\mathrm{SE}(\bar{X})=\sigma/\sqrt{n}$：精度按 $\sqrt{n}$ 提高。
- S^2 以 $n-1$ 为分母才无偏；S 仍略低估 σ。标准误的估计为 $S/\sqrt{n}$。
- 不放回抽样的方差要乘 $\frac{N-n}{N-1}\approx 1-\frac{n}{N}$；精度主要取决于 n 而非 N。
- 分层抽样消去层间方差；按比例分配不会更差，Neyman 分配 $n_h\propto p_h\sigma_h$ 最优。

习题

A 基础：熟悉概念与计算

习题 1.1 对数据 $1,1,2,2,2,3,4,10$，求均值、中位数、五数概括，画出箱线图。若把 10 改成 100，哪些量变了？

习题 1.2 一台仪器单次测量的标准差为 2。取 4 次测量的平均，标准误是多少？要使标准误不超过 0.25，至少要测多少次？

习题 1.3 从总体 $\{1,2,3,4,5\}$ 中简单随机抽取 2 个。列出样本均值的全部可能值及其概率，直接计算它的期望和方差，并与定理 1.11 比较。

习题 1.4 某校学生分为两层：住校生占 60%，成绩标准差约为 10；走读生占 40%，标准差约为 30。总共抽 100 人（忽略有限总体修正）。分别求按比例分配与 Neyman 分配下分层估计量的方差。

B 进阶：推导与理解

习题 1.5　证明数据方差可以写成所有两两差的平方的平均：$v = \dfrac{1}{2n^2}\sum_{i=1}^{n}\sum_{j=1}^{n}(x_i - x_j)^2$。由此说明 $S^2 = \dfrac{1}{n(n-1)}\sum_{i<j}(X_i - X_j)^2$，并据此再证一次 $\mathbb{E}S^2 = \sigma^2$。

习题 1.6　两组数据分别有 n_1, n_2 个，均值为 $\bar{x}_1, \bar{x}_2$，数据方差（以 n 为分母）为 v_1, v_2。用命题 1.13 的思路，写出合并后 $n_1 + n_2$ 个数的数据方差。

习题 1.7　一次民意调查抽取 $n = 1000$ 人，支持率真值为 $p = 0.5$（每人回答 0 或 1，故 $\sigma^2 = p(1-p)$）。分别对 $N = 10^4$ 与 $N = 10^7$ 的总体，计算样本比例的标准误。

习题 1.8　设 X_i 独立服从 Bernoulli(p)，$0 < p < 1$。常用 $\sqrt{\bar{X}(1-\bar{X})/n}$ 估计 $\bar{X}$ 的标准误。这个估计值等于 0 的概率是多少？当 $p = 0.05$、$n = 20$ 时，这个概率约为多少？这说明了什么？

C 挑战：综合与探索（选做）

习题 1.9（原讲义习题 1.1）　设 $a_1 < a_2 < \cdots < a_{2m}$，$m \geq 2$。把这 $2m$ 个数分成 m 对，从每对中独立等概率地抽一个，用所得 m 个数的平均估计总体均值。求使方差最小的全部配对方式与最小方差，并证明它严格小于从 $2m$ 个数中简单随机抽取 m 个所得均值的方差。

提示：一对 $\{u, v\}$ 贡献的方差是 $(u-v)^2/4$。用交换论证说明 a_1 必须与 a_2 配对。比较时，计算“对所有配对方式等概率平均”的方差。

习题 1.10（原讲义例 1.3）　四个实数构成有限总体。从中简单随机抽取两个，其平均值在 $\frac{1}{2}, 1, \frac{3}{2}, 2, \frac{5}{2}, 3$ 六个值上等可能。求原总体的全部可能取值。这说明了什么？

习题 1.11（原讲义例 1.4 的一部分）　设 $n \geq 3$ 个实数的均值为 μ，数据方差为 $v > 0$。证明极差 $R = \max x_i - \min x_i$ 满足 $R \leq \sqrt{2nv}$，并求出取等号的全部数据。

提示：不妨设 $\mu = 0$。记最小值和最大值为 $a < 0 < b$，则 $(b-a)^2 \leq 2(a^2 + b^2) \leq 2\sum x_i^2$。

第 2 章

估计量及其误差

本章要解决的问题　同一个参数往往有许多看起来都合理的估计方法。怎样比较它们的好坏？本章引入评价估计量的三把尺子：**偏差**、**方差**与**均方误差**，以及大样本下的**相合性**。我们会看到：无偏并不总是最重要的，有偏的估计可能更准；而把几个估计合理地合并，可以比其中最好的一个还要好。

预备　第 1 章的抽样分布与标准误；第 0 章的马尔可夫不等式与依概率收敛。

2.1　估计量是随机变量

用正面比例估计 p、用样本均值估计 μ，每次抽样都得到一个估计值，它可能偏高，也可能偏低。评价一个估计方法，要看它在反复使用时的表现：平均而言是否瞄准了目标？每次偏离目标多远？

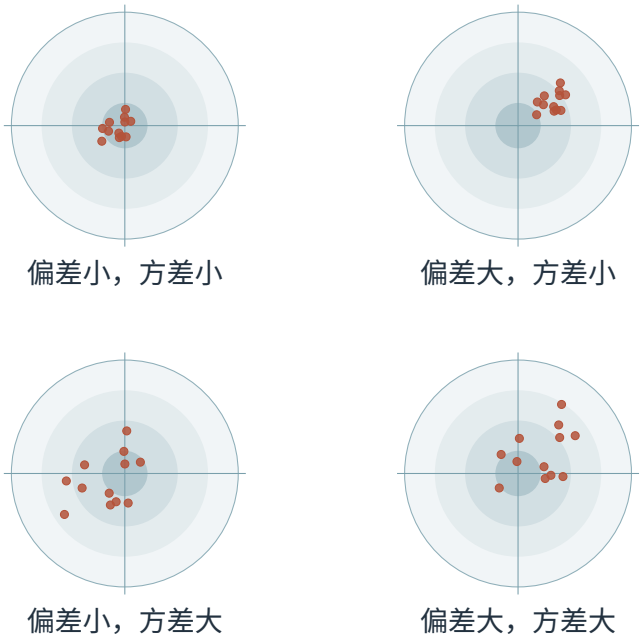


图 2.1　偏差与方差：靶心是要估计的真值，每个点是一次抽样得到的估计值。偏差是点群中心离靶心的距离，方差是点群自身的分散程度。

2.2　偏差、方差与均方误差

定义 2.1 偏差、无偏与均方误差　设统计量 T 用来估计 $g(\theta)$，且 $\mathbb{E}_\theta T^2 < \infty$。称

$$\operatorname{bias}_\theta(T) = \mathbb{E}_\theta T - g(\theta), \qquad \operatorname{MSE}_\theta(T) = \mathbb{E}_\theta\big(T - g(\theta)\big)^2$$

为 T 在 θ 处的**偏差**与**均方误差**。若对每个 $\theta \in \Theta$ 都有 $\operatorname{bias}_\theta(T) = 0$，称 T 为 $g(\theta)$ 的**无偏估计量**。

定理 2.2 （均方误差的分解）

$\operatorname{MSE}_\theta(T) = \operatorname{Var}_\theta(T) + \operatorname{bias}_\theta(T)^2$。

证明. $T - g(\theta) = (T - \mathbb{E}_\theta T) + \operatorname{bias}_\theta(T)$。平方后取期望，交叉项中 $\mathbb{E}_\theta(T - \mathbb{E}_\theta T) = 0$，故消失。 ■

均方误差同时惩罚“瞄不准”和“手不稳”。对无偏估计量，均方误差就是方差。由第 1 章，$\bar X$ 是 μ 的无偏估计，$\operatorname{MSE} = \sigma^2/n$；$S^2$ 是 σ^2 的无偏估计。

常见误区

无偏性要求“对每个参数值，期望都等于目标”。一个在某些参数下恰好期望正确的估计不叫无偏。例如常数 $1/2$ 只在 $p = 1/2$ 时期望等于 p，它不是 p 的无偏估计。

2.3　案例：估计均匀分布的上界

设 $X_1, \dots, X_n$ 独立服从 $\mathrm{U}(0, \theta)$，$\theta > 0$ 未知。例如公交车每 θ 分钟一班，你在随机时刻到站后等待的时间就服从 $\mathrm{U}(0, \theta)$。怎样估计 θ？至少有两种自然的想法。

想法一：利用均值　$\mathbb{E}X_1 = \theta/2$，所以 $T_1 = 2\bar X$ 是无偏估计，$\operatorname{Var} T_1 = 4 \cdot \frac{\theta^2/12}{n} = \frac{\theta^2}{3n}$。

想法二：利用最大值　θ 是数据能达到的上界，样本最大值 $M = \max_i X_i$ 应该很接近它。$M \le m$ 当且仅当每个 $X_i \le m$，所以

$$\mathbb{P}(M \le m) = (m/\theta)^n, \qquad \text{密度 } f_M(m) = \frac{n m^{n-1}}{\theta^n} \quad (0 < m < \theta).$$

积分得 $\mathbb{E}M = \frac{n}{n+1}\theta$，$\mathbb{E}M^2 = \frac{n}{n+2}\theta^2$，$\operatorname{Var} M = \frac{n\theta^2}{(n+1)^2(n+2)}$。$M$ 总是偏小（它不可能超过 θ），偏差为 $-\theta/(n+1)$。修正后的 $T_3 = \frac{n+1}{n} M$ 是无偏的。

表 2.1　$\mathrm{U}(0,\theta)$ 上界的几个估计量（MSE 以 θ^2 为单位）

估计量	偏差	均方误差	$n=10$ 时
$T_1 = 2\bar{X}$	0	$\dfrac{1}{3n}$	0.0333
$T_2 = M$	$-\dfrac{\theta}{n+1}$	$\dfrac{2}{(n+1)(n+2)}$	0.0152
$T_3 = \dfrac{n+1}{n}M$	0	$\dfrac{1}{n(n+2)}$	0.0083
$T_4 = \dfrac{n+2}{n+1}M$	$-\dfrac{\theta}{(n+1)^2}$	$\dfrac{1}{(n+1)^2}$	0.0083

（T_4 是所有 cM 中均方误差最小的：$\mathbb{E}(cM-\theta)^2$ 是 c 的二次函数，在 $c=\theta\mathbb{E}M/\mathbb{E}M^2=\frac{n+2}{n+1}$ 处取最小值。$n=10$ 时它比 T_3 只小一点点：$1/121$ 对 $1/120$。）

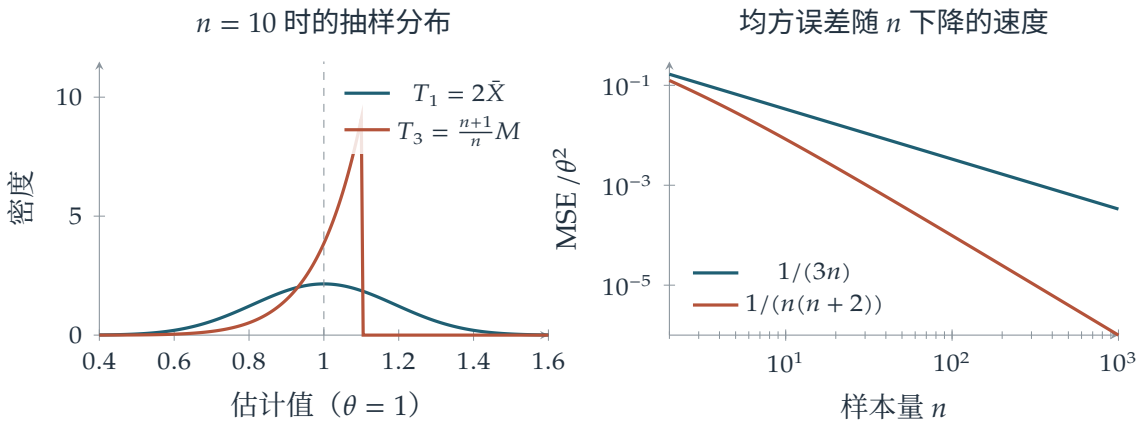


图 2.2　左：T_1 的分布是钟形的，较宽；T_3 的分布高度集中，但不对称（它最多只能比 θ 大 θ/n）。右（对数坐标）：T_1 的均方误差按 $1/n$ 下降，T_3 按 $1/n^2$ 下降，样本量越大差距越悬殊。

◆ 为什么最大值好得多

θ 是数据的边界。n 个点均匀撒在 $(0,\theta)$ 上，最靠右的点与边界的距离约为 θ/n，所以 M 的误差是 $1/n$ 量级；而 $\bar{X}$ 的误差是 $1/\sqrt{n}$ 量级。此外，$2\bar{X}$ 甚至可能给出与数据矛盾的值：数据 $(1,1,1,5)$ 给出 $2\bar{X}=4$，但已经观察到了 5，θ 不可能是 4。这说明“用到了数据的哪些部分”至关重要。

2.4　无偏性的局限

无偏性是个好性质，但不应被奉为最高原则。下面几个现象都值得记住。

2.4.1　无偏性在非线性变换下不保持

$\bar{X}$ 无偏估计 p，但 $\bar{X}^2$ 不是 p^2 的无偏估计：$\mathbb{E}\bar{X}^2 = \operatorname{Var}\bar{X} + (\mathbb{E}\bar{X})^2 = p^2 + \frac{p(1-p)}{n}$。要得到 p^2 的无偏估计，可以利用“两次都是正面”：$\mathbb{E}(X_iX_j) = p^2$（$i \neq j$），对所有 $i \neq j$ 平均，得

$$\frac{1}{n(n-1)}\sum_{i\neq j} X_iX_j = \frac{K(K-1)}{n(n-1)}, \qquad K = \sum X_i.$$

同样的想法也适用于泊松分布：若 $X \sim \text{Poisson}(\lambda)$，则 $\mathbb{E}X(X-1) = \lambda^2$（直接对级数求和可得），所以 $X(X-1)$ 无偏估计 λ^2，而 X^2 多出了 λ。

2.4.2　无偏估计可能不存在

例 2.1（$1/p$ 没有无偏估计） 设 $X_1, \dots, X_n$ 独立服从 Bernoulli(p)，$0 < p \leq 1$。任何统计量 T 只在有限多个结果序列上取值，所以

$$\mathbb{E}_pT = \sum_{x\in\{0,1\}^n} t(x)\, p^{\sum x_i}(1-p)^{n-\sum x_i}$$

是 p 的次数不超过 n 的多项式，在 $p \to 0$ 时有界。而 $1/p \to \infty$，所以不存在对所有 p 都无偏的估计。（若允许样本量随机，例如一直抛到出现正面为止，情况就不同了；见习题 2.10。）

2.4.3　无偏估计可能荒谬

例 2.2（一个荒谬的无偏估计） 只观测一次 $X \sim \text{Poisson}(\lambda)$，要估计 $g(\lambda) = e^{-2\lambda}$（它是两个相继时段都没有事件发生的概率）。若 $T(X)$ 无偏，则

$$\sum_{k\geq 0} T(k)\frac{e^{-\lambda}\lambda^k}{k!} = e^{-2\lambda} \iff \sum_{k\geq 0} T(k)\frac{\lambda^k}{k!} = e^{-\lambda} = \sum_{k\geq 0}\frac{(-1)^k\lambda^k}{k!}$$

对一切 $\lambda \geq 0$ 成立。比较幂级数系数，唯一的无偏估计是 $T(X) = (-1)^X$：观测到奇数时估计一个概率为 -1！有偏的 e^{-2X} 至少总落在 $[0,1]$ 内。

◆ 直观理解

无偏性保证的是“平均而言没有系统误差”，它不保证每次的估计合理，也不保证误差小。实践中更关心的是均方误差（或其他误差度量）。但无偏性在合并多个估计、构造区间时仍然很方便，所以它依然是常用的出发点。

2.5 合并几个估计：逆方差加权

两个实验室独立测量同一个物理常数：甲得 10.2（标准误 0.3），乙得 9.8（标准误 0.6）。应该怎样合并？

定理 2.3 （最小方差的线性无偏组合）

设 $Y_1, \dots, Y_m$ 两两不相关，$\mathbb{E}Y_i = \theta$，$\operatorname{Var} Y_i = v_i > 0$ 已知。在所有系数固定且满足 $\sum a_i = 1$ 的组合 $T = \sum a_i Y_i$ 中（$\sum a_i = 1$ 正是对一切 θ 无偏的条件），方差最小的是

$$a_i = \frac{1/v_i}{\sum_j 1/v_j}, \qquad \operatorname{Var} T = \frac{1}{\sum_j 1/v_j}.$$

证明. $\operatorname{Var} T = \sum a_i^2 v_i$。由柯西–施瓦茨不等式，$1 = \left(\sum a_i\right)^2 = \left(\sum a_i \sqrt{v_i} \cdot \frac{1}{\sqrt{v_i}}\right)^2 \le \sum a_i^2 v_i \cdot \sum \frac{1}{v_i}$，所以 $\operatorname{Var} T \ge 1/\sum(1/v_j)$，等号当且仅当 $a_i \sqrt{v_i} \propto 1/\sqrt{v_i}$，即 $a_i \propto 1/v_i$。 ■

> **例 2.3 （两个实验室）** 权重正比于 $1/0.09$ 与 $1/0.36$，即 0.8 与 0.2。合并估计为 $0.8 \times 10.2 + 0.2 \times 9.8 = 10.12$，标准误为 $1/\sqrt{1/0.09 + 1/0.36} \approx 0.268$，比甲单独的 0.3 还小。
>
> 如果简单平均，标准误是 $\frac{1}{2}\sqrt{0.09 + 0.36} \approx 0.335$——比只用甲的结果更差。精度差的测量并非没用，但要给它较小的权重。

2.6 相合性：样本越大，越接近真值

偏差和方差都是固定 n 时的性质。另一个基本要求是：数据越来越多时，估计应当越来越准。

定义 2.4 相合估计量 设 T_n 是由容量为 n 的样本得到的估计量。若对每个 $\theta \in \Theta$，$T_n \xrightarrow{\mathrm{P}} g(\theta)$，称 T_n 是 $g(\theta)$ 的**相合估计量**。

命题 2.5 （均方误差趋于零蕴含相合）

若对每个 θ 有 $\operatorname{MSE}_\theta(T_n) \to 0$，则 T_n 相合。

证明. 对非负变量 $(T_n - g(\theta))^2$ 用马尔可夫不等式：$\mathbb{P}_\theta(|T_n - g(\theta)| > \varepsilon) \le \operatorname{MSE}_\theta(T_n)/\varepsilon^2 \to 0$。 ■

由表 2.1，四个均匀分布估计量都相合。相合与无偏是两回事：

- $V_n = \frac{1}{n}\sum(X_i - \bar{X})^2$ 有偏，但偏差 $-\sigma^2/n \to 0$，它是相合的（例 0.5）；
- 只用第一个观测 X_1 估计 μ 是无偏的，但它的分布不随 n 改变，所以不相合。

◆ 直观理解

相合性是对估计量的最低要求：如果连无穷多数据都估不准，这个方法就有根本缺陷。在相合的估计量之间，我们再比较它们的误差有多大、以什么速度下降——这正是图 2.2 右图所示。

2.7　★ 深入讨论

★ 深入讨论：去掉人为的随机性只会更好

设 X_1, X_2 独立同分布，均值 μ、方差 σ^2。抽样后再抛一枚公平硬币：正面用 X_1、反面用 X_2 估计 μ。这个估计无偏，均方误差为 σ^2；而对硬币的两种结果取平均，得到 $(X_1 + X_2)/2$，均方误差减半。

一般地，设估计量 $t_J(D)$ 依赖数据 D 和一个与数据独立的随机选择 J（$\mathbb{P}(J = j) = w_j$）。把 J 平均掉，得 $\bar{t}(D) = \sum_j w_j t_j(D)$。由于平方函数是凸的，对每份数据都有

$$(\bar{t}(D) - g)^2 = \Big(\sum_j w_j (t_j(D) - g)\Big)^2 \le \sum_j w_j (t_j(D) - g)^2,$$

两边取期望得 $\mathrm{MSE}(\bar{t}) \le \mathrm{MSE}(t_J)$。所以与数据无关的随机性只会增加误差。

这个想法的推广是著名的 **Rao–Blackwell 定理**：若统计量 U 包含了数据中关于参数的全部信息（称为**充分统计量**），那么用 $\mathbb{E}(T \mid U)$ 代替任何估计量 T 都不会增大均方误差。例如独立抛币时，给定正面总数 $K = k$，k 个正面落在哪些位置是等可能的、与 p 无关，所以 K 是充分统计量——关于 p 的信息全在“几次正面”里，不在“哪几次”。

本章小结

- 估计量是随机变量。用偏差衡量系统误差，方差衡量随机波动，$\mathrm{MSE} = \mathrm{Var} + \mathrm{bias}^2$ 综合两者。
- 不同估计方法可能差别巨大：$\mathrm{U}(0, \theta)$ 中，基于最大值的估计误差是 $1/n$ 量级，基于均值的是 $1/\sqrt{n}$ 量级。
- 无偏性在非线性变换下不保持；无偏估计可能不存在，也可能荒谬；有偏估计

的均方误差可能更小。

- 合并独立的无偏估计时，按方差的倒数加权最优，合并后的方差为 $1/\sum(1/v_i)$。
- 相合性：$T_n \xrightarrow{\mathrm{P}} g(\theta)$；MSE $\to 0$ 是它的充分条件。

习题

A 基础：熟悉概念与计算

习题 2.1 $X_1, \dots, X_n$ 独立同分布，均值 μ、方差 σ^2，$n \geq 2$。比较 $T = (X_1 + X_2)/2$ 与 $\bar{X}$ 的偏差、方差与均方误差。T 相合吗？

习题 2.2 三台仪器独立测量同一长度，读数为 5.03、5.11、4.98，已知标准误分别为 0.02、0.05、0.04。求逆方差加权的合并估计及其标准误。

习题 2.3 用 $c\bar{X}$（$0 < c < 1$ 为常数）估计 μ。求它的均方误差。μ 满足什么条件时，它比 $\bar{X}$ 更好？这个条件能事先检验吗？

习题 2.4 对 $\mathrm{U}(0, \theta)$ 的一组数据 0.8, 2.3, 1.1, 3.6, 0.4，分别计算表 2.1 中四个估计量的值。

B 进阶：推导与理解

习题 2.5 设样本来自正态总体，已知（第 4 章将证明）$\operatorname{Var} S^2 = \frac{2\sigma^4}{n-1}$。分别求 S^2 与 $V_n = \frac{n-1}{n}S^2$ 的均方误差，证明有偏的 V_n 的均方误差总是更小。

习题 2.6（原讲义习题 3.3） 容量为 N 的总体中有 M 个“成功”单位，M 未知，记 $p = M/N$。不放回简单随机抽取 $n \geq 2$ 个，样本中成功数为 K。

(1) 只用 K 构造 p^2 的无偏估计量。

(2) 求 $(K/n)^2$ 估计 p^2 的偏差，并指出何时偏差为 0。

> 提示：先求 $\mathbb{E}K(K-1)$。$K(K-1)$ 是样本中“有序的不同成功对”的个数。

习题 2.7 只观测一次 $X \sim \mathrm{Poisson}(\lambda)$。证明 $e^{-2\lambda}$ 的无偏估计只有 $(-1)^X$，并计算 e^{-2X} 的偏差。λ 很小时哪个均方误差更小？

习题 2.8 对 $\mathrm{U}(0, \theta)$，不用均方误差，直接证明 $M = \max X_i \xrightarrow{\mathrm{P}} \theta$。

C 挑战：综合与探索（选做）

习题 2.9（原讲义习题 3.7）　$X_1, \dots, X_n$ 独立服从均值为 θ 的指数分布，$n \geq 2$。比较 θ^2 的两个无偏估计

$$A_n = \frac{1}{2n}\sum_i X_i^2, \qquad B_n = \frac{1}{n(n-1)}\sum_{i \neq j} X_i X_j$$

的方差。哪一个更好？为什么答案与 n 有关？

提示：$\mathbb{E}X^k = k!\,\theta^k$。$B_n$ 中共享一个下标的两项相关。

习题 2.10（原讲义例 3.4）　硬币正面概率为未知的 $p \in [0,1]$。掷币前先独立地随机选一个非负整数 N（其分布不依赖 p），再掷 N 次；全是反面（含 $N=0$）时记 $T=1$，否则 $T=0$。

(1) 求使 T 无偏估计 $1/(1+p)$ 的全部 N 的分布，并求 $\mathbb{E}N$。

(2) 求 T 的最大均方误差，并与“不做观察，恒取 $3/4$”的最大均方误差比较。

提示：$\mathbb{E}_p T = \sum_k \mathbb{P}(N=k)(1-p)^k$；令 $t = 1-p$，把 $1/(2-t)$ 展开成幂级数。

第 3 章

构造估计量：矩估计与极大似然

本章要解决的问题　第 2 章教我们评价估计量，本章教我们构造估计量。两种通用方法：**矩估计**（让样本的矩等于总体的矩）和**极大似然估计**（选择最能解释已观测数据的参数）。后者是现代统计的主力，我们会看到它在大样本下近似正态、近似无偏，而且精度达到理论极限（Fisher 信息给出的下界）。

预备　第 2 章的偏差、均方误差、相合性；第 0 章的大数定律、中心极限定理、Delta 方法。

3.1　矩估计

若总体均值可以写成参数的函数，就可以反过来，让样本均值“扮演”总体均值，解出参数。这一想法推广到二阶、三阶矩，就是矩估计。

定义 3.1 样本矩与矩估计　记 $m_r(\theta)=\mathbb{E}_\theta X_1^r$ 为 r 阶总体矩，$M_r=\frac{1}{n}\sum_i X_i^r$ 为 r 阶样本矩。选择适当的若干阶（通常是前 k 阶，k 为参数个数），解方程组 $m_r(\theta)=M_r$，所得的解称为**矩估计**。

例 3.1（几个矩估计）

- Poisson(λ)：$\mathbb{E}X=\lambda$，矩估计 $\hat\lambda=\bar X$。
- Exp(λ)：$\mathbb{E}X=1/\lambda$，矩估计 $\hat\lambda=1/\bar X$。
- U$(0,\theta)$：$\mathbb{E}X=\theta/2$，矩估计 $\hat\theta=2\bar X$（第 2 章已看到它不如基于最大值的估计）。
- U(a,b)：$\mathbb{E}X=\frac{a+b}{2}$，$\operatorname{Var}X=\frac{(b-a)^2}{12}$。用前两阶矩，记 $V=M_2-M_1^2=\frac{1}{n}\sum(X_i-\bar X)^2$，解得 $\hat a=\bar X-\sqrt{3V}$，$\hat b=\bar X+\sqrt{3V}$。

为什么矩估计合理？由大数定律，$M_r\xrightarrow{\mathrm{P}}m_r(\theta)$（只要 $\mathbb{E}|X_1|^r<\infty$）。若矩方程的解是样本矩的连续函数，连续映射（命题 0.9）立刻给出：矩估计是相合的。它的渐近正

态性则可以由中心极限定理加 Delta 方法得到（例 0.7 就是一例）。

常见误区

矩估计不检查数据与参数是否相容。$\mathrm{U}(0,\theta)$ 的数据 $(1,1,1,5)$ 给出 $\hat\theta = 2\bar X = 4$，可是已观测到 5。矩方程甚至可能在参数空间内无解：若 X 以概率 $1-\theta, \theta/2, \theta/2$ 取 $0,1,2$（$0 \le \theta \le 1$），$\mathbb{E}X = 3\theta/2$；观测到两个 2 时 $\bar X = 2$，解得 $\theta = 4/3 \notin [0,1]$。这两个缺点都促使我们寻找更好的原则。

3.2　可识别性：数据能否区分参数

在讨论任何估计方法之前，先要问：两个不同的参数，会不会产生完全相同的数据分布？如果会，再多的数据也无法区分它们。

定义 3.2 可识别性　若 $\theta \neq \eta$ 时观测数据在两个参数下的分布总不相同，即 $P_\theta = P_\eta \Rightarrow \theta = \eta$，称参数在该模型中**可识别**。

例 3.2（只记录绝对值）　$X \sim \mathcal{N}(\mu, 1)$，仪器只记录 $|X|$。μ 与 $-\mu$ 下 $|X|$ 的分布完全相同，所以 μ 不可识别，能识别的只有 $|\mu|$。

例 3.3（只记录和）　$X_1 \sim \mathcal{N}(\mu_1, 1)$、$X_2 \sim \mathcal{N}(\mu_2, 1)$ 独立，只记录 $Y = X_1 + X_2 \sim \mathcal{N}(\mu_1+\mu_2, 2)$。$(\mu_1, \mu_2)$ 不可识别，但 $\mu_1 + \mu_2$ 可识别。

这两个例子说明一个一般道理：对数据做任何与参数无关的处理（只保留 $|X|$、只保留和），都不能增加可识别性，只可能丢失信息。这与第 1 章深入讨论中“只保存部分数据”的思想一脉相承。

3.3　似然函数

假设抛硬币 10 次得到 7 次正面。$p = 0.3$ 时得到这样一份记录（某个特定的正反序列）的概率是 $0.3^7\,0.7^3 \approx 7.5 \times 10^{-5}$，$p = 0.7$ 时是 $0.7^7\,0.3^3 \approx 2.2 \times 10^{-3}$，大了约 30 倍。把这个概率看成参数的函数，就得到似然。

定义 3.3 似然函数　设观测到 $x=(x_1,\dots,x_n)$。离散时称 $L(\theta)=\mathbb{P}_\theta(X=x)$，有密度时称 $L(\theta)=f_\theta(x)$ 为**似然函数**；$\ell(\theta)=\log L(\theta)$ 为**对数似然**。对独立同分布样本，

$$L(\theta)=\prod_{i=1}^{n} f_\theta(x_i),\qquad \ell(\theta)=\sum_{i=1}^{n}\log f_\theta(x_i).$$

常见误区

似然是参数的函数，数据固定不动；它不是参数的概率分布（对 θ 积分一般不等于 1）。$L(0.7)/L(0.3)\approx 30$ 的意思是“若 $p=0.7$，看到这份数据的可能性是 $p=0.3$ 时的 30 倍”，而不是“$p=0.7$ 的可能性是 $p=0.3$ 的 30 倍”。

与参数无关的正因子不影响似然的比较。记录全部序列时 $L(p)=p^7(1-p)^3$，只记录正面次数时 $L(p)=\binom{10}{7}p^7(1-p)^3$，两者成比例，给出完全相同的推断。因此常常只写出似然中与参数有关的部分。

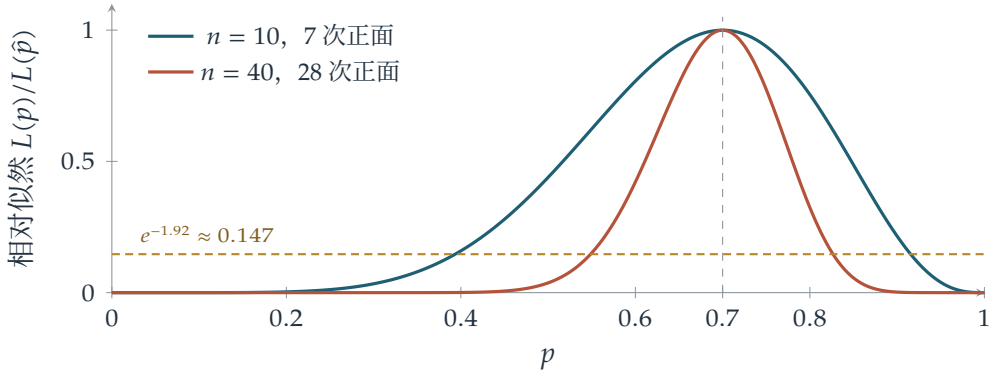


图 3.1　伯努利模型的相对似然。两份数据的正面比例都是 0.7，峰值位置相同；数据多四倍时，曲线窄约一半。落在虚线以上的参数值是“与数据相当相容的”，这一范围正是第 4 章似然区间的雏形。

3.4　极大似然估计

定义 3.4 极大似然估计　在参数空间 Θ 内使 $L(\theta)$ 达到最大值的参数 $\hat\theta$ 称为**极大似然估计**（MLE）。

由于 log 严格递增，最大化 L 与最大化 ℓ 等价，而 ℓ 是求和，更好处理。当 ℓ 光滑且最大值在参数空间内部时，它满足**似然方程** $\ell'(\theta)=0$（多参数时是偏导数全为零）。但驻点不一定是最大点，最大点也不一定是驻点，求出后要检验。

例 3.4（伯努利与泊松） 伯努利：$\ell(p) = k\log p + (n-k)\log(1-p)$，$k = \sum x_i$。若 $0 < k < n$，$\ell'(p) = \frac{k}{p} - \frac{n-k}{1-p} = 0$ 给出 $\hat p = k/n$，且 ℓ 是凹函数，驻点就是最大点。$k = 0$ 或 n 时 ℓ 单调，最大点在端点 0 或 1，仍是 $\hat p = k/n$。

泊松：$\ell(\lambda) = (\sum x_i)\log\lambda - n\lambda +$ 常数，得 $\hat\lambda = \bar X$。两例中 MLE 与矩估计相同。

例 3.5（正态分布） $\ell(\mu,\sigma^2) = -\frac{n}{2}\log\sigma^2 - \frac{1}{2\sigma^2}\sum(x_i-\mu)^2 +$ 常数。对任意 σ^2，$\mu = \bar x$ 使平方和最小；代入后对 σ^2 求导，得

$$\hat\mu = \bar X, \qquad \widehat{\sigma^2} = \frac{1}{n}\sum (X_i - \bar X)^2 = V_n.$$

注意 $\widehat{\sigma^2}$ 以 n 为分母，是有偏的（第 1 章）。MLE 不保证无偏，但偏差随 $n\to\infty$ 消失。

例 3.6（均匀分布：最大值不在驻点） $\mathrm{U}(0,\theta)$ 的似然为

$$L(\theta) = \prod_i \frac{\mathbf{1}\{0 < x_i \le \theta\}}{\theta} = \begin{cases} \theta^{-n}, & \theta \ge \max_i x_i, \\ 0, & \theta < \max_i x_i. \end{cases}$$

θ 小于最大观测值时，数据不可能出现，似然为零；此后似然随 θ 递减。所以 $\hat\theta = M = \max_i X_i$（图 3.2）。导数在这里毫无用处——最大点恰在似然的跳跃处。MLE 自动拒绝了与数据矛盾的参数，这正是矩估计 $2\bar X$ 做不到的。

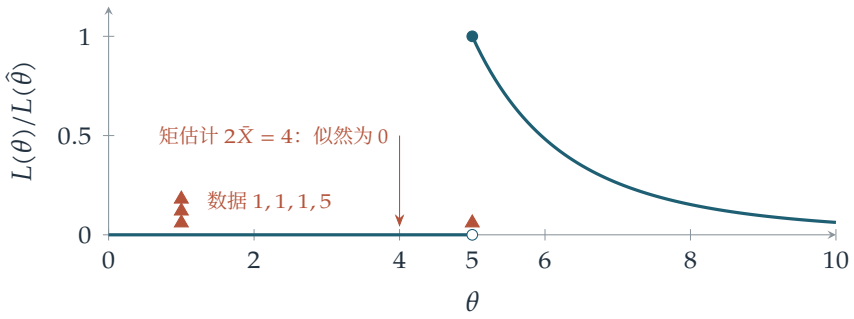


图 3.2　$\mathrm{U}(0,\theta)$ 在数据 $(1,1,1,5)$ 下的似然。$\theta < 5$ 的参数与数据矛盾，似然为零；最大值在 $\hat\theta = 5$ 处取到。

命题 3.5（MLE 的不变性）

若 $\hat\theta$ 是 θ 的 MLE，g 是一一映射，则 $g(\hat\theta)$ 是 $g(\theta)$ 的 MLE。

证明. 把模型改用 $\eta = g(\theta)$ 作参数，似然为 $L^*(\eta) = L(g^{-1}(\eta))$，它在 $\eta = g(\hat\theta)$ 处最大。■

例如指数分布寿命超过 1 年的概率 $e^{-\lambda}$ 的 MLE 是 $e^{-\widehat{\lambda}} = e^{-1/\bar X}$；正态分布 σ 的 MLE 是 $\sqrt{V_n}$。不变性很方便，但要注意它与无偏性冲突：无偏性在非线性变换下不保持，MLE 却保持。

常见误区

MLE 可能不存在，也可能不唯一。

- 设 X_i 独立服从 $\mathrm{Exp}(\lambda)$，但仪器只记录超过阈值 c 的个数 $B \sim \mathrm{Bin}(n, e^{-\lambda c})$。若 $B = 0$，似然 $(1-e^{-\lambda c})^n$ 随 λ 严格递增，在 $(0,\infty)$ 内没有最大点；若 $0 < B < n$，$\hat\lambda = -\frac{1}{c}\log\frac{B}{n}$。
- 若 X_i 独立服从 $\mathrm{U}(\theta, \theta+1)$，似然在 $\max x_i - 1 \le \theta \le \min x_i$ 上处处等于 1，整个区间都是 MLE。

3.5 极大似然估计有多准：Fisher 信息

图 3.1 暗示：似然在峰值附近越“尖”，数据对参数的约束越强，估计越准。把“尖”的程度量化，就是 Fisher 信息。

定义 3.6 得分函数与 Fisher 信息 对单个观测的密度（或概率函数）$f_\theta(x)$，称 $s_\theta(x) = \dfrac{\partial}{\partial\theta}\log f_\theta(x)$ 为**得分函数**，称

$$I(\theta) = \mathbb{E}_\theta\big[s_\theta(X)^2\big]$$

为单个观测的 **Fisher 信息**。n 个独立同分布观测的信息为 $nI(\theta)$。

在常见的“正则”模型中（支撑集不依赖 θ，求导与积分可以交换），得分函数有两个基本性质：

$$\mathbb{E}_\theta s_\theta(X) = 0, \qquad I(\theta) = \mathrm{Var}_\theta\, s_\theta(X) = -\mathbb{E}_\theta\Big[\frac{\partial^2}{\partial\theta^2}\log f_\theta(X)\Big]. \tag{3.1}$$

第一式来自对 $\int f_\theta(x)\,\mathrm{d}x = 1$ 求导：$0 = \int \partial_\theta f_\theta = \int s_\theta f_\theta = \mathbb{E}_\theta s_\theta$；第二式再求一次导即得。第二个表达式说明：信息就是对数似然的平均弯曲程度。

例 3.7 （两个信息的计算） 伯努利：$\log f_p(x) = x\log p + (1-x)\log(1-p)$，$-\partial_p^2 \log f_p = \frac{x}{p^2} + \frac{1-x}{(1-p)^2}$，取期望得 $I(p) = \frac{1}{p(1-p)}$。

指数分布：$\log f_\lambda(x) = \log\lambda - \lambda x$，$-\partial_\lambda^2 \log f_\lambda = \frac{1}{\lambda^2}$，所以 $I(\lambda) = \frac{1}{\lambda^2}$。

定理 3.7 （MLE 的渐近正态性）

在正则条件下，若 $\hat\theta_n$ 是相合的 MLE，$0 < I(\theta) < \infty$，则

$$\sqrt{n}\,(\hat\theta_n - \theta) \xrightarrow{\mathrm{d}} \mathcal{N}\Big(0,\ \frac{1}{I(\theta)}\Big).$$

推导梗概. 在 θ 附近展开似然方程：$0 = \ell_n'(\hat\theta_n) \approx \ell_n'(\theta) + \ell_n''(\theta)(\hat\theta_n - \theta)$，于是

$$\sqrt{n}(\hat\theta_n - \theta) \approx \frac{\ell_n'(\theta)/\sqrt{n}}{-\ell_n''(\theta)/n}.$$

分子是 n 个独立、均值为 0、方差为 $I(\theta)$ 的得分之和除以 $\sqrt{n}$，由中心极限定理 $\xrightarrow{\mathrm{d}} \mathcal{N}(0, I(\theta))$；分母是 n 项的平均，由大数定律 $\xrightarrow{\mathrm{P}} I(\theta)$。由 Slutsky 定理，比值 $\xrightarrow{\mathrm{d}} \mathcal{N}(0, I(\theta)/I(\theta)^2)$。严格证明需要控制展开的余项。 ■

于是 MLE 的标准误近似为 $1/\sqrt{nI(\theta)}$；用 $\hat\theta$ 代替未知的 θ，得到可以计算的

$$\widehat{\mathrm{SE}}(\hat\theta) = \frac{1}{\sqrt{nI(\hat\theta)}}.$$

伯努利：$\widehat{\mathrm{SE}} = \sqrt{\hat p(1-\hat p)/n}$，与第 1 章一致；指数分布：$\widehat{\mathrm{SE}}(\hat\lambda) = \hat\lambda/\sqrt{n}$，与 Delta 方法（例 0.7）一致。

这已经是最好的了吗　下面的定理说明，在正则模型中，没有哪个无偏估计的方差能小于 $1/(nI(\theta))$。

定理 3.8 （Cramér–Rao 下界）

在正则条件下，若 T 是 θ 的无偏估计且方差有限，则

$$\mathrm{Var}_\theta\, T \geq \frac{1}{nI(\theta)}.$$

证明. 记 $U = \sum_{i=1}^n s_\theta(X_i) = \partial_\theta \log f_\theta(X_1, \dots, X_n)$，由 (3.1)，$\mathbb{E}U = 0$，$\mathrm{Var}\, U = nI(\theta)$。对 $\mathbb{E}_\theta T = \theta$ 两边求导：

$$1 = \frac{\mathrm{d}}{\mathrm{d}\theta}\int t(x) f_\theta(x)\,\mathrm{d}x = \int t(x)\,\partial_\theta \log f_\theta(x) f_\theta(x)\,\mathrm{d}x = \mathbb{E}_\theta(TU) = \mathrm{Cov}_\theta(T, U).$$

由柯西–施瓦茨不等式，$1 = \mathrm{Cov}(T,U)^2 \leq \mathrm{Var}\, T \cdot \mathrm{Var}\, U = \mathrm{Var}\, T \cdot nI(\theta)$。 ■

伯努利模型中 $\operatorname{Var}\bar{X} = p(1-p)/n$ 恰好等于下界，所以 $\bar{X}$ 是 p 的最小方差无偏估计。MLE 在大样本下渐近达到这个下界，这是它被广泛使用的根本原因。

◆ 均匀分布为什么能“打破”下界

第 2 章中 $\mathrm{U}(0,\theta)$ 的无偏估计 $\frac{n+1}{n}M$ 的方差是 $\frac{\theta^2}{n(n+2)}$，按 $1/n^2$ 下降，远快于 $1/n$。这并不违反 Cramér–Rao 定理，因为这个模型**不正则**：数据的取值范围 $(0,\theta)$ 依赖参数，求导和积分不能交换。直观上，“边界”的位置比“中心”的位置容易确定得多。

3.6 ★ 深入讨论

★ 深入讨论：观测不完整时的似然：截尾数据

测试 n 个元件的寿命 $X_i \sim \mathrm{Exp}(\lambda)$，但试验只进行到时刻 c。到时还没坏的元件只知道 $X_i > c$。写似然的原则是：每条记录贡献“它实际被观测到的那个事件”的概率或密度。已损坏的元件贡献密度 $\lambda e^{-\lambda x_i}$，未损坏的贡献概率 $\mathbb{P}(X_i > c) = e^{-\lambda c}$。若 d 个元件损坏，记总的“暴露时间” $T = \sum_i \min(x_i, c)$，则

$$L(\lambda) = \lambda^d e^{-\lambda T}, \qquad \hat{\lambda} = \frac{d}{T} \quad (d \geq 1).$$

即“损坏数除以总暴露时间”。如果错误地丢掉未损坏的元件、只用损坏元件的寿命，得到的 $d/\sum_{\text{损坏}} x_i$ 会系统性地高估失效率——因为寿命长的元件恰恰被丢掉了。这是生存分析的起点。

★ 深入讨论：两种记录方式，两种似然

同一批原始数据，记录方式不同，似然就不同。上面的指数寿命试验，若只记录“超过 c 的个数” B，似然变为 $\binom{n}{B}e^{-\lambda cB}(1-e^{-\lambda c})^{n-B}$，MLE 为 $-\frac{1}{c}\log\frac{B}{n}$。它使用的信息比截尾数据少，Fisher 信息也更小：单个观测的信息从截尾记录的 $\frac{1-e^{-\lambda c}}{\lambda^2}$ 降为 $\frac{c^2 e^{-\lambda c}}{1-e^{-\lambda c}}$（习题 3.8）。

本章小结

- 矩估计：令样本矩等于总体矩；简单、相合，但可能与数据矛盾或无解。
- 可识别性是一切估计的前提；对数据的任何处理都不能增加信息。

- 似然是参数的函数，不是参数的概率。MLE 使似然最大；与参数无关的因子可以丢掉。
- 求 MLE：先写对数似然，解似然方程，再检验是否为最大值；注意边界、跳跃、不存在与不唯一。MLE 具有不变性。
- Fisher 信息 $I(\theta) = \mathbb{E}s^2 = -\mathbb{E}\,\partial^2 \log f$；MLE 渐近服从 $\mathcal{N}(\theta, 1/(nI(\theta)))$，标准误约为 $1/\sqrt{nI(\hat\theta)}$。
- Cramér–Rao：正则模型中无偏估计的方差 $\geq 1/(nI(\theta))$。

习题

A 基础：熟悉概念与计算

习题 3.1 某路口每分钟到达的车辆数服从 Poisson(λ)。连续 8 分钟的记录为 $3,5,2,4,6,3,4,5$。求 λ 的矩估计与 MLE，以及 MLE 的近似标准误。“一分钟内没有车”的概率的 MLE 是多少?

习题 3.2 重复独立试验直到第一次成功，所需次数 X 服从几何分布 $\mathbb{P}(X = k) = (1-p)^{k-1}p$，$k \geq 1$。根据 n 次独立重复的记录 $x_1, \dots, x_n$ 求 p 的 MLE。

习题 3.3 某种灯泡的寿命（千小时）服从 Exp(λ)。6 个灯泡的寿命为 0.8，2.1，1.3，0.4，3.0，1.6。求 λ 的 MLE、寿命中位数 $\log 2/\lambda$ 的 MLE，以及 $\hat\lambda$ 的近似标准误。

习题 3.4 对 $\mathcal{N}(\mu, \sigma^2)$ 的数据 4.1, 5.3, 3.8, 4.9, 5.4，求 μ 和 σ^2 的 MLE，并与样本方差 s^2 比较。

B 进阶：推导与理解

习题 3.5 对 U(a,b)（$a<b$ 均未知），求 (a,b) 的 MLE，并与例 3.1 的矩估计比较：哪个可能与数据矛盾?

习题 3.6 对 Poisson(λ)，求 Fisher 信息 $I(\lambda)$，并验证 $\bar X$ 的方差恰好达到 Cramér–Rao 下界。

习题 3.7 拉普拉斯分布的密度为 $f_\theta(x) = \frac{1}{2}e^{-|x-\theta|}$。证明 θ 的 MLE 是样本中位数（n 为奇数时唯一；n 为偶数时中间两个次序统计量之间的任何值都是 MLE）。

提示：$\ell(\theta) = -\sum|x_i-\theta| +$ 常数，考察它在相邻两个次序统计量之间的斜率。

习题 3.8 接深入讨论中的指数寿命试验。分别对两种记录方式（截尾记录 $\min(X,c)$ 与

是否超过 c），求单个观测的 Fisher 信息，并证明前者总是更大。

提示：截尾记录的对数似然为 $\delta \log\lambda - \lambda \min(X, c)$，其中 $\delta = \mathbf{1}\{X \le c\}$；对后者，$B_1 = \mathbf{1}\{X > c\}$ 是伯努利变量，可用伯努利信息与链式法则。

C 挑战：综合与探索（选做）

习题 3.9 （原讲义例 2.3） 每轮独立地取 $X \sim \mathrm{Exp}(\lambda)$、$Y \sim \mathrm{Exp}(\nu)$，$\lambda, \nu > 0$ 未知。做 n 轮，只记录 $X < Y$ 的轮数 $K = k$ 和各轮 $\min(X, Y)$ 之和 $T = t$。求 (λ, ν) 的 MLE，并讨论何时不存在。

提示：先证明 $\min(X, Y) \sim \mathrm{Exp}(\lambda + \nu)$，且 $\mathbf{1}\{X < Y\}$ 与 $\min(X, Y)$ 独立，$\mathbb{P}(X < Y) = \lambda/(\lambda + \nu)$。

习题 3.10 （原讲义习题 2.4） $X_1, \dots, X_n$（$n \ge 2$）独立服从 $\mathrm{U}(0, \theta)$，只记录最大的两个观测值之差 $D_n = X_{(n)} - X_{(n-1)}$。

(1) 证明 D_n 的密度为 $n(\theta - d)^{n-1}/\theta^n$（$0 < d < \theta$）。

(2) 求 θ 的 MLE 和形如 $c_n D_n$ 的无偏估计。

(3) 这两个估计量相合吗？

提示：(2) 令 $u = d/\theta$，似然正比于 $u(1-u)^{n-1}$。(3) 求 $\mathbb{P}(nD_n/\theta > a)$ 的极限。

第 4 章

置信区间与假设检验

本章要解决的问题　一个估计值本身没有告诉我们它有多可靠。本章介绍统计推断的两种基本形式：**置信区间**（给出一个“大概率罩住真值”的范围）和**假设检验**（判断数据是否与某个具体的说法相矛盾），并说明两者其实是一回事的两面。我们会讲清楚 t 分布从哪里来、p 值到底是什么意思、功效与样本量怎样计算，以及几种最常见的误用。

预备　第 0 章的中心极限定理与 Slutsky 定理；第 1 章的标准误；第 3 章的似然。

4.1　从标准误到置信区间

估计睡眠药物的平均效果，我们得到 $\bar{d} = 1.58$ 小时，标准误约 0.39 小时。只报告“1.58”会让人误以为它很精确；更诚实的说法是给出一个范围，并说明这个范围有多可靠。

定义 4.1 置信区间　设 $L = L(X)$、$U = U(X)$ 是两个统计量，$L \le U$。若对每个 $\theta \in \Theta$，

$$\mathbb{P}_\theta(L \le g(\theta) \le U) \ge 1 - \alpha,$$

称 $[L, U]$ 是 $g(\theta)$ 的置信水平为 $1-\alpha$ 的**置信区间**。概率左端的最小值称为**覆盖概率**。

最常见的构造方式来自一个近似正态的估计量。由第 0 章式 (0.2)，$\sqrt{n}(\bar{X} - \mu)/S \xrightarrow{\mathrm{d}} \mathcal{N}(0,1)$，所以

$$\mathbb{P}\Big(-z_{1-\alpha/2} \le \frac{\bar{X} - \mu}{S/\sqrt{n}} \le z_{1-\alpha/2} \Big) \to 1 - \alpha,$$

把不等式中的 μ 解出来，就得到大样本的近似置信区间

$$\bar{X} \pm z_{1-\alpha/2}\,\frac{S}{\sqrt{n}} \qquad (95\%\text{ 时} z_{0.975} \approx 1.96). \tag{4.1}$$

一般的模式是：**估计值 ± 临界值 × 标准误**。

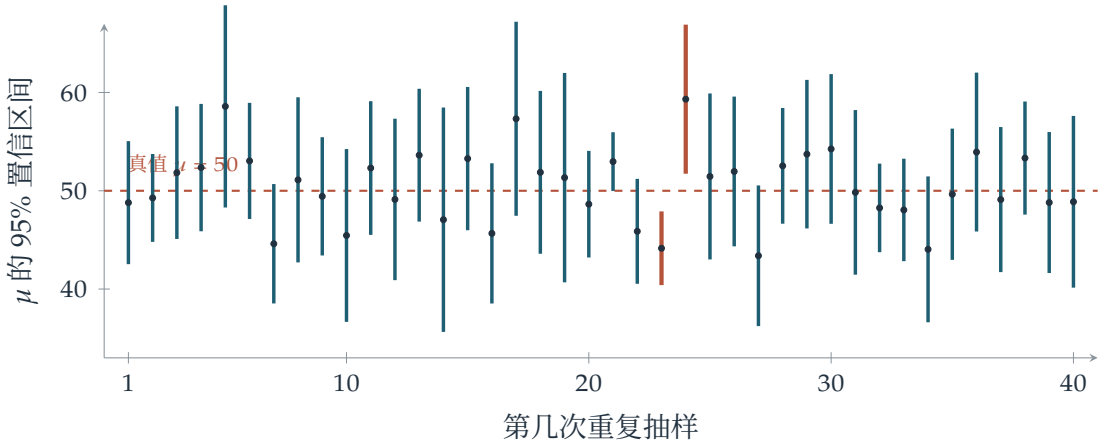


图 4.1　从 $\mathcal{N}(50, 10^2)$ 中重复抽取 40 个容量为 10 的样本，各自算出 95% 的 t 区间（模拟，区间公式见 4.2 节）。40 个区间中有 38 个罩住了真值，2 个（红色）没有。区间的位置和长度都随样本变化，真值始终不动。

怎样正确理解 95%

算出睡眠数据的区间 [0.70, 2.46] 后，不能说“μ 落在 $[0.70, 2.46]$ 内的概率是 95%”。μ 是固定的数，这个具体区间要么罩住了它，要么没有。95% 描述的是构造区间的方法：反复使用这个方法，大约 95% 的区间会罩住真值（图 4.1）。我们相信这一次的区间，是因为它出自一个可靠的方法。

区间长度 $2z_{1-\alpha/2}S/\sqrt{n}$ 也直接给出了样本量的计划方法：要使 95% 区间的半宽不超过 h，需要 $n \geq (1.96\,\sigma/h)^2$。又一次看到 $\sqrt{n}$ 规律：区间缩短一半，样本量要 4 倍。

4.2　正态样本的精确理论：t 分布

式 (4.1) 依赖大样本。小样本时把 σ 换成 S 会额外引入 S 自身的波动，区间应当更宽。1908 年，Gosset 求出了正态总体下这个比值的精确分布。

定义 4.2 卡方分布与 t 分布　设 $Z_1, \dots, Z_\nu$ 独立服从 $\mathcal{N}(0,1)$。$U = Z_1^2 + \cdots + Z_\nu^2$ 的分布称为自由度为 ν 的**卡方分布**，记作 χ^2_ν。若 $Z \sim \mathcal{N}(0,1)$ 与 $U \sim \chi^2_\nu$ 独立，$T = Z/\sqrt{U/\nu}$ 的分布称为自由度为 ν 的 **t 分布**，记作 t_ν。

由 $\mathbb{E}Z^2 = 1$、$\mathbb{E}Z^4 = 3$ 得 $\operatorname{Var} Z^2 = 2$，所以 $\mathbb{E}\chi^2_\nu = \nu$，$\operatorname{Var}\chi^2_\nu = 2\nu$。$t_\nu$ 关于 0 对称，比正态分布“尾巴更厚”（图 4.2）；$\nu \to \infty$ 时 $U/\nu \xrightarrow{\mathrm{P}} 1$，由 Slutsky 定理 t_ν 趋于 $\mathcal{N}(0,1)$。

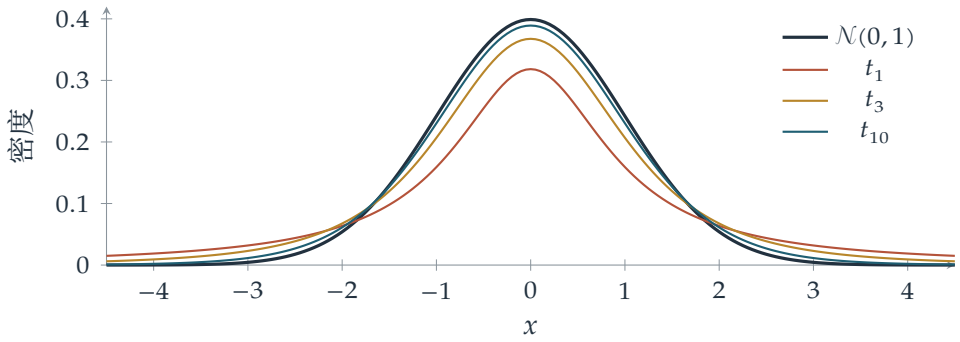


图 4.2　t 分布与标准正态分布。自由度越小，中间越矮、两尾越厚；$\nu = 10$ 时已经很接近正态。

定理 4.3　（正态样本的均值与方差）

设 $X_1, \dots, X_n$（$n \ge 2$）独立服从 $\mathcal{N}(\mu, \sigma^2)$。则

(1) $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$；

(2) $\bar{X}$ 与 S^2 相互独立；

(3) $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$；

(4) $\dfrac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t_{n-1}$。

证明. 令 $Z_i = (X_i - \mu)/\sigma$，它们独立服从 $\mathcal{N}(0,1)$。取一个 $n \times n$ 正交矩阵 A，第一行为 $(1/\sqrt{n}, \dots, 1/\sqrt{n})$（其余各行可由 Gram–Schmidt 正交化补齐），令 $Y = AZ$。

Z 的联合密度 $(2\pi)^{-n/2} e^{-\|z\|^2/2}$ 只依赖长度 $\|z\|$，而正交变换保持长度、雅可比行列式绝对值为 1，所以 Y 的联合密度与 Z 相同：$Y_1, \dots, Y_n$ 也独立服从 $\mathcal{N}(0,1)$。现在

$$Y_1 = \sqrt{n}\,\bar{Z}, \qquad \sum_{i=2}^{n} Y_i^2 = \|Y\|^2 - Y_1^2 = \|Z\|^2 - n\bar{Z}^2 = \sum_{i=1}^{n}(Z_i - \bar{Z})^2 = \frac{(n-1)S^2}{\sigma^2}.$$

于是 $\sqrt{n}(\bar{X}-\mu)/\sigma = Y_1 \sim \mathcal{N}(0,1)$，$(n-1)S^2/\sigma^2 = \sum_{i \ge 2} Y_i^2 \sim \chi^2_{n-1}$，两者分别是不同 Y_i 的函数，故独立。(4) 是 (1)(3) 按 t 分布的定义相除的结果：$\dfrac{\sqrt{n}(\bar{X}-\mu)/\sigma}{\sqrt{S^2/\sigma^2}}$。 ■

◆ 自由度的几何意义

把 n 个数据看成 $\mathbb{R}^n$ 中的一个向量。它在“全 1 方向”上的投影给出 $\bar{X}$，剩下的部分落在与之垂直的 $n-1$ 维空间里，给出 S^2。两部分互相垂直，正态分布又是“各向同性”的，所以它们独立；剩下的空间是 $n-1$ 维，所以自由度是 $n-1$。第 6 章的回归会把这幅图推广：拟合两个参数，残差落在 $n-2$ 维空间里。

由定理 4.3(4)，正态总体均值的精确置信区间为

$$\bar{X} \pm t_{n-1,\,1-\alpha/2}\,\frac{S}{\sqrt{n}}. \tag{4.2}$$

表 4.1　t 分布与正态分布的 97.5% 分位数（用于 95% 双侧区间）

自由度 ν	1	2	3	5	10	20	30	60	∞
$t_{\nu,0.975}$	12.706	4.303	3.182	2.571	2.228	2.086	2.042	2.000	1.960

▣ 案例　睡眠数据：药物 B 比 A 多让人睡多久

10 个差值的 $\bar{d} = 1.58$，$s = 1.230$，标准误 $s/\sqrt{10} = 0.389$，$t_{9,0.975} = 2.262$。95% 置信区间为

$$1.58 \pm 2.262 \times 0.389 = 1.58 \pm 0.88 = [0.70,\ 2.46] \text{ 小时}.$$

若误用正态临界值 1.96，区间会窄约 13%，覆盖率达不到 95%。这个区间完全在 0 的右侧——下面会看到，这意味着在 5% 水平上可以断言两种药有差别。（这里假设差值近似正态。第 1 章的箱线图显示有一个偏大的值，第 5 章会检查这一假设，并给出不依赖正态性的方法。）

同样，由定理 4.3(3)，σ^2 的 $1-\alpha$ 置信区间为 $\left[\dfrac{(n-1)S^2}{\chi^2_{n-1,1-\alpha/2}},\ \dfrac{(n-1)S^2}{\chi^2_{n-1,\alpha/2}}\right]$。不过它对正态性的依赖比 t 区间严重得多，非正态数据慎用。

4.3　比例的区间：不要只会用 Wald 区间

对 n 次伯努利试验，最常见的区间是 **Wald 区间** $\hat{p} \pm z_{1-\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n}$，即式 (4.1) 的特例。它的毛病在 $\hat{p}$ 接近 0 或 1 时暴露无遗：20 次试验 0 次成功时，Wald 区间是 $[0,0]$——它“确信”成功率恰好为零。

问题出在标准误本身也是估计出来的，而且估计得最差的地方恰恰是它最小的地方。一个更好的办法是不估计标准误，而是收集所有满足 $|\hat{p}-p| \le z\sqrt{p(1-p)/n}$ 的 p——用的是假设的 p 下的真实标准误。解这个关于 p 的二次不等式，得到 **Wilson 区间**：

$$\frac{\hat{p} + \frac{z^2}{2n}}{1+\frac{z^2}{n}} \pm \frac{z}{1+\frac{z^2}{n}}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}, \qquad z = z_{1-\alpha/2}.$$

它的中心被拉向 $1/2$，即使 $\hat{p}=0$ 也有正的长度：20 次 0 次成功时，95% Wilson 区间为 $[0,\,0.161]$。

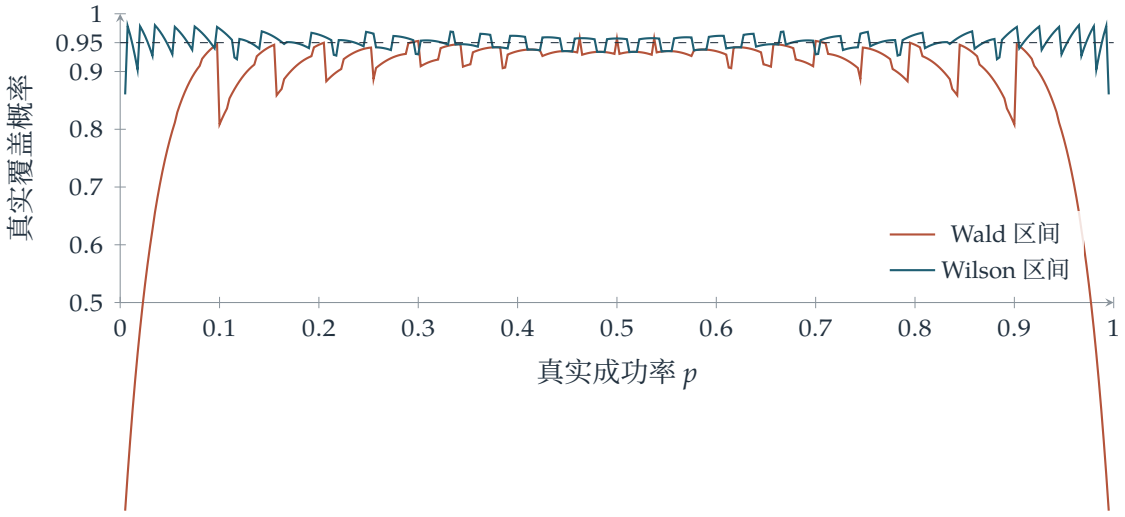


图 4.3　$n=30$ 时名义 95% 的两种比例区间的精确覆盖概率。由于二项分布是离散的，两条曲线都锯齿状起伏；但 Wald 区间在 p 靠近 0 或 1 时严重不足，Wilson 区间则始终在 95% 附近。

◆ 一个实用的经验法则

n 次试验全部失败时，“3 法则”给出成功率的近似 95% 上界 $3/n$：因为 $(1-p)^n \le 0.05$ 当且仅当 $p \ge 1-0.05^{1/n} \approx 3/n$。$n=20$ 时 $3/20=0.15$，与 Wilson 上界 0.161 相近。

4.4　假设检验的逻辑

抛一枚硬币 10 次，得到 9 次正面。它偏吗？即使是公平硬币，9 次正面也可能出现。检验的思路是：先假定硬币公平，算出这样极端的结果有多罕见；如果足够罕见，就怀疑原先的假定。这和反证法很像，只不过“矛盾”是概率意义上的。

定义 4.4 假设、检验与两类错误　把参数空间分成两部分，提出**原假设** $H_0:\theta\in\Theta_0$ 与**备择假设** $H_1:\theta\in\Theta_1$。**检验**是一条事先规定的规则：数据落入**拒绝域** C 时拒绝 H_0，否则不拒绝。称 $\pi(\theta)=\mathbb{P}_\theta(X\in C)$ 为**功效函数**。

	不拒绝 H_0	拒绝 H_0
H_0 为真	正确	**第一类错误**（概率 $\pi(\theta)$，$\theta\in\Theta_0$）
H_1 为真	**第二类错误**（概率 $1-\pi(\theta)$）	正确（概率 $\pi(\theta)$ 称为**功效**）

若 $\sup_{\theta\in\Theta_0}\pi(\theta)\le\alpha$，称检验的**显著性水平**为 α。

两类错误不能同时任意小：拒绝域越大，第一类错误越多、第二类错误越少。经典的做法是先把第一类错误控制在 α（常取 0.05）以内，再在此前提下让功效尽量大。所以原假设应当是“默认的、需要证据才能推翻的”说法，例如“新药无效”“硬币公平”。

例 4.1（正态均值的单侧检验） $X_1,\dots,X_n$ 独立服从 $\mathcal{N}(\mu,1)$，检验 $H_0:\mu\le 0$ 对 $H_1:\mu>0$。自然的规则是 $\bar X$ 足够大时拒绝：拒绝域 $\{\sqrt{n}\,\bar X > z_{1-\alpha}\}$。它的功效函数为

$$\pi(\mu)=\mathbb{P}_\mu\big(\sqrt{n}(\bar X-\mu)>z_{1-\alpha}-\sqrt{n}\mu\big)=1-\Phi(z_{1-\alpha}-\sqrt{n}\,\mu),$$

随 μ 递增，所以在 Θ_0 上的最大值在边界 $\mu=0$ 处取到，恰为 α。

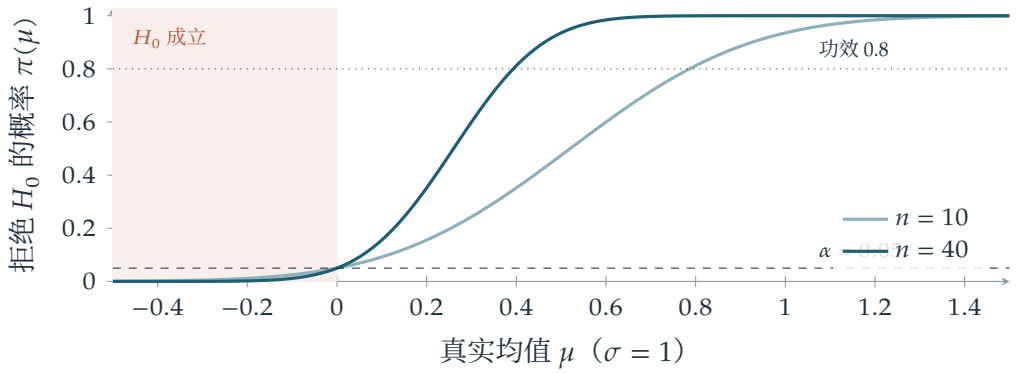


图 4.4　单侧 z 检验的功效函数。在 H_0 区域内拒绝概率都不超过 0.05；在备择区域内，样本量越大，功效上升得越快。$n=40$ 时，$\mu=0.4$ 已有约 0.8 的功效；$n=10$ 则需要 $\mu\approx 0.79$。

样本量计划　要在 $\mu=\delta$ 处达到功效 $1-\beta$，需要 $z_{1-\alpha}-\sqrt{n}\,\delta/\sigma\le -z_{1-\beta}$，即

$$n\ge\Big(\frac{(z_{1-\alpha}+z_{1-\beta})\,\sigma}{\delta}\Big)^2.$$

例如 $\alpha=0.05$、功效 0.8、想检测出半个标准差的效应，$n\ge((1.645+0.842)/0.5)^2\approx 24.7$，至少 25 个。做试验之前算好样本量，是避免“做完了才发现功效太低”的唯一办法。

4.5　p 值：用尾概率表示证据

固定 α 只告诉我们“拒绝”或“不拒绝”。更有信息量的做法是报告：要把 α 定得多大，这份数据才会被拒绝？

定义 4.5 p 值　设检验统计量 T 越大越不利于 H_0，观测值为 t_{obs}。在 H_0（复合时取其中最不利的参数）下，

$$p = \mathbb{P}_{H_0}(T \geq t_{\text{obs}})$$

称为**p 值**：原假设为真时，得到“至少与实际观测一样极端”的结果的概率。p 值 $\leq \alpha$ 当且仅当在水平 α 下拒绝。

例 4.2（抛币）　10 次 9 次正面，$H_0 : p = 1/2$，T 为正面次数。单侧（$H_1 : p > 1/2$）p 值为 $\mathbb{P}(T \geq 9) = \dfrac{\binom{10}{9}+\binom{10}{10}}{2^{10}} = \dfrac{11}{1024} \approx 0.011$。若事先关心的是“硬币偏向任何一边”（双侧），另一边同样极端的结果是 $T \leq 1$，p 值加倍为 0.021。

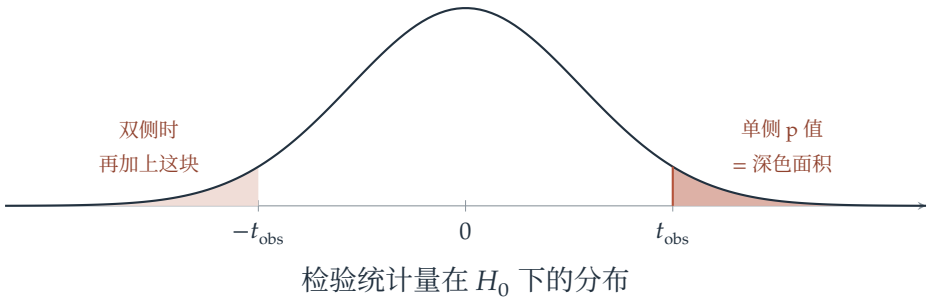


图 4.5　p 值是原假设分布中“比观测更极端”的尾部面积。观测值越靠外，p 值越小，证据越强。

p 值的四个误读

(1) **p 值不是“H_0 为真的概率”**。它是在假定 H_0 为真时计算的，不能反过来给出 H_0 的概率。

(2) **p 值小不等于效应大**。样本量很大时，微不足道的差别也会给出极小的 p 值。要同时报告效应的估计值和置信区间。

(3) **p 值大不等于 H_0 为真**。“不拒绝”可能只是因为样本太小、功效太低。“没有证据表明有差别”不等于“有证据表明没有差别”。

(4) **0.049 和 0.051 没有本质区别**。0.05 是约定，不是自然常数。

当 T 在 H_0 下有连续分布 F 时，单侧 p 值等于 $1 - F(T)$，它在 H_0 下服从 $\mathrm{U}(0,1)$（习题 4.6）。所以“$\mathbb{P}_{H_0}(p \leq \alpha) = \alpha$”：用 p 值做决定，第一类错误恰好是 α。离散时 $\mathbb{P}_{H_0}(p \leq \alpha) \leq \alpha$，检验偏保守。

4.6 检验与区间：一枚硬币的两面

定理 4.6 （检验与置信区间的对偶）

设对每个 θ_0 都有一个水平为 α 的检验 $H_0:\theta=\theta_0$，接受域为 $A(\theta_0)$。令 $C(X)=\{\theta_0 : X\in A(\theta_0)\}$（所有不会被拒绝的参数值），则 $C(X)$ 是置信水平为 $1-\alpha$ 的置信集。反之亦然。

证明. 对任意真值 θ，$\theta\in C(X)\iff X\in A(\theta)$，所以 $\mathbb{P}_\theta(\theta\in C(X))=\mathbb{P}_\theta(X\in A(\theta))\geq 1-\alpha$。反过来，给定置信集 C，令 $A(\theta_0)=\{x:\theta_0\in C(x)\}$ 即可。 ■

这条对偶在实际中极其有用：*95%* 置信区间不含 θ_0，就等价于在 *5%* 水平上拒绝 $\theta=\theta_0$，而且区间同时告诉我们效应的大小。Wilson 区间正是这样由检验“反解”出来的。

▣ 案例 睡眠数据的单样本 t 检验

检验 $H_0:\mu_d=0$（两药效果相同）。t 统计量为 $\bar d/(s/\sqrt{n})=1.58/0.389=4.06$，在 H_0 下服从 t_9，双侧 p 值 $=2\mathbb{P}(t_9\geq 4.06)\approx 0.0028$。与置信区间 $[0.70, 2.46]$ 不含 0 一致。结论：药物 B 平均比 A 多让人睡约 1.6 小时（95% 区间 0.7 到 2.5 小时），差别在统计上非常显著。

4.7 常见的陷阱

看了数据再选方向 设 $Z\sim\mathcal{N}(0,1)$。若事先规定做上侧检验，$\mathbb{P}(Z>z_{1-\alpha})=\alpha$。但如果看到 $Z>0$ 就做上侧、看到 $Z<0$ 就做下侧，真正的拒绝事件是 $|Z|>z_{1-\alpha}$，概率为 2α。用数据决定检验方式，就改变了检验本身，必须重新计算第一类错误。单侧还是双侧，要在看数据之前根据研究问题决定。

多重检验 同时做 20 个相互独立的检验，每个水平 0.05。即使所有原假设都成立，至少一个被拒绝的概率也是 $1-0.95^{20}\approx 0.64$。如果只报告“显著”的那一个，读者会被严重误导。最简单的补救是 **Bonferroni 校正**：每个检验用水平 α/m，则由 $\mathbb{P}(\bigcup A_j)\leq\sum\mathbb{P}(A_j)$，犯任一第一类错误的概率不超过 α。

统计显著与实际重要 一项涉及一百万人的调查发现两组平均身高相差 0.1 厘米，p 值可以小到 10^{-6}，但这个差别毫无实际意义。反过来，一个小试验中“不显著”的差别可能很重要，只是证据还不够。这就是为什么应当优先报告置信区间。

4.8　★ 深入讨论

★ 深入讨论：最优检验：Neyman–Pearson 引理

对简单原假设 $H_0:\theta=\theta_0$ 对简单备择 $H_1:\theta=\theta_1$，哪个水平 α 的检验功效最大？答案是似然比检验：当 $f_{\theta_1}(x)/f_{\theta_0}(x)>k$ 时拒绝，k 选得使 $\mathbb{P}_{\theta_0}(\text{拒绝})=\alpha$。

证明：设 ϕ^* 是似然比检验的拒绝示性函数，ϕ 是任一水平 $\le\alpha$ 的检验。对每个 x，若 $\phi^*(x)=1$，则 $f_1-kf_0>0$ 且 $\phi^*-\phi\ge 0$；若 $\phi^*(x)=0$，则 $f_1-kf_0\le 0$ 且 $\phi^*-\phi\le 0$。总有 $(\phi^*-\phi)(f_1-kf_0)\ge 0$。积分得

$$\mathbb{E}_{\theta_1}\phi^*-\mathbb{E}_{\theta_1}\phi\ \ge\ k(\mathbb{E}_{\theta_0}\phi^*-\mathbb{E}_{\theta_0}\phi)=k(\alpha-\mathbb{E}_{\theta_0}\phi)\ge 0.$$

例 4.1 中，对任意 $\mu_1>0$，似然比 $\exp\left(n\mu_1\bar{x}-n\mu_1^2/2\right)$ 是 $\bar{x}$ 的增函数，所以“$\bar{X}$ 大时拒绝”同时对所有 $\mu_1>0$ 最优——这样的检验称为**一致最优势检验**。

★ 深入讨论：离散检验与随机化

二项分布的尾概率是一档一档跳的。$n=10$、$p_0=1/2$ 时，$\mathbb{P}(T\ge 9)=0.011$，$\mathbb{P}(T\ge 8)=0.055$，任何非随机的拒绝域都无法使水平恰为 0.05。理论上可以引入随机化：$T\ge 9$ 时拒绝，$T=8$ 时以概率 $\gamma=(0.05-0.0107)/0.0439\approx 0.89$ 拒绝，使水平恰为 0.05。这在理论上（如 Neyman–Pearson 引理的离散版本）是必需的，但实践中很少有人愿意“抛一枚硬币”决定结论，通常接受偏保守的非随机检验，并报告 p 值。

本章小结

- 置信区间 = 估计值 $\pm$ 临界值 $\times$ 标准误；95% 是方法的覆盖率，不是这一个区间含真值的概率。
- 正态样本：$\bar{X}$ 与 S^2 独立，$(n-1)S^2/\sigma^2\sim\chi^2_{n-1}$，$\sqrt{n}(\bar{X}-\mu)/S\sim t_{n-1}$。小样本用 t 临界值。
- 比例区间优先用 Wilson 区间；Wald 区间在 p 接近 0,1 或 n 较小时覆盖不足。
- 检验先控制第一类错误 $\le\alpha$，再追求功效；功效函数和样本量公式 $n\ge\left((z_{1-\alpha}+z_{1-\beta})\sigma/\delta\right)^2$ 用于试验设计。
- p 值是 H_0 下“至少同样极端”的概率；不是 H_0 的概率，不衡量效应大小。
- 区间与检验对偶：区间不含 θ_0 $\iff$ 拒绝 $\theta=\theta_0$。

- 不要看数据选方向；多重检验要校正；显著不等于重要，不显著不等于没有差别。

习题

A 基础：熟悉概念与计算

习题 4.1 来自正态总体的 16 个观测，$\bar{x} = 52.3$，$s = 4.8$。求 μ 的 95% 置信区间（$t_{15,0.975} = 2.131$）。在 5% 水平上能否拒绝 $\mu = 50$？

习题 4.2 公平性检验：一枚硬币抛 20 次得到 15 次正面。求 $H_0 : p = 1/2$ 对 $H_1 : p > 1/2$ 的精确 p 值。

习题 4.3 判断下列说法是否正确，并说明理由。

(1)“95% 置信区间 $[2.1, 3.4]$ 表示 μ 有 95% 的概率在 2.1 与 3.4 之间。”

(2)“p 值为 0.03，所以原假设为真的概率是 3%。”

(3)“p 值为 0.40，所以我们证明了两组没有差别。”

(4)“其他条件相同，样本量越大，95% 置信区间越短。”

习题 4.4 已知总体标准差约为 10，希望 μ 的 95% 置信区间半宽不超过 2。至少需要多少个观测？若半宽要求不超过 1 呢？

B 进阶：推导与理解

习题 4.5 在例 4.1 中，取 $\alpha = 0.05$，σ 一般（不一定为 1）。推导在 $\mu = \delta > 0$ 处达到功效 $1 - \beta$ 所需的样本量，并验证正文中 $\delta = 0.5\sigma$、功效 0.8 时 $n = 25$ 的结论。

习题 4.6 设 T 在 H_0 下的分布函数 F 连续且严格递增。证明 p 值 $P = 1 - F(T)$ 在 H_0 下服从 $\mathrm{U}(0, 1)$。

习题 4.7 对睡眠数据的差值，求 σ^2 与 σ 的 95% 置信区间（$\chi^2_{9,0.025} = 2.700$，$\chi^2_{9,0.975} = 19.023$）。

习题 4.8 某研究者对同一份数据先后做了上侧检验和下侧检验（各在 $\alpha = 0.05$ 水平），只要有一个显著就宣布“有差别”。在正态 z 检验中，他的真实第一类错误是多少？他其实在做什么检验？

C 挑战：综合与探索（选做）

习题 4.9（原讲义习题 4.3）　P_1, P_2 是同一原假设的两个合法 p 值，即对 H_0 下的每个 $u \in [0,1]$ 有 $\mathbb{P}(P_i \le u) \le u$。

(1) 若二者独立且都服从 $\mathrm{U}(0,1)$，求 $Q = P_1 P_2$ 的分布函数，并据此把 Q 变成一个服从 $\mathrm{U}(0,1)$ 的 p 值。

(2) 不再假设独立。证明 $\min\{1,\, 2\sqrt{P_1 P_2}\}$ 仍是合法 p 值，而常数 2 不能再减小。

提示：(2) 若 $P_1 > u/2$ 且 $P_2 > u/2$，则 $2\sqrt{P_1 P_2} > u$。证明常数最优时，构造 $P_1 = U$，并在 $U < s$ 时令 $P_2 = s - U$、否则 $P_2 = U$。

习题 4.10（原讲义习题 4.5）　X_1, X_2 独立服从 $\mathrm{U}(0,\theta)$。检验 $H_0 : \theta \le 1$ 对 $H_1 : \theta > 1$，$0 < \alpha < 1/2$。

(1) 证明任何水平 $\le \alpha$ 的检验，在 $\theta > 1$ 时的功效不超过 $1 - (1-\alpha)/\theta^2$。

(2) 构造一个只依赖 $\max(X_1, X_2)$ 的拒绝域，对每个 $\theta > 1$ 达到这一上界。

提示：$\theta > 1$ 时，把样本空间分成 $(0,1)^2$ 和其余部分；前者上的概率是 $\theta = 1$ 时的 $1/\theta^2$ 倍。

第 5 章

两个样本的比较

本章要解决的问题　新药与旧药、处理组与对照组、男生与女生——统计学最常见的任务是比较。本章的核心信息是：比较的方法由试验设计决定。配对数据先作差；两组独立数据要看方差是否相同，方差不同（或不知道是否相同）时用 **Welch 检验**；比例有专门的方法；不愿意假设正态时，可以用**置换检验**得到精确的 p 值。最后，我们学习怎样检查这些方法所依赖的假设。

预备　第 4 章的 t 分布、置信区间与 p 值。

5.1　先问设计，再选方法

拿到两列数，第一个问题不是“用哪个公式”，而是“数据是怎样产生的”。图 5.1 是本章的路线图。

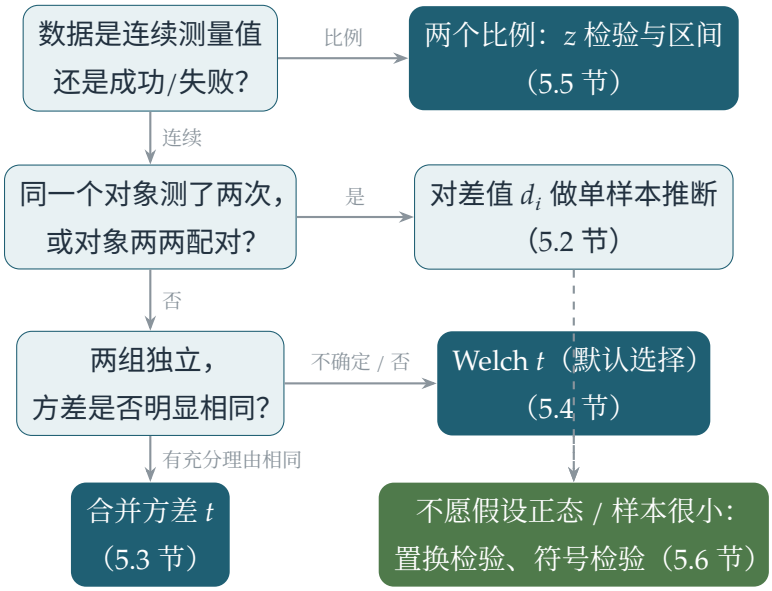


图 5.1　两样本比较的方法选择。虚线表示：任何一种情形都可以用不依赖正态的方法补充或替代。

5.2　配对数据：先求差，再推断

同一个人服用两种药、同一块地的两半用两种肥料、同一个学生测验前后的成绩——这样的数据成对出现 (A_i, B_i)，同一对的两个数往往高度相关，因为它们共享这个对象自身的特点（体质、土壤、基础）。

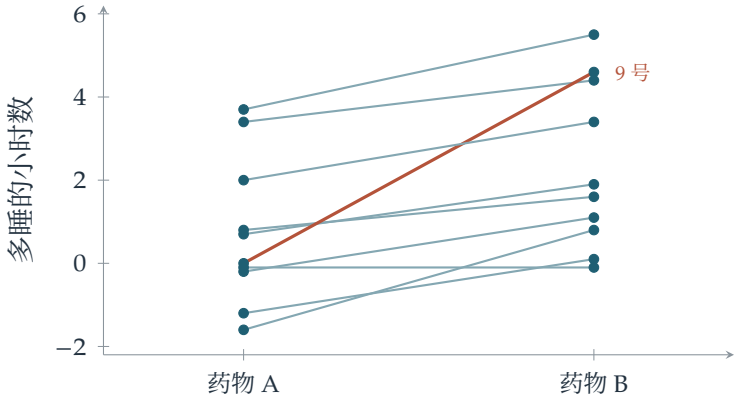


图 5.2　睡眠数据的配对图：每条线连接同一位病人的两个结果。病人之间的差别很大（从 −1.6 到 3.7），但几乎每条线都向上倾斜——差别主要来自病人，而药物效应体现在“每条线的斜率”上。

配对分析的方法很简单：令 $D_i = B_i - A_i$，把 $D_1, \dots, D_n$ 当作一个样本，用第 4 章的单样本 t 方法推断平均差 μ_D。它为什么比把两列当作独立样本好？关键在于差的方差：

$$\operatorname{Var}(B_i - A_i) = \sigma_A^2 + \sigma_B^2 - 2\rho\,\sigma_A\sigma_B.$$

同一对象的两个结果正相关（$\rho > 0$）时，差的方差比 $\sigma_A^2 + \sigma_B^2$ 小得多。睡眠数据中 $s_A^2 = 3.20$，$s_B^2 = 4.01$，相关系数 $r = 0.795$，差值的方差只有 $3.20 + 4.01 - 2\times 0.795\times 1.789\times 2.002 \approx 1.51$。配对把病人之间的差异消掉了。

第 4 章已经完成了睡眠数据的配对分析：平均差 1.58 小时，95% 区间 [0.70, 2.46]，$t = 4.06$，p 值 0.0028。

5.3　两个独立正态样本：合并方差 t 检验

现在设 $X_1, \dots, X_m \overset{\text{iid}}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$、$Y_1, \dots, Y_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$，两组相互独立。要推断 $\mu_1 - \mu_2$，自然的估计是 $\bar{X} - \bar{Y}$，

$$\operatorname{Var}(\bar{X} - \bar{Y}) = \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}.$$

若假定 $\sigma_1 = \sigma_2 = \sigma$，可以把两组的信息合起来估计这个共同的 σ^2。

定理 5.1 （合并方差 t 统计量）

设 $\sigma_1=\sigma_2=\sigma$。令合并样本方差 $S_p^2=\dfrac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2}$，则

$$T_p=\frac{(\bar X-\bar Y)-(\mu_1-\mu_2)}{S_p\sqrt{1/m+1/n}}\sim t_{m+n-2}.$$

证明. 由定理 4.3，$(m-1)S_X^2/\sigma^2\sim\chi^2_{m-1}$、$(n-1)S_Y^2/\sigma^2\sim\chi^2_{n-1}$，两者独立，和为 $(m+n-2)S_p^2/\sigma^2\sim\chi^2_{m+n-2}$（独立卡方之和的自由度相加，由定义即得）。分子除以 $\sigma\sqrt{1/m+1/n}$ 后服从 $\mathcal{N}(0,1)$，且与 S_X^2,S_Y^2 都独立。按 t 分布的定义相除即可。 ■

5.4 方差不等时：Welch 检验

原讲义正确地指出：两组方差不同时，T_p 不再服从 t 分布。那该怎么办？答案是不再合并方差，直接分别估计：

$$T_W=\frac{(\bar X-\bar Y)-(\mu_1-\mu_2)}{\sqrt{S_X^2/m+S_Y^2/n}}.$$

它的精确分布依赖未知的 σ_1/σ_2（这是著名的 **Behrens–Fisher 问题**，没有完美的精确解），但可以用一个 t 分布很好地近似，只需选对自由度。

Welch–Satterthwaite 自由度 记 $W=S_X^2/m+S_Y^2/n$，$w=\mathbb{E}W=\sigma_1^2/m+\sigma_2^2/n$。若 W 恰好形如 $w\chi^2_\nu/\nu$，T_W 就精确服从 t_ν。让两者的方差相等来选 ν：$\operatorname{Var}(w\chi^2_\nu/\nu)=2w^2/\nu$，而由 $\operatorname{Var}S^2=2\sigma^4/(n-1)$，

$$\operatorname{Var}W=\frac{2\sigma_1^4}{m^2(m-1)}+\frac{2\sigma_2^4}{n^2(n-1)}\quad\Longrightarrow\quad \nu=\frac{(\sigma_1^2/m+\sigma_2^2/n)^2}{\dfrac{(\sigma_1^2/m)^2}{m-1}+\dfrac{(\sigma_2^2/n)^2}{n-1}}.$$

把 σ_i^2 换成 S_X^2,S_Y^2，就得到 Welch 检验使用的自由度 $\hat\nu$。可以证明 $\min(m,n)-1\le\hat\nu\le m+n-2$（习题 5.6）。

合并方差检验到底错得多严重 下表用模拟比较了两种检验的真实第一类错误（名义水平 5%，每种情形重复 20 万次）。

表 5.1　两组均值相等时，名义 5% 双侧检验的真实拒绝率（模拟）

m	n	σ_1/σ_2	合并方差 t	Welch t
10	10	1	5.0%	4.9%
10	10	2	5.5%	5.0%
10	10	4	6.2%	5.1%
10	40	1	5.0%	5.2%
10	40	2	**18.4%**	5.1%
10	40	4	**29.4%**	5.0%
40	10	2	**0.5%**	5.0%
40	10	4	**0.1%**	5.0%

◆ 读懂这张表

- 两组样本量相等时，$S_p^2(2/n) = (S_X^2 + S_Y^2)/n$，合并检验与 Welch 检验的统计量**完全相同**，只是自由度不同，所以合并检验相当稳健。
- 样本量不等时，合并方差是按自由度加权的平均，它会被**大样本组**的方差主导。若方差大的恰是小样本组，标准误被低估，假阳性率可高达 30%；反之标准误被高估，检验过分保守、功效损失严重。
- Welch 检验在所有情形下都接近 5%；而方差真正相等时，它与合并检验几乎没有差别。

所以**默认使用 Welch 检验**。只有当有充分的先验理由相信方差相等时（例如同一台仪器、同一个过程），合并方差检验才有微小的好处。“先做方差齐性检验、再决定用哪个”的两步法并不推荐：方差检验在小样本时功效很低，而且这种“看了数据再选方法”本身会扭曲第一类错误（见习题 5.9）。

Welch 方法的 $1-\alpha$ 置信区间为 $(\bar{X}-\bar{Y}) \pm t_{\hat{\nu},1-\alpha/2}\sqrt{S_X^2/m + S_Y^2/n}$。

▣ 案例　如果把睡眠数据当成两个独立样本

假如有人忽略了配对，把两列数当作独立的两组。Welch 检验给出：差 1.58，标准误 $\sqrt{3.20/10 + 4.01/10} = 0.849$，$\hat{\nu} = 17.8$，$t = 1.86$，p 值 0.079，95% 区间

$[-0.21,\ 3.37]$——不显著。

同一份数据，配对分析的 p 值是 0.0028，独立分析是 0.079。差别全在标准误：0.389 对 0.849。忽略配对等于把病人之间的巨大差异（图 5.2）当成了随机误差。正确的分析由试验设计决定（这里每位病人都试了两种药），而不是由哪个结果更“好看”决定。

5.5 两个比例

两组独立的伯努利试验：第一组 n_1 次中成功 X_1 次，第二组 n_2 次中成功 X_2 次。$\hat p_i = X_i/n_i$，

$$\operatorname{Var}(\hat p_1 - \hat p_2) = \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}.$$

- **检验** $H_0: p_1 = p_2$：在 H_0 下两组成功率相同，用合并比例 $\hat p = (X_1+X_2)/(n_1+n_2)$ 估计标准误，$Z = \dfrac{\hat p_1 - \hat p_2}{\sqrt{\hat p(1-\hat p)(1/n_1 + 1/n_2)}}$ 近似服从 $\mathcal{N}(0,1)$。
- **区间**：不能假定 $p_1 = p_2$，分别估计：$(\hat p_1 - \hat p_2) \pm z_{1-\alpha/2}\sqrt{\hat p_1(1-\hat p_1)/n_1 + \hat p_2(1-\hat p_2)/n_2}$。

这两个都是大样本近似，要求每组的成功数与失败数都不太少（常用标准：都不少于 5 到 10）。否则应使用基于超几何分布的 Fisher 精确检验。

▣ 案例 1954 年脊髓灰质炎疫苗试验

美国 1954 年的 Salk 疫苗试验中，随机、双盲部分的结果（据 Freedman、Pisani、Purves《Statistics》整理的约数）为：接种组约 200 000 名儿童中 56 例麻痹型脊髓灰质炎，安慰剂组约 200 000 名中 142 例，即每十万人 28 例对 71 例。$Z \approx 6.1$，p 值约 10^{-9}；发病率之差的 95% 区间约为每十万人 29 到 57 例。接种组的发病率约为对照组的 0.39 倍。

注意两点。第一，发病率极低（万分之几），所以需要数十万人才能得出结论——比例的标准误由 $p(1-p)/n$ 决定，p 很小时要看的是病例数而非总人数。第二，结论之所以能解释为因果，靠的是随机分组：随机化保证了两组除接种外在各方面可比。

5.6 不依赖正态的精确检验

t 检验依赖正态性（或大样本）。另一类方法从试验设计本身的随机性出发，不需要任何分布假设。

5.6.1　随机分组与置换检验

设 $N = m + n$ 个对象中，随机选 m 个接受处理，其余作对照。原假设是“处理对每个对象都没有作用”：无论分到哪组，每个对象的结果都一样。那么观测到的 N 个结果是固定的，唯一的随机性来自分组，而分组的 $\binom{N}{m}$ 种方式等可能。于是可以精确算出任何统计量的零分布。

例 5.1（一个可以手算的置换检验） 6 只小鼠随机分成两组，处理组的结果为 $12, 10, 8$，对照组为 $9, 6, 5$。用 $T = \bar{X} - \bar{Y}$ 作统计量，观测值为 $10 - 6.67 = 3.33$。把 6 个数重新分成“3 个对 3 个”共 $\binom{6}{3} = 20$ 种方式，算出每种的 T：其中 $T \geq 3.33$ 的只有 2 种（实际的分组和 $\{12, 10, 9\}$ 对 $\{8, 6, 5\}$）。所以单侧精确 p 值为 $2/20 = 0.10$。

注意：3 对 3 时最小可能的单侧 p 值是 $1/20 = 0.05$。样本太小时，无论效应多大都无法得到很小的 p 值——这是置换检验诚实的一面。

◆ **置换检验的合法性从哪里来**

置换检验的有效性来自“在原假设下各种标签排列等可能”。随机分组的试验自动保证这一点。但如果两组**本来**就不同（例如方差不同），即使均值相同，标签也不可交换，此时把置换检验当作“均值相等”的检验就可能失效。**能不能置换，要由设计或假设来论证，而不是默认。**

5.6.2　配对数据：符号翻转

对配对数据，原假设“两种处理无差别”意味着：每一对内部谁先谁后是对称的，所以每个差值 D_i 取 $+|D_i|$ 或 $-|D_i|$ 等可能且相互独立。于是 2^n 种符号组合等可能，可以算出 $\sum D_i$ 的精确零分布。

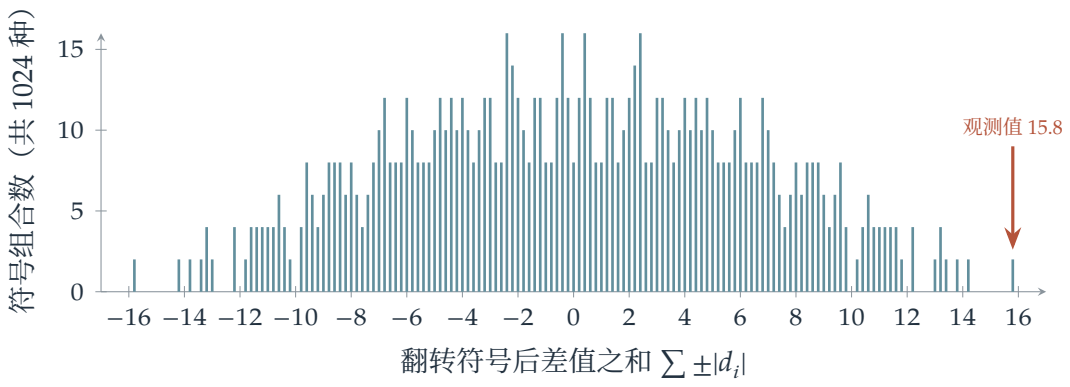


图 5.3　睡眠数据差值之和的符号翻转零分布（精确枚举）。观测值位于最右端：只有“全部取正号”（第 5 号病人的差值为 0，取正取负都一样，故计 2 种）达到它。

睡眠数据中，观测和 15.8 是所有组合中最大的，单侧精确 p 值为 $2/1024 \approx 0.002$，双侧为 0.004。它只假设每个差值的分布关于 0 对称，不需要正态，结论与 t 检验一致。

更粗糙但更简单的是**符号检验**：只看差值的正负。睡眠数据中 9 个非零差值全为正，在原假设下概率为 $2^{-9} \approx 0.002$。介于两者之间的是 **Wilcoxon 符号秩检验**：把 $|d_i|$ 排秩后再按符号求和，它既不依赖正态，又比符号检验利用了更多信息，是实践中最常用的非参数配对检验。

5.7 检查假设

每种方法都有前提。t 方法的前提是：观测独立；（配对的差值或各组）近似正态；Welch 不要求方差相等，合并方法要求。独立性由设计保证，无法从数据中可靠地检查；正态性可以用图形检查。

5.7.1 QQ 图

把排序后的数据 $x_{(1)} \le \dots \le x_{(n)}$ 对标准正态分位数 $\Phi^{-1}((i-0.5)/n)$ 作图。数据若来自正态分布，点应大致落在一条直线上（截距约为均值，斜率约为标准差）。

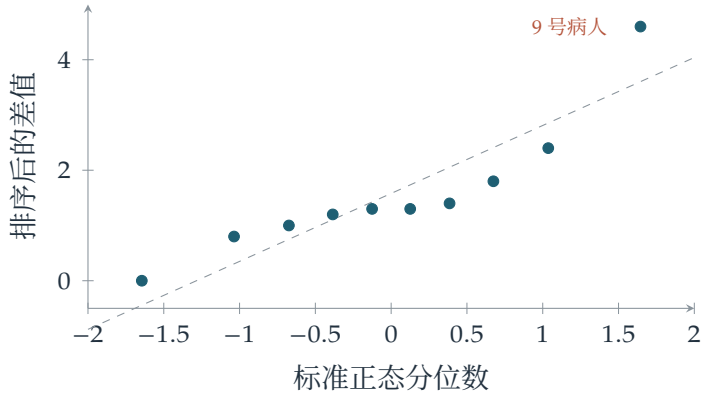


图 5.4　睡眠差值的正态 QQ 图。虚线为 $\bar{d} + s \cdot z$。中间 8 个点很贴近直线，最大的一个点（4.6）明显偏上，最小的一个（0）略偏上。10 个点的 QQ 图本身波动就很大，这种程度的偏离不算严重，但值得做敏感性分析。

5.7.2 敏感性分析

当某个点可疑时，不要悄悄删掉它，而是两种都做、都报告。去掉第 9 号病人后，其余 9 个差值的均值为 1.24，标准差 0.66，$t = 5.66$（自由度 8），p 值 0.0005。结论不变——这个异常点不是结论的来源。如果结论随一个点的去留而改变，就必须如实说明，并设法弄清这个点是否可信。

◆ t 方法有多稳健

由中心极限定理，样本量较大时 $\bar{X}$ 近似正态，t 方法对正态性的偏离并不敏感。小样本时，它对明显的偏斜和离群值比较敏感，这时可以用 Wilcoxon 或置换检验作为补充。两类方法结论一致，结论就更可信。

表 5.2　两样本比较方法一览

情形	方法	主要前提
配对数据	配对 t（对差值的单样本 t）	差值独立、近似正态
	符号翻转 / Wilcoxon 符号秩 / 符号检验	差值独立，分布关于 0 对称（符号检验只需中位数为 0）
独立两组	Welch t	各组独立、近似正态；方差可不等
	合并方差 t	另需方差相等，样本量不等时对此很敏感
	置换检验 / Wilcoxon 秩和检验	原假设下标签可交换（随机分组保证）
两个比例	两比例 z 检验与区间	独立，各格计数不太少；否则用 Fisher 精确检验

5.8　★ 深入讨论

★ 深入讨论：固定预算下怎样分配样本量

两组独立，方差为 σ_1^2, σ_2^2，每个观测的成本为 c_1, c_2，总预算 $B = c_1 m + c_2 n$。要使 $\mathrm{Var}(\bar{X} - \bar{Y}) = \sigma_1^2/m + \sigma_2^2/n$ 最小，由柯西–施瓦茨不等式，

$$\left(\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)(c_1 m + c_2 n) \geq \left(\sigma_1\sqrt{c_1} + \sigma_2\sqrt{c_2}\right)^2,$$

等号当且仅当 $m/n = \dfrac{\sigma_1/\sqrt{c_1}}{\sigma_2/\sqrt{c_2}}$。即：方差大的组多抽，成本高的组少抽，按标准差除以成本的平方根分配。等方差、等成本时就是两组一样多。这与第 1 章的 Neyman 分配是同一个道理。

★ 深入讨论：两样本 t 检验就是一个回归

令 $x_i = 0$ 表示第一组、$x_i = 1$ 表示第二组，用直线 $y = a + bx$ 拟合全部 N 个点。最小二乘斜率恰为 $\hat{b} = \bar{Y} - \bar{X}$，而第 6 章的斜率 t 统计量恰好就是合并方差 t 统计量（可能差一个符号）。这说明两样本比较是回归的特例，也解释了为什么合并方差检验与回归一样，都要求“误差方差处处相同”。

本章小结

- 方法由设计决定：配对数据先求差；独立两组再看方差；比例另有方法。
- 配对之所以有效，是因为 $\mathrm{Var}(B - A) = \sigma_A^2 + \sigma_B^2 - 2\rho\sigma_A\sigma_B$，正相关时大大减小。忽略配对会严重损失功效。
- 合并方差 t 要求方差相等；样本量不等且方差不等时，第一类错误可严重失控。默认使用 Welch t，自由度用 Welch–Satterthwaite 公式。
- 两比例：检验时用合并比例算标准误，区间用各自的比例；要求计数不太少。
- 置换检验与符号翻转检验的有效性来自设计的随机性或对称性，给出精确 p 值；小样本时最小可达 p 值有下限。
- 用 QQ 图检查正态性，对可疑点做敏感性分析，并如实报告。

习题

A 基础：熟悉概念与计算

习题 5.1 下列研究应该用配对方法还是独立两样本方法?

(1) 20 名学生在培训前后各测一次成绩。

(2) 随机选 20 名学生参加培训，另 20 名不参加，比较期末成绩。

(3) 15 对双胞胎，每对中随机一人用新教材、一人用旧教材。

(4) 比较 30 个城市家庭与 30 个农村家庭的月支出。

习题 5.2 两组独立样本：$m = 12$，$\bar{x} = 24.1$，$s_X = 3.2$；$n = 15$，$\bar{y} = 21.5$，$s_Y = 5.9$。

(1) 用 Welch 方法求 $\mu_1 - \mu_2$ 的 95% 置信区间（$\hat{\nu} \approx 22.3$，$t_{22.3,0.975} \approx 2.072$）。

(2) 用合并方差方法重新计算（$t_{25,0.975} = 2.060$）。两者相差大吗？为什么？

习题 5.3 新旧两种工艺各生产 150 件，次品分别为 45 件和 30 件。检验两种工艺的次品

率是否相同，并求次品率之差的 95% 置信区间。

习题 5.4　8 个对象随机分成两组各 4 个，处理组结果为 15, 13, 12, 11，对照组为 10, 9, 14, 8。以 $\bar{X}-\bar{Y}$ 为统计量，求置换检验的单侧精确 p 值（$\binom{8}{4}=70$）。

B 进阶：推导与理解

习题 5.5　在配对设计中，若同一对内两个结果负相关，配对分析与独立分析哪个标准误更小？举一个可能出现负相关的实际例子。

习题 5.6　证明 Welch–Satterthwaite 自由度满足 $\min(m,n)-1\le\hat{\nu}\le m+n-2$。

提示：记 $u=S_X^2/m$、$v=S_Y^2/n$，$\hat{\nu}=(u+v)^2/(u^2/(m-1)+v^2/(n-1))$。上界用柯西–施瓦茨，下界用 $u^2+v^2\le(u+v)^2$。

习题 5.7　证明 $m=n$ 时合并方差 t 统计量与 Welch 统计量相等。这时两种检验还有什么区别？

习题 5.8　对睡眠数据做符号检验和 Wilcoxon 符号秩检验（第 5 号病人差值为 0，舍去），分别求双侧 p 值。

提示：Wilcoxon：9 个非零差值全为正，秩和取到最大值，在原假设下只有一种符号组合（共 2^9 种）能达到。

C 挑战：综合与探索（选做）

习题 5.9（原讲义习题 6.1）　两批独立样本各有 $n\ge 2$ 个观测，都来自 $\mathcal{N}(\mu,\sigma^2)$。分析者比较两批的样本标准差后，只用标准差较小的那一批算 $T=\sqrt{n}(\bar{X}_J-\mu_0)/S_J$，按 t_{n-1} 的双侧临界值检验 $H_0:\mu=\mu_0$。证明真实第一类错误严格大于 α；若改选标准差较大的一批，则严格小于 α。

提示：条件于两批的 S_1^2,S_2^2，被选中的 $\sqrt{n}(\bar{X}_J-\mu_0)/\sigma$ 仍是标准正态（为什么?）。拒绝的条件概率是 S_J 的严格递减函数。

习题 5.10（原讲义习题 6.7）　每招募一名受试者花费 $c>0$，每次测量花费 1。每人测 k 次，总经费 B，人数为 $\lfloor B/(c+k)\rfloor$。第 j 人第 ℓ 次观测为 $Y_{j\ell}=\mu+U_j+\varepsilon_{j\ell}$，$U_j$ 的方差为 τ^2（个体差异），$\varepsilon_{j\ell}$ 的方差为 σ^2（测量误差），全部独立。以所有读数的平均估计 μ。

(1) 固定 k，求 $\lim_{B\to\infty} B\,\mathrm{Var}(\hat{\mu})$。

(2) 求使这个极限最小的正整数 k。结果怎样依赖 $c\sigma^2/\tau^2$？给出直观解释。

第 6 章

一元线性回归

本章要解决的问题　两个变量之间有什么样的关系？能不能用一个去预测另一个？预测有多准？本章从散点图和最小二乘直线出发，给出它的几何解释（正交投影），然后建立统计模型，推导斜率的精度与推断方法，区分“平均响应的置信区间”和“新观测的预测区间”，最后学习用残差图检查模型、识别异常点与强影响点。全章以 Forbes 的沸点–气压数据为主线，最后给出一份完整的分析。

预备　第 4 章的 t 分布与置信区间；第 0 章的协方差与柯西–施瓦茨不等式。

▣ 案例　Forbes 的沸点与气压数据（1857）

19 世纪的登山者想知道自己所在的海拔。气压计能测海拔，但又贵又易碎；温度计便宜得多。苏格兰物理学家 J. D. Forbes 在阿尔卑斯山和苏格兰的 17 个地点同时测量了水的沸点（°F）和气压（英寸汞柱），希望用沸点推算气压，进而推算海拔。

编号	1	2	3	4	5	6	7	8	9
沸点（°F）	194.5	194.3	197.9	198.4	199.4	199.9	200.9	201.1	201.4
气压（英寸汞柱）	20.79	20.79	22.40	22.67	23.15	23.35	23.89	23.99	24.02
编号	10	11	12	13	14	15	16	17	
沸点（°F）	201.3	203.6	204.6	209.5	208.6	210.7	211.9	212.2	
气压（英寸汞柱）	24.01	25.14	26.57	28.49	27.76	29.04	29.88	30.06	

物理学（Clausius–Clapeyron 关系）提示：在这个温度范围内，气压的对数与沸点近似成直线关系。按 Weisberg 的经典处理，下文的响应取 $y = 100\log_{10}(\text{气压})$，自变量 x 为沸点。

6.1　最小二乘直线

给定 n 个点 (x_i, y_i)，其中 x_i 不全相等，我们想找一条直线 $y = a + bx$ 尽量贴近它们。“贴近”的标准是竖直方向偏差的平方和最小。

定义 6.1 最小二乘直线、拟合值与残差　使 $Q(a,b) = \sum_{i=1}^{n}(y_i - a - bx_i)^2$ 最小的 $(\hat{a}, \hat{b})$ 确定的直线称为**最小二乘直线**。$\hat{y}_i = \hat{a} + \hat{b}x_i$ 称为**拟合值**，$e_i = y_i - \hat{y}_i$ 称为**残差**。

记 $t_i = x_i - \bar{x}$，以及

$$S_{xx} = \sum_i (x_i - \bar{x})^2, \qquad S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), \qquad S_{yy} = \sum_i (y_i - \bar{y})^2.$$

定理 6.2 （最小二乘解）

最小二乘直线唯一存在，

$$\hat{b} = \frac{S_{xy}}{S_{xx}}, \qquad \hat{a} = \bar{y} - \hat{b}\,\bar{x}.$$

残差满足 $\sum_i e_i = 0$ 与 $\sum_i x_i e_i = 0$；直线经过点 $(\bar{x}, \bar{y})$；最小平方和为 $\mathrm{SSE} = \sum e_i^2 = S_{yy} - \hat{b}^2 S_{xx}$。

证明. 把直线写成 $y = c + b(x - \bar{x})$ 的形式（$c = a + b\bar{x}$）。由于 $\sum_i t_i = 0$，

$$Q = \sum_i \left[(y_i - \bar{y}) - bt_i + (\bar{y} - c)\right]^2 = \sum_i \left[(y_i - \bar{y}) - bt_i\right]^2 + n(\bar{y} - c)^2.$$

第二项在 $c = \bar{y}$ 时最小。第一项展开为 $S_{yy} - 2bS_{xy} + b^2 S_{xx} = S_{xx}\left(b - S_{xy}/S_{xx}\right)^2 + S_{yy} - S_{xy}^2/S_{xx}$，在 $b = S_{xy}/S_{xx}$ 时最小，最小值即 SSE。两个残差恒等式就是 $\partial Q/\partial a = \partial Q/\partial b = 0$。 ■

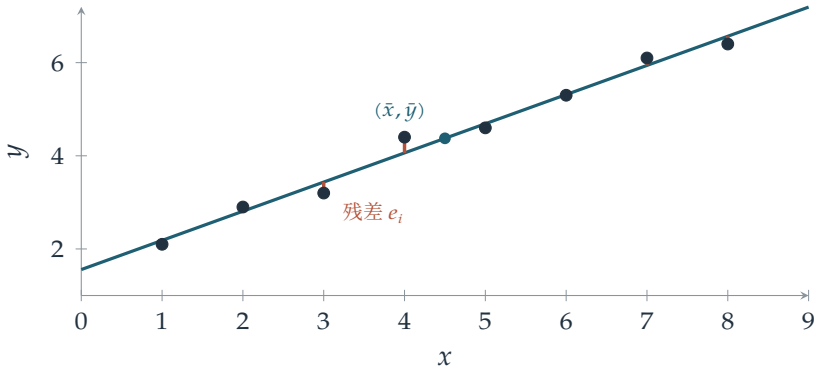


图 6.1　最小二乘直线使红色竖线（残差）的平方和最小。直线必经过均值点 $(\bar{x}, \bar{y})$；残差有正有负，总和为零。

常见误区

最小二乘只最小化竖直方向的误差，所以“用 x 预测 y”的直线与“用 y 预测 x”的直线一般不是同一条。回归是有方向的：先想清楚哪个是用来预测的变量、哪个是被预测的变量。

6.2 几何视角：投影与平方和分解

把 n 个响应看成 $\mathbb{R}^n$ 中的一个向量 y。所有形如 $a\mathbf{1}+bx$ 的向量组成一个二维平面（由全 1 向量与 x 张成）。最小二乘就是在这个平面上找离 y 最近的点——即 y 在平面上的**正交投影** $\hat{y}$。残差向量 $e=y-\hat{y}$ 垂直于这个平面，这正是两个恒等式 $\sum e_i=0$（$e\perp\mathbf{1}$）与 $\sum x_i e_i=0$（$e\perp x$）的含义。

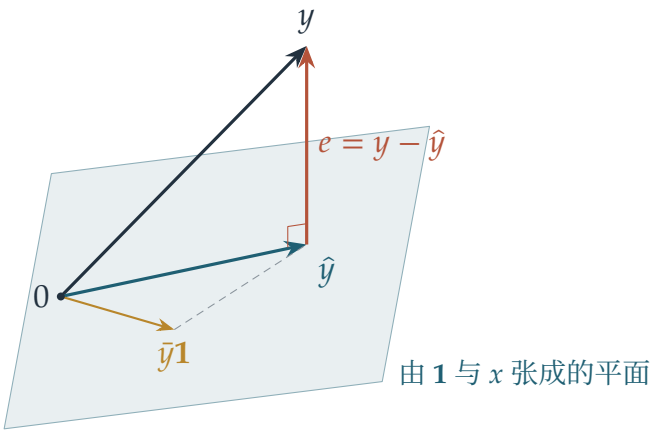


图 6.2　最小二乘是正交投影。三角形 $(\bar{y}\mathbf{1},\ \hat{y},\ y)$ 在 $\hat{y}$ 处是直角，勾股定理给出 SST = SSR + SSE。

由勾股定理（$\hat{y}-\bar{y}\mathbf{1}$ 在平面内，e 垂直于平面），

$$\underbrace{\sum (y_i-\bar{y})^2}_{\mathrm{SST}=S_{yy}} = \underbrace{\sum (\hat{y}_i-\bar{y})^2}_{\mathrm{SSR}=\hat{b}^2 S_{xx}} + \underbrace{\sum e_i^2}_{\mathrm{SSE}}.$$

决定系数 $R^2=\mathrm{SSR}/\mathrm{SST}$ 是 y 的总变异中被直线“解释”的比例；容易验证 $R^2=r^2$，其中 $r=S_{xy}/\sqrt{S_{xx}S_{yy}}$ 是样本相关系数。

▣ 案例　Forbes 数据的最小二乘直线

$\bar{x}=202.95$，$\bar{y}=139.60$，$S_{xx}=530.78$，$S_{xy}=475.38$，$S_{yy}=427.91$。于是

$$\hat{b}=\frac{475.38}{530.78}=0.8956,\qquad \hat{a}=139.60-0.8956\times 202.95=-42.16,$$

$\mathrm{SSE}=2.156$，$R^2=0.995$。沸点每升高 1°F，$100\log_{10}$(气压) 平均增加约 0.90。

常见误区

R^2 高不代表直线模型正确，也不代表因果关系。下面会看到，用原始气压（不取对数）拟合也有 $R^2 = 0.994$，但残差图清楚地显示直线并不合适。

6.3　统计模型与估计精度

到此为止我们只做了几何计算。要谈“斜率估计有多准”，需要说明数据的随机性从何而来。

定义 6.3 一元线性回归模型　$x_1, \dots, x_n$ 是事先确定的、不全相等的常数，

$$Y_i = a + bx_i + \varepsilon_i, \qquad i = 1, \dots, n,$$

其中误差 ε_i 均值为 0、方差都等于 σ^2，且两两不相关。a, b, σ^2 未知。

模型说的是：在每个 x 处，响应的平均值恰好落在直线 $a + bx$ 上，围绕平均值的波动大小处处相同。

定理 6.4 （最小二乘估计的均值与方差）

在上述模型下，$\hat b$ 与 $\hat a$ 无偏，且

$$\operatorname{Var}\hat b = \frac{\sigma^2}{S_{xx}}, \qquad \operatorname{Var}\left(\hat a + \hat b x_0\right) = \sigma^2\Big(\frac{1}{n} + \frac{(x_0 - \bar x)^2}{S_{xx}}\Big).$$

证明. $\hat b = \sum_i t_i Y_i / S_{xx}$（因为 $\sum t_i \bar y = 0$），是 Y_i 的线性组合。$\mathbb{E}\hat b = \sum t_i (a + bx_i)/S_{xx} = b\sum t_i x_i / S_{xx} = b$；由定理 0.4，$\operatorname{Var}\hat b = \sigma^2 \sum t_i^2 / S_{xx}^2 = \sigma^2 / S_{xx}$。拟合均值 $\hat a + \hat b x_0 = \bar Y + \hat b (x_0 - \bar x)$，而 $\operatorname{Cov}(\bar Y, \hat b) = \frac{\sigma^2}{n S_{xx}} \sum t_i = 0$，于是方差为 $\frac{\sigma^2}{n} + (x_0 - \bar x)^2 \frac{\sigma^2}{S_{xx}}$。 ■

◆ 这两个公式告诉了我们什么

- **斜率的精度取决于 x 的散布 S_{xx}。**在很窄的范围内测量，很难看清斜率；把 x 拉开，斜率就准得多。
- **离 $\bar x$ 越远，平均响应估计得越差，**而且按平方增长。直线像一根绕 $(\bar x, \bar y)$ 摆动的跷跷板，两端摆幅最大。外推到数据范围之外尤其危险——不仅误差大，而且直线关系本身可能不再成立。

在所有可能的估计方法中，最小二乘斜率是最好的吗？在“线性、无偏”的范围内，

答案是肯定的。

定理 6.5 （高斯–马尔可夫（斜率情形））

若 $T=\sum_i w_i Y_i$（权重只依赖已知的 x_i）对一切 a,b 无偏估计 b，则 $\operatorname{Var} T \geq \sigma^2/S_{xx} = \operatorname{Var}\hat{b}$，等号仅当 $T=\hat{b}$。

证明. 无偏要求 $\sum w_i = 0$ 且 $\sum w_i x_i = 1$，从而 $\sum w_i t_i = 1$。由柯西–施瓦茨，$1 = (\sum w_i t_i)^2 \leq \sum w_i^2 \cdot S_{xx}$，故 $\operatorname{Var} T = \sigma^2 \sum w_i^2 \geq \sigma^2/S_{xx}$；等号当且仅当 $w_i \propto t_i$，再由 $\sum w_i t_i = 1$ 得 $w_i = t_i/S_{xx}$。 ■

估计 σ^2 误差 ε_i 观测不到，只能用残差代替。由于估计了两个参数，残差满足两个约束，只剩 $n-2$ 个“自由度”：

命题 6.6 （残差方差）

$s^2 = \mathrm{SSE}/(n-2)$ 是 σ^2 的无偏估计。

证明. $\mathrm{SSE} = S_{yy} - \hat{b}^2 S_{xx}$。一方面 $Y_i - \bar{Y} = b t_i + (\varepsilon_i - \bar{\varepsilon})$，由第 1 章 $\mathbb{E}\sum(\varepsilon_i-\bar{\varepsilon})^2 = (n-1)\sigma^2$，交叉项期望为零，所以 $\mathbb{E}S_{yy} = b^2 S_{xx} + (n-1)\sigma^2$。另一方面 $\mathbb{E}\hat{b}^2 = \operatorname{Var}\hat{b} + b^2 = \sigma^2/S_{xx} + b^2$。相减得 $\mathbb{E}\,\mathrm{SSE} = (n-2)\sigma^2$。 ■

6.4 正态误差下的推断

若进一步假设 ε_i 独立服从 $\mathcal{N}(0,\sigma^2)$，用与定理 4.3 完全相同的正交变换论证（这次取前两个正交方向为 $\mathbf{1}/\sqrt{n}$ 与 $t/\sqrt{S_{xx}}$），可以证明：$\hat{a},\hat{b}$ 与 s^2 独立，$(n-2)s^2/\sigma^2 \sim \chi^2_{n-2}$，因此

$$\frac{\hat{b}-b}{s/\sqrt{S_{xx}}} \sim t_{n-2}, \qquad \frac{(\hat{a}+\hat{b}x_0)-(a+bx_0)}{s\sqrt{1/n + (x_0-\bar{x})^2/S_{xx}}} \sim t_{n-2}.$$

斜率的 $1-\alpha$ 置信区间为 $\hat{b} \pm t_{n-2,1-\alpha/2}\, s/\sqrt{S_{xx}}$；检验 $H_0: b=0$（x 与 y 没有线性关系）用 $t = \hat{b}/(s/\sqrt{S_{xx}})$。

6.4.1 平均响应的区间与新观测的预测区间

在 x_0 处，有两个不同的问题：

- **平均响应** $a+bx_0$ 在哪里？——这是一个固定的数，置信区间为

$$\hat{y}_0 \pm t_{n-2,1-\alpha/2}\, s\sqrt{\frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}}.$$

- **一个新观测** $Y_0 = a + bx_0 + \varepsilon_0$ 会落在哪里？——它还带着自己的误差 ε_0，与已有数据独立，$\operatorname{Var}(Y_0 - \hat{y}_0) = \sigma^2\left(1 + \frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}\right)$，所以**预测区间**为

$$\hat{y}_0 \pm t_{n-2,1-\alpha/2}\, s\sqrt{1 + \frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}}\,.$$

样本量增大时，置信区间缩成一条线，预测区间却始终至少有 $\pm 1.96\sigma$ 宽：再多的数据也消除不了单个新观测的随机性。

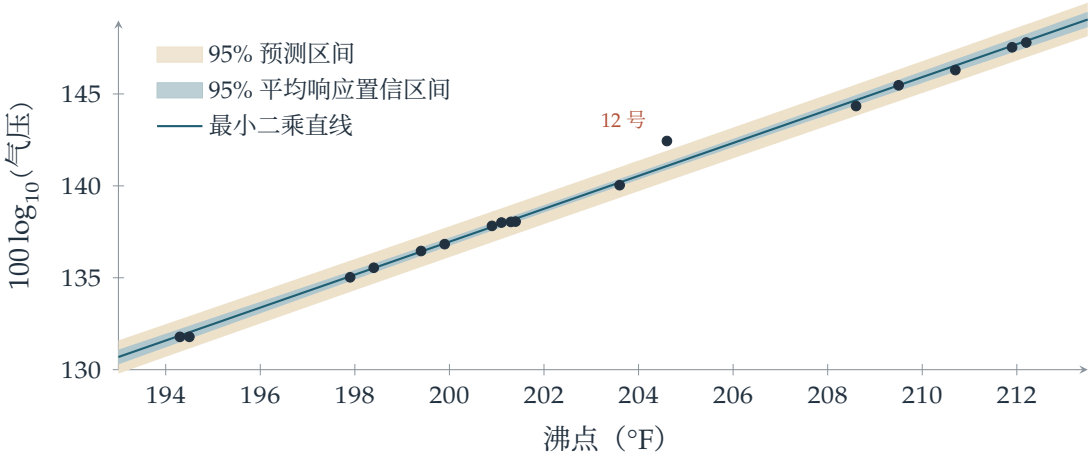


图 6.3　Forbes 数据（全部 17 点）的拟合直线、平均响应的置信带（深色，中间最窄）与新观测的预测带（浅色）。由于 R^2 极高，两条带都很窄，但预测带始终明显宽于置信带。

▣ 案例　Forbes：斜率与预测

$s = \sqrt{2.156/15} = 0.379$，斜率的标准误 $0.379/\sqrt{530.78} = 0.0165$，$t_{15,0.975} = 2.131$，95% 区间为 $[0.861,\ 0.931]$。$t = 54.4$，“没有线性关系”被彻底否定。在沸点 200°F 处，平均响应的估计为 136.96，95% 置信区间 ± 0.22，预测区间 ± 0.84；换算回气压，约为 23.42 英寸汞柱。

6.5　检查模型：残差图

模型的每个假设（直线形状、等方差、无异常点）都可能不成立，而 R^2 和 t 统计量对此几乎毫无反应。最有效的检查工具是**残差图**：把残差对拟合值（或对 x）作图。模型正确时，残差应当像一团没有结构的随机点，围绕 0 上下均匀分布。

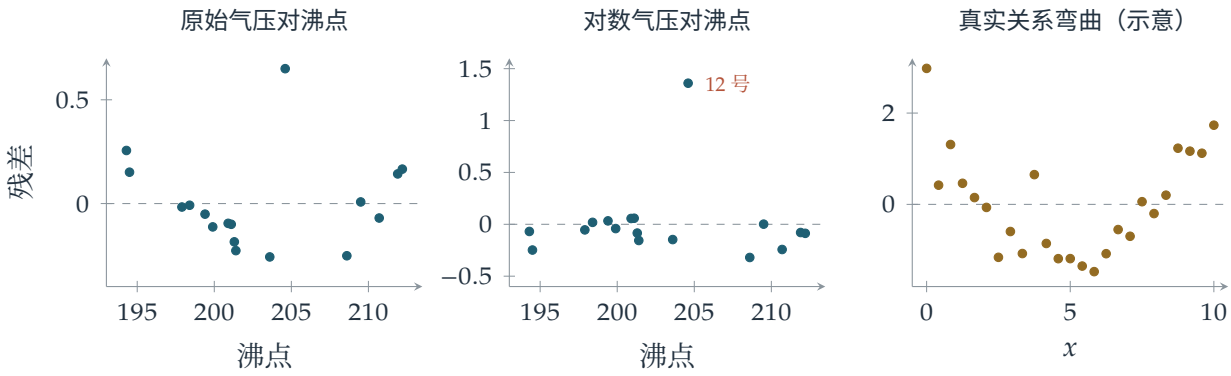


图 6.4　三幅残差图。左：用原始气压拟合，残差呈系统的弧形（两端偏高、中间偏低），说明直线不合适——尽管 $R^2 = 0.994$。中：取对数后弧形消失，但 12 号点远离其余各点。右：示意数据中真实关系是抛物线，残差呈明显的 U 形。

6.5.1　残差也有不同的方差

即使模型正确，残差的方差也不全相同：可以证明 $\operatorname{Var} e_i = \sigma^2(1 - h_{ii})$，其中

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

称为第 i 个点的**杠杆值**。离 $\bar{x}$ 远的点杠杆值大，直线被它“拉”得更近，残差反而偏小。为了公平比较，常用**标准化残差** $r_i = e_i / (s\sqrt{1 - h_{ii}})$，模型正确时它大致像标准正态变量，绝对值超过 3 就值得注意。Forbes 数据中 12 号点的标准化残差为 3.71，其余都在 ± 1 以内。

6.5.2　真实关系不是直线时，斜率在估计什么

若真实均值是某个函数 $\mathbb{E}Y_i = f(x_i)$，最小二乘斜率仍可计算，它的期望是

$$\mathbb{E}\hat{b} = \frac{\sum_i t_i f(x_i)}{S_{xx}}.$$

这是 f 在各段上的斜率的某种加权平均。例如 $f(x) = a + bx + cx^2$ 时，$\mathbb{E}\hat{b} = b + c\sum_i t_i x_i^2 / S_{xx} = f'(\xi)$，其中 $\xi = \frac{\sum t_i x_i^2}{2S_{xx}}$ 只依赖设计。所以弯曲的关系下，“斜率”描述的是某个特定位置的变化率，换一组 x 就会变；用它外推尤其不可靠。

6.6　异常点与强影响点

数据中“不寻常”的点有两种，需要区分：

- **离群点**：y 方向上远离直线，标准化残差大。它可能是记录错误，也可能是模型没有考虑到的现象。

- **高杠杆点**：x 远离其他点，h_{ii} 大。它不一定离群，但它有能力单独改变直线。

一个点对拟合的实际影响，由两者共同决定。删去第 i 个点后重新拟合，斜率的变化有一个精确的公式：

$$\hat{b} - \hat{b}_{(i)} = \frac{(x_i - \bar{x})\, e_i}{S_{xx}\,(1 - h_{ii})}.$$

残差 e_i 大、且 x_i 远离中心（h_{ii} 接近 1）时，影响最大。

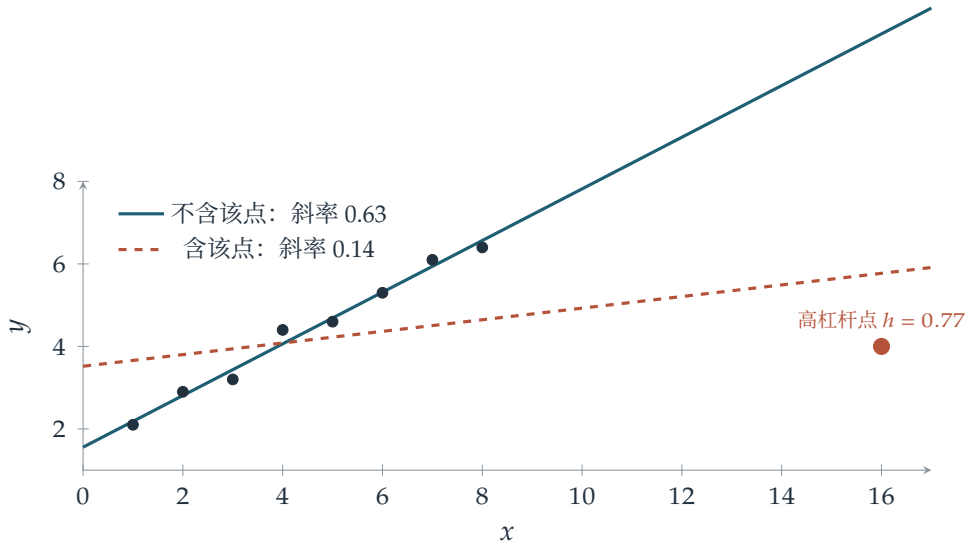


图 6.5　一个高杠杆点的影响。前 8 个点清楚地显示斜率约为 0.63；加入 $x = 16$ 处的一个点后，斜率骤降到 0.14。而且加入后它的残差并不算特别大——高杠杆点把直线拉向自己，从而“掩盖”了自己的异常。

▣ 案例　Forbes 的 12 号点

12 号点的标准化残差为 3.71，是明显的离群点，但它的杠杆值只有 0.064（$x = 204.6$ 接近中心）。删去它后，斜率从 0.8956 变为 0.8911，几乎不变；但 s 从 0.379 降到 0.114，缩小到三分之一，斜率的 95% 区间变为 [0.881, 0.902]，预测区间也窄得多。也就是说，这个点不影响“直线是什么”，却严重影响“直线有多准”。Forbes 本人也怀疑过这个点；Weisberg 推测可能是记录有误。

常见误区

发现异常点后，不能因为它“不好看”就删掉。正确的做法是：检查原始记录；分别报告含与不含该点的结果；如果删去，要说明理由。

6.7 完整案例：Forbes 数据分析

▣ 案例 一份完整的回归分析

(1) **明确问题**：用沸点 x 预测气压，进而推算海拔。x 是预测变量，$y = 100\log_{10}(\text{气压})$ 是响应。

(2) **作图**：散点图显示很强的直线趋势（图 6.3）。

(3) **选择变换**：用原始气压拟合，残差有系统弧形（图 6.4 左）；按物理学提示取对数后弧形消失。

(4) **拟合**：$\hat{y} = -42.16 + 0.8956x$，$R^2 = 0.995$，$s = 0.379$。

(5) **诊断**：残差图中 12 号点标准化残差 3.71，杠杆值低。

(6) **敏感性分析**：删去 12 号点，斜率 0.8911，$s = 0.114$。斜率结论稳定，精度结论依赖于这个点。

(7) **报告**：沸点每升高 1°F，$\log_{10}$ 气压约增加 0.0090（95% 区间 0.0086 到 0.0093）；由沸点预测对数气压的典型误差约为 0.4（含 12 号点）或 0.1（不含）个单位。12 号点疑为记录误差。在 194–212°F 范围外使用此直线需谨慎。

6.8 ★ 深入讨论

★ 深入讨论：辛普森悖论：合并数据可以颠倒趋势

图 6.6 中有两组数据，每组内部 y 都随 x 增大而减小（斜率约 -0.46 与 -0.74）；但两组的位置不同，第二组 x 和 y 都更大。把它们合并后拟合一条直线，斜率变成 $+0.74$——方向完全相反。

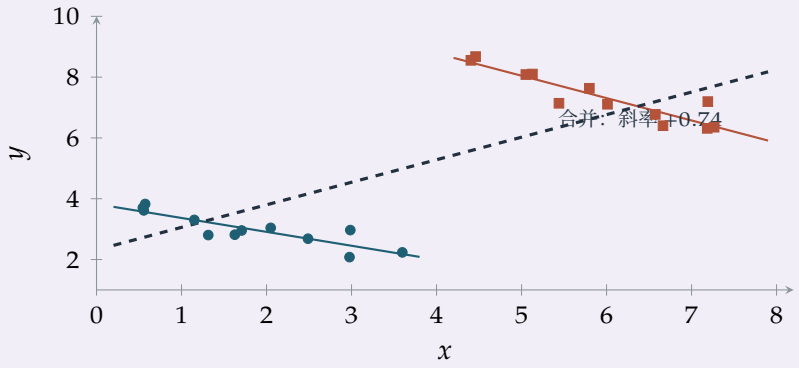


图 6.6　辛普森悖论（示意数据）。

教训是：忽略一个同时影响 x 和 y 的变量（这里是“组别”），回归斜率可能

完全误导。观察数据中的相关关系，不能直接解释为因果。解决办法是把这个变量也放进模型（多元回归），或者用随机化试验切断它的影响。

★ 深入讨论：向均值回归

“回归”一词来自 Galton 对父子身高的研究：极高的父亲，儿子平均也高，但没那么高。这并非遗传的神秘力量，而是标准化后最小二乘斜率等于相关系数 r、且 $|r|<1$ 的必然结果：若 x 高于平均 k 个标准差，y 的预测值只高于平均 rk 个标准差。第一次考得特别好的学生第二次平均会退步，受罚之后表现“改善”——很多看似因果的现象其实只是向均值回归。

本章小结

- 最小二乘：$\hat{b}=S_{xy}/S_{xx}$，$\hat{a}=\bar{y}-\hat{b}\bar{x}$；几何上是正交投影，$\mathrm{SST}=\mathrm{SSR}+\mathrm{SSE}$，$R^2=r^2$。
- 模型 $Y=a+bx+\varepsilon$ 下：$\operatorname{Var}\hat{b}=\sigma^2/S_{xx}$（$x$ 越分散越准）；拟合均值的方差离 $\bar{x}$ 越远越大；$s^2=\mathrm{SSE}/(n-2)$ 无偏。
- 高斯–马尔可夫：最小二乘斜率是方差最小的线性无偏估计。
- 正态误差下，斜率与拟合均值的标准化统计量服从 t_{n-2}。预测区间比平均响应的置信区间宽，多出的“1”永远消不掉。
- 一定要画残差图。R^2 高不代表模型对。用标准化残差找离群点，用杠杆值找高杠杆点，用删点公式衡量影响。
- 异常点要核查、做敏感性分析、如实报告；警惕外推、辛普森悖论与向均值回归。

习题

A 基础：熟悉概念与计算

习题 6.1 数据 $(1,2),(2,4),(3,5),(4,4),(5,6)$。

(1) 求最小二乘直线、各残差、SSE、s^2 与 R^2。

(2) 求斜率的 95% 置信区间（$t_{3,0.975}=3.182$）。在 5% 水平上能否断言斜率不为零？

习题 6.2 用自己的话解释 Forbes 分析中的 $R^2=0.995$ 和 $s=0.379$ 各说明了什么。为什

么不能仅凭 R^2 判断模型是否合适?

习题 6.3 要在 $x \in [0,10]$ 范围内做 10 次试验估计斜率。比较两种设计的 $\operatorname{Var}\hat{b}$：(i) $x = 0,1,\dots,9$；(ii) 五次在 $x=0$、五次在 $x=10$。第二种设计有什么隐患?

习题 6.4 x 取 $1,2,3,4,10$。求各点的杠杆值 h_{ii}，并验证它们之和等于 2。

B 进阶：推导与理解

习题 6.5 证明 $\sum_i h_{ii} = 2$ 且 $\frac{1}{n} \le h_{ii} \le 1$，并证明 $h_{ii}=1$ 当且仅当除第 i 个点外其余各点的横坐标全部相同。这时第 i 个点对拟合直线有什么样的影响?

习题 6.6 证明 $R^2 = r^2$，其中 r 为样本相关系数；并证明“用 x 预测 y”与“用 y 预测 x”的两个斜率之积等于 r^2。

习题 6.7 两组数据：第一组 m 个观测，令 $x=0$；第二组 n 个，令 $x=1$。证明最小二乘斜率等于两组均值之差，s^2 等于合并样本方差 S_p^2，因此斜率的 t 统计量就是两样本合并方差 t 统计量。

习题 6.8 在正态误差模型下，若两个新观测在同一个 x_0 处，它们的平均值的预测区间是什么？与单个新观测的预测区间相比如何?

C 挑战：综合与探索（选做）

习题 6.9（原讲义习题 7.1） 横坐标固定为 $0,1,3$。设 $g:\mathbb{R}\to\mathbb{R}$ 连续。要求对任意 y_1,y_2,y_3，把响应替换为 $g(y_1),g(y_2),g(y_3)$ 后，最小二乘斜率为零当且仅当原斜率为零。求全部这样的 g。

> 提示：原斜率为 $(-4y_1 - y_2 + 5y_3)/14$。取 $y_3 = (4y_1+y_2)/5$，得到 g 满足的函数方程。

习题 6.10（原讲义习题 7.7） 固定不全相等的 $x_1,\dots,x_n$ 与实数 $y_1,\dots,y_n$。把响应随机重新排列（$n!$ 种排列等可能），得到的最小二乘斜率记为 B_Π。

(1) 求 $\mathbb{E}B_\Pi$ 与 $\operatorname{Var}B_\Pi$。

(2) 这给出了检验“x 与 y 无关”的置换检验。说明它的合理性来自何处，并与 t 检验比较。

> 提示：$B_\Pi = \sum_i t_i z_{\Pi(i)}/S_{xx}$，$z_j = y_j - \bar{y}$。随机排列下 $z_{\Pi(i)}$ 与 $z_{\Pi(j)}$ 的协方差与第 1 章不放回抽样的情形相同。

附录 A

习题解答

A、B 级习题给出完整解答；C 级习题给出完整解答或详细的证明要点。建议先独立思考，至少写下一种思路后再对照。

第 0 章

0.1 $\mathbb{E}X = \frac{1+\cdots+6}{6} = 3.5$，$\mathbb{E}X^2 = \frac{91}{6}$，$\operatorname{Var} X = \frac{91}{6} - \frac{49}{4} = \frac{35}{12}$。两颗独立骰子之和的方差为 $\frac{35}{6}$。由双线性与独立性，$\operatorname{Cov}(X_1 + X_2, X_1) = \operatorname{Var} X_1 + \operatorname{Cov}(X_2, X_1) = \frac{35}{12}$。

0.2 $\operatorname{Cov}(X+Y, X-Y) = \operatorname{Var} X - \operatorname{Cov}(X,Y) + \operatorname{Cov}(Y,X) - \operatorname{Var} Y = \operatorname{Var} X - \operatorname{Var} Y = 0$。不一定独立：两颗骰子之和为 12 时差必为 0，所以 $\mathbb{P}(\text{和}=12,\ \text{差}=1) = 0 \neq \mathbb{P}(\text{和}=12)\mathbb{P}(\text{差}=1) = \frac{1}{36}\cdot\frac{10}{36}$。

0.3 $\operatorname{Var}\bar{X} = \frac{1/4}{400} = \frac{1}{1600}$，切比雪夫给出 $\mathbb{P}(|\bar{X} - \frac{1}{2}| \geq 0.05) \leq \frac{1/1600}{0.0025} = 0.25$。中心极限定理：$K$ 的均值 200、标准差 10，事件为 $|K-200| \geq 20$，连续性修正后 $\approx 2(1-\Phi(19.5/10)) = 2(1-\Phi(1.95)) \approx 0.0512$，与精确值 0.0510 几乎相同；切比雪夫界大了约 5 倍。

0.4 对任意 $0 < \varepsilon < n$，$\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}(X_n = n) = 1/n \to 0$，故 $X_n \xrightarrow{\mathrm{P}} 0$。$\mathbb{E}X_n = n\cdot\frac{1}{n} = 1$；$\mathbb{E}X_n^2 = n$，$\operatorname{Var} X_n = n - 1 \to \infty$。少量概率放在很远的地方，不影响“依概率”，却能左右期望。

0.5 (1) 由定理 0.4，$\operatorname{Var}(\sum X_i) = n\sigma^2 + n(n-1)\rho\sigma^2$，除以 n^2 即得。(2) 方差非负，$1 + (n-1)\rho \geq 0$，即 $\rho \geq -1/(n-1)$。$\rho > 0$ 时 $\operatorname{Var}\bar{X} \to \rho\sigma^2 > 0$：若各次测量共享一个共同的误差（例如仪器的系统偏差），再多次平均也消除不了它。“多测几次取平均”只对独立的误差有效。（第 1 章不放回抽样中 $\rho = -1/(N-1)$，$n = N$ 时方差恰好为 0。）

0.6 (1) $g(x) = x(1-x)$，$g'(p) = 1 - 2p \neq 0$。中心极限定理给出 $\sqrt{n}(\bar{X} - p) \xrightarrow{\mathrm{d}} \mathcal{N}(0, p(1-p))$，由 Delta 方法 $\sqrt{n}(T_n - p(1-p)) \xrightarrow{\mathrm{d}} \mathcal{N}(0, (1-2p)^2 p(1-p))$。(2) $T_n - \frac{1}{4} = -(\bar{X} - \frac{1}{2})^2$，所以 $n(T_n - \frac{1}{4}) = -\left(\sqrt{n}(\bar{X} - \frac{1}{2})\right)^2$。$\sqrt{n}(\bar{X} - \frac{1}{2}) \xrightarrow{\mathrm{d}} Z/2$，$Z \sim \mathcal{N}(0,1)$；

连续映射定理对依分布收敛同样成立，故 $n(T_n - \frac{1}{4}) \xrightarrow{\mathrm{d}} -Z^2/4 = -\frac{1}{4}\chi_1^2$。

第 1 章

1.1 均值 $25/8 = 3.125$，中位数 2。两半为 $(1,1,2,2)$ 与 $(2,3,4,10)$，$Q_1 = 1.5$，$Q_3 = 3.5$，$I = 2$，五数概括 $(1, 1.5, 2, 3.5, 10)$。区间 $[-1.5, 6.5]$，须到 1 与 4，10 单独标出。改成 100 后，箱体、须、中位数都不变，最大值变为 100，均值增加 90/8 变为 14.375，方差剧增。

1.2 标准误 $2/\sqrt{4} = 1$。要 $2/\sqrt{n} \le 0.25$，需 $n \ge 64$。

1.3 10 个二元子集的均值：$1.5, 2, 2.5, 3, 2.5, 3, 3.5, 3.5, 4, 4.5$。分布为 $1.5, 2, 4, 4.5$ 各 $\frac{1}{10}$，$2.5, 3, 3.5$ 各 $\frac{2}{10}$。期望 3；方差 $\frac{1}{10}(2.25 + 1 + 2\times 0.25 + 0 + 2\times 0.25 + 1 + 2.25) = 0.75$。总体 $\mu = 3$，$\sigma^2 = 2$，公式给出 $\frac{5-2}{5-1}\cdot\frac{2}{2} = 0.75$，一致。

1.4 按比例：$n_1 = 60$, $n_2 = 40$, $\operatorname{Var} T = 0.6^2\cdot\frac{100}{60} + 0.4^2\cdot\frac{900}{40} = 0.6 + 3.6 = 4.2$。Neyman：$n_h \propto p_h\sigma_h = 6, 12$，$n_1 \approx 33$，$n_2 \approx 67$，$\operatorname{Var} T = \frac{(6+12)^2}{100} = 3.24$。走读生内部差异大，应当多抽。

1.5 $\sum_i\sum_j (x_i - x_j)^2 = 2n\sum x_i^2 - 2(\sum x_i)^2 = 2n^2(\overline{x^2} - \bar{x}^2) = 2n^2 v$。因 $S^2 = \frac{n}{n-1}v$，$S^2 = \frac{1}{2n(n-1)}\sum_{i,j}(X_i - X_j)^2 = \frac{1}{n(n-1)}\sum_{i<j}(X_i - X_j)^2$。独立同分布时 $\mathbb{E}(X_i - X_j)^2 = \operatorname{Var}(X_i - X_j) = 2\sigma^2$，共 $\binom{n}{2}$ 项，故 $\mathbb{E}S^2 = \frac{1}{n(n-1)}\cdot\frac{n(n-1)}{2}\cdot 2\sigma^2 = \sigma^2$。

1.6 记 $w = \frac{n_1}{n_1+n_2}$。合并均值 $w\bar{x}_1 + (1-w)\bar{x}_2$，合并方差 $wv_1 + (1-w)v_2 + w(1-w)(\bar{x}_1 - \bar{x}_2)^2$（组内方差的加权平均加上组间方差）。

1.7 $\sigma^2 = 0.25$。$N = 10^4$：$\mathrm{SE} = \sqrt{\frac{9000}{9999}\cdot\frac{0.25}{1000}} \approx 0.0150$；$N = 10^7$：$\approx 0.0158$。总体扩大一千倍，标准误只差 5%。

1.8 估计值为 0 当且仅当全为 0 或全为 1，概率 $(1-p)^n + p^n$。$p = 0.05$、$n = 20$ 时约为 $0.95^{20} \approx 0.36$。三分之一以上的情况下，这个“标准误估计”说误差为零，而真实标准误是 $\sqrt{0.05\times 0.95/20} \approx 0.049$。这正是第 4 章 Wald 区间失效的根源。

1.9 一对 $\{u, v\}$ 中等概率取一个，方差为 $(u-v)^2/4$，各对独立，故配对 $\mathcal{P}$ 下估计量方差为 $V(\mathcal{P}) = \frac{1}{4m^2}\sum_{\{i,j\}\in\mathcal{P}}(a_i - a_j)^2$，期望总是总体均值。

最优配对：若 a_1 与 a_j、a_2 与 a_k 配对 $(j, k > 2)$，改为 $\{a_1, a_2\}, \{a_j, a_k\}$，平方差之和减少 $(a_j - a_1)^2 + (a_k - a_2)^2 - (a_2 - a_1)^2 - (a_j - a_k)^2 = 2(a_j - a_2)(a_k - a_1) > 0$。所以最优配对必含 $\{a_1, a_2\}$，对剩下的数归纳，唯一最优配对为 $\{a_1, a_2\}, \{a_3, a_4\}, \ldots$，最小方差 $\frac{1}{4m^2}\sum_{j=1}^{m}(a_{2j} - a_{2j-1})^2$。

与简单随机抽样比较：对所有配对方式等概率平均，任一指定的 $\{i,j\}$ 成对的概率为 $\frac{1}{2m-1}$，于是平均方差为 $\frac{1}{4m^2(2m-1)}\sum_{i<j}(a_i-a_j)^2=\frac{\sigma^2}{2m-1}$（用习题 1.5 的恒等式，$\sigma^2$ 以 $2m$ 为分母）。这恰好等于简单随机抽取 m 个的方差 $\frac{2m-m}{2m-1}\cdot\frac{\sigma^2}{m}$。$m\geq 2$ 时配对方式不止一种，而最优者唯一，所以最小值严格小于平均值。

1.10　六个两数之和互不相同且等可能，恰为 $1,2,\dots,6$。设 $a\leq b\leq c\leq d$，每个数在和中出现 3 次，$a+b+c+d=21/3=7$。最小两个和 $a+b=1$、$a+c=2$，最大两个和 $c+d=6$、$b+d=5$。令 $a=t$，得 $(t,1-t,2-t,4+t)$，剩下的 $a+d=4+2t$ 与 $b+c=3-2t$ 须为 $\{3,4\}$，得 $t=0$ 或 $t=-\frac{1}{2}$。答案：$\{0,1,2,4\}$ 或 $\{-\frac{1}{2},\frac{3}{2},\frac{5}{2},\frac{7}{2}\}$。即使知道统计量的完整抽样分布，也未必能确定总体。

1.11　平移使 $\mu=0$，则 $\sum x_i^2=nv$。设最小、最大值为 $a<0<b$（$v>0$ 保证两者异号），$(b-a)^2\leq 2(a^2+b^2)\leq 2\sum x_i^2=2nv$。第一个等号要求 $a=-b$，第二个要求其余 $n-2$ 个数都是 0。所以取等的数据恰为 $\mu-\sqrt{nv/2}$、$n-2$ 个 μ、$\mu+\sqrt{nv/2}$，验证可知它们确实满足条件。

第 2 章

2.1　两者都无偏。$\operatorname{Var}T=\sigma^2/2$，$\operatorname{Var}\bar X=\sigma^2/n$；均方误差等于方差。$n>2$ 时 $\bar X$ 更好。T 的分布不随 n 改变，$\sigma>0$ 时不相合。

2.2　权重正比于 $1/0.02^2=2500$、$1/0.05^2=400$、$1/0.04^2=625$，合计 3525。合并估计 $\frac{2500\times5.03+400\times5.11+625\times4.98}{3525}\approx 5.030$，标准误 $1/\sqrt{3525}\approx 0.0168$。

2.3　$\mathbb{E}(c\bar X)=c\mu$，$\mathrm{MSE}=c^2\frac{\sigma^2}{n}+(1-c)^2\mu^2$。比 $\bar X$ 好当且仅当 $(1-c)^2\mu^2<(1-c^2)\frac{\sigma^2}{n}$，即 $\mu^2<\frac{1+c}{1-c}\cdot\frac{\sigma^2}{n}$。条件涉及未知的 μ，无法事先保证；μ 接近 0（或 n 很小）时收缩估计更好，反之更差。

2.4　$\bar X=8.2/5=1.64$，$T_1=3.28$——小于已观测到的 3.6，与数据矛盾。$T_2=3.6$，$T_3=\frac{6}{5}\times 3.6=4.32$，$T_4=\frac{7}{6}\times 3.6=4.2$。

2.5　$\mathrm{MSE}(S^2)=\operatorname{Var}S^2=\frac{2\sigma^4}{n-1}$。$V_n=\frac{n-1}{n}S^2$：方差 $\frac{(n-1)^2}{n^2}\cdot\frac{2\sigma^4}{n-1}$，偏差 $-\frac{\sigma^2}{n}$，$\mathrm{MSE}=\frac{2(n-1)+1}{n^2}\sigma^4=\frac{(2n-1)\sigma^4}{n^2}$。$\frac{2n-1}{n^2}<\frac{2}{n-1}\iff(2n-1)(n-1)<2n^2\iff 1<3n$，恒成立。

2.6　(1) $K(K-1)$ 是样本中有序的不同成功对数，每个有序位置对都是成功对的概率为 $\frac{M(M-1)}{N(N-1)}$，所以 $\mathbb{E}K(K-1)=n(n-1)\frac{M(M-1)}{N(N-1)}$；又 $\mathbb{E}K=\frac{nM}{N}$。由 $M^2=M(M-1)+M$，

$$T=\frac{(N-1)K(K-1)}{Nn(n-1)}+\frac{K}{nN}$$

满足 $\mathbb{E}T=\frac{M(M-1)+M}{N^2}=p^2$。(2) $\operatorname{Var}K=np(1-p)\frac{N-n}{N-1}$（定理 1.11），故 $\mathbb{E}(K/n)^2-p^2=\frac{p(1-p)}{n}\cdot\frac{N-n}{N-1}$。偏差为 0 当且仅当 $p\in\{0,1\}$ 或 $n=N$。

2.7 正文已证无偏估计满足 $\sum T(k)\lambda^k/k!=\sum(-1)^k\lambda^k/k!$ 对所有 $\lambda\geq 0$；两个幂级数在一个区间上相等，系数必相等，故 $T(k)=(-1)^k$ 唯一。$\mathbb{E}e^{-2X}=\exp\left(\lambda(e^{-2}-1)\right)$，偏差为 $\exp\left(\lambda(e^{-2}-1)\right)-e^{-2\lambda}$。$(-1)^X$ 的均方误差为 $\operatorname{Var}(-1)^X=1-e^{-4\lambda}$（因 $\mathbb{E}(-1)^{2X}=1$），λ 小时约为 4λ；e^{-2X} 的均方误差约为 $\mathbb{P}(X=1)(1-e^{-2})^2\approx 0.75\lambda$。例如 $\lambda=0.1$ 时两者分别为 0.33 与 0.075，有偏的估计好得多。

2.8 $M\leq\theta$ 总成立，且 $\mathbb{P}(M\leq\theta-\varepsilon)=\left(\frac{\theta-\varepsilon}{\theta}\right)^n\to 0\,(0<\varepsilon<\theta)$，所以 $\mathbb{P}(|M-\theta|>\varepsilon)\to 0$。

2.9 $\mathbb{E}X^k=k!\,\theta^k$，两者都无偏。$\operatorname{Var}(X^2/2)=\frac{24\theta^4}{4}-\theta^4=5\theta^4$，故 $\operatorname{Var}A_n=5\theta^4/n$。$B_n$ 是 $m=\binom{n}{2}$ 个乘积 $H_{ij}=X_iX_j$ 的平均：$\operatorname{Var}H=(2\theta^2)^2-\theta^4=3\theta^4$；共享一个下标的两项协方差为 $\mathbb{E}X_1^2\mathbb{E}X_2\mathbb{E}X_3-\theta^4=\theta^4$，这样的无序项对有 $3\binom{n}{3}$ 个；不共享下标的独立。于是

$$\operatorname{Var}B_n=\frac{3m\theta^4+2\cdot 3\binom{n}{3}\theta^4}{m^2}=\frac{2(2n-1)}{n(n-1)}\theta^4.$$

$\operatorname{Var}B_n<\operatorname{Var}A_n\iff 2(2n-1)<5(n-1)\iff n>3$。$n=2$ 时 A_n 好，$n=3$ 相同，$n\geq 4$ 时 B_n 好。B_n 平均了很多项，但它们共享样本而彼此相关；小样本时相关性抵消了平均的好处。

2.10 (1) 记 $a_k=\mathbb{P}(N=k)$，$\mathbb{E}_pT=\sum_k a_k(1-p)^k$。令 $t=1-p\in[0,1]$，要求 $\sum a_kt^k=\frac{1}{1+p}=\frac{1}{2-t}=\sum_k\frac{t^k}{2^{k+1}}$。两个幂级数在 $[0,1]$ 上相等，系数相等（取 $t=0$ 得常数项相等，除以 t 后令 $t\downarrow 0$ 依次得到各项），所以唯一的分布是 $\mathbb{P}(N=k)=2^{-k-1}$，$\mathbb{E}N=\sum_{m\geq 1}\mathbb{P}(N\geq m)=\sum_{m\geq 1}2^{-m}=1$。(2) T 取 0,1 且无偏，$\mathrm{MSE}=g(1-g)=\frac{p}{(1+p)^2}\leq\frac{1}{4}$，在 $p=1$ 时取到。恒取 3/4 时 $\mathrm{MSE}=\left(\frac{3}{4}-\frac{1}{1+p}\right)^2$，而 $\frac{1}{1+p}\in[\frac{1}{2},1]$，最大为 $\frac{1}{16}$。不看数据的常数在最坏情况下比这个无偏估计好 4 倍——无偏性与精度是两回事。

第 3 章

3.1 $\bar{X}=32/8=4$，矩估计与 MLE 都是 $\hat{\lambda}=4$。$I(\lambda)=1/\lambda$，标准误约 $\sqrt{\hat{\lambda}/n}=\sqrt{0.5}\approx 0.71$。由不变性，“一分钟没有车”的概率的 MLE 为 $e^{-4}\approx 0.018$。

3.2 $\ell(p)=n\log p+(\sum x_i-n)\log(1-p)$，$\ell'(p)=\frac{n}{p}-\frac{\sum x_i-n}{1-p}=0$ 得 $\hat{p}=n/\sum x_i=1/\bar{X}$（$\ell$ 为凹函数；若全部 $x_i=1$，$\hat{p}=1$）。

3.3 $\bar{X}=9.2/6\approx 1.533$，$\hat{\lambda}=1/\bar{X}\approx 0.652$；中位数的 MLE 为 $\log 2\cdot\bar{X}\approx 1.063$ 千小时；标准误约 $\hat{\lambda}/\sqrt{6}\approx 0.266$。

3.4　$\hat{\mu}=4.7$，离差平方和 2.06，$\widehat{\sigma^2}=2.06/5=0.412$，$s^2=2.06/4=0.515$。

3.5　$L(a,b)=(b-a)^{-n}$ 当 $a\le\min x_i$ 且 $b\ge\max x_i$，否则为 0。要使 $b-a$ 最小，取 $\hat{a}=\min X_i$，$\hat{b}=\max X_i$。矩估计 $\bar{X}\pm\sqrt{3V}$ 可能给出 $\hat{a}>\min x_i$ 或 $\hat{b}<\max x_i$，与数据矛盾；MLE 不会。

3.6　$\log f=x\log\lambda-\lambda-\log x!$，$-\partial_\lambda^2\log f=x/\lambda^2$，$I(\lambda)=1/\lambda$。下界 $\frac{1}{nI}=\frac{\lambda}{n}=\operatorname{Var}\bar{X}$，$\bar{X}$ 达到下界。

3.7　$\ell(\theta)=-\sum|x_i-\theta|+$ 常数 是凹的分段线性函数。在不等于任何 x_i 的 θ 处，斜率为 $\#\{x_i>\theta\}-\#\{x_i<\theta\}$。$n=2k+1$ 时，斜率在 $x_{(k+1)}$ 左侧为正、右侧为负，唯一最大点是中位数；$n=2k$ 时，斜率在 $(x_{(k)},x_{(k+1)})$ 上为 0，整段都是最大点。

3.8　截尾记录：$\ell=\delta\log\lambda-\lambda\min(X,c)$，$-\ell''=\delta/\lambda^2$，$I_1=\frac{1-e^{-\lambda c}}{\lambda^2}$。超过与否：$B_1\sim\text{Bernoulli}(q)$，$q=e^{-\lambda c}$，伯努利信息为 $\frac{1}{q(1-q)}$，乘以 $(\,\mathrm{d}q/\,\mathrm{d}\lambda)^2=c^2q^2$，得 $I_2=\frac{c^2e^{-\lambda c}}{1-e^{-\lambda c}}$。令 $u=\lambda c>0$，$I_1\ge I_2\iff(1-e^{-u})^2\ge u^2e^{-u}\iff e^{u/2}-e^{-u/2}\ge u$，即 $2\sinh(u/2)\ge u$，恒成立。

3.9　$\mathbb{P}(\min(X,Y)>s,\,X<Y)=\int_s^\infty\lambda e^{-\lambda x}e^{-\nu x}\,\mathrm{d}x=\frac{\lambda}{\lambda+\nu}e^{-(\lambda+\nu)s}$，乘积形式说明 $\min\sim\text{Exp}(\lambda+\nu)$、$\mathbf{1}\{X<Y\}\sim\text{Bernoulli}\left(\frac{\lambda}{\lambda+\nu}\right)$ 且两者独立。$K\sim\text{Bin}\left(n,\frac{\lambda}{\lambda+\nu}\right)$ 与 $T\sim\text{Gamma}(n,\lambda+\nu)$ 独立，似然正比于

$$\left(\frac{\lambda}{\lambda+\nu}\right)^k\left(\frac{\nu}{\lambda+\nu}\right)^{n-k}(\lambda+\nu)^ne^{-(\lambda+\nu)t}=\lambda^k\nu^{n-k}e^{-(\lambda+\nu)t}.$$

它对 λ,ν 分离。$0<k<n$ 时 $\hat{\lambda}=k/t$，$\hat{\nu}=(n-k)/t$。$k=0$ 时似然随 λ 严格递减，在 $\lambda>0$ 内取不到最大值，MLE 不存在；$k=n$ 同理。

3.10　(1) 第二大值 s 与最大值 $s+d$ 的联合密度为 $n(n-1)s^{n-2}/\theta^n$（选出这两个观测的编号，其余 $n-2$ 个都小于 s）。对 $0<s<\theta-d$ 积分得 $f(d)=n(\theta-d)^{n-1}/\theta^n$。(2) 令 $u=d/\theta\in(0,1)$，$f=\frac{n}{d}u(1-u)^{n-1}$，在 $u=1/n$ 处唯一最大，故 $\hat{\theta}=nD_n$。$\mathbb{P}(D_n>d)=(1-d/\theta)^n$，$\mathbb{E}D_n=\int_0^\theta(1-d/\theta)^n\,\mathrm{d}d=\frac{\theta}{n+1}$，唯一的无偏比例估计为 $(n+1)D_n$。(3) $\mathbb{P}(nD_n/\theta>a)=(1-a/n)^n\to e^{-a}$，即 $nD_n/\theta\xrightarrow{\mathrm{d}}\text{Exp}(1)$，不收敛到 1；两个估计都不相合。一个“间距”只携带一个观测量级的信息，样本再多也不变。

第 4 章

4.1　$52.3\pm2.131\times4.8/4=52.3\pm2.56$，即 $[49.74,\,54.86]$。区间包含 50，在 5% 水平上不能拒绝 $\mu=50$。

4.2 $\mathbb{P}(T\ge 15)=\dfrac{\binom{20}{15}+\binom{20}{16}+\cdots+\binom{20}{20}}{2^{20}}=\dfrac{15504+4845+1140+190+20+1}{1048576}=\dfrac{21700}{1048576}\approx 0.0207$。

4.3 (1) 错：μ 是固定的，95% 指方法的覆盖率。(2) 错：p 值是在 H_0 为真的前提下计算的。(3) 错：可能只是功效不足。(4) 基本正确：区间长度与 $1/\sqrt{n}$ 成正比（t 区间的长度是随机的，但其期望随 n 增大而减小）。

4.4 $n\ge(1.96\times 10/2)^2=96.04$，至少 97；半宽 1 时 $n\ge 384.2$，至少 385——精度提高一倍，样本量约 4 倍。

4.5 拒绝域 $\{\sqrt{n}\bar{X}/\sigma>z_{1-\alpha}\}$，功效 $1-\Phi(z_{1-\alpha}-\sqrt{n}\delta/\sigma)\ge 1-\beta\iff z_{1-\alpha}-\sqrt{n}\delta/\sigma\le -z_{1-\beta}$，即 $n\ge\left((z_{1-\alpha}+z_{1-\beta})\sigma/\delta\right)^2$。$\delta=0.5\sigma$：$(2.487/0.5)^2=24.7$，取 25。

4.6 $\mathbb{P}(P\le u)=\mathbb{P}(F(T)\ge 1-u)=\mathbb{P}(T\ge F^{-1}(1-u))=1-F(F^{-1}(1-u))=u$（用到 F 连续严格递增）。

4.7 $(n-1)s^2=9\times 1.513=13.62$。$\sigma^2$ 的区间 $[13.62/19.023,\ 13.62/2.700]=[0.716,\ 5.04]$，$\sigma$ 的区间 $[0.846,\ 2.25]$。注意区间不对称，且很宽：10 个观测估计方差很不精确。

4.8 他在 $Z>z_{0.95}$ 或 $Z<-z_{0.95}$ 时拒绝，即 $|Z|>1.645$，第一类错误为 0.10。这正是水平 10% 的双侧检验，而不是 5%。

4.9 (1) 对 $0<t<1$，$\mathbb{P}(P_1P_2\le t)=\int_0^1\mathbb{P}(P_2\le t/x)\,\mathrm{d}x=\int_0^t 1\,\mathrm{d}x+\int_t^1\frac{t}{x}\,\mathrm{d}x=t(1-\log t)$。此函数连续严格递增，故 $Q(1-\log Q)\sim\mathrm{U}(0,1)$ 是合法 p 值（这就是 Fisher 合并法的两检验情形；用到了独立与均匀）。

(2) 若 $P_1>u/2$ 且 $P_2>u/2$，则 $2\sqrt{P_1P_2}>u$。所以 $\{2\sqrt{P_1P_2}\le u\}\subseteq\{P_1\le u/2\}\cup\{P_2\le u/2\}$，概率 $\le u/2+u/2=u$，无需独立。常数不能减小：任取 $0<s<1$，令 $U\sim\mathrm{U}(0,1)$，$P_1=U$；$U<s$ 时 $P_2=s-U$，否则 $P_2=U$。两者都均匀。$U<s$ 时 $\sqrt{P_1P_2}=\sqrt{U(s-U)}\le s/2$，所以 $\mathbb{P}(\sqrt{P_1P_2}\le s/2)\ge s$。若常数 $c<2$，取 $u=cs/2<s$，则 $\mathbb{P}(c\sqrt{P_1P_2}\le u)\ge s>u$，违反合法性。

4.10 (1) 设 $A=(0,1)^2$。$\theta>1$ 时 (X_1,X_2) 在 $(0,\theta)^2$ 上均匀，对任一拒绝域 C，$\mathbb{P}_\theta(C\cap A)=\theta^{-2}\mathbb{P}_1(C)\le\theta^{-2}\alpha$，而 $\mathbb{P}_\theta(A^c)=1-\theta^{-2}$，所以 $\mathbb{P}_\theta(C)\le 1-\frac{1-\alpha}{\theta^2}$。(2) 取 $b=\sqrt{1-\alpha}$，$C=\{\max(X_1,X_2)>b\}$。$\theta\le b$ 时拒绝概率为 0；$b<\theta\le 1$ 时为 $1-b^2/\theta^2\le\alpha$，水平为 α；$\theta>1$ 时为 $1-b^2/\theta^2=1-(1-\alpha)/\theta^2$，达到上界。

第 5 章

5.1　(1) 配对（同一学生前后）。(2) 独立两样本。(3) 配对（双胞胎配对）。(4) 独立两样本。

5.2　差 2.6。Welch：标准误 $\sqrt{3.2^2/12+5.9^2/15}=1.782$，区间 $2.6\pm 2.072\times 1.782=[-1.09,\ 6.29]$。合并：$s_p=\sqrt{(11\times 10.24+14\times 34.81)/25}=4.899$，标准误 $4.899\sqrt{1/12+1/15}=1.897$，区间 $[-1.31,\ 6.51]$。两者差别不大，因为两组样本量相近；这里方差大的恰是较大的一组，合并方差高估了标准误，区间偏宽（若反过来，就会偏窄）。

5.3　$\hat p_1=0.30$，$\hat p_2=0.20$，合并 $\hat p=0.25$，$Z=\dfrac{0.10}{\sqrt{0.25\times 0.75\times 2/150}}=2.00$，双侧 p 值 0.046。区间：$0.10\pm 1.96\sqrt{0.3\times 0.7/150+0.2\times 0.8/150}=0.10\pm 0.097$，即 $[0.003,\ 0.197]$。

5.4　全部 8 个数之和为 92，$\bar X-\bar Y=(2S-92)/4$，S 为“处理组”4 个数之和，观测 $S=51$。和 ≥ 51 的 4 元子集有

$$\{15,14,13,12\},\ \{15,14,13,11\},\ \{15,14,13,10\},\ \{15,14,13,9\},$$
$$\{15,14,12,11\},\ \{15,14,12,10\},\ \{15,13,12,11\},$$

共 7 个，单侧 p 值 $7/70=0.10$。

5.5　$\mathrm{Var}(B-A)=\sigma_A^2+\sigma_B^2-2\rho\sigma_A\sigma_B$，$\rho<0$ 时大于独立分析时的 $\sigma_A^2+\sigma_B^2$，配对反而更差。例如同一盆中的两株植物争夺有限的养分，一株长得好另一株就差；或同一个人在固定时间内分配给两项任务的产出。

5.6　记 $u=S_X^2/m$，$v=S_Y^2/n$。上界：由柯西–施瓦茨，$(u+v)^2=\left(\frac{u}{\sqrt{m-1}}\sqrt{m-1}+\frac{v}{\sqrt{n-1}}\sqrt{n-1}\right)^2\le\left(\frac{u^2}{m-1}+\frac{v^2}{n-1}\right)(m+n-2)$。下界：设 $m\le n$，$\frac{u^2}{m-1}+\frac{v^2}{n-1}\le\frac{u^2+v^2}{m-1}\le\frac{(u+v)^2}{m-1}$，故 $\hat\nu\ge m-1$。

5.7　$m=n$ 时 $S_p^2=\frac{S_X^2+S_Y^2}{2}$，$S_p^2\cdot\frac{2}{n}=\frac{S_X^2+S_Y^2}{n}$，两个统计量的分母相同。区别只在自由度：合并检验用 $2n-2$，Welch 用 $\hat\nu\le 2n-2$，后者临界值略大、略保守。

5.8　舍去 0 后 9 个差值全为正。符号检验：$\mathbb{P}(\text{全正})=2^{-9}$，双侧 p 值 $2^{-8}\approx 0.0039$。Wilcoxon：秩和取最大值 45，只有全正这一种组合，双侧 p 值同样为 $2/512\approx 0.0039$。

5.9　记 $\nu=n-1$，$Z_j=\sqrt{n}(\bar X_j-\mu_0)/\sigma$，$U_j=\nu S_j^2/\sigma^2$。由定理 4.3，$(Z_1,Z_2)$ 与 (U_1,U_2) 独立，$Z_j\sim\mathcal{N}(0,1)$，$U_j\sim\chi^2_\nu$。选择 J 只依赖 (U_1,U_2)，所以给定 (U_1,U_2) 后 Z_J 仍为标准正态。记 $c=t_{\nu,1-\alpha/2}$，条件拒绝概率为 $h(U_J)=2\Phi(-c\sqrt{U_J/\nu})$，$h$ 严格递减。对

固定的第一批，$\mathbb{E}h(U_1)=\alpha$；而 $\min(U_1,U_2)\le U_1\le\max(U_1,U_2)$ 且两边严格不等号都以正概率成立，故 $\mathbb{E}h(\min)>\alpha>\mathbb{E}h(\max)$。选标准差小的一批，等于挑了一个“看起来更精确”的样本，假阳性增多。

5.10 (1) 每人的平均 $\bar Y_j$ 的方差为 $\tau^2+\sigma^2/k$，人与人独立，$\operatorname{Var}\hat\mu=\frac{\tau^2+\sigma^2/k}{[B/(c+k)]}$，故极限 $F(k)=(c+k)(\tau^2+\sigma^2/k)=c\tau^2+\sigma^2+\tau^2k+\frac{c\sigma^2}{k}$。(2) $F(k+1)-F(k)=\tau^2-\frac{c\sigma^2}{k(k+1)}$ 随 k 递增。记 $R=c\sigma^2/\tau^2$，k 最优当且仅当 $k(k-1)\le R\le k(k+1)$；$R=j(j+1)$ 时 j 与 $j+1$ 并列。直观上：招募越贵（c 大）、测量误差越大（σ^2 大）、个体差异越小（τ^2 小），越应该对每个人多测几次；连续实变量近似下最优 $k\approx\sqrt{R}$。

第 6 章

6.1 $\bar x=3$，$\bar y=4.2$，$S_{xx}=10$，$S_{xy}=8$，$S_{yy}=8.8$。$\hat b=0.8$，$\hat a=1.8$。残差 $-0.6,\ 0.6,\ 0.8,\ -1.0,\ 0.2$，$\mathrm{SSE}=2.4$，$s^2=0.8$，$R^2=1-2.4/8.8=0.727$。斜率标准误 $\sqrt{0.8/10}=0.283$，区间 $0.8\pm3.182\times0.283=[-0.10,\ 1.70]$，含 0，不能断言斜率非零。只有 5 个点、3 个自由度，t 临界值很大。

6.2 $R^2=0.995$：对数气压的变异有 99.5% 可由沸点的直线关系解释。$s=0.379$：在给定沸点下，观测值围绕直线的典型偏差约为 0.38 个单位。R^2 只衡量线性拟合的相对程度，不能发现弯曲（原始气压的拟合 R^2 也有 0.994）、离群点或方差不等，这些要靠残差图。

6.3 (i) $S_{xx}=\sum(x-4.5)^2=82.5$；(ii) $S_{xx}=10\times25=250$。设计 (ii) 的方差约为 (i) 的 1/3。隐患：只在两个 x 值测量，完全无法检查关系是不是直线。

6.4 $\bar x=4$, $t=(-3,-2,-1,0,6)$, $S_{xx}=50$。$h_{ii}=0.2+t_i^2/50$: 0.38, 0.28, 0.22, 0.20, 0.92, 和为 2。$x=10$ 的点几乎独自决定斜率。

6.5 $\sum h_{ii}=1+\sum t_i^2/S_{xx}=2$；显然 $h_{ii}\ge1/n$。$h_{ii}\le1\iff t_i^2\le\frac{n-1}{n}S_{xx}$。由 $\sum_j t_j=0$，$t_i=-\sum_{j\ne i}t_j$，柯西–施瓦茨给出 $t_i^2\le(n-1)\sum_{j\ne i}t_j^2=(n-1)(S_{xx}-t_i^2)$，即 $nt_i^2\le(n-1)S_{xx}$。等号当且仅当所有 t_j（$j\ne i$）相等，即其余各点的 x 全部相同。此时直线必须经过第 i 个点（$h_{ii}=1$ 意味着 $\operatorname{Var}e_i=0$，$e_i\equiv0$），该点完全决定斜率。

6.6 $R^2=\frac{\hat b^2S_{xx}}{S_{yy}}=\frac{S_{xy}^2}{S_{xx}S_{yy}}=r^2$。两条回归线的斜率分别为 S_{xy}/S_{xx} 与 S_{xy}/S_{yy}，乘积为 $r^2\le1$；所以除非所有点共线，两条直线不重合。

6.7 $\bar x=\frac{n}{m+n}$，t_i 在第一组为 $-\frac{n}{m+n}$，在第二组为 $\frac{m}{m+n}$，$S_{xx}=\frac{mn}{m+n}$。$S_{xy}=\sum t_iy_i=\frac{mn}{m+n}(\bar Y-\bar X)$，故 $\hat b=\bar Y-\bar X$，$\hat a=\bar X$。拟合值就是各组均值，$\mathrm{SSE}=(m-1)S_X^2+(n-1)S_Y^2$，

$s^2 = S_p^2$。$\hat b/(s/\sqrt{S_{xx}}) = \dfrac{\bar Y - \bar X}{S_p\sqrt{1/m+1/n}}$，正是合并方差 t 统计量。

6.8　两个新观测的平均为 $a + bx_0 + \bar\varepsilon_0$，$\operatorname{Var}\bar\varepsilon_0 = \sigma^2/2$，区间为

$$\hat y_0 \pm t_{n-2,1-\alpha/2}\, s\sqrt{\frac{1}{2} + \frac{1}{n} + \frac{(x_0-\bar x)^2}{S_{xx}}},$$

比单个观测的预测区间窄，但永远宽于平均响应的置信区间。

6.9　原斜率为 $(-4y_1 - y_2 + 5y_3)/14$。取 $y_1 = u$、$y_2 = v$、$y_3 = \frac{4u+v}{5}$，原斜率为零，题设要求 $5g(\frac{4u+v}{5}) = 4g(u) + g(v)$。令 $h = g - g(0)$，则 $h(0) = 0$ 且满足同一方程。取 $u = 0$ 得 $h(v/5) = h(v)/5$，代回得 $h(4u+v) = 4h(u) + h(v)$；取 $v = 0$ 得 $h(4u) = 4h(u)$，于是 $h(A+v) = h(A) + h(v)$ 对一切实数成立。由加法性与连续性，$h(x) = cx$。$c = 0$ 时变换后斜率恒为零，违反“仅当”；$c \neq 0$ 时变换后斜率是原斜率的 c 倍，满足要求。答案：$g(x) = d + cx$，$c \neq 0$。保持“斜率是否为零”的连续变换只有非退化的仿射变换。

6.10　(1) $z_{\Pi(i)}$ 的均值为 0，方差为 S_{yy}/n；$i \neq j$ 时 $\mathbb{E}z_{\Pi(i)}z_{\Pi(j)} = \dfrac{\sum_{r\neq s} z_r z_s}{n(n-1)} = -\dfrac{S_{yy}}{n(n-1)}$。又 $\sum_{i\neq j} t_i t_j = -S_{xx}$，

$$\mathbb{E}B_\Pi = 0, \qquad \operatorname{Var} B_\Pi = \frac{1}{S_{xx}^2}\Big(\frac{S_{yy}}{n}S_{xx} + \frac{S_{yy}}{n(n-1)}S_{xx}\Big) = \frac{S_{yy}}{(n-1)S_{xx}}.$$

(2) 若 x 是随机分配给各单位的（或原假设下 y 可交换），“x 与 y 无关”意味着所有排列等可能，于是可以把观测斜率与 $n!$ 个排列斜率比较，得到精确 p 值，不需要正态假设。注意 $\hat b/\sqrt{\operatorname{Var} B_\Pi} = r\sqrt{n-1}$，而 t 统计量为 $r\sqrt{n-2}/\sqrt{1-r^2}$，r 小时两者相近；样本较大时两种检验结论通常一致。

附录 B

分位数表与内容对照

表中 $\nu = \infty$ 一行即标准正态分布的分位数 z_q。常用：双侧 90%、95%、99% 区间分别用 1.645、1.960、2.576；单侧 5% 检验用 1.645。

B.1 t 分布的分位数 $t_{\nu,q}$

ν	$q=0.90$	0.95	0.975	0.99	0.995
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
12	1.356	1.782	2.179	2.681	3.055
15	1.341	1.753	2.131	2.602	2.947
20	1.325	1.725	2.086	2.528	2.845
25	1.316	1.708	2.060	2.485	2.787
30	1.310	1.697	2.042	2.457	2.750
40	1.303	1.684	2.021	2.423	2.704
60	1.296	1.671	2.000	2.390	2.660
120	1.289	1.658	1.980	2.358	2.617
∞	1.282	1.645	1.960	2.326	2.576

B.2 卡方分布的分位数 $\chi^2_{\nu,q}$

ν	$q=0.025$	0.05	0.95	0.975
1	0.001	0.004	3.841	5.024
2	0.051	0.103	5.991	7.378
3	0.216	0.352	7.815	9.348
4	0.484	0.711	9.488	11.143
5	0.831	1.145	11.070	12.833
6	1.237	1.635	12.592	14.449
7	1.690	2.167	14.067	16.013
8	2.180	2.733	15.507	17.535
9	2.700	3.325	16.919	19.023
10	3.247	3.940	18.307	20.483
15	6.262	7.261	24.996	27.488
20	9.591	10.851	31.410	34.170
30	16.791	18.493	43.773	46.979

B.3　原讲义内容的去向

原讲义	本讲义
1.1–1.3 样本、统计量、抽样分布、样本方差	第 1 章 1.1–1.4，补充睡眠数据与图
1.4 简单随机抽样与分层抽样	1.5–1.6（协方差已在第 0 章讲过），新增 Neyman 分配；例 1.1、1.2 移入 ★ 深入讨论
1.5 只保存部分数据	1.7 ★ 深入讨论（精简）
2.1–2.3 矩估计、可识别性、似然	第 3 章 3.1–3.4
2.4、2.6 偏差、MSE、相合性	第 2 章，新增均匀分布估计量的完整比较与图
2.5 不完整记录与随机停止	3.6 ★ 截尾数据、记录方式与 Fisher 信息
2.6 渐近正态、Delta 方法	第 0 章 0.6–0.7 先讲工具，第 3 章新增 Fisher 信息与 Cramér–Rao 下界
2.7、第 3 章无偏构造与估计量比较	第 2 章 2.4–2.5，2.7 ★（对称化、Rao–Blackwell 思想）
第 4 章检验的概率逻辑	第 4 章，新增置信区间的覆盖、t 分布推导、Wilson 区间、功效与样本量、p 值误读；随机化检验移入 ★
第 5 章合法对称性与精确检验	第 5 章 5.6 置换检验与符号翻转（以睡眠数据为例），其余（游程等）从略
第 6 章单样本与双样本	第 4 章 4.2、第 5 章；新增 **Welch 检验**、模拟比较、比例比较案例、QQ 图与敏感性分析
第 7 章一元线性回归	第 6 章；新增几何图示、置信带与预测带、残差图、杠杆点图、Forbes 完整案例、辛普森悖论
53 道章末习题与各节例题	选取 13 道作为 C 级挑战题，另新编 A、B 级习题，全部附解答