新领军计划

数理统计

自学讲义

抽样　估计　检验　回归

学生讲义

目录

第一章抽样、数据与信息 **3**

1.1 样本、参数与统计量 3
1.2 数据的均值、方差与次序 5
1.3 抽样分布、标准误与样本方差 6
1.4 简单随机抽样与分层抽样 9
1.5 只保存部分数据时能确定什么 14
1.6 习题 17

第二章参数估计 **19**

2.1 总体矩、样本矩与矩估计 19
2.2 模型可识别性与观测信息 20
2.3 似然函数与极大似然估计 22
2.4 偏差、方差与均方误差 24
2.5 观测范围、不完整记录与随机停止 26
2.6 相合性与大样本误差 30
2.7 无偏估计与样本长度 33

第三章无偏构造与估计量比较 **35**

3.1 从参数的平方谈起 35
3.2 利用总体分布的特殊性质 37
3.3 对称化与条件平均 39
3.4 均方误差与最坏情况 41

第四章假设检验的概率逻辑 **45**

4.1 假设检验：先确定要控制哪一种错误 45
4.2 根据数据选方向，必须重新计算拒绝概率 46
4.3 复合假设与不同参数下的样本范围 47
4.4 用尾概率表示证据：p 值 49
4.5 离散检验为何有时需要随机化 51
4.6 条件检验与置信界的反演 53

第五章合法对称性与精确检验 **56**

5.1 什么样的重新排列可以用来计算概率 56
5.2 独立对称差值与符号秩 57
5.3 可交换配对与重复观测 58
5.4 均匀随机分组与标签置换 59
5.5 分组条件、事后选择与游程 61

第六章单样本与双样本 **64**

6.1 从样本均值到精确的 t 分布 64

6.2 配对观测：先求差，再做推断 66

6.3 两个独立正态样本：为什么合并方差有条件 68

6.4 两组比例：先找出真正的随机量 69

6.5 两组标签丢失以后 70

第七章一元线性回归 **73**

7.1 最小二乘直线、拟合值与残差 73

7.2 加入一个新观测 74

7.3 随机误差、回归参数与估计精度 76

7.4 正态误差下的精确推断 79

7.5 真实均值不是直线时 80

7.6 杠杆量与删点后重新拟合 81

7.7 两组数据合并后的线性趋势 82

第一章　抽样、数据与信息

1.1　样本、参数与统计量

一枚硬币正面朝上的概率为 p, 但我们不知道 p 的值. 假定各次抛掷相互独立, 连续抛掷 n 次, 用 X_i 表示第 i 次的结果: 正面记为 1, 反面记为 0. 则

$$\mathbb{P}(X_i = 1) = p, \qquad \mathbb{P}(X_i = 0) = 1 - p.$$

给定 p 以后, 每次结果的分布以及 n 次结果的联合分布就都确定了. 现在的问题反过来: 观察了这 n 次结果以后, 怎样估计原先不知道的 p?

定义 1.1　统计模型与参数.　用来描述总体分布的未知常数称为**参数**, 通常记为 θ. 参数可以是一个数, 也可以是一组数. 它的全部允许取值组成的集合 Θ 称为**参数空间**. 当 θ 遍历 Θ 时, 得到的一族可能的观测分布称为**统计模型**.

在上述抛币问题中, 参数为 p, 参数空间为 $[0,1]$. 若观测来自均值和方差都未知的正态分布, 则参数可以写成

$$\theta = (\mu, \sigma^2), \qquad \Theta = \{(\mu, \sigma^2) : \mu \in \mathbb{R},\ \sigma^2 > 0\}.$$

例如 $(0,1)$ 和 $(2,1)$ 分别对应 $N(0,1)$ 和 $N(2,1)$. 在本书的模型中, 真实参数是固定的; 随机的是抽样所得的结果.

计算概率和期望时, 有时需要注明使用哪个参数. 我们用 $\mathbb{P}_\theta, \mathbb{E}_\theta, \mathsf{Var}_\theta$ 分别表示参数为 θ 时的概率、期望和方差. 例如

$$\mathbb{P}_{p=1/3}(X_i = 1) = \frac{1}{3}, \qquad \mathbb{P}_{p=2/3}(X_i = 1) = \frac{2}{3}, \qquad \mathbb{E}_p X_i = p.$$

若上下文已经给定分布, 就省略这些下标.

定义 1.2　随机样本与样本观测值.　设 $n \geq 1$. 若 $X_1, \ldots, X_n$ 相互独立, 且都服从同一个总体分布, 则称它们为来自该总体的容量为 n 的**随机样本**. 这里 n 也称为**样本量**. 一次抽样实际得到的数 $x_1, \ldots, x_n$ 称为**样本观测值**.

例如, 四次独立抛币的随机样本是 (X_1, X_2, X_3, X_4). 一次实际结果可能为 $(1,0,1,0)$, 另一次可能为 $(1,1,1,0)$. 大写字母表示随机变量, 小写字母表示某一次已经得到的数值.

本书也会研究不放回抽样. 这时取到的数通常不独立. 例如, 从数值为 0 和 1 的两个单位中依次不放回抽取, 一旦第一个数是 0, 第二个数就必为 1. 后面遇到这类抽样时, 按题目给出的抽样方式计算概率.

定义 1.3　统计量.　设观测数据组成随机向量 $X = (X_1, \ldots, X_n)$. 若 $T = t(X)$ 是随机变量或随机向量, 且函数 t 已知、不含未知参数, 则称 T 为**统计量**. 统计量可以是一个数, 也可以由几个分量组成.

例如, 样本均值和样本最大值

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad H = \max_{1 \leq i \leq n} X_i$$

都是统计量. 给定一组数据, 这两个量就能算出. 若 μ 未知, $\bar{X}-\mu$ 则不是统计量, 因为除了样本之外还需要知道 μ. 若 μ_0 是已知常数, $\bar{X}-\mu_0$ 就是统计量.

还可以数一数样本中有多少个数大于 1. 用 $\mathbf{1}_{\{X_i>1\}}$ 表示事件 $X_i>1$ 的指示变量, 即事件发生时取 1, 否则取 0, 则这个统计量为

$$T=\sum_{i=1}^{n}\mathbf{1}_{\{X_i>1\}}.$$

对于数据 $(2,0,3,1)$, 它的值为 2.

统计量的公式已知, 它的分布却可能随参数而变. 例如四次独立抛币的正面总数 $K=X_1+\cdots+X_4$ 总是按同一个加法公式计算. 当 $0<p<1$ 时, 它的分布为

$$\mathbb{P}_p(K=k)=\binom{4}{k}p^k(1-p)^{4-k},\qquad k=0,1,2,3,4.$$

改变 p, 这些概率也会改变. 当 $p=0$ 时 K 恒为 0, 当 $p=1$ 时 K 恒为 4.

定义 1.4 估计量与估计值. 设要估计的量为 $g(\theta)$, 其中 g 是已知函数. 用统计量 $T=t(X)$ 估计 $g(\theta)$ 时, 称 T 为它的**估计量**. 把一次观测值 x 代入后得到的 $t(x)$, 称为这一次的**估计值**.

例如, 可以用四次抛币中正面出现的比例

$$T=\frac{X_1+X_2+X_3+X_4}{4}$$

估计 p. 对数据 $(1,0,1,0)$, 估计值为 $1/2$; 对数据 $(1,1,1,0)$, 估计值为 $3/4$. 两次使用的是同一个估计量, 算出的估计值不同.

我们也会估计参数的函数. 例如总体均值为 μ 时, 待估计的量可以是 μ^2; 正态模型中的待估计量可以是方差 σ^2. 定义中的 $g(\theta)$ 包含了这些情形.

定义 1.5 无偏估计. 若估计量 T 对每个 $\theta\in\Theta$ 都满足

$$\mathbb{E}_\theta|T|<\infty,\qquad \mathbb{E}_\theta T=g(\theta),$$

则称 T 为 $g(\theta)$ 的**无偏估计量**.

这里求的是估计量在抽样分布下的期望. 每次抽样的估计值可以大于或小于真实值; 无偏性要求按各种抽样结果的概率取平均后, 恰好等于待估计的量.

以上述抛币问题为例, 因为 $0\le T\le 1$, 它的期望存在. 对每个 $p\in[0,1]$, 期望的线性性给出

$$\mathbb{E}_pT=\frac{1}{4}\sum_{i=1}^{4}\mathbb{E}_pX_i=p.$$

因此 T 是 p 的无偏估计量. 常数 $1/2$ 的期望则始终为 $1/2$, 只在 $p=1/2$ 时等于 p, 所以它不是这个模型中 p 的无偏估计量.

1.2 数据的均值、方差与次序

先讨论已经得到的一组实数. 这一节只计算数据本身的数量特征; 下一节再研究这些数量随抽样怎样变化.

定义 1.6 数据均值与数据方差. 对 $n \geq 1$ 个实数 $x_1, \ldots, x_n$, 定义**均值**和**数据方差**为

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad v = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

均值给出数据的平均水平, 方差用各数与均值之差的平方来描述分散程度.

例如, 数据 $1, 2, 3$ 的均值为 2, 方差为 $2/3$; 数据 $0, 2, 4$ 的均值仍为 2, 方差则为 $8/3$. 后一组的每个数离均值的距离都是前一组的两倍, 所以方差是前一组的四倍.

展开平方, 有

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - 2\bar{x}\sum_{i=1}^{n} x_i + n\bar{x}^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2.$$

因此

$$v = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2. \tag{1.1}$$

由于各平方项都非负, $v = 0$ 当且仅当 $x_1 = \cdots = x_n$.

定义 1.7 次序统计量与中位数. 将样本按数值从小到大排列, 记为

$$X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}.$$

称 $X_{(j)}$ 为第 j 个**次序统计量**. 相等的数按它们出现的次数重复列入. 对已观测的数据, 相应记为 $x_{(1)}, \ldots, x_{(n)}$.

例如原数据是 $(4, 1, 1, 7)$, 则 $x_1 = 4$, 而排序后为

$$x_{(1)} = 1, \quad x_{(2)} = 1, \quad x_{(3)} = 4, \quad x_{(4)} = 7.$$

x_1 中的下标指第一次观测; $x_{(1)}$ 中的下标指最小的观测值.

当 $n = 2m + 1$ 时, 定义**样本中位数**为 $X_{(m+1)}$; 当 $n = 2m$ 时, 定义为 $(X_{(m)} + X_{(m+1)})/2$. 即样本量为奇数时取中间一个数, 为偶数时取中间两个数的平均.

若把数据改成 $y_i = a + bx_i$, 其中 $b \neq 0$, 则 $\bar{y} = a + b\bar{x}$. 又由

$$y_i - \bar{y} = b(x_i - \bar{x}),$$

可知新方差为 $b^2 v$. 新中位数也等于原中位数乘 b 再加 a: 当 $b > 0$ 时次序不变; 当 $b < 0$ 时次序反向, 中间一个位置仍在中间, 中间两个位置则彼此交换.

定义 1.8 四分位数与五数概括. 对 $n \geq 2$ 个数据, 记中位数为 Q_2. 四分位数采用以下约定: 若 n 为偶数, 把排序后的数据等分成前、后两半; 若 n 为奇数, 去掉正中一个数后, 再分成两半. 前一半的中位数记为 Q_1, 后一半的中位数记为 Q_3.

称 Q_1, Q_3 分别为**下四分位数**、**上四分位数**, 称 $I = Q_3 - Q_1$ 为**四分位距**. 五个数

$$(x_{(1)}, Q_1, Q_2, Q_3, x_{(n)})$$

称为数据的**五数概括**. 本章题目均沿用上述四分位数约定.

箱线图按如下方法绘制. 在数轴上以 Q_1, Q_3 为两端画出箱体, 在 Q_2 处标一条线. 从箱体向两侧画出两条须, 分别延伸至

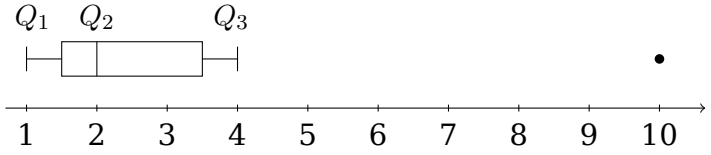
$$[Q_1 - 1.5I,\ Q_3 + 1.5I]$$

内最小和最大的观测值. 落在这个区间以外的观测值单独标出. 当 $I = 0$ 时, 箱体缩成一条线, 须和单独的观测点仍按上述规则画出.

例如, 数据 $1, 1, 2, 2, 2, 3, 4, 10$ 的两半为 $(1, 1, 2, 2)$ 和 $(2, 3, 4, 10)$, 所以

$$Q_1 = \frac{3}{2}, \qquad Q_2 = 2, \qquad Q_3 = \frac{7}{2}, \qquad I = 2.$$

上述区间为 $[-3/2, 13/2]$, 区间内最小的观测为 1, 最大的观测为 4. 因此两条须到 1 和 4 为止, 10 单独标出.



这组数据的最大值是 10, 而右侧须的端点是 4. 若把 10 改成 100, 箱体和两条须都不变, 只有单独标出的点向右移动; 均值则增加 $90/8$.

1.3 抽样分布、标准误与样本方差

定义 1.9 抽样分布. 固定总体参数和抽样方法后, 一个统计量的概率分布称为它的**抽样分布**.

例如, 独立抛掷一枚正面概率为 $1/2$ 的硬币 4 次, 用 $\bar{X}$ 表示正面出现的比例. 总共 16 种等可能结果, 按正面个数分组后得到

$\bar{X}$	0	1/4	1/2	3/4	1
概率	1/16	4/16	6/16	4/16	1/16

表中每个概率描述的是一次包含 4 次抛掷的整组试验. 例如正面比例等于 $1/2$, 就是 4 次中恰有 2 次正面, 这样的结果有 $\binom{4}{2} = 6$ 种.

对一般的 n 和 $0 < p < 1$, 正面总数 $K = n\bar{X}$ 服从二项分布, 因而

$$\mathbb{P}_p\left(\bar{X} = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0, 1, \ldots, n.$$

当 $p = 0$ 或 1 时, $\bar{X}$ 分别恒为 0 或 1. 抽样分布中的参数 p 保持固定, 改变的是整组试验可能得到的结果.

定义 1.10 标准误. 设统计量 T 满足 $\mathbb{E}_\theta T^2 < \infty$. 它的标准差称为**标准误**, 记为

$$\mathrm{SE}_\theta(T) = \sqrt{\mathrm{Var}_\theta(T)}.$$

标准误描述 T 在重复抽样中的波动大小. 它衡量的是 T 围绕自身期望的波动, 所以即使 T 用来估计某个参数, 标准误也不等于某一次估计值与参数之差.

命题 1.1 独立样本均值. 设 $X_1, \dots, X_n$ 相互独立且同分布, 均值为 μ, 方差为 $\sigma^2 < \infty$. 则

$$\mathbb{E}\bar{X} = \mu, \qquad \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}, \qquad \mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

证明. 由期望的线性性,

$$\mathbb{E}\bar{X} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}X_i = \mu.$$

各个 X_i 都有有限二阶矩. 对 $i \neq j$, 独立性给出

$$\mathbb{E}[(X_i - \mu)(X_j - \mu)] = \mathbb{E}(X_i - \mu)\mathbb{E}(X_j - \mu) = 0.$$

因此平方展开后,

$$\begin{aligned}
\mathrm{Var}(\bar{X}) &= \frac{1}{n^2}\mathbb{E}\left(\sum_{i=1}^{n}(X_i - \mu)\right)^2 \\
&= \frac{1}{n^2}\left\{\sum_{i=1}^{n}\mathbb{E}(X_i - \mu)^2 + 2\sum_{1 \le i < j \le n}\mathbb{E}[(X_i - \mu)(X_j - \mu)]\right\} \\
&= \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.
\end{aligned}$$

再取平方根, 得到标准误公式.

例如每次独立测量的标准差为 2, 取 4 次测量的平均时, 标准误为 1; 取 16 次测量的平均时, 标准误为 $1/2$. 总体中单次测量的标准差仍是 2, 降低的是平均值的标准差.

实际使用 $\sigma/\sqrt{n}$ 时, 总体标准差 σ 往往未知. 为估计 σ^2, 可以从样本自身的平方离差出发. 先记

$$V_n = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

这正是上一节数据方差的公式, 只是现在把数据看作随机变量. 我们将证明, 它的期望不是 σ^2, 而是 $(n-1)\sigma^2/n$. 为此引入另一个分母.

定义 1.11 样本方差与样本标准差. 当 $n \ge 2$ 时, 定义**样本方差**和**样本标准差**为

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2, \qquad S = \sqrt{S^2}.$$

它们都是统计量. 对已观测的数据 $x_1, \dots, x_n$, 相应数值记为 s^2, s. 数据方差与样本方差满足

$$V_n = \frac{n-1}{n}S^2.$$

命题 1.2　样本方差的期望. 在命题1.1的条件下, 若 $n \geq 2$, 则

$$\mathbb{E}V_n = \frac{n-1}{n}\sigma^2, \qquad \mathbb{E}S^2 = \sigma^2.$$

所以 S^2 是总体方差 σ^2 的无偏估计量.

证明. 把每个 $X_i - \mu$ 写成

$$X_i - \mu = (X_i - \bar{X}) + (\bar{X} - \mu).$$

平方后对 i 求和. 由于 $\sum_i (X_i - \bar{X}) = 0$, 交叉项之和为零, 因而

$$\sum_{i=1}^{n}(X_i - \mu)^2 = \sum_{i=1}^{n}(X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

移项并取期望, 再用命题1.1, 得

$$\begin{aligned}\mathbb{E}\sum_{i=1}^{n}(X_i - \bar{X})^2 &= \sum_{i=1}^{n}\mathbb{E}(X_i - \mu)^2 - n\mathbb{E}(\bar{X} - \mu)^2 \\ &= n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2.\end{aligned}$$

两边分别除以 n 和 $n-1$, 就得到所需的两个期望. 这些量都非负且期望有限, 因而也满足无偏估计定义中的可积条件.

这个计算给出了分母 $n-1$ 的来源: 平方离差以样本均值为中心, 而不是以真实均值为中心; 两者的期望相差 σ^2. 证明只用了独立同分布和有限方差, 对非正态总体同样成立. 当 $n = 1$ 时, 样本方差 S^2 没有定义.

例如已取得数据 $1, 2, 3$, 则

$$\bar{x} = 2, \qquad \sum_{i=1}^{3}(x_i - \bar{x})^2 = 2, \qquad v = \frac{2}{3}, \qquad s^2 = 1.$$

其中 v 描述这三个数的分散程度; 若它们是来自某总体的独立同分布观测, s^2 则是总体方差的一个估计值, 相应估计量 S^2 是无偏的.

把总体标准差 σ 换成样本标准差 S, 可得到样本均值标准误的估计

$$\frac{S}{\sqrt{n}}.$$

在上述数据中, 算出的标准误估计值为 $1/\sqrt{3}$. 精确的标准误仍是 $\sigma/\sqrt{3}$, 因为真实的 σ 尚不知道.

S^2 的无偏性并不直接传给它的平方根. 一个具体计算是: 若 X_1, X_2 独立且都服从正面概率 $1/2$ 的伯努利分布, 则 S^2 以各 $1/2$ 的概率取 0 和 $1/2$. 于是

$$\mathbb{E}S^2 = \frac{1}{4} = \sigma^2, \qquad \mathbb{E}S = \frac{1}{2\sqrt{2}} < \frac{1}{2} = \sigma.$$

对 n 个伯努利观测, 样本均值的精确标准误为 $\sqrt{p(1-p)/n}$. 用 $\bar{X}$ 代替 p 还能得到另一个标准误估计 $\sqrt{\bar{X}(1-\bar{X})/n}$. 如果一次观测全是 0, 这个估计值就是 0. 当真实参数满足 $0 < p < 1$ 时, 发生这种结果的概率为 $(1-p)^n > 0$, 而精确标准误仍大于 0. 这个例子说明, 样本算出的标准误估计也会随抽样结果变化.

1.4 简单随机抽样与分层抽样

上一节讨论的随机样本相互独立. 从一个有限总体中不放回抽样时, 各次观测之间有依赖关系, 均值的方差也随之改变.

定义 1.12 有限总体与简单随机抽样. 一个**有限总体**由 N 个有编号的单位组成, 对应数值为 $a_1,\dots,a_N$. 不同单位的数值允许相同. 总体均值和总体方差定义为

$$\mu=\frac{1}{N}\sum_{i=1}^{N}a_i,\qquad \sigma^2=\frac{1}{N}\sum_{i=1}^{N}(a_i-\mu)^2.$$

从中不放回抽取 n 个单位, $1\le n\le N$. 若每个包含 n 个不同编号的子集都以概率 $1/\binom{N}{n}$ 被抽到, 则称这种抽样为**简单随机抽样**.

例如从编号 1、2、3、4 中简单随机抽两个, 六个可能子集为

$$\{1,2\},\ \{1,3\},\ \{1,4\},\ \{2,3\},\ \{2,4\},\ \{3,4\},$$

各有概率 $1/6$. 如果只以各 $1/2$ 的概率抽取 $\{1,2\}$ 或 $\{3,4\}$, 虽然每个单位被抽中的概率也都是 $1/2$, 却不是简单随机抽样, 因为其余四个子集不会被抽到.

记抽中编号的集合为 D, 样本均值为 $\bar X=n^{-1}\sum_{i\in D}a_i$. 固定总体后, a_i,μ,σ^2 都是常数, 随机的是 D 以及由它计算的 $\bar X$.

先看总体 $0,1,2$, 抽取两个数求平均. 有放回独立抽样时, 九个有序结果等可能, 均值在 $0,1/2,1,3/2,2$ 上的概率依次为

$$\frac{1}{9},\quad \frac{2}{9},\quad \frac{3}{9},\quad \frac{2}{9},\quad \frac{1}{9}.$$

不放回简单随机抽样时, 三个可能子集为 $\{0,1\},\{0,2\},\{1,2\}$, 均值在 $1/2,1,3/2$ 上各有概率 $1/3$. 两种均值的期望都是 1, 方差却分别为 $1/3$ 和 $1/6$.

命题 1.3 有限总体均值的抽样方差. 设 $N\ge 2$. 若有放回独立等概率抽取 $n\ge 1$ 次, 则

$$\mathbb{E}\bar X=\mu,\qquad \mathsf{Var}(\bar X)=\frac{\sigma^2}{n}.$$

若不放回简单随机抽取 n 个单位, $1\le n\le N$, 则

$$\mathbb{E}\bar X=\mu,\qquad \mathsf{Var}(\bar X)=\frac{N-n}{N-1}\frac{\sigma^2}{n}.$$

证明. 有放回独立抽样时, 每次观测的均值为 μ, 方差为 σ^2, 直接应用命题1.1即可.

不放回时, 把抽出的 n 个单位再等概率排列, 依次记其数值为 $X_1,\dots,X_n$. 每个有序的 n 元不同编号序列都有相同概率 $1/[\binom{N}{n}n!]$. 排列不会改变样本均值.

因此每个位置出现任一总体编号的概率为 $1/N$, 得到 $\mathbb{E}X_r=\mu$, $\mathsf{Var}(X_r)=\sigma^2$. 若 $n=1$, 结论至此已经成立. 若 $n\ge 2$, 对不同位置 r,s, 任一有序不同编号对出现的概率为 $1/[N(N-1)]$. 于是

$$\begin{aligned}\mathsf{Cov}(X_r,X_s)&=\frac{1}{N(N-1)}\sum_{i\ne j}(a_i-\mu)(a_j-\mu)\\&=\frac{\left(\sum_i(a_i-\mu)\right)^2-\sum_i(a_i-\mu)^2}{N(N-1)}\\&=-\frac{\sigma^2}{N-1}.\end{aligned}$$

各位置期望相同, 所以 $\mathbb{E}\bar{X}=\mu$. 方差展开为

$$\begin{aligned}\mathrm{Var}(\bar{X}) &= \frac{1}{n^2}\left\{n\sigma^2 + n(n-1)\left(-\frac{\sigma^2}{N-1}\right)\right\}\\ &= \frac{N-n}{N-1}\frac{\sigma^2}{n}.\end{aligned}$$

这里 $n(n-1)$ 是有序的不同位置对的个数.

当 $n=N$ 时, 全部总体数值都被抽到, 样本均值恒等于 μ, 公式也给出方差 0. 若总体只有一个单位, 则抽到的数恒定, 方差同样为 0.

例 1.1. 设 $N\geq 3$. 一个抽样规则从 N 个有编号的单位中抽取两个不同单位, 各二元子集被抽中的概率预先固定, 与总体数值无关. 对任意实数总体, 所抽两数的平均值都以总体均值为期望, 且其方差不超过简单随机抽样所得平均值的方差. 证明该规则必为简单随机抽样.

解. 记总体数值为 $a_1,\dots,a_N$, 抽样均值为 T. 令 I_i 表示单位 i 是否入选: 入选时 $I_i=1$, 否则 $I_i=0$. 于是

$$T=\frac{1}{2}\sum_{i=1}^{N} a_i I_i.$$

记 $\pi_i=\mathbb{P}(I_i=1)$, 以及 $q_{ij}=\mathbb{P}(I_i=I_j=1)$, 其中 $i<j$. 因为每次恰抽两个单位, q_{ij} 也是抽到子集 $\{i,j\}$ 的概率.

题设对任意实数总体都成立, 可以先让大部分数为 0. 只取 $a_i=1$, 其余为 0 时, $T=I_i/2$, 总体均值为 $1/N$. 由无偏性,

$$\frac{\pi_i}{2}=\frac{1}{N},\qquad \pi_i=\frac{2}{N}.$$

这确定了每个单位的入选概率, 还需确定各对的入选概率.

固定 $i<j$, 取 $a_i=u, a_j=v$, 其余为 0. 此时 $T=(uI_i+vI_j)/2$. 由于 $I_i^2=I_i$, 得

$$\mathbb{E}T^2=\frac{1}{4}\left(u^2\pi_i+v^2\pi_j+2uvq_{ij}\right)=\frac{u^2+v^2}{2N}+\frac{uv}{2}q_{ij}.$$

记同一总体下简单随机抽样的均值为 T_0. 两者期望都等于 $(u+v)/N$, 所以

$$\mathrm{Var}(T)-\mathrm{Var}(T_0)=\mathbb{E}T^2-\mathbb{E}T_0^2=\frac{uv}{2}\left(q_{ij}-\frac{1}{\binom{N}{2}}\right).$$

取 $u=v=1$, 题设给出 $q_{ij}\leq 1/\binom{N}{2}$; 取 $u=1, v=-1$, 则给出相反的不等式. 因而对每一对 $i<j$,

$$q_{ij}=\frac{1}{\binom{N}{2}}.$$

所有二元子集等可能, 所以该规则正是简单随机抽样.

定义 1.13 分层抽样. 将总体分成若干个互不重叠且合起来覆盖整个总体的部分, 每部分称为一**层**. 在每层内分别抽样, 称为**分层抽样**. 以下先研究各层抽样相互独立, 且层内均为简单随机抽样的情形.

设共有两层, 第 i 层有 N_i 个单位, 均值为 μ_i, 以 N_i 为分母的方差为 σ_i^2, $i=1,2$. 第一层占总体的比例为

$$p=\frac{N_1}{N_1+N_2}.$$

整个总体的均值就是按人数比例计算的加权平均:

$$\mu = p\mu_1 + (1-p)\mu_2.$$

整个总体的方差还要计入两层均值的差异.

命题 1.4　总体合并后的方差. 上述两层合并后的总体方差为

$$\sigma^2 = p\sigma_1^2 + (1-p)\sigma_2^2 + p(1-p)(\mu_1-\mu_2)^2.$$

证明. 从第一层等概率取一个数 X. 写成

$$X - \mu = (X-\mu_1) + (\mu_1 - \mu).$$

在这一层内取平方的平均时, $X-\mu_1$ 的平均为 0, 交叉项消失. 因此第一层各数相对于总均值 μ 的平均平方离差为 $\sigma_1^2 + (\mu_1-\mu)^2$. 同样, 第二层为 $\sigma_2^2 + (\mu_2-\mu)^2$.

再按人数比例平均, 得到

$$\sigma^2 = p\sigma_1^2 + (1-p)\sigma_2^2 + p(\mu_1-\mu)^2 + (1-p)(\mu_2-\mu)^2.$$

代入 $\mu_1 - \mu = (1-p)(\mu_1-\mu_2)$ 和 $\mu_2 - \mu = -p(\mu_1-\mu_2)$, 后两项之和为 $p(1-p)(\mu_1-\mu_2)^2$, 即得结论.

现在从第 i 层简单随机抽取 n_i 个单位, $1 \le n_i \le N_i$, 样本均值记为 $\bar{X}_i$. 用两层样本均值分别估计 μ_1, μ_2, 再按总体人数比例加权, 就得到 μ 的估计量.

命题 1.5　分层均值估计量的方差. 假设两层的抽样相互独立, 令

$$T = p\bar{X}_1 + (1-p)\bar{X}_2.$$

则

$$\mathbb{E}T = \mu, \qquad \mathrm{Var}(T) = p^2\,\mathrm{Var}(\bar{X}_1) + (1-p)^2\,\mathrm{Var}(\bar{X}_2).$$

当 $N_1, N_2 \ge 2$ 时, 方差具体为

$$\mathrm{Var}(T) = p^2\frac{N_1-n_1}{N_1-1}\frac{\sigma_1^2}{n_1} + (1-p)^2\frac{N_2-n_2}{N_2-1}\frac{\sigma_2^2}{n_2}.$$

证明. 由命题1.3, $\mathbb{E}\bar{X}_i = \mu_i$. 所以

$$\mathbb{E}T = p\mu_1 + (1-p)\mu_2 = \mu.$$

又由两层抽样独立,

$$\mathbb{E}[(\bar{X}_1-\mu_1)(\bar{X}_2-\mu_2)] = \mathbb{E}(\bar{X}_1-\mu_1)\mathbb{E}(\bar{X}_2-\mu_2) = 0.$$

将 $T-\mu = p(\bar{X}_1-\mu_1) + (1-p)(\bar{X}_2-\mu_2)$ 平方并取期望, 交叉项为零, 得到方差公式. 最后分别代入命题1.3给出的层内抽样方差.

若某层的全部单位均被抽到, 该层均值为常数, 对 $\mathrm{Var}(T)$ 的贡献为 0; 层内只有一个单位时也属于这种情形. 若各层改为有放回独立等概率抽样, 则 $\mathrm{Var}(\bar{X}_i) = \sigma_i^2/n_i$.

例如第一层占总体的 $3/4$, 第二层占 $1/4$, 但在两层各抽取 10 个单位. 估计总体均值应使用

$$T = \frac{3}{4}\bar{X}_1 + \frac{1}{4}\bar{X}_2.$$

它的期望为 $3\mu_1/4+\mu_2/4=\mu$. 若把抽到的 20 个数直接平均, 期望则为 $(\mu_1+\mu_2)/2$, 一般与 μ 不同. 若样本量的分配比例与总体各层比例相同, 加权估计量就恰好等于全部样本的普通均值.

多层时, 设各层比例为 $p_1,\dots,p_k$, 且 $\sum_i p_i=1$. 各层独立抽样得到的样本均值为 $\bar{X}_i$, 则

$$T=\sum_{i=1}^{k} p_i\bar{X}_i, \qquad \mathbb{E}T=\sum_{i=1}^{k} p_i\mu_i, \qquad \mathsf{Var}(T)=\sum_{i=1}^{k} p_i^2\,\mathsf{Var}(\bar{X}_i).$$

期望由线性性得到; 方差由平方展开得到, 因为每两个不同层的中心化均值乘积的期望都是 0.

分层方式对精度有影响. 对总体 $-3,-1,1,3$, 总体均值为 0, 方差为 5. 分成 $\{-3,-1\}$ 和 $\{1,3\}$, 各层独立抽一个, 两个层内方差均为 1, 所得两数平均值的方差为 $(1+1)/4=1/2$. 若改分为 $\{-3,3\}$ 和 $\{-1,1\}$, 同样抽样所得方差为 $(9+1)/4=5/2$. 而不分层, 直接简单随机抽两个时, 方差为

$$\frac{4-2}{4-1}\frac{5}{2}=\frac{5}{3}.$$

这三种抽样面对同一个总体, 但均值估计量的方差不同.

下一题允许两层的选择相互依赖, 因此要保留两层间的协方差, 再选择使总方差最小的抽样方式.

例 1.2. 两层各有 $m\ge 2$ 个单位, 数值分别为 $a_1<\cdots<a_m$ 与 $b_1<\cdots<b_m$. 每层等概率抽一个, 但允许两层的选择相互依赖. 求所得两数平均值的最小方差, 以及达到最小值的全部联合抽样规则.

解. 记两层抽到的数分别为 A,B, 并记

$$\bar{a}=\frac{1}{m}\sum_{i=1}^{m} a_i, \qquad \bar{b}=\frac{1}{m}\sum_{j=1}^{m} b_j, \qquad q_{ij}=\mathbb{P}(A=a_i,B=b_j).$$

每层等概率抽一个, 就要求这个概率表满足

$$q_{ij}\ge 0, \qquad \sum_{j=1}^{m} q_{ij}=\frac{1}{m}\ (1\le i\le m), \qquad \sum_{i=1}^{m} q_{ij}=\frac{1}{m}\ (1\le j\le m).$$

每行的和是抽到某个 a_i 的概率, 每列的和是抽到某个 b_j 的概率. 改变联合抽样方式, 就是在保持这些行和、列和的条件下改变表内各概率.

$\mathbb{E}A,\mathbb{E}B,\mathbb{E}A^2,\mathbb{E}B^2$ 均由各层的等概率分布确定. 所以由

$$\mathsf{Var}\left(\frac{A+B}{2}\right)=\frac{\mathbb{E}A^2+\mathbb{E}B^2+2\mathbb{E}(AB)}{4}-\frac{(\bar{a}+\bar{b})^2}{4},$$

只需使 $\mathbb{E}(AB)=\sum_{i,j} a_ib_jq_{ij}$ 最小.

先让最小的 a_1 尽可能与最大的 b_m 一起出现. 如果 $q_{1m}<1/m$, 第一行的其他位置必有某个 $q_{1j}>0$, 其中 $j<m$; 第 m 列也必有某个 $q_{km}>0$, 其中 $k>1$. 令

$$\delta=\min\{q_{1j},q_{km}\}>0.$$

把 (a_1,b_j) 和 (a_k,b_m) 的概率各减少 δ, 把 (a_1,b_m) 和 (a_k,b_j) 的概率各增加 δ. 各概率仍非负, 每行、每列的和都保持不变. 而 $\mathbb{E}(AB)$ 减少了

$$\begin{aligned}&\delta(a_1b_j+a_kb_m-a_1b_m-a_kb_j)\\&\quad=\delta(a_k-a_1)(b_m-b_j)>0.\end{aligned}$$

因此这样的交换会严格减小所求方差.

每次交换至少把第一行或第 m 列中一个原先为正的其他概率减到 0, 新增加的概率除了 q_{1m} 之外都在这行、这列以外. 所以这些其他正概率的个数逐次减少. 最多经过有限次交换, 第一行、第 m 列的概率就全部集中到 $q_{1m}=1/m$.

此后固定这一行和这一列, 对剩余的第 2 行与第 $m-1$ 列作相同的交换. 逐次进行, 最终得到

$$q_{i,m+1-i}=\frac{1}{m}\quad(1\le i\le m),\qquad q_{ij}=0\quad(j\ne m+1-i).$$

也就是等概率选择 i, 再同时抽取 a_i 和 b_{m+1-i}. 从任意其他联合抽样规则出发, 上述过程至少有一次严格减小方差, 所以这是唯一的最优规则.

此时平均值以各 $1/m$ 的概率取 $(a_i+b_{m+1-i})/2$, 其期望为 $(\bar a+\bar b)/2$. 最小方差为

$$\boxed{\frac{1}{4m}\sum_{i=1}^{m}(a_i+b_{m+1-i}-\bar a-\bar b)^2}.$$

它等于 0 当且仅当所有 a_i+b_{m+1-i} 都相同.

例 1.3. 四个实数构成有限总体. 从中简单随机抽取两个, 其平均值在 $\frac12,1,\frac32,2,\frac52,3$ 六个值上等可能. 求原总体的全部可能取值, 忽略排列.

解. 六个二元子集各以概率 $1/6$ 出现, 题给的六个均值又互不相同, 所以六个两数之和恰为 $1,2,3,4,5,6$.

将原数据排为 $a\le b\le c\le d$. 所有两数之和相加, 每个原数出现三次, 因此

$$a+b+c+d=\frac{1+2+3+4+5+6}{3}=7.$$

最小的两个和分别为 $a+b,a+c$, 最大的两个分别为 $b+d,c+d$. 于是

$$a+b=1,\qquad a+c=2,\qquad b+d=5,\qquad c+d=6.$$

记 $a=t$, 得到 $(a,b,c,d)=(t,1-t,2-t,4+t)$. 还没使用的两个和 $a+d,b+c$ 必须恰为 3、4, 故

$$\{4+2t,3-2t\}=\{3,4\}.$$

这给出 $t=-1/2$ 或 $t=0$, 两者都满足原排序. 逐项核对两数之和, 确实均为 $1,2,3,4,5,6$. 所以全部答案为

$$\boxed{\{0,1,2,4\}\quad\text{或}\quad\{-\tfrac12,\tfrac32,\tfrac52,\tfrac72\}.}$$

这说明即使保留了某个统计量的完整抽样分布, 也未必能恢复原总体.

1.5 只保存部分数据时能确定什么

给定一组数据 $x_1,\dots,x_n$, 假设只保存数据个数 n、总和 $A=\sum_i x_i$ 和平方和 $B=\sum_i x_i^2$. 由这三个数仍能算出

$$\bar{x}=\frac{A}{n},\qquad v=\frac{B}{n}-\left(\frac{A}{n}\right)^2.$$

当 $n\ge 2$ 时, 还能算出样本方差 $s^2=(B-A^2/n)/(n-1)$. 对任意给定常数 a, 展开平方又有

$$\sum_{i=1}^{n}(x_i-a)^2=B-2aA+na^2.$$

因此, 要计算这些量, 无须知道每个 x_i 各是多少.

中位数的情形不同. 两组数据

$$(0,0,0,3,3),\qquad (0,0,1,1,4)$$

都有 $n=5,A=6,B=18$, 中位数却分别为 0 和 1. 只知道 $(n,A,B)=(5,6,18)$ 时, 无法区分这两种可能, 所以不能唯一确定中位数.

定义 1.14 由已知量唯一确定. 设 x 表示一组允许的数据, 保存的量为 $h(x)$, 想求的量为 $t(x)$. 如果存在一个只以 $h(x)$ 为自变量的函数 g, 使每组允许的数据都满足

$$t(x)=g(h(x)),$$

就称 $t(x)$ 能由 $h(x)$ **唯一确定**.

命题 1.6 由已知量确定所求量的判据. $t(x)$ 能由 $h(x)$ 唯一确定, 当且仅当对任意两组允许的数据 x,y, 都有

$$h(x)=h(y)\quad\Longrightarrow\quad t(x)=t(y).$$

证明. 若 $t(x)=g(h(x))$, 那么 $h(x)=h(y)$ 就给出 $t(x)=g(h(x))=g(h(y))=t(y)$.

反过来, 假设相同的 h 值总对应相同的 t 值. 对每个可能的值 c, 所有满足 $h(x)=c$ 的数据都有同一个 $t(x)$ 值. 把这个唯一的值定义为 $g(c)$, 就有 $t(x)=g(h(x))$, 结论成立.

这个判据在证明无法确定某个量时尤其方便: 找到两组保存信息相同、所求结果却不同的数据即可. 上面的两组五元数据就是中位数的反例.

如果限制数据只能取 0、1、2, 结论又不同. 记三个数的出现次数分别为 N_0,N_1,N_2. 那么

$$N_0+N_1+N_2=n,\qquad N_1+2N_2=A,\qquad N_1+4N_2=B.$$

后两式相减再代回, 得

$$N_2=\frac{B-A}{2},\qquad N_1=2A-B,\qquad N_0=n-\frac{3A-B}{2}.$$

出现次数全部确定, 排序后的数据也就确定了, 因而能求中位数. 这里是已知数据范围提供了额外的信息.

两组数据分别保存 (n_1,A_1,B_1) 和 (n_2,A_2,B_2) 时, 合并后只需将对应的三个数相加. 若两组均值为 $\bar{x}_1,\bar{x}_2$, 方差为 v_1,v_2, 记 $w=n_1/(n_1+n_2)$, 由命题1.4对两组确定数据的结论, 合并方差为

$$wv_1+(1-w)v_2+w(1-w)(\bar{x}_1-\bar{x}_2)^2.$$

最后一项正是两组均值不同带来的贡献.

保存的信息减少后, 计算其概率分布时要合并对应的原始结果. 例如独立抛币 n 次, 只保存正面总数 K. 对 $0<p<1$ 和 $0\le k\le n$, 任意一个恰含 k 个 1 的具体序列都有概率 $p^k(1-p)^{n-k}$. 这样的序列共有 $\binom{n}{k}$ 个, 所以

$$\mathbb{P}_p(K=k)=\binom{n}{k}p^k(1-p)^{n-k}.$$

给定 $K=k$ 后, 每个这样的具体序列 x 的条件概率为

$$\mathbb{P}_p(X=x\mid K=k)=\frac{p^k(1-p)^{n-k}}{\binom{n}{k}p^k(1-p)^{n-k}}=\frac{1}{\binom{n}{k}}.$$

这是一个有限等可能分布. 例如 $K=2,n=4$ 时, 1100 和 1010 仍是不同的可能序列, 它们的相邻结果改变次数分别为 1 和 3.

一般地, 若离散型随机向量 X 只保留 $C=h(X)$, 则

$$\mathbb{P}_\theta(C=c)=\sum_{x:\,h(x)=c}\mathbb{P}_\theta(X=x),$$

求和遍历 X 所有产生这个 c 的可能取值. 这些结果互斥, 因此它们的概率相加.

连续型的例子也一样具体. 若 X 有密度 f_θ, 只记下它是否不超过已知常数 a, 即 $C=\mathbf{1}_{\{X\le a\}}$, 那么

$$\mathbb{P}_\theta(C=1)=\int_{-\infty}^{a}f_\theta(x)\,\mathrm{d}x,\qquad \mathbb{P}_\theta(C=0)=1-\int_{-\infty}^{a}f_\theta(x)\,\mathrm{d}x.$$

这里记录了一个 0 或 1, 因而它的分布由这两个概率给出.

只保存均值和方差, 虽然无法恢复所有原始数据, 但仍能限制极差, 即最大值与最小值的差. 这样的限制不仅要证明上界和下界, 还要判断两端之间的数是否真的可能出现.

例 1.4. 设 $n\ge 3$ 个实数的均值为 μ, 以 n 为分母的方差为 $v>0$. 记极差

$$R=\max_{1\le i\le n}x_i-\min_{1\le i\le n}x_i.$$

只知道 n,μ,v 时, 求 R 的全部可能值, 并刻画达到两端值的全部数据（不计排列）.

解. 将每个数据减去 μ 再除以 $\sqrt{v}$, 均值变为 0, 方差变为 1, 极差变为 $R/\sqrt{v}$. 因此先证明在 $\sum_i x_i=0$, $\sum_i x_i^2=n$ 时的结论.

极差的上界. 记最小值和最大值分别为 $a<0<b$. 由

$$(b-a)^2\le 2(a^2+b^2)\le 2\sum_{i=1}^{n}x_i^2=2n$$

得到 $R\le\sqrt{2n}$. 第一个不等式取等当且仅当 $a=-b$; 第二个取等当且仅当其余 $n-2$ 个数全是 0. 因而达到上界的数据只能是

$$-\sqrt{n/2},\quad \underbrace{0,\dots,0}_{n-2\text{个}},\quad \sqrt{n/2}.$$

这组数据确实满足均值、方差条件.

极差的下界. 这次固定极差 $R=b-a>0$, 把数据变成

$$z_i=\frac{x_i-a}{R}\in[0,1].$$

平移不改变方差, 缩放 $1/R$ 使方差变为 $1/R^2$, 故

$$\frac{1}{R^2}=\frac{1}{n}\sum_{i=1}^{n}(z_i-\bar{z})^2.$$

我们先求右端在所有 $z_i\in[0,1]$ 时的最大值. 固定其余 $n-1$ 个数, 令第 i 个数为 t. 展开方差可知它是关于 t 的二次函数, 二次项系数为 $(n-1)/n^2>0$. 因此它在 $[0,1]$ 上的最大值只能在端点取得; 若 $0<t<1$, 至少有一个端点使方差严格增大. 依次处理各个坐标, 可知方差最大时每个数只能是 0 或 1.

若有 k 个 0、$n-k$ 个 1, 其均值为 $(n-k)/n$, 方差为

$$\frac{k(n-k)}{n^2}.$$

其中 $k(n-k)$ 在整数 $0\le k\le n$ 上的最大值为

$$M=\left\lfloor\frac{n^2}{4}\right\rfloor,$$

且只有 $k=\lfloor n/2\rfloor$ 或 $k=\lceil n/2\rceil$ 时取到. 因而

$$\frac{1}{R^2}\le\frac{M}{n^2},\qquad R\ge\frac{n}{\sqrt{M}}.$$

取等当且仅当数据恰有两个不同取值, 其中较小值出现 k 次, 较大值出现 $n-k$ 次, $k\in\{\lfloor n/2\rfloor,\lceil n/2\rceil\}$. 由均值为 0、极差为 $n/\sqrt{M}$, 两个取值只能是

$$a=-\frac{n-k}{\sqrt{M}},\qquad b=\frac{k}{\sqrt{M}}.$$

此时方差确实为 1. n 为偶数时两个 k 相同; n 为奇数时对应两组互为相反数的数据.

中间值都能取到. 取两组确定的数据. 第一组 $u=(u_1,\dots,u_n)$ 是刚得到的某组下界取等数据, 按不减顺序排列; 第二组

$$v=(v_1,\dots,v_n)=(-\sqrt{n/2},\underbrace{0,\dots,0}_{n-2\text{个}},\sqrt{n/2})$$

是上界取等数据. 二者的均值均为 0, 平方和均为 n, 且首项为负、末项为正. 对 $0\le t\le1$, 记

$$w_i(t)=(1-t)u_i+tv_i,\qquad d(t)=\sqrt{\frac{1}{n}\sum_{i=1}^{n}w_i(t)^2}.$$

由于 $w_1(t)<0$、$w_n(t)>0$, 所以 $d(t)>0$. 数据 $w_i(t)/d(t)$ 始终均值为 0、方差为 1. 它们的极差

$$F(t)=\frac{\max_i w_i(t)-\min_i w_i(t)}{d(t)}$$

随 t 连续变化, 且 $F(0)=n/\sqrt{M}$, $F(1)=\sqrt{2n}$. 介值定理说明两个端点之间的每个值都能达到.

最后恢复平移和尺度, 得到全部可能值

$$\boxed{\frac{n\sqrt{v}}{\sqrt{\lfloor n^2/4\rfloor}}\le R\le\sqrt{2nv}.}$$

上界取等的数据为 $\mu-\sqrt{nv/2}$, $n-2$ 个 μ, 以及 $\mu+\sqrt{nv/2}$. 下界取等的数据为 k 个

$$\mu-\frac{n-k}{\sqrt{M}}\sqrt{v}$$

和 $n-k$ 个

$$\mu+\frac{k}{\sqrt{M}}\sqrt{v},$$

其中 $M=\lfloor n^2/4\rfloor$, $k\in\{\lfloor n/2\rfloor,\lceil n/2\rceil\}$. 这些也是全部的取等情形.

排序保留了全部数值及其重复次数, 但不保留原始次序. 例如 $(1,2,3)$ 与 $(1,3,2)$ 排序后相同, 原始数据中相邻两项满足前小后大的次数却分别为 2 和 1. 因而排序后的数据能确定中位数, 但通常不能确定涉及原始相邻次序的量.

1.6 习题

习题 1.1. 设 $a_1<a_2<\cdots<a_{2m}$, $m\ge 2$. 将这些数分成 m 对, 从每对中独立等概率抽一个, 用所得 m 个数的平均值估计总体均值. 求使估计量方差最小的全部配对及最小方差, 并证明这个最小方差严格小于从 $2m$ 个数中简单随机抽取 m 个所得均值的方差.

习题 1.2. 数据只取 $0,1,2,3$. 每次只保留数据个数 n、总和 S 和平方和 Q. 求所有函数 $h:\{0,1,2,3\}\to\mathbb{R}$, 使对任意 $n\ge 1$ 和任意这样的数据, $\sum_{i=1}^{n}h(x_i)$ 都能由 (n,S,Q) 唯一确定.

习题 1.3. 从六个有编号的单位中选取三个. 预先指定若干个不同的三元子集, 抽样时在这些子集中等概率选一个. 所选子集的数值平均记为 T, 要求对任意实数总体, T 的期望和方差都与简单随机抽样相同. 求至少需要指定多少个子集, 并给出达到最少数量的全部方案, 其中仅由重新编号得到的方案视为相同.

习题 1.4. 九个实数的五数概括为 $(-2,-1,0,1,2)$, 四分位数沿用本章约定. 求以 9 为分母的数据方差的全部可能值, 并给出取到两端值的全部数据, 忽略排列.

习题 1.5. $n\ge 4$ 个有编号的位置排成圆圈, 从中简单随机选 k 个涂黑, $1\le k<n$. 相邻的黑色位置连成黑段, 记黑段数为 R. 求 R 的分布和标准误.

习题 1.6. 从整数总体 $\{1,2,\dots,N\}$ 中简单随机抽取 n 个, $3\le n<N$. 样本只留下最小值 A 和最大值 B. 证明 $(A+B)/2$ 以总体均值为期望, 求其标准误, 并与完整样本均值的标准误比较.

习题 1.7. 一个由 $N\ge 2$ 个单位组成的有限总体, 均值为 μ, 以 N 为分母的方差为 $\sigma^2>0$. 先随机决定样本量 $K\in\{1,\dots,N\}$, 随后在给定 $K=k$ 时, 从总体中简单随机抽取 k 个单位. 已知 $\mathbb{E}K=\tau\in[1,N]$, 以所抽单位的均值 T 估计 μ. 求 $\mathsf{Var}(T)$ 的**全部可能值**, 并刻画达到两端值的全部 K 的分布.

习题 1.8. 总体分成 $k \geq 2$ 个等大的层, 第 i 层的总体方差为 $i(i+1)$. 在各层有放回独立等概率抽样, 第 i 层抽 $n_i \geq 1$ 次, 用各层样本均值的平均估计总体均值. 总次数为 $k(k+1)/2+s$, 其中 $s \in \{0, 1, \ldots, k\}$. 求最小方差及全部最优整数分配.

第二章　参数估计

2.1　总体矩、样本矩与矩估计

我们已经知道, 样本均值可以估计总体均值. 如果总体分布由一个或几个未知参数决定, 而总体均值恰好能用这些参数表示, 就可以把这一关系反过来, 利用样本均值求参数. **矩估计**正是把这个想法推广到平方、立方等更高次幂.

先看一个简单模型. 设 $X_1,\dots,X_n$ 独立服从 $U(0,\theta)$, $\theta>0$. 因为

$$\mathbb{E}_\theta X_i=\frac{\theta}{2},$$

我们用样本均值 $\bar X$ 代替未知的总体均值, 令 $\theta/2=\bar X$, 便得到估计量 $2\bar X$. 对一次具体数据 $(1,1,1,5)$, 估计值为 4. 虽然在参数 $\theta=4$ 的均匀分布下不可能观测到 5, 这仍是按刚才的均值关系得到的矩估计值; 它不负责使观测数据在候选参数下最可能出现. 后一种要求属于稍后介绍的极大似然估计.

定义 2.1　总体矩与样本矩.　设 $X_1,\dots,X_n$ 为参数空间 Θ 中某个未知 θ 所对应的独立同分布样本, $r\ge 1$ 为整数, 且对每个 $\theta\in\Theta$ 都有 $\mathbb{E}_\theta|X_1|^r<\infty$. 称

$$m_r(\theta)=\mathbb{E}_\theta X_1^r,\qquad M_r=\frac{1}{n}\sum_{i=1}^n X_i^r$$

分别为 r **阶总体原点矩**与 r **阶样本原点矩**. 前者是参数的函数, 后者是可以从样本计算的统计量. 对实际数据 $x_1,\dots,x_n$, M_r 的值为 $n^{-1}\sum_i x_i^r$.

定义 2.2　矩估计.　选定若干正整数 $r_1,\dots,r_k$, 用相应的样本矩代替总体矩, 建立方程

$$m_{r_j}(\theta)=M_{r_j}\qquad(1\le j\le k).\tag{2.1}$$

在原参数空间 Θ 内求得的解称为**矩估计值**; 用随机样本代入解的公式得到的统计量称为**矩估计量**. 如果方程在参数空间内没有解, 就应当如实说明这种选法没有产生矩估计; 若有多个解, 则须说明所有解, 或事先规定选取哪一个解.

并非必须恰好选与参数个数相同的矩, 但方程数量与参数个数不同可能影响是否存在解及解是否唯一. 当模型具有对称性时, 直接使用中心矩或阶乘矩等也很方便; 它们最终仍须由样本中相应的可计算量代替.

一个矩方程可能没有解.　若 X 只取 $0,1,2$, 对应概率分别为 $1-\theta,\theta/2,\theta/2$, $0\le\theta\le 1$, 则 $\mathbb{E}_\theta X=3\theta/2$. 假如两次观测均为 2, 样本均值等于 2, 矩方程给 $\theta=4/3$, 不属于参数空间. 因而此时一阶矩估计不存在. 这组数据本身却完全可能出现: 任意 $\theta>0$ 时, 两次都取 2 的概率为 $\theta^2/4>0$.

两个未知参数.　若 X_i 独立服从 $U(a,b)$, $a<b$, 则

$$m_1=\frac{a+b}{2},\qquad m_2=\frac{a^2+ab+b^2}{3},\qquad m_2-m_1^2=\frac{(b-a)^2}{12}.$$

记 $V=M_2-M_1^2=n^{-1}\sum_i(X_i-\bar X)^2$. 当 $V>0$ 时, 解前两个矩方程得到

$$\widehat a=\bar X-\sqrt{3V},\qquad \widehat b=\bar X+\sqrt{3V}.$$

因为 $b>a$, 两个根的次序已经由参数条件确定. 当 $V=0$ 时, 方程强迫 $a=b$, 因而没有合法解. 注意这里使用的 V 以 n 为分母: 它就是两个样本原点矩之差, 不是第一章定义的无偏样本方差 S^2.

为什么用样本矩代替总体矩值得考虑? 至少当有关方差有限时, 样本矩随着样本量增加会越来越接近总体矩.

命题 2.1 样本矩的期望与误差界. 固定 $\theta\in\Theta$. 若 $\mathbb{E}_\theta|X_1|^{2r}<\infty$, 则

$$\mathbb{E}_\theta M_r=m_r(\theta),\qquad \mathrm{Var}_\theta(M_r)=\frac{\mathrm{Var}_\theta(X_1^r)}{n}.$$

特别地, 对任意 $\varepsilon>0$,

$$\mathbb{P}_\theta(|M_r-m_r(\theta)|>\varepsilon)\le\frac{\mathrm{Var}_\theta(X_1^r)}{n\varepsilon^2}\xrightarrow[n\to\infty]{}0.$$

证明. 记 $Y_i=X_i^r$. 因为 $Y_1,\dots,Y_n$ 独立同分布且具有有限方差, 所以

$$\mathbb{E}_\theta\Big(\frac1n\sum_i Y_i\Big)=\mathbb{E}_\theta Y_1,\qquad \mathrm{Var}_\theta\Big(\frac1n\sum_i Y_i\Big)=\frac{1}{n^2}\sum_i\mathrm{Var}_\theta(Y_i)=\frac{\mathrm{Var}_\theta(Y_1)}{n}.$$

再对 M_r 应用切比雪夫不等式即可. 这里的极限对每个固定参数 θ 成立.

不过, 样本矩接近总体矩, 还不自动意味着由矩方程得到的参数估计接近真参数. 例如两个不同参数可能有完全相同的一阶矩. 要理解这个问题, 需要先分清什么信息能够区分参数.

2.2 模型可识别性与观测信息

设某种观测在参数 θ 下的分布为 P_θ. 如果两个不同的参数会产生完全一样的观测分布, 即使无限次独立重复这种观测, 我们也不可能仅凭数据判断实际使用了哪一个参数. 这就是**可识别性**所讨论的问题.

定义 2.3 参数的可识别性. 如果在参数空间 Θ 内, 只要 $\theta\neq\eta$, 观测随机对象在这两个参数下的分布就不同, 则称参数在这一观测模型中**可识别**. 等价地,

$$P_\theta=P_\eta\quad\Longrightarrow\quad\theta=\eta.$$

这里比较的是全部可能观测的分布, 不是同一次观测所得的两个数值. 如果原本可以观察 X, 实际只记录 $R=h(X)$, 就应比较 R 的分布.

例如, $X\sim\mathrm{Bernoulli}(p)$ 时, 由 $\mathbb{P}_p(X=1)=p$ 能够区分各个 $p\in[0,1]$. 但如果只记录 $R=|2X-1|$, 则不论 p 是多少, 总有 $R=1$. 原始观测可识别 p, 这一记录却不行. 这个简单例子还说明, 重要的不是数据表有多长, 而是保留的数据是否真的包含区别参数的信息.

命题 2.2 对观测作确定处理不能增加可识别性. 若在两个不同参数 θ,η 下, X 的分布完全相同, 则任何预先规定、与参数无关的统计量 $R=h(X)$ 在这两个参数下也有相同分布. 反过来, X 的分布可识别参数, 不保证 R 仍能识别参数.

证明. 只要 X 的分布相同, 对每个能够由 R 描述的事件, 如 $\{R\le t\}$, 就有

$$\mathbb{P}_\theta(R\le t)=\mathbb{P}_\theta(h(X)\le t)=\mathbb{P}_\eta(h(X)\le t)=\mathbb{P}_\eta(R\le t).$$

对实值 R, 这说明两种情况下 R 的分布函数相同; 若 R 是向量, 可对各分量的联合不等式作同样比较. 因而 R 的分布也相同. 反向结论已由前面的伯努利例子否定.

分布可识别与所选矩可识别还不是一回事. 例如

$$\mathbb{P}_\theta(X=0)=\theta,\qquad \mathbb{P}_\theta(X=1)=\mathbb{P}_\theta(X=-1)=\frac{1-\theta}{2},\quad 0\le\theta\le 1.$$

不同 θ 对应不同分布, 但 $\mathbb{E}_\theta X=0$ 对所有参数都相同. 只列一阶矩方程, 根本无法求出 θ; 改用二阶矩 $\mathbb{E}_\theta X^2=1-\theta$ 才可以.

一般地, 选定 $r_1,\dots,r_k$ 后, 矩方程能否从总体矩唯一恢复参数, 取决于映射

$$\theta\longmapsto\big(m_{r_1}(\theta),\dots,m_{r_k}(\theta)\big)$$

在 Θ 中是否为一一对应. 即使这个映射是一一对应, 有限样本的样本矩向量也未必恰好落在它的取值范围内, 因而矩估计仍可能不存在.

从这里再看**无偏估计**, 会遇到另一个问题: 分布能够区分参数, 并不意味着每个参数函数都能用一份固定长度的样本无偏估计. 一个很短的例子就能说明.

设 X_1,X_2 独立服从 Bernoulli(p). 一次观测 X_1 的任何函数只有 $T(0),T(1)$ 两个值, 因而

$$\mathbb{E}_pT(X_1)=(1-p)T(0)+pT(1)$$

至多是 p 的一次式, 无法对所有 $0<p<1$ 恒等于 p^2. 但两次独立观测时,

$$\mathbb{E}_p(X_1X_2)=p^2,$$

所以 X_1X_2 正好是 p^2 的无偏估计量. 下面的正式例题把类似现象放在连续型混合分布中研究.

例 2.1. 每次实验只记录 $X=a\varepsilon+Z$，其中 $a>0$ 未知，ε 等概率取 ±1，$Z\sim N(0,v)$，$v\ge0$ 也未知，且 ε 与 Z 独立；当 $v=0$ 时约定 $Z=0$。欲估计 a^4。

1. 若只观测一次 X，证明不存在对所有 (a,v) 都无偏的可积估计量。
2. 若独立重复 $n\ge2$ 次，记 $M_j=n^{-1}\sum_{i=1}^n X_i^j$。构造只依赖 M_2,M_4 的 a^4 的无偏估计量，并求 $\big(3M_2^2-M_4\big)/2$ 的偏差。

解. 先计算总体矩。由对称性和独立性,

$$\mu_2=\mathbb{E}X^2=a^2+v,\qquad \mu_4=\mathbb{E}X^4=a^4+6a^2v+3v^2.$$

其中正态变量的四阶矩为 $3v^2$：$v>0$ 时写 $Z=\sqrt{v}\,U$，标准正态密度满足 $\varphi'(u)=-u\varphi(u)$，分部积分给

$$\mathbb{E}U^4=-\int_{-\infty}^{\infty}u^3\varphi'(u)\,\mathrm{d}u=3\int_{-\infty}^{\infty}u^2\varphi(u)\,\mathrm{d}u=3;$$

$v=0$ 时公式也成立。于是

$$\boxed{2a^4=3\mu_2^2-\mu_4.}\tag{1}$$

(1) 假设存在仅依赖一次记录的可积估计量 $T(X)$，满足对每个 $a>0,v\ge0$ 都有 $\mathbb{E}_{a,v}T(X)=a^4$。在 $v=0$ 时，X 等概率取 $a,-a$，故

$$\frac{T(a)+T(-a)}{2}=a^4\qquad(a>0).\tag{2}$$

记 $T_{\mathrm{e}}(x)=[T(x)+T(-x)]/2$。式 (2) 说明 $T_{\mathrm{e}}(x)=x^4$ 对每个 $x\neq 0$ 都成立。另一方面，$v>0$ 时 X 的分布关于零对称且连续。由于 $T(X)$ 可积，对称性也保证 $T(-X)$ 可积，并有

$$\mathbb{E}_{a,v}T(X)=\mathbb{E}_{a,v}T_{\mathrm{e}}(X)=\mathbb{E}_{a,v}X^4=a^4+6a^2v+3v^2>a^4.$$

这与无偏性矛盾。因此单次观测时所求估计量不存在；这里使用了参数域允许 $v=0$，并未对 T 预设连续或多项式形式。

(2) 对 $n\geq 2$，利用不同观测间的独立性，定义

$$U_2=\frac{1}{n(n-1)}\sum_{i\neq j}X_i^2X_j^2=\frac{nM_2^2-M_4}{n-1}.$$

每个交叉项的期望均为 μ_2^2，故 $\mathbb{E}U_2=\mu_2^2$；同时 $\mathbb{E}M_4=\mu_4$。由 (1)，

$$\boxed{\widehat{a^4}=\frac{3U_2-M_4}{2}=\frac{3nM_2^2-(n+2)M_4}{2(n-1)}}$$

对所有 $a>0,v\geq 0$ 无偏。该估计量可能为负；无偏性的定义并不要求估计值逐次落在参数函数的取值范围内。

若直接将总体矩替换为样本矩，取 $A_n=(3M_2^2-M_4)/2$，则

$$\mathbb{E}M_2^2=\mu_2^2+\mathrm{Var}(M_2)=\mu_2^2+\frac{\mu_4-\mu_2^2}{n}.$$

因此其偏差恰为

$$\boxed{\mathbb{E}A_n-a^4=\frac{3(\mu_4-\mu_2^2)}{2n}=\frac{3(2a^2v+v^2)}{n}.}$$

$v>0$ 时偏差严格为正，$v=0$ 时为零。两种构造的区别不在代数恒等式，而在于 M_2^2 的期望一般不等于 μ_2^2；用两次不同观测相乘才可以无偏估计这个平方。

2.3 似然函数与极大似然估计

矩估计关注的是总体矩应该等于多少. 另一种常用方法直接考察: 对于已经得到的这份数据, 不同参数使它出现的概率或密度有多大? 例如重复抛币得到十次中七次正面, 我们可以分别计算 $p=0.3$、$p=0.7$ 时出现这一记录的概率, 然后寻找最有利于解释数据的参数.

定义 2.4 似然函数. 设实际观测为 r, 参数空间为 Θ. 对每个 $\theta\in\Theta$, 按这一参数下实际记录 R 的分布计算

$$L(\theta;r)=\begin{cases}\mathbb{P}_\theta(R=r), & R\text{为离散型记录},\\ f_\theta(r), & R\text{具有约定的概率密度}f_\theta.\end{cases}$$

把 r 固定、把 θ 当作变量时, $L(\theta;r)$ 称为**似然函数**. 多个观测值须使用它们的联合概率或密度; 在给定参数下相互独立时, 才可以相乘. 如果记录同时包含一个离散标记和一个连续数值, 则用标记的概率乘上在该标记下连续数值的条件密度.

似然并不是参数的概率分布. 在这里 θ 是未知但固定的常数, 不是我们随机抽取的量. 对连续型记录, $f_\theta(r)$ 是密度值, 而不是单点事件 $\{R=r\}$ 的概率.

定义 2.5　极大似然估计.　固定实际记录 r, 在题目规定的参数空间 Θ 内寻找使 $L(\theta;r)$ 达到全局最大值的参数, 称所得值为**极大似然估计值**. 全部极大似然估计值组成的集合记为

$$\operatorname{argmax}_{\theta\in\Theta} L(\theta;r)=\{\theta\in\Theta : L(\theta;r)=\sup_{\eta\in\Theta} L(\eta;r)\}.$$

如果最大值只在极限处逼近却不能达到, 这个集合就是空集; 如果几个参数都取到最大值, 就必须保留全部解. 对每份样本作同样的运算, 得到相应的极大似然估计量（在最大点非唯一或不存在的记录上, 还要说明怎样处理）.

伯努利样本.　若 n 次独立抛币只记录正面次数 $K=k$, $0\le k\le n$, 则

$$L(p;k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad 0\le p\le 1.$$

组合数与 p 无关, 因而可以只比较 $p^k(1-p)^{n-k}$. 当 $0<k<n$ 时, 对数似然在 $p=k/n$ 以前递增、以后递减; $k=0$ 或 $k=n$ 时, 最大值分别在端点 $p=0$ 或 $p=1$ 取得. 所以对所有可能记录,

$$\widehat{p}=\frac{k}{n}$$

都是唯一极大似然估计. 这里组合因子不会影响最优参数, 但这并不表示任意删减记录都保持似然的最大点.

命题 2.3　去掉与参数无关的正因子.　对固定记录 r, 若两个非负似然函数满足

$$L_1(\theta;r)=c(r)L_2(\theta;r),\qquad 0<c(r)<\infty,$$

且都在同一参数空间上比较, 则它们的全局最大点集合相同. 在 $L>0$ 的区域, 改为最大化 $\log L$ 也不改变最优参数.

证明.　对任意两个参数 θ,η, 因为 $c(r)>0$,

$$L_1(\theta;r)\ge L_1(\eta;r)\quad\Longleftrightarrow\quad L_2(\theta;r)\ge L_2(\eta;r).$$

两函数对参数的大小排序完全一致, 最大点自然一致. 第二个结论来自对数函数在 $(0,\infty)$ 上严格递增. 使用对数以前, 仍须确定哪些参数的似然为零.

正态总体的均值.　若 X_i 独立服从 $N(\mu,\sigma^2)$, $\sigma^2>0$ 已知, $\mu\in\mathbb{R}$ 未知, 则

$$L(\mu;x_1,\dots,x_n)\ \propto\ \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right].$$

固定数据以后, 最大化这个似然就等于最小化平方和. 而

$$\sum_i (x_i-\mu)^2=\sum_i (x_i-\bar{x})^2+n(\mu-\bar{x})^2,$$

右边仅第二项与 μ 有关, 在 $\mu=\bar{x}$ 时唯一最小. 这便自然得到 $\widehat{\mu}=\bar{X}$, 并且直接证明了全局最优, 不必先求导再检查驻点.

参数允许范围的重要性.　假设每次试验真实结果为 $X\sim\text{Bernoulli}(p)$, 但记录时以已知概率 $1/5$ 把结果翻转, 各次翻转与试验独立. 那么实际看到 1 的概率为

$$q=\frac{1}{5}(1-p)+\frac{4}{5}p=\frac{1+3p}{5},\qquad \frac{1}{5}\le q\le\frac{4}{5}.$$

n 次独立记录中有 k 次为 1, 则似然与 $q^k(1-q)^{n-k}$ 成正比. 如果不考虑区间限制, 它在 $q=k/n$ 处最大; 但真实允许的 q 只能在 $[1/5,4/5]$ 中变化. 因而

$$\widehat{q}=\min\left\{\frac{4}{5},\max\left\{\frac{1}{5},\frac{k}{n}\right\}\right\},\qquad \widehat{p}=\frac{5\widehat{q}-1}{3}.$$

例如观测中一次 1 也没有, 最优参数就是 $p=0$. 这里合法区间的端点确实属于参数空间, 所以可以取到最大值. 与上一节矩方程没有域内解的情形应当区分.

2.4 偏差、方差与均方误差

不同方法常常得到不同估计量. 怎样判断哪个更好? 对同一目标, 我们至少要区分两个问题: 估计量的平均值是否偏离目标, 以及估计值通常离目标有多远.

定义 2.6 偏差与均方误差. 设 T 是估计 $g(\theta)$ 的统计量, 对每个 $\theta\in\Theta$ 都有 $\mathbb{E}_\theta T^2<\infty$. 定义它在参数 θ 处的**偏差**和**均方误差**分别为

$$b_\theta(T)=\mathbb{E}_\theta T-g(\theta),\qquad \mathrm{MSE}_\theta(T)=\mathbb{E}_\theta\big(T-g(\theta)\big)^2.$$

偏差描述长期平均估计值相对于目标的偏移, 均方误差则把偏移和随机波动一起计入. 因此无偏性并不自动意味着均方误差最小.

命题 2.4 均方误差的分解. 若 T 具有有限二阶矩, 则

$$\mathrm{MSE}_\theta(T)=\mathrm{Var}_\theta(T)+b_\theta(T)^2.$$

证明. 将 $T-g(\theta)$ 写为

$$T-g(\theta)=\big(T-\mathbb{E}_\theta T\big)+\big(\mathbb{E}_\theta T-g(\theta)\big).$$

平方后取期望, 第一项的期望为方差, 第二项为偏差平方. 交叉项的期望含有 $\mathbb{E}_\theta(T-\mathbb{E}_\theta T)=0$, 所以为零.

可以用一个简单的伯努利模型看到二者的取舍. 设 $\bar X$ 是 n 次独立伯努利试验的平均数, 考虑

$$T_c=c\bar X+(1-c)\frac{1}{2},\qquad 0\le c\le 1.$$

这是把样本均值朝 $1/2$ 拉近的一类估计量. 因为 $\mathbb{E}_p\bar X=p$, $\mathrm{Var}_p\,\bar X=p(1-p)/n$, 所以

$$b_p(T_c)=(1-c)\Big(\frac12-p\Big),\qquad \mathrm{MSE}_p(T_c)=\frac{c^2p(1-p)}{n}+(1-c)^2\Big(p-\frac12\Big)^2.$$

当 $p=1/2$ 时, 减小 c 会降低方差而不引入偏差; 当 p 远离 $1/2$ 时, 过小的 c 又会产生明显偏差. 因而比较估计量时, 要说清比较的是哪些参数值, 以及使用方差、均方误差还是别的准则.

例 2.2. 袋中有 $N\ge 1$ 个编号不同的球，N 未知。有放回地独立等概率抽取四次，只记录号码相同的无序位置对数 C。

1. 当 $C=0$ 或 $C=1$ 时，求 N 的全部极大似然估计。
2. 在所有只依赖 C、对每个 $N\ge 1$ 都无偏估计 $1/N$ 的统计量中，求一个对每个 N 方差都最小的统计量，并证明其唯一性。

解. 先求实际记录的分布。四个位置中，相同号码的无序对数只能是 $0,1,2,3,6$，依次对应 $1+1+1+1$、$2+1+1$、$2+2$、$3+1$、4 五种重数类型。逐种指定位置和不同球号，得到

c	0	1	2	3	6
$N^4\mathbb{P}_N(C=c)$	$N(N-1)(N-2)(N-3)$	$6N(N-1)(N-2)$	$3N(N-1)$	$4N(N-1)$	$N.$

不够多的不同球号时相应概率为零。记 $t=1/N$，同一分布也可写为

$$\begin{aligned} p_0(t) &= (1-t)(1-2t)(1-3t),\\ p_1(t) &= 6t(1-t)(1-2t),\\ p_2(t) &= 3t^2(1-t), \qquad p_3(t) = 4t^2(1-t), \qquad p_6(t) = t^3. \end{aligned}$$

这些式子对全部整数 $N\geq 1$ 都成立。

(1) 记录 $C=0$ 时，只有 $N\geq 4$ 给出正似然；似然为

$$\left(1-\frac{1}{N}\right)\left(1-\frac{2}{N}\right)\left(1-\frac{3}{N}\right).$$

三个因子在 $N\geq 4$ 都随 N 严格增大，乘积趋于 1 而从不取到。因此此时**不存在极大似然估计**。

记录 $C=1$ 时，只有 $N\geq 3$ 给出正似然；舍去常数因子后须最大化

$$f(N)=\frac{(N-1)(N-2)}{N^3}.$$

这里 N 只能取整数, 直接比较相邻两项比把它暂时当作实变量更合适。对 $N\geq 3$,

$$\frac{f(N+1)}{f(N)}=\frac{N^4}{(N-2)(N+1)^3}.$$

该比值大于 1 当且仅当

$$g(N)=-N^3+3N^2+5N+2>0.$$

因为 $g(3)=17$, $g(4)=6$, $g(5)=-23$, 且 $g(N+1)-g(N)=-3N^2+3N+7<0$ 对所有整数 $N\geq 3$ 成立, 所以 $f(N)$ 从 $N=3$ 严格增至 $N=5$, 此后严格递减. 因而唯一极大似然估计为 $\boxed{\widehat{N}_{\mathrm{ML}}=5}$.

(2) 令 $g(c)$ 表示所求估计在记录为 c 时的值，写 $u_c=g(c)$。无偏条件是

$$u_0p_0(t)+u_1p_1(t)+u_2p_2(t)+u_3p_3(t)+u_6p_6(t)=t \qquad (t=1,1/2,1/3,\ldots).$$

左右都是次数至多为 3 的多项式。由于两者在无穷多个不同的 t 处相等，它们恒等；比较 $1,t,t^2,t^3$ 的系数依次得到

$$\boxed{u_0=0,\quad u_1=\frac{1}{6},\quad 3u_2+4u_3=3,\quad u_6=1.}$$

反之，满足这四个条件的每个 g 都处处可积且无偏，因此这确实刻画了全部候选估计量。

所有候选量的期望相同，比较方差等价于比较二阶矩。上式只有 u_2,u_3 尚可变化，而

$$\mathbb{P}_N(C=2)u_2^2+\mathbb{P}_N(C=3)u_3^2=t^2(1-t)(3u_2^2+4u_3^2).$$

由柯西不等式,

$$3u_2^2+4u_3^2\ge\frac{(3u_2+4u_3)^2}{3+4}=\frac{9}{7},$$

等号当且仅当 $u_2=u_3=3/7$。于是所求估计量为

C	0	1	2	3	6
$T_*(C)$	0	1/6	3/7	3/7	1

对每个 $N\ge 2$, $t^2(1-t)>0$, 所以等号条件迫使这一选择唯一; $N=1$ 虽不能单独区分 u_2,u_3, 却不影响对所有 N 同时最优的唯一性。

这个结果还能用一次条件平均解释。记六对位置相同的指示量为 I_{ij}, 则 $C/6$ 无偏估计 t。任意两对不同位置的指示量, 即使共享一个位置, 也因三次编号相同的概率为 t^2 而两两独立, 因此

$$\mathrm{Var}_N(C/6)=\frac{t(1-t)}{6}.$$

对于 $A=\{C=2\text{ 或}3\}$, 由 $p_2(t):p_3(t)=3:4$ 可知, 在 A 上把 $C/6$ 按 $3:4$ 的概率平均, 得到

$$\frac{3}{7}\cdot\frac{2}{6}+\frac{4}{7}\cdot\frac{3}{6}=\frac{3}{7}=T_*(2)=T_*(3).$$

这一平均不改变期望, 却减少方差; 精确减少量为

$$\mathbb{P}_N(A)\,\mathrm{Var}_N(C/6\mid A)=7t^2(1-t)\cdot\frac{3\cdot4}{7^2}\left(\frac{3}{6}-\frac{2}{6}\right)^2=\frac{t^2(1-t)}{21}.$$

故还得到

$$\boxed{\mathrm{Var}_N(T_*)=\frac{t(1-t)(7-2t)}{42},\qquad t=1/N.}$$

这也给出最优估计比直接按碰撞对数作估计更精确的定量幅度。

2.5 观测范围、不完整记录与随机停止

在写似然之前, 应先问清楚实际记录的到底是什么. 同一批原始随机变量, 若只保留其中某个函数, 其似然便由这个函数的分布决定. 此外, 观测本身也可能限制哪些参数仍然可能.

给定一次实际记录 r, 有些参数会使它的似然为零, 另一些参数则使它的似然为正. 为了比较似然, 可以先确定

$$\Theta_+(r)=\{\theta\in\Theta:L(\theta;r)>0\}.$$

这一般只是原参数空间 Θ 的一部分. 在这个集合上继续比较似然, 才能求出极大似然估计; 如果最大值只在某个不属于参数空间的边界处被逼近, 估计值就不存在.

从样本最大值确定参数的范围. 设 X_i 独立服从 $U(0,\theta)$, $\theta>0$, 一次观测得到 $x_i>0$, 记 $M=\max_i x_i$. 为讨论最大值, 采用密度 $\theta^{-1}\mathbf{1}_{\{0\le x\le\theta\}}$. 给定数据的似然为

$$L(\theta;x_1,\dots,x_n)=\theta^{-n}\mathbf{1}_{\{\theta\ge M\}}.$$

参数至少要满足 $\theta\ge M$; 在这个范围内, θ^{-n} 随 θ 增大严格减小, 故唯一极大似然估计是 $\widehat{\theta}=M$. 这里先确定取值范围, 再比较函数, 比机械地对 θ^{-n} 求导更直接.

同样, 如果密度为 $e^{-(x-\theta)}\mathbf{1}_{\{x\ge\theta\}}$, $\theta\in\mathbb{R}$, 那么样本要求 $\theta\le m=\min_i x_i$, 似然在这一范围内与 $e^{n\theta}$ 成正比, 所以唯一最大点为 $\theta=m$. 最大值、最小值都可以成为估计量, 取决于样本的分布如何随参数移动.

还有两种值得比较的情况. 对长度固定为 1 的均匀分布 $U(\theta,\theta+1)$, $\theta\in\mathbb{R}$, 记样本最大、最小值为 M,m. 只要数据确实来自这个模型, 就有 $M-m\le 1$, 且似然等于 1 的全部参数为

$$\boxed{\theta\in[M-1,m]}.$$

这个区间里的参数都是极大似然估计. 相反, 若伯努利参数规定为 $0<p<1$, 且 n 次观测全为 0, 则似然 $(1-p)^n$ 随 p 趋近 0 而接近 1, 却永远不能达到 1. 因此这份记录没有极大似然估计. 一个模型会出现多个最优参数, 另一个则可能根本不取到最优参数.

超过观察期限的寿命. 设 n 个寿命 X_i 相互独立, 都服从速率为 $\lambda>0$ 的指数分布. 我们只能观察到时间 1: 在此之前结束的寿命记下精确时间, 到时间 1 仍未结束的只记作“至少存活了 1”. 于是实际记录为

$$Z_i=\min(X_i,1).$$

如果 $0<z_i<1$, 该记录提供密度 $\lambda e^{-\lambda z_i}$; 如果 $z_i=1$, 记录的是事件 $X_i\ge 1$, 其概率是 $e^{-\lambda}$. 设 $z_i<1$ 的记录共有 r 个, $t=\sum_i z_i>0$, 根据独立性,

$$L(\lambda;z_1,\dots,z_n)=(\lambda^r e^{-\lambda\sum_{z_i<1}z_i})e^{-\lambda(n-r)}=\lambda^r e^{-\lambda t}.$$

当 $r>0$ 时, 这个函数在 $\lambda=r/t$ 处唯一最大; 当 $r=0$ 时, 它等于 $e^{-\lambda n}$, 在 $\lambda>0$ 上只有上确界 1 而无最大点. 这里记录 $z_i=1$ 并不是说观测到了恰好等于 1 的连续寿命; 它代表的是一个具有正概率的尾部事件.

下面的例题还会考虑观察到某种结果便立即停止的试验. 停止规则与最终究竟保留哪些量共同决定记录的分布. 即使原始随机试验完全一样, 固定做 n 次与随机决定做几次也可能得到不同的似然.

例 2.3. 每轮重新取相互独立的 $X\sim\mathrm{Exp}(\lambda)$、$Y\sim\mathrm{Exp}(\nu)$，其中 $\lambda,\nu>0$ 均未知；不同轮独立。

(1) 做 n 轮，只保留 $X<Y$ 的次数 $K=k$ 和各轮 $\min(X,Y)$ 之和 $T=t>0$。求 (λ,ν) 的全部极大似然估计。

(2) 改为在第 r 次出现 $X<Y$ 时结束，$r\ge 1$ 固定，只保留结束前各轮 $\min(X,Y)$ 之和 $T=t>0$，不保留轮数。求 (λ,ν) 的全部极大似然估计。

解. (1) 先求一轮的实际记录。令 $B=\mathbf{1}_{\{X<Y\}}$、$W=\min(X,Y)$。对 $w>0$，由独立性,

$$\mathbb{P}(B=1,W\in\mathrm{d}w)=\lambda e^{-(\lambda+\nu)w}\,\mathrm{d}w,\qquad \mathbb{P}(B=0,W\in\mathrm{d}w)=\nu e^{-(\lambda+\nu)w}\,\mathrm{d}w.$$

记 $s=\lambda+\nu$、$p=\lambda/s$。上式分别为 p、$1-p$ 乘以 $se^{-sw}\,\mathrm{d}w$,所以 B 与 W 独立,$B\sim\mathrm{Bernoulli}(p)$, $W\sim\mathrm{Exp}(s)$。各轮记录独立，故整个胜负序列与整个等待时间序列独立。

r 个独立 $\mathrm{Exp}(s)$ 变量之和的密度为

$$f_r(t)=\frac{s^r t^{r-1}e^{-st}}{(r-1)!},\quad t>0.$$

$r=1$ 时成立；若 r 时成立，则与 se^{-su} 卷积，积分 $\int_0^t(t-u)^{r-1}\,\mathrm{d}u=t^r/r$ 给出 $r+1$ 时的式子。这也证明了以下使用的和密度，而非引入新的分布前置。

因此固定 n 时，(K,T) 的联合概率与密度为

$$\binom{n}{k}\frac{t^{n-1}}{(n-1)!}\lambda^k\nu^{n-k}e^{-(\lambda+\nu)t}.$$

删去与参数无关的正因子。若 $0<k<n$，对数似然分成 $k\log\lambda-t\lambda$ 与 $(n-k)\log\nu-t\nu$，两项导数各自先正后负，故唯一最大点是

$$\boxed{(\widehat{\lambda},\widehat{\nu})=(k/t,(n-k)/t)}.$$

若 $k=0$，固定 ν 后减小 λ 总会增加似然，而 $\lambda=0$ 不属于参数域，所以没有 MLE。$k=n$ 时同理，减小 ν 即可严格增加似然，也没有 MLE。

(2) 未保留的轮数不能补回记录中，必须对它求和。令 N 为结束时的总轮数。由于每轮第一通道获胜的概率为 $p>0$，等待一次胜利的轮数超过 m 的概率为 $(1-p)^m\to0$；重复 r 次可知 N 以概率 1 有限。对 $k\geq0$，结束于第 $r+k$ 轮等价于最后一轮获胜且前 $r+k-1$ 轮恰有 $r-1$ 次胜利，故

$$\mathbb{P}(N=r+k)=\binom{r+k-1}{k}p^r(1-p)^k.$$

停止只由胜负序列决定。该序列与全部等待时间独立，所以给定 $N=r+k$ 后，T 仍是 $r+k$ 个独立 $\mathrm{Exp}(s)$ 变量之和。实际记录的密度为

$$\begin{aligned}f_T(t)&=\sum_{k=0}^{\infty}\binom{r+k-1}{k}\left(\frac{\lambda}{s}\right)^r\left(\frac{\nu}{s}\right)^k\frac{s^{r+k}t^{r+k-1}e^{-st}}{(r+k-1)!}\\&=\frac{\lambda^rt^{r-1}e^{-(\lambda+\nu)t}}{(r-1)!}\sum_{k=0}^{\infty}\frac{(\nu t)^k}{k!}=\frac{\lambda^rt^{r-1}e^{-\lambda t}}{(r-1)!}.\end{aligned}$$

所有项非负，求和是离散条件分布的混合。密度已不含 ν。其关于 λ 的对数导数为 $r/\lambda-t$，故全部 MLE 为

$$\boxed{\{(r/t,\nu):\nu>0\}}.$$

同样的通道与等待时间，在不同停止、保留规则下，参数信息并不相同。

例 2.4. 每轮独立抛掷两枚硬币，正面概率为 p,q，其中 $0\leq p\leq q\leq1$。只记录每轮正面的总数；n 轮中记录为 $0,1,2$ 的次数分别为 $a,b,c>0$，$a+b+c=n$。

(1) 求由前两阶矩得到的 (p,q) 的矩估计及其存在条件。

(2) 求 (p,q) 的全部极大似然估计。

解. (1) 记一轮的记录为 Y。它的三个概率为

$$u=(1-p)(1-q),\qquad w=p(1-q)+q(1-p),\qquad v=pq.$$

与其直接展开两个参数，不如先确定它们的和与积：

$$\mathbb{E}Y=p+q,\qquad\mathbb{E}[Y(Y-1)]=2pq.$$

这与使用前两阶原点矩完全等价。因此矩方程为

$$p+q=\frac{b+2c}{n},\qquad pq=\frac{c}{n}.$$

令 $D=b^2-4ac$，二次方程的判别式为 D/n^2。若 $D\ge 0$，唯一符合 $p\le q$ 的矩解为

$$\boxed{p_{\mathrm{M}}=\frac{b+2c-\sqrt{D}}{2n},\qquad q_{\mathrm{M}}=\frac{b+2c+\sqrt{D}}{2n}.} \tag{3}$$

这两个根都为正，因为和、积均为正；又 $(1-p)(1-q)=a/n>0$ 且 $p+q<2$，所以两个根都小于 1。故 $D\ge 0$ 也足以保证合法。$D<0$ 时没有矩解。

(2) 对一次观测，记录 $0,1,2$ 的概率依次为

$$u=(1-p)(1-q),\qquad w=p+q-2pq,\qquad v=pq.$$

三者之和为 1，这次数据的似然与 $u^a w^b v^c$ 成正比. 先把 u,w,v 暂时看成任意三个非负且和为 1 的数. 当三者都为正时，由加权基本不等式，

$$\left(\frac{nu}{a}\right)^{a/n}\left(\frac{nw}{b}\right)^{b/n}\left(\frac{nv}{c}\right)^{c/n}\le \frac{a}{n}\frac{nu}{a}+\frac{b}{n}\frac{nw}{b}+\frac{c}{n}\frac{nv}{c}=1.$$

等号当且仅当 $u=a/n,\ w=b/n,\ v=c/n$. 有零概率时似然为 0，也不可能优于这一正值. 因而若这三个经验频率确实能由某个合法 (p,q) 产生，相应参数就是全局最大点. 第一问表明这恰好发生在 $D\ge 0$ 时，且满足 $p\le q$ 的参数唯一. 此时极大似然估计正是 (3).

再设 $D<0$. 因为允许的参数集合 $0\le p\le q\le 1$ 是闭且有界的，似然连续，必有最大点. $a,b,c>0$ 保证在 $p=q=1/2$ 处似然严格为正. 所以最大点不可能落在 $p=0$ 或 $q=1$ 的边上：前者使 $v=0$，后者使 $u=0$.

如果最大点还满足 $0<p<q<1$，就可以把上一问用过的和与积

$$s=p+q,\qquad t=pq$$

作为这点附近的两个变量. 这是合法的局部换元：由 $p<q$，二次方程 $z^2-sz+t=0$ 有两个不同实根，因而在 (s,t) 的一个小邻域中仍能确定满足 $0<p<q<1$ 的两个根. 在这些变量下

$$u=1-s+t,\qquad w=s-2t,\qquad v=t.$$

内部最大点必使对数似然 $\ell=a\log u+b\log w+c\log v$ 对 s,t 的一阶偏导数都为零，即

$$-\frac{a}{u}+\frac{b}{w}=0,\qquad \frac{a}{u}-\frac{2b}{w}+\frac{c}{v}=0.$$

两式给出 $a/u=b/w=c/v$，再利用 $u+w+v=1$ 得到

$$(u,w,v)=\left(\frac{a}{n},\frac{b}{n},\frac{c}{n}\right).$$

这将要求存在满足 $p\le q$ 的两个实根，与 $D<0$ 矛盾. 因此最大点只能落在 $p=q$ 这条边上.

令 $p=q=t$，$0\le t\le 1$. 此时似然为

$$L(t,t)=2^b t^{b+2c}(1-t)^{2a+b}$$

乘上一个与参数无关的正因子. 其对数导数在 $0<t<1$ 时与 $b+2c-2nt$ 同号，因而唯一最大点是

$$\boxed{p_{\mathrm{ML}}=q_{\mathrm{ML}}=\frac{b+2c}{2n}\qquad (D<0)}.$$

综上，$D\ge 0$ 时 MLE 与矩估计相同；$D<0$ 时矩方程无解，MLE 仍存在并落在两币概率相同的边界上。

2.6 相合性与大样本误差

一个估计量即使有偏, 也可能随着样本量增加而越来越接近参数. 为了准确表述这一点, 我们把针对样本量 n 构造的估计量记为 T_n, 考察它偏离目标超过固定误差 ε 的概率.

定义 2.7 相合估计量. 设 T_n 是由容量为 n 的样本得到的估计量. 若对每个 $\theta \in \Theta$ 及每个 $\varepsilon > 0$ 都有

$$\mathbb{P}_\theta\big(|T_n - g(\theta)| > \varepsilon\big) \longrightarrow 0 \qquad (n \to \infty),$$

则称 T_n 为 $g(\theta)$ 的**相合估计量**（也称一**致估计量**）. 记为 $T_n \xrightarrow{\mathbb{P}_\theta} g(\theta)$. 这是对每个固定参数的依概率收敛, 并不要求单次抽样所得估计值随着 n 增加而逐次单调变化.

命题 2.5 由均方误差得到相合性. 若对每个固定 $\theta \in \Theta$ 都有 $\mathrm{MSE}_\theta(T_n) \to 0$, 则 T_n 相合.

证明. 对任意 $\varepsilon > 0$, 由切比雪夫不等式的同类估计（直接对非负变量 $(T_n - g(\theta))^2$ 用 Markov 不等式）,

$$\mathbb{P}_\theta(|T_n - g(\theta)| > \varepsilon) \le \frac{\mathbb{E}_\theta (T_n - g(\theta))^2}{\varepsilon^2} \longrightarrow 0.$$

这就是相合性的定义.

两种均匀分布估计量. 对于独立 $U(0,\theta)$ 样本, 矩估计 $2\bar{X}$ 的方差为 $\theta^2/(3n)$, 又因其无偏, 均方误差同样趋于零, 所以它相合. 极大似然估计 $H_n = \max_i X_i$ 一般有偏, 但对 $0 < \varepsilon < \theta$,

$$\mathbb{P}_\theta(|H_n - \theta| > \varepsilon) = \mathbb{P}_\theta(H_n < \theta - \varepsilon) = \Big(1 - \frac{\varepsilon}{\theta}\Big)^n \longrightarrow 0.$$

当 $\varepsilon \ge \theta$ 时, 上述概率为 0. 因而 H_n 也相合. 两种估计依靠不同的数学性质趋于真参数.

很多时候, 参数不是某个矩本身, 而是它的函数. 如果 T_n 接近 c, 那么连续函数 $h(T_n)$ 也接近 $h(c)$. 这是后面研究渐近误差的基础.

命题 2.6 连续变换保持依概率收敛. 设 $T_n \xrightarrow{\mathbb{P}} c$, 函数 h 在 c 处连续且在 c 的某邻域有定义. 如果 $h(T_n)$ 在邻域外也已规定为合法数值, 则

$$h(T_n) \xrightarrow{\mathbb{P}} h(c).$$

证明. 给定 $\varepsilon > 0$, 由连续性可取 $\delta > 0$, 使 $|u - c| < \delta$ 时 $|h(u) - h(c)| < \varepsilon$. 因而

$$\mathbb{P}(|h(T_n) - h(c)| > \varepsilon) \le \mathbb{P}(|T_n - c| \ge \delta) \le \mathbb{P}(|T_n - c| > \delta/2) \longrightarrow 0.$$

这正是所需结论.

相合性只说明误差趋于零, 还不能说明它通常有多大. 对独立同分布样本均值, 中心极限定理给出了更精细的尺度: 误差乘以 $\sqrt{n}$ 后可能趋于一个非退化正态分布. 当参数估计是样本均值的函数时, 还可以用一阶导数确定误差放大多少倍.

命题 2.7 可微变换下的正态极限. 设 $T_n \xrightarrow{\mathbb{P}} c$, 且

$$\sqrt{n}(T_n - c) \xrightarrow{d} N(0, v), \qquad v \ge 0.$$

若 h 在 c 附近有定义并在 c 处可微, 且 $h(T_n)$ 在其余取值处已有合法定义, 则

$$\sqrt{n}\big(h(T_n) - h(c)\big) \xrightarrow{d} N\big(0, h'(c)^2 v\big).$$

证明. 当 $u \ne c$ 时, 记

$$r(u) = \frac{h(u) - h(c)}{u - c} - h'(c), \qquad r(c) = 0.$$

在 c 附近, 可微性说明 $r(u)\to 0$. 对已经补充定义 h 的其余值也按此式定义 r. 因而恒有

$$h(u)-h(c)=(u-c)\big[h'(c)+r(u)\big].$$

由 $T_n\xrightarrow{\mathbb{P}}c$ 及上一命题, 有 $r(T_n)\xrightarrow{\mathbb{P}}0$. 记 $Z_n=\sqrt{n}(T_n-c)$. 因为 Z_n 依分布收敛到有限随机变量, 对任意 $\eta>0$, 可以先取充分大的 M 使充分大 n 时 $\mathbb{P}(|Z_n|>M)<\eta$. 对 $\varepsilon>0$,

$$\mathbb{P}(|Z_nr(T_n)|>\varepsilon)\le\mathbb{P}(|Z_n|>M)+\mathbb{P}(|r(T_n)|>\varepsilon/M).$$

第二项趋于 0, 第一项可通过选取 M 任意缩小. 因而 $Z_nr(T_n)\xrightarrow{\mathbb{P}}0$. 此时

$$\sqrt{n}\big(h(T_n)-h(c)\big)=h'(c)Z_n+Z_nr(T_n).$$

还需要说明: 若 $U_n\xrightarrow{d}U$ 且 $V_n\xrightarrow{\mathbb{P}}0$, 则 $U_n+V_n\xrightarrow{d}U$. 事实上对任意 $\delta>0$ 及实数 x,

$$\mathbb{P}(U_n\le x-\delta)-\mathbb{P}(|V_n|>\delta)\le\mathbb{P}(U_n+V_n\le x)\le\mathbb{P}(U_n\le x+\delta)+\mathbb{P}(|V_n|>\delta).$$

在 U 的分布函数的连续点先令 $n\to\infty$, 再令 $\delta\downarrow 0$, 便得到该事实. 把它用于 $h'(c)Z_n$ 与 $Z_nr(T_n)$, 即得结论. 当 $v=0$ 或 $h'(c)=0$ 时, 极限是集中在 0 的一点分布, 证明同样成立.

定义 2.8　渐近方差.　若固定 θ 时有

$$\sqrt{n}\big(T_n-g(\theta)\big)\xrightarrow{d}N(0,V(\theta)),$$

则称 $V(\theta)$ 为估计量在 $\sqrt{n}$ 尺度下的**渐近方差**. 当 $V(\theta)>0$ 时, 它说明大样本估计误差具有 $1/\sqrt{n}$ 的尺度; 这个名称不表示有限样本方差恰等于 $V(\theta)/n$. 单靠依分布收敛, 也不能推断 $n\,\mathrm{Var}_\theta(T_n)$ 必然收敛到 $V(\theta)$.

例如 $X_i\sim\text{Bernoulli}(p)$, $0<p<1$, 则中心极限定理给

$$\sqrt{n}(\bar X-p)\xrightarrow{d}N(0,p(1-p)).$$

对 $h(x)=x^2$, 我们不必重新推导 $\bar X^2$ 的整个分布, 只要注意 $h'(p)=2p$, 就得到

$$\sqrt{n}(\bar X^2-p^2)\xrightarrow{d}N(0,4p^3(1-p)).$$

这也提醒我们: 要比较两种记录方式的估计精度, 必须先根据实际保留的记录推出各自的抽样分布, 再比较渐近方差.

例 2.5.　已知 $a>0$。设 $X_1,\dots,X_n$ 独立服从 $\mathrm{Exp}(\lambda)$（$\lambda>0$ 未知)。仪器对同一批寿命只记录

$$A=\#\{i:X_i>a\},\qquad B=\#\{i:X_i>2a\}.$$

1. 求仅根据 (A,B) 的全部极大似然估计，并与只记录 A 时的结果比较。

2. 对固定 $\lambda>0$，证明两种估计均一致，求其 $\sqrt{n}$-渐近方差，并比较大小。

当某次记录下极大似然估计不存在时，令相应估计量等于 $1/a$。

解.　记 $q=e^{-\lambda a}\in(0,1)$。对单个寿命，令 $U=\mathbf{1}_{\{X>a\}}$、$V=\mathbf{1}_{\{X>2a\}}$。由于指数分布的尾概率为 $e^{-\lambda t}$，三种可能的记录概率分别是

$$\mathbb{P}(U=0,V=0)=1-q,\quad\mathbb{P}(U=1,V=0)=q(1-q),\quad\mathbb{P}(U=1,V=1)=q^2.$$

这相当于连续进行两次成功概率为 q 的试验，一旦首次失败即停止：每个寿命必给出第一步记录，只有超过 a 才给出第二步记录。因此虽然 $B \le A$、二者并不独立，(A,B) 的似然仍可化简为

$$L(q) \;\propto\; (1-q)^{n-A}\,[q(1-q)]^{A-B}(q^2)^B = q^{A+B}(1-q)^{n-B}. \tag{1}$$

当 $0 < A+B$ 且 $B < n$ 时，对数似然的二阶导数为

$$-\frac{A+B}{q^2} - \frac{n-B}{(1-q)^2} < 0.$$

唯一驻点满足 $(A+B)(1-q) = (n-B)q$，即

$$\widehat{q}_{AB} = \frac{A+B}{n+A}, \qquad \boxed{\widehat{\lambda}_{AB} = -\frac{1}{a}\log\frac{A+B}{n+A}}. \tag{2}$$

当 $A = B = 0$ 时，$L(q) = (1-q)^n$ 在 $q \downarrow 0$ 时趋于上确界而不取到；当 $A = B = n$ 时，$L(q) = q^{2n}$ 在 $q \uparrow 1$ 时趋于上确界而不取到。由 $0 \le B \le A \le n$ 知，除此两种情形外 (2) 都是唯一 MLE。前者对应 $\lambda \to \infty$，后者对应 $\lambda \downarrow 0$，均不能称为有限参数下的 MLE。

若只记录 A，则 $A \sim \mathrm{Bin}(n,q)$；$0 < A < n$ 时唯一 MLE 为

$$\widehat{\lambda}_A = -\frac{1}{a}\log(A/n), \tag{3}$$

而 $A = 0$ 或 $A = n$ 时不存在 MLE。两种边界记录按题意另定义为 $1/a$。

(2) 记 $U_i = \mathbf{1}_{\{X_i > a\}}$、$V_i = \mathbf{1}_{\{X_i > 2a\}}$，于是 $A = \sum U_i$、$B = \sum V_i$，且

$$\mathbb{E}U_i = q, \qquad \mathbb{E}V_i = q^2.$$

由大数定律或切比雪夫不等式，$A/n \xrightarrow{\mathbb{P}} q$、$B/n \xrightarrow{\mathbb{P}} q^2$，故

$$\widehat{q}_{AB} = \frac{A/n + B/n}{1 + A/n} \xrightarrow{\mathbb{P}} q, \qquad A/n \xrightarrow{\mathbb{P}} q.$$

因为 $q \in (0,1)$, 两种记录落在无法取得 MLE 的边界上的概率均趋于零。函数 $u \mapsto -(\log u)/a$ 在 q 处连续，所以补充定义后的 $\widehat{\lambda}_{AB}$、$\widehat{\lambda}_A$ 均依概率收敛于 λ。

求渐近分布时，不必假设两个嵌套计数独立。将 (2) 直接移项，得到精确恒等式

$$\widehat{q}_{AB} - q = \frac{\sum_{i=1}^{n}[(1-q)U_i + V_i - q]}{n+A}. \tag{4}$$

令 $W_i = (1-q)U_i + V_i$。利用 $V_i \le U_i$、$U_iV_i = V_i$，有

$$\begin{aligned}
\mathbb{E}W_i &= (1-q)q + q^2 = q,\\
\mathrm{Var}(W_i) &= (1-q)^2 q(1-q) + q^2(1-q^2) + 2(1-q)q^2(1-q)\\
&= q(1-q)(1+q).
\end{aligned}$$

W_i 独立同分布且有界。由一元中心极限定理及 $(n+A)/n \xrightarrow{\mathbb{P}} 1+q$，(4) 给出

$$\sqrt{n}(\widehat{q}_{AB} - q) \xrightarrow{d} N\!\left(0, \frac{q(1-q)}{1+q}\right).$$

另一方面，$A \sim \mathrm{Bin}(n,q)$，故

$$\sqrt{n}(A/n - q) \xrightarrow{d} N(0, q(1-q)).$$

对 $h(u) = -(\log u)/a$ 利用刚证明的可微变换下的正态极限，$h'(q) = -1/(aq)$，得到

$$\boxed{\sqrt{n}(\widehat{\lambda}_{AB} - \lambda) \xrightarrow{d} N\left(0, \frac{1-q}{a^2 q(1+q)}\right)}, \qquad \boxed{\sqrt{n}(\widehat{\lambda}_{A} - \lambda) \xrightarrow{d} N\left(0, \frac{1-q}{a^2 q}\right)}.$$

两种极限正态分布的方差之比为

$$\boxed{\frac{V_{AB}}{V_A} = \frac{1}{1+q} = \frac{1}{1+e^{-\lambda a}} \in (1/2, 1)}.$$

因此，同一批寿命增加第二道阈值记录，总会严格降低渐近方差。这里比较的是 $\sqrt{n}$ 标准化估计的渐近方差，而非任意有限 n 的精确方差。

2.7 无偏估计与样本长度

无偏估计要求同一个统计量对参数空间内所有参数都有正确的期望. 有时, 只要观察轮数固定, 样本能够实现的期望函数就受到很强的限制.

以 n 次独立 Bernoulli(p) 试验为例. 无论统计量 $T(X_1, \ldots, X_n)$ 怎样设计, 只要它在有限样本空间的每种结果上取有限实数, 它的期望必为

$$\mathbb{E}_p T = \sum_{x \in \{0,1\}^n} T(x) p^{\sum_i x_i} (1-p)^{n - \sum_i x_i}.$$

右边是关于 p 的次数不超过 n 的多项式. 因而当参数空间为 $0 < p < 1$ 时, 不存在只用这 n 次观测、对所有 p 都无偏估计 $1/p$ 的统计量. 否则某个多项式 $Q(p)$ 将在 $(0,1)$ 上恒等于 $1/p$, 从而多项式 $pQ(p) - 1$ 有无限多个零点, 必为零多项式; 但代入 $p = 0$ 却得到 -1, 矛盾.

注意这个结论真正使用的是固定的有限样本空间. 如果试验可以一直进行到某个随机时刻才停止, 最终记录可能有无穷多种取值, 对期望的这种多项式限制便可能消失. 下一道习题正是让我们比较两种观察方式.

习题

习题 2.1. 设 $X_1, \ldots, X_n$ 独立服从 $U(0, \theta)$（$n \geq 2, \theta > 0$），记乘积 $P = \prod_{i=1}^n X_i$ 与最大值 $M = \max_i X_i$。

1. 分别求仅根据 P、仅根据 M 的极大似然估计。
2. 若估计量 $A(P)$、$B(M)$ 分别满足 $A(c^n p) = cA(p)$、$B(cm) = cB(m)$（任意 $c, p, m > 0$），求各自唯一的无偏形式，并证明 $\mathbb{E}_\theta[A(P) \mid M] = B(M)$，比较二者的方差。

习题 2.2. 设 $X_1,\dots,X_n$ 独立服从 $U(0,\theta)$，$\theta>0$，仪器只能记录整数部分 $Y_i=\lfloor X_i\rfloor$。记 $M_n=\max_i Y_i$，并令 $R_n=\#\{i:Y_i=M_n\}$。

1. 已知完整的整数记录，求 θ 的全部极大似然估计。

2. 若仪器只保存 M_n，重新求极大似然估计。对每个固定的 $\theta>1$，分别判断两种估计能否在 $n\to\infty$ 时一致，并说明理由。

习题 2.3. 给定不全相等的实数 $x_1,\dots,x_n$，记 $M_j=n^{-1}\sum_{i=1}^n x_i^j$。

(1) 求唯一的两点分布 $\mathbb{P}(Y=a)=p$、$\mathbb{P}(Y=b)=1-p$，其中 $a<b$、$0<p<1$，使 $\mathbb{E}Y^j=M_j$（$j=1,2,3$），并证明 $a,b\in[\min_i x_i,\max_i x_i]$。

(2) 比较 $\mathbb{E}Y^4$ 与 M_4，并确定等号成立的全部情形。

习题 2.4. 设 $n\ge 2$，$X_1,\dots,X_n$ 独立服从 $U(0,\theta)$，其中 $\theta>0$ 未知。只记录最大的两个观测值之差 $D_n=X_{(n)}-X_{(n-1)}$。

1. 求 θ 的极大似然估计和形如 c_nD_n 的无偏估计量。

2. 当 $n\to\infty$ 时，判断这两个估计量是否一致。

习题 2.5. 每轮独立取 $X\sim\mathrm{Exp}(\theta)$、$Y\sim\mathrm{Exp}(1)$，只记录 $K=\lfloor X/Y\rfloor$，其中 $\theta>0$ 未知，不同轮相互独立。

1. 一轮记录为 $K=k\ge 0$ 时，求 θ 的全部极大似然估计。

2. 对任意固定的 $n\ge 1$，证明只根据 n 轮记录 $K_1,\dots,K_n$ 不可能构造 θ 的无偏估计量；但 $1/(1+\theta)$ 可以无偏估计。

习题 2.6. 一枚正面概率为 $p\in(0,1)$ 的硬币反复抛掷，直到首次出现与第一面不同的结果。记此前连续相同的次数为 R，但不记录正反面。各轮试验独立重复。令 $t=p(1-p)$。

1. 证明：无论独立观察多少个 R，都不能无偏估计 p；但只观察一次 R 就能无偏估计 t。

2. 若每轮只保留 R 的奇偶性，证明固定任意轮数都不能无偏估计 t，但可以一致估计它。若允许借助独立的公平硬币随机决定观测何时结束，构造一个有界的 t 的无偏估计量，并证明平均所用轮数不超过 $3/2$。

习题 2.7. 设 $n\ge 2$，$X_1,\dots,X_n$ 独立服从密度 $\mathbf{1}_{\{\theta\le x\le\theta+1\}}$，$\theta\in\mathbb{R}$。记 $m_n=\min_i X_i$、$M_n=\max_i X_i$。

(1) 在所有 $T_{n,c}=cm_n+(1-c)(M_n-1)$（$0\le c\le 1$，$c$ 不依赖样本或 θ）中，求对每个 θ 均使均方误差最小的 c 及最小值，并证明所选估计量是一致的 MLE。

(2) 求所选估计误差乘以 n 后的极限分布，并与一阶矩估计 $\bar X-1/2$ 的收敛尺度比较。

第三章　无偏构造与估计量比较

3.1　从参数的平方谈起

第二章中，我们用样本均值估计总体均值。但实际问题要估计的量未必就是参数本身。例如，一枚硬币正面出现的概率为 p，我们有时关心连续两次都出现正面的概率 p^2。已经知道 p 的无偏估计量，并不等于把它平方就能得到 p^2 的无偏估计量。

设 $X_1,\dots,X_n$ 为独立同分布的伯努利随机变量，且 $n\ge 2$。由

$$\mathbb{E}_p\bar X = p,\qquad \mathsf{Var}_p(\bar X)=\frac{p(1-p)}{n}$$

可知

$$\mathbb{E}_p\bar X^2 = p^2+\frac{p(1-p)}{n}.$$

所以 $\bar X^2$ 通常高估 p^2。可是取两次不同的观测，独立性给出

$$\mathbb{E}_p(X_1X_2)=\mathbb{E}_pX_1\,\mathbb{E}_pX_2=p^2.$$

这样就得到了一个无偏估计量。对 n 个观测，既然任取两个不同位置都有相同的期望，自然可以尝试把这些乘积平均起来，希望在保持无偏的同时减小估计的波动。

这种办法不限于伯努利分布。设 $X_1,\dots,X_n$ 独立同分布，$\mathbb{E}X_i=\mu$，$\mathbb{E}X_i^2<\infty$。仍有

$$\mathbb{E}\bar X^2=\mu^2+\frac{\sigma^2}{n},\qquad \sigma^2=\mathsf{Var}(X_1).$$

要消除后一项，可以利用不同观测的乘积，也可以利用第一章的样本方差 S^2，因为 $\mathbb{E}S^2=\sigma^2$。下面的例题把这两种表示联系起来，并比较估计量的方差。

例 3.1.　设 $X_1,\dots,X_n$ 独立同分布，$n\ge 2$，且 $\mathbb{E}X_i=\mu$、$\mathbb{E}X_i^2<\infty$。令

$$T=X_1X_2,\qquad U=\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.$$

(1) 证明 T,U 都是 μ^2 的无偏估计量，且 $\mathsf{Var}(U)\le\mathsf{Var}(T)$。

(2) 证明 $U=\bar X^2-S^2/n$，其中 $S^2=(n-1)^{-1}\sum_i(X_i-\bar X)^2$。由此说明只保留 $(\bar X,S^2)$ 时 U 仍可恢复，而 T 一般不能恢复。

解.　(1) 因为 X_1,X_2 独立，

$$\mathbb{E}T=\mathbb{E}X_1\mathbb{E}X_2=\mu^2.$$

对每个 $i\neq j$ 同样有 $\mathbb{E}(X_iX_j)=\mu^2$，所以 $\mathbb{E}U=\mu^2$。

方差比较不需要展开所有协方差。对任意已经实现的样本 $x_1,\dots,x_n$，令

$$y_{ij}=x_ix_j-\mu^2\qquad (i\neq j).$$

有限个实数的平方满足“平均的平方不超过平方的平均”，故

$$\left(\frac{1}{n(n-1)}\sum_{i\neq j}y_{ij}\right)^2\le\frac{1}{n(n-1)}\sum_{i\neq j}y_{ij}^2.$$

左边就是 $(U-\mu^2)^2$。对随机样本取期望，右边各项与 $(X_1X_2-\mu^2)^2$ 同分布，于是

$$\mathbb{E}(U-\mu^2)^2 \le \mathbb{E}(T-\mu^2)^2.$$

两者都无偏，所以这正是 $\mathsf{Var}(U) \le \mathsf{Var}(T)$。

(2) 由

$$\left(\sum_i X_i\right)^2 = \sum_i X_i^2 + \sum_{i\neq j} X_iX_j$$

以及

$$(n-1)S^2 = \sum_i X_i^2 - n\bar{X}^2$$

得到

$$\sum_{i\neq j} X_iX_j = n^2\bar{X}^2 - \big((n-1)S^2 + n\bar{X}^2\big) = (n-1)(n\bar{X}^2 - S^2).$$

除以 $n(n-1)$，

$$\boxed{U = \bar{X}^2 - \frac{S^2}{n}.}$$

因此只知道 $\bar{X}, S^2$，仍能精确算出 U。

而 $T = X_1X_2$ 取决于原来的观测顺序。以 $n=3$ 为例，样本 $(-1,0,1)$ 与 $(-1,1,0)$ 有相同的 $\bar{X}$ 与 S^2，但前者 $X_1X_2=0$，后者 $X_1X_2=-1$。所以仅凭 $(\bar{X}, S^2)$ 一般不能求出 T。与 T 相比，U 既有不增的方差，也只需要两个样本统计量便能计算。

如果目标由 μ^2 变成 μ^3 或更高次幂，同样可以把来自不同观测的随机变量相乘。这里真正重要的是独立性：X_1^3 的期望一般不是 μ^3，而 $X_1X_2X_3$ 的期望恰好是 μ^3。

命题 3.1　不依赖总体分布的高阶无偏估计.　设 $r \ge 1$ 是整数，$n \ge 1$。对所有满足 $\mathbb{E}|X_1|^r < \infty$ 的独立同分布实随机样本 $X_1, \dots, X_n$，希望用一个不依赖未知总体分布、只由样本计算的统计量，无偏估计 $(\mathbb{E}X_1)^r$。这样的统一估计公式存在，当且仅当 $n \ge r$。

证明.　当 $n \ge r$ 时，记 $\mu = \mathbb{E}X_1$，并取

$$U_r = \frac{1}{n(n-1)\cdots(n-r+1)} \sum_{\substack{1\le i_1,\dots,i_r\le n \\ i_1,\dots,i_r \text{ 两两不同}}} X_{i_1}\cdots X_{i_r}.$$

求和中的每项都由 r 次不同的独立观测组成，其期望为 μ^r。由 $\mathbb{E}|X_1|^r < \infty$ 可得 $\mathbb{E}|X_1| < \infty$，再由独立性知每个乘积绝对可积。因此 $\mathbb{E}U_r = \mu^r$。

为证明 $n < r$ 时不可能存在对所有总体分布都适用的公式，只须考察其中最简单的一族分布：$X_i \sim \mathsf{Bernoulli}(p)$，$0<p<1$。对任一不含 p 的统计量 $T = t(X_1,\dots,X_n)$，按全部 2^n 种样本取值求期望，

$$\mathbb{E}_pT = \sum_{(x_1,\dots,x_n)\in\{0,1\}^n} t(x_1,\dots,x_n)p^{x_1+\cdots+x_n}(1-p)^{n-x_1-\cdots-x_n}.$$

右边是次数不超过 n 的多项式。当 $r > n$ 时，它不可能在整个区间 $0<p<1$ 上恒等于 p^r。因而这样的统计量不存在。

这个命题回答的是：不知道总体属于哪一个具体分布族时，是否存在同一套无偏估计公式？如果事先知道总体属于某个分布族，还可以利用该分布特有的关系构造估计量。下一节就会看到这样的例子。

3.2 利用总体分布的特殊性质

设 $X \sim \text{Poisson}(\lambda)$，$\lambda \geq 0$。它的均值为 λ。对 λ^2 而言，直接使用 X^2 会多出方差项，因为

$$\mathbb{E}_\lambda X^2 = \lambda^2 + \lambda.$$

把 X^2 改成 $X(X-1)$，正好把这一项消去：

$$\mathbb{E}_\lambda[X(X-1)] = \lambda^2.$$

后一个等式可以直接从泊松分布的概率公式推出；它不仅解释了二次情形，还给出了所有正整数次幂的构造办法。

命题 3.2 泊松分布的阶乘矩. 设 $X \sim \text{Poisson}(\lambda)$，$\lambda \geq 0$。对整数 $r \geq 1$，记

$$(X)_r = X(X-1)\cdots(X-r+1).$$

则 $\mathbb{E}_\lambda (X)_r = \lambda^r$。

证明. 先设 $\lambda > 0$。当 $X < r$ 时，$(X)_r = 0$；其余取值按泊松概率公式计算，

$$\begin{aligned}\mathbb{E}_\lambda (X)_r &= \sum_{k=r}^{\infty} \frac{k!}{(k-r)!} e^{-\lambda}\frac{\lambda^k}{k!} \\ &= \lambda^r \sum_{j=0}^{\infty} e^{-\lambda}\frac{\lambda^j}{j!} = \lambda^r.\end{aligned}$$

各项非负，求和合法。当 $\lambda = 0$ 时，$X = 0$ 的概率为 1，两边也都等于零。

例如，单次泊松观测的 $(X)_2$ 就能无偏估计 λ^2。这不违背上一节的结论，因为这里已知 X 服从泊松分布，无偏性只需在 $\lambda \geq 0$ 这一个分布族中成立。

不同的无偏估计量可能具有不同方差。如果两个估计量都对同一个目标无偏，那么它们的任何固定线性组合只要系数之和为 1，仍然无偏。因而还可以在这些组合中比较哪一个更稳定。这里说系数固定，是指计算公式不得使用未知的参数。

例 3.2. 设 X, Y 独立且均服从 $\text{Poisson}(\lambda)$，$\lambda \geq 0$。记 $(z)_2 = z(z-1)$，并定义

$$T_1 = XY, \qquad T_2 = \frac{(X)_2 + (Y)_2}{2}.$$

(1) 证明 T_1, T_2 都是 λ^2 的无偏估计量。对实数 c，令 $T_c = cT_1 + (1-c)T_2$，求使 $\text{Var}(T_c)$ 最小的 c 及最小方差。

(2) 将最优估计量只用 $S = X + Y$ 表示，并直接由 S 的分布重新证明其无偏性。

解. (1) 由独立性，$\mathbb{E}(XY) = \lambda^2$；泊松分布的阶乘矩给出 $\mathbb{E}(X)_2 = \mathbb{E}(Y)_2 = \lambda^2$. 因此 T_1, T_2 都无偏.

下面先比较二者的方差. 由 $\mathbb{E}X^2 = \lambda^2 + \lambda$,

$$\text{Var}(T_1) = \mathbb{E}X^2\mathbb{E}Y^2 - \lambda^4 = 2\lambda^3 + \lambda^2.$$

对于非负整数 x, 展开两边的多项式可得

$$[(x)_2]^2 = (x)_4 + 4(x)_3 + 2(x)_2.$$

因此

$$\mathrm{Var}((X)_2) = 4\lambda^3 + 2\lambda^2.$$

X, Y 独立，故

$$\mathrm{Var}(T_2) = \frac{\mathrm{Var}((X)_2) + \mathrm{Var}((Y)_2)}{4} = 2\lambda^3 + \lambda^2 = \mathrm{Var}(T_1).$$

两个无偏估计量有相同方差时, 取它们的平均尤其自然. 令

$$A = \frac{T_1 + T_2}{2}, \qquad B = \frac{T_1 - T_2}{2}.$$

因为

$$\mathrm{Cov}(A, B) = \frac{\mathrm{Var}(T_1) - \mathrm{Var}(T_2)}{4} = 0,$$

而 $T_c = A + (2c-1)B$, 所以

$$\mathrm{Var}(T_c) = \mathrm{Var}(A) + (2c-1)^2 \mathrm{Var}(B) \geq \mathrm{Var}(A).$$

当 $\lambda > 0$ 时，B 并非常数：$(X, Y) = (0, 0)$ 时 $B = 0$，而 $(X, Y) = (2, 0)$ 时 $B = -1/2$，这两种结果都有正概率. 故 $\mathrm{Var}(B) > 0$，等号只在 $\boxed{c = 1/2}$ 时成立.

(2) 写 $S = X + Y$. 直接整理,

$$A = \frac{1}{2}XY + \frac{1}{4}\{X(X-1) + Y(Y-1)\} = \boxed{\frac{S(S-1)}{4}}.$$

对每个整数 $k \geq 0$，由独立性和二项式定理,

$$\begin{aligned}\mathbb{P}(S = k) &= \sum_{j=0}^{k} \mathbb{P}(X = j)\mathbb{P}(Y = k - j) \\ &= e^{-2\lambda}\frac{\lambda^k}{k!}\sum_{j=0}^{k}\binom{k}{j} = e^{-2\lambda}\frac{(2\lambda)^k}{k!}.\end{aligned}$$

因此 $S \sim \mathrm{Poisson}(2\lambda)$. 于是

$$\mathbb{E}A = \frac{(2\lambda)^2}{4} = \lambda^2,$$

从 $\mathrm{Var}((S)_2) = 4(2\lambda)^3 + 2(2\lambda)^2$ 又有

$$\boxed{\min_c \mathrm{Var}(T_c) = \mathrm{Var}(A) = 2\lambda^3 + \frac{\lambda^2}{2}} \qquad (\lambda > 0).$$

当 $\lambda = 0$ 时 $X = Y = 0$ 几乎必然, 所有 T_c 方差均为 0，任意 $c \in \mathbb{R}$ 都最优. 上述最优值公式在 $\lambda = 0$ 时仍成立.

3.3 对称化与条件平均

独立抽样后，如果统计量还依赖一个人为加入的随机选择，就可以尝试把这个选择带来的波动消去。

先看最简单的情形。设 X_1, X_2 独立同分布，具有有限方差 σ^2，并且期望都是 μ。抽样后，再独立抛一次公平硬币：正面时用 X_1 估计 μ，反面时用 X_2 估计 μ。两种选择都无偏，但这样得到的估计量 T 还多了抛币带来的随机性。不再抛币而直接使用

$$T^* = \frac{X_1 + X_2}{2},$$

同样无偏，方差却只有 $\sigma^2/2$，而 T 的方差为 σ^2。这个变化来自平均，不是来自增加观测次数；两种做法看到的都是同一份 (X_1, X_2)。

更一般地，对某份已经得到的数据 d，若有 m 个可能选择，分别算出实数 $t_1(d), \dots, t_m(d)$，选择第 j 种的概率为 $w_j > 0$ 且 $\sum_j w_j = 1$，那么在完成随机选择之前，可以直接计算它们的加权平均 $\sum_j w_j t_j(d)$。平均之后的平方误差不大于原随机选择的平均平方误差。这一事实只用到初等恒等式。

命题 3.3　消去独立随机选择不会增大均方误差.　设 D 是已取得的数据，J 与 D 独立，且 $\mathbb{P}(J = j) = w_j > 0$ $(1 \le j \le m)$，$\sum_{j=1}^m w_j = 1$。已知函数 t_j 使每个 $t_j(D)$ 都有有限二阶矩。对某个固定的目标值 $g \in \mathbb{R}$，定义

$$T = t_J(D), \qquad T^* = \sum_{j=1}^m w_j t_j(D).$$

则 $\mathbb{E}T^* = \mathbb{E}T$，且

$$\mathbb{E}(T^* - g)^2 \le \mathbb{E}(T - g)^2.$$

等号成立当且仅当 $t_1(D), \dots, t_m(D)$ 以概率 1 全部相等。

证明.　先把数据固定为 d，记 $a_j = t_j(d) - g$，$\bar{a} = \sum_j w_j a_j$。展开平方得

$$\sum_{j=1}^m w_j (a_j - \bar{a})^2 = \sum_{j=1}^m w_j a_j^2 - \bar{a}^2 \ge 0.$$

这就是说，对这份数据先取平均再计算平方误差，不会超过先计算各选择的平方误差再加权平均。由于 J 独立于 D，对数据再次取期望便得到

$$\mathbb{E}(T^* - g)^2 \le \sum_j w_j \mathbb{E}(t_j(D) - g)^2 = \mathbb{E}(T - g)^2.$$

同样由独立性及期望的线性性，

$$\mathbb{E}T = \sum_j w_j \mathbb{E}t_j(D) = \mathbb{E}T^*.$$

前面的非负平方和为零，当且仅当所有 $t_j(d)$ 相等。因每个权重严格为正，取期望后的等号条件也恰好如此。

如果 T 本来对目标 $g(\theta)$ 无偏，那么 T^* 也无偏，上述均方误差比较就成为方差比较。从概率论的角度，T^* 正是先给定 D、再对额外选择 J 求平均得到的条件期望 $\mathbb{E}(T \mid D)$。这里的公式完全由有限求和定义，不需要更一般的条件期望理论。

另一个常见平均办法是对称化。对独立同分布样本 $X_1,\dots,X_n$，把一个估计公式依次用于所有可能的下标排列，再将结果平均。如果原估计量无偏，各个排列后的统计量也无偏；平方的平均不小于平均的平方，所以这种对称化不会增加均方误差。第一节的跨下标乘积平均便是这一思想的具体表现。

例 3.3. 设 $(X_1,Y_1),\dots,(X_n,Y_n)$ 独立同分布，$n\ge 2$，同一对中的 X_i,Y_i 允许相关，且 $\mathbb{E}(X_i^2+Y_i^2)<\infty$。记 $\mu=\mathbb{E}X_i$、$\nu=\mathbb{E}Y_i$。

(1) 从样本中只保留

$$A=\sum_i X_i,\qquad B=\sum_i Y_i,\qquad C=\sum_i X_iY_i.$$

构造 $\mu\nu$ 的无偏估计量。

(2) 若进一步只保留 A,B，说明第 (1) 问的估计量一般不能由记录恢复。

解. 由柯西不等式，$\mathbb{E}|X_iY_i|\le\sqrt{\mathbb{E}X_i^2\mathbb{E}Y_i^2}<\infty$，故 C 可积。

(1) 直接用同一对的 X_iY_i 会混入未知协方差；真正稳定的是不同下标。展开

$$AB-C=\sum_{i,j}X_iY_j-\sum_i X_iY_i=\sum_{i\ne j}X_iY_j.$$

当 $i\ne j$ 时，X_i 与 Y_j 来自不同独立样本对，因此独立，并且

$$\mathbb{E}(X_iY_j)=\mathbb{E}X_i\mathbb{E}Y_j=\mu\nu.$$

这样的有序对共有 $n(n-1)$ 个，所以

$$\boxed{U=\frac{AB-C}{n(n-1)}}$$

满足 $\mathbb{E}U=\mu\nu$。这里同一对内部是否相关完全不影响证明。

(2) 只给 A,B 时，C 一般不能恢复。以 $n=2$ 为例，两组具体数据

$$((0,0),(1,1)),\qquad((0,1),(1,0))$$

都有 $A=B=1$。第一组 $C=1$，故 $U=0$；第二组 $C=0$，故 $U=1/2$。于是相同的 (A,B) 对应不同的 U，只知道 (A,B) 便无法唯一算出第 (1) 问的估计量。

这证明的是第 (1) 问的具体估计公式无法仅由 A,B 恢复；它本身并未证明其他形式的无偏估计量也不存在。

有时我们不保留每个观测值，只保留和、平方和、极值等统计量。一个估计公式能否从这些数值算出来，可以直接检查：若两份原始样本给出相同的保留数据，却让这个公式取不同值，就不可能仅凭保留数据计算该公式。这个判断只涉及这一个估计公式能否恢复，不能据此直接断言不存在其他无偏估计量。

不过，如果在某个模型中，保留数据 R 的分布与未知参数 θ 完全无关，那么每个只依赖 R 且期望存在的统计量，其期望也与 θ 无关。这时它就不可能无偏估计一个随 θ 变化的目标 $g(\theta)$。习题 3.8 会用到这个更强的判断。

3.4 均方误差与最坏情况

无偏性要求估计量的期望等于真实目标，但这并不保证它在每份样本上都更接近真实值。第二章已经证明，对具有有限二阶矩的估计量 T，有

$$\mathrm{MSE}_\theta(T) = \mathrm{Var}_\theta(T) + \big(\mathbb{E}_\theta T - g(\theta)\big)^2.$$

后一项是偏差的平方。稍微引入一些偏差，有时能够显著减小方差，因而改善均方误差。

例如 $X_1, \dots, X_n$ 独立服从 $\mathrm{Bernoulli}(p)$，以 $\bar X$ 估计 p 时无偏，均方误差为 $p(1-p)/n$。如果改用

$$T = \frac{1}{2}\bar X + \frac{1}{4},$$

则 $\mathbb{E}_p T - p = (1/2 - p)/2$，并且

$$\mathrm{MSE}_p(T) = \frac{p(1-p)}{4n} + \frac{(p-1/2)^2}{4}.$$

在 $p = 1/2$ 处，这个估计量的均方误差是 $1/(16n)$，小于 $\bar X$ 的 $1/(4n)$；可是在 $p = 0$ 处，它的均方误差为 $1/16$，反而大于 $\bar X$ 的零误差。因而说一个估计量“更好”，必须先说明按什么标准比较。

一种标准是考虑所有可能参数中最大的均方误差。设 Θ 为参数空间，称

$$R_{\max}(T) = \sup_{\theta \in \Theta} \mathrm{MSE}_\theta(T)$$

为估计量的**最大风险**或**最坏均方误差**。它的值可以是 $+\infty$。选择使这个数尽可能小的估计量，叫作按最坏情况进行比较。这与只在某一个固定参数值下比较方差是不同的问题。

还有一种常见比较：我们已经有几个无偏估计量，希望在预先指定的线性组合范围内让方差最小。例如，若 Y_1, Y_2 独立，都以 θ 为期望，方差分别为已知的 $v_1, v_2 > 0$，则

$$\mathrm{Var}\big(tY_1 + (1-t)Y_2\big) = t^2 v_1 + (1-t)^2 v_2 = (v_1 + v_2)\left(t - \frac{v_2}{v_1 + v_2}\right)^2 + \frac{v_1 v_2}{v_1 + v_2}.$$

因此两个观测的权重应与各自方差成反比。同样的原则可以推广到任意有限个独立估计量。

命题 3.4　已知方差的最小方差线性无偏组合。　设 $Y_1, \dots, Y_m$ 相互独立，$\mathbb{E}Y_i = \theta$，方差 $\mathrm{Var}(Y_i) = v_i > 0$ 均为已知常数。在全部 $T = \sum_{i=1}^m a_i Y_i$ 中，要求系数 a_i 是事先固定的实数并且 $\sum_i a_i = 1$。则唯一使方差最小的估计量为

$$T_* = \frac{\sum_{i=1}^m Y_i / v_i}{\sum_{i=1}^m 1/v_i}, \qquad \mathrm{Var}(T_*) = \frac{1}{\sum_{i=1}^m 1/v_i}.$$

证明.　独立性给出 $\mathrm{Var}(T) = \sum_i a_i^2 v_i$。由柯西不等式，

$$1 = \left(\sum_i a_i\right)^2 \le \left(\sum_i a_i^2 v_i\right)\left(\sum_i v_i^{-1}\right).$$

所以 $\mathrm{Var}(T) \ge (\sum_i v_i^{-1})^{-1}$。取 $a_i = v_i^{-1} / \sum_j v_j^{-1}$ 时等号成立。反过来，柯西不等式的等号要求所有 $a_i v_i$ 相等；再结合 $\sum_i a_i = 1$，便得到唯一的这一组权重。

最后一个例题把抽样次数本身也纳入设计。即使目标函数和每次观测的分布都很简单，允许事先独立随机决定样本量，也可能出现固定次数抽样时意想不到的估计方式；得到估计量之后，我们再按最坏均方误差检验它是否真的值得采用。

例 3.4. 一枚硬币每次掷出正面的概率为未知的 $p \in [0,1]$。允许在掷币前独立地随机决定一个非负整数 N（其分布不能依赖 p），随后独立掷币 N 次。若所有结果均为反面，记 $T=1$；否则记 $T=0$。约定 $N=0$ 时也记 $T=1$。

(1) 求使 T 对 $g(p)=1/(1+p)$ 在整个 $[0,1]$ 上无偏的全部 N 的分布，并求此时 $\mathbb{E}N$。

(2) 求 T 的最大均方误差，与不进行任何观察而恒取估计值 $3/4$ 的最大均方误差比较。

解. 令 $a_k=\mathbb{P}(N=k)$，$k=0,1,2,\ldots$。这里 N 的分布预先选好，与 p 无关。给定 $N=k$，全部 k 次掷币都是反面的概率为 $(1-p)^k$；当 $k=0$ 时这个概率也是 1。因此

$$\mathbb{E}_pT=\mathbb{P}(T=1)=\sum_{k=0}^{\infty}a_k(1-p)^k.$$

要使它对所有 $p\in[0,1]$ 都等于 $1/(1+p)$，令 $t=1-p$，就要求

$$\sum_{k=0}^{\infty}a_kt^k=\frac{1}{2-t}=\sum_{k=0}^{\infty}\frac{t^k}{2^{k+1}},\qquad 0\le t\le 1. \tag{1}$$

后一个等式来自等比级数。由此可以猜出，也确实得到一种可行分布：

$$\boxed{\mathbb{P}(N=k)=2^{-k-1}\quad(k=0,1,2,\ldots).} \tag{2}$$

它的概率和为 1，代入上式即得到所需无偏性。

还须证明这是唯一可行分布。设另有一组概率 a_k 满足 (1)，记 $c_k=a_k-2^{-k-1}$，于是 $\sum_{k\ge0}|c_k|\le 2$,且 $\sum_{k\ge0}c_kt^k=0(0\le t\le 1)$。先取 $t=0$ 得 $c_0=0$。如果已知 $c_0=\cdots=c_{m-1}=0$，则对 $0<t<1$，将等式除以 t^m，得到

$$0=c_m+\sum_{k=m+1}^{\infty}c_kt^{k-m}.$$

后面的级数绝对值不超过 $t\sum_{k>m}|c_k|\le 2t$，故令 $t\downarrow 0$ 便有 $c_m=0$。依次类推，全部 c_k 都为零，所以 (2) 唯一。

在这个分布下，$\mathbb{P}(N\ge m)=2^{-m}$（$m\ge1$）。将非负整数 N 写成 $\sum_{m\ge1}\mathbf{1}_{\{N\ge m\}}$，用非负项求和，得到

$$\boxed{\mathbb{E}N=\sum_{m=1}^{\infty}2^{-m}=1.}$$

(2) T 只取 $0,1$，而且对 $g(p)$ 无偏，所以

$$\mathrm{MSE}_p(T)=\mathrm{Var}_p(T)=g(p)(1-g(p))=\frac{p}{(1+p)^2}.$$

由 $(1-p)^2\ge0$ 可得 $4p\le(1+p)^2$，等号当且仅当 $p=1$，故

$$\boxed{\sup_{0\le p\le1}\mathrm{MSE}_p(T)=\frac14.}$$

若不观察硬币而恒取 $T_0=3/4$，则 $g(p)=1/(1+p)$ 在 $[0,1]$ 上的取值恰为 $[1/2,1]$，因此

$$\boxed{\sup_{0\le p\le1}\mathrm{MSE}_p(T_0)=\max\left\{\left(\frac34-\frac12\right)^2,\left(\frac34-1\right)^2\right\}=\frac{1}{16}.}$$

随机选样本量使 T 实现了无偏估计，但这里恒取 $3/4$ 的估计量虽然有偏，最大均方误差反而更小。

习题

习题 3.1. 设 $N = 2m \geq 4$，$X_1, \ldots, X_N$ 独立服从 $U(0,1)$。观察全部数据后，独立地将 N 个有编号的位置等可能地分成 m 对。每对取两个数中较小的那个，记这些较小数的平均值为 T。再令 T_* 为固定原数据后，对全部可能配对所得 T 的平均值。

(1) 只用次序统计量 $X_{(1)} \leq \cdots \leq X_{(N)}$ 表示 T_*。

(2) 求 $\mathsf{Var}(T)$ 与 $\mathsf{Var}(T_*)$，证明 T_* 的方差严格小于 T 的方差。

习题 3.2. (X_i, Y_i)（$1 \leq i \leq n$，$n \geq 3$）为独立同分布样本，且 $\mathbb{E}(X_1^4 + Y_1^4) < \infty$。从所有无固定点置换中等概率抽取 Π，独立于样本。只保留

$$C = \sum_i X_i Y_i, \qquad D = \sum_i X_i Y_{\Pi(i)}.$$

(1) 只用 C, D 构造 $\mathsf{Cov}(X_1, Y_1)$ 的无偏估计量。(2) 若可以读取完整样本，对全部无固定点置换作平均，证明新估计量方差不会增大，并写出其显式形式。

习题 3.3. 一个容量为 N 的总体中有 M 个“成功”单位，$N \geq n \geq 2$ 已知，M 未知。无放回简单随机抽取 n 个单位，记样本中的成功数为 K，并记 $p = M/N$。

(1) 只用 K 构造 p^2 的无偏估计量。

(2) 求 $(K/n)^2$ 估计 p^2 的偏差，并指出何时偏差为 0。

习题 3.4. $X_1, \ldots, X_n$ 独立服从 $U(a, a+\theta)$，$n \geq 2$，其中 $a \in \mathbb{R}$ 与 $\theta > 0$ 均未知。只保留 $L = \min_i X_i$ 与 $H = \max_i X_i$。(1) 在所有 $uH + vL + w$（系数只能依赖 n）中，求对 θ 无偏的全部估计量，并求其方差。(2) 若 a 已知，只用 H 构造 θ 的无偏估计量；比较两种观测要求下的方差。

习题 3.5. 设 $X_1, \ldots, X_n$ 独立服从 $\mathsf{Bernoulli}(p)$，$Y_1, \ldots, Y_n$ 独立服从 $\mathsf{Bernoulli}(q)$，两组相互独立，$n \geq 2$，$p, q \in [0,1]$。只保留成功次数 $K = \sum_i X_i$、$L = \sum_i Y_i$。

(1) 构造只依赖 (K, L) 的 $(p-q)^2$ 的无偏估计量。

(2) 证明不存在对所有 $(p, q) \in [0,1]^2$ 都无偏、且在每份可能记录上都非负的估计量。

习题 3.6. 设 $n \geq 2$. 对每个 $i = 1, \ldots, n$，有同一批次的两次读数

$$Y_i = \mu + U_i + \varepsilon_i, \qquad Z_i = \mu + U_i + \eta_i.$$

其中 U_i 独立同分布于 $N(0, \tau^2)$，ε_i, η_i 独立同分布于 $N(0, \sigma^2)$，上述全部随机变量相互独立，$\mu \in \mathbb{R}$、$\tau^2 > 0$、$\sigma^2 > 0$ 均未知. 记

$$C = \frac{1}{n-1} \sum_{i=1}^{n} (Y_i - \bar{Y})(Z_i - \bar{Z}).$$

(1) 证明 C 对 τ^2 无偏. 利用两次读数的差值具有已知期望 0 这一信息，构造另一个对 τ^2 无偏的估计量 T，使其对所有允许的参数均满足 $\mathsf{Var}(T) < \mathsf{Var}(C)$，并求 $\mathsf{Var}(C) - \mathsf{Var}(T)$ 的精确表达式.

(2) 若每批只保留两次读数的和 $S_i = Y_i + Z_i$，证明不存在仅依赖 $S_1, \ldots, S_n$、对全部参数可积且对 τ^2 无偏的估计量.

习题 3.7. 设 $X_1,\dots,X_n$ 独立服从均值为 $\theta>0$ 的指数分布，即密度为 $\theta^{-1}e^{-x/\theta}$（$x>0$），$n\ge 2$。比较下面两个 θ^2 的无偏估计量的方差：

$$A_n=\frac{1}{2n}\sum_{i=1}^{n}X_i^2,\qquad B_n=\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.$$

确定哪一个更好，并说明样本量为何会改变答案。

习题 3.8. $X_i=\mu+\sigma Z_i$（$1\le i\le n$，$n\ge 2$），其中 Z_i 独立同分布，$\mathbb{E}Z_i=0$、$\mathsf{Var}(Z_i)=1$，$\mu\in\mathbb{R},\sigma>0$ 未知。假设只观察到 $D_i=X_i-X_1$（$2\le i\le n$）与 $W=X_1+\varepsilon$，其中 ε 独立于样本，均值为 0，方差为已知的 $\tau^2>0$。(1) 在所有系数不依赖未知参数的线性仿射估计量 $T=aW+\sum_{i=2}^{n}b_iD_i+c$ 中，求对每个 (μ,σ) 无偏且方差最小的全部估计量。(2) 如果 W 也被删除，证明任一仅依赖差值的可积估计量都不可能对所有 μ 无偏。

第四章　假设检验的概率逻辑

4.1　假设检验：先确定要控制哪一种错误

设想连续抛一枚正面概率未知的硬币十次，记正面次数为 S。我们想判断这枚硬币是否更容易出现正面。参数 p 是固定而未知的数，数据 S 则是随机的。若观察到 $S=9$，我们有理由怀疑 $p>1/2$；但即使 $p=1/2$，十次中出现九次正面仍有可能。统计检验要做的，就是把这种判断变成一个可以计算错误概率的规则。

定义 4.1　统计假设与检验.　在参数空间 Θ 中，取两个互不相交的非空集合 Θ_0,Θ_1，分别提出

$$H_0:\theta\in\Theta_0,\qquad H_1:\theta\in\Theta_1.$$

H_0 称为**原假设**（也称零假设），H_1 称为**备择假设**。若 Θ_0 只包含一个参数值，原假设称为**简单假设**；若包含多个值，称为**复合假设**。一个**非随机化检验**是事先规定的决定规则：观察数据后，或者拒绝 H_0，或者不拒绝 H_0。所有会导致拒绝的样本结果组成**拒绝域** C。下文讨论的拒绝事件均假设在所给概率模型下有定义。

例如，检验 $H_0:p\le 1/2$ 对 $H_1:p>1/2$ 时，可以规定 $S\ge 8$ 就拒绝。此时拒绝域是 $\{S\ge 8\}$；拒绝与否完全由观察到的十次结果决定。这个规则在参数 p 下的拒绝概率为

$$\pi(p)=\mathbb{P}_p(S\ge 8)=\sum_{j=8}^{10}\binom{10}{j}p^j(1-p)^{10-j}.$$

这是一个随参数改变的函数，而不是单独的常数。

定义 4.2　两类错误、检验功效与显著性水平.　对拒绝域 C，记 $\pi_C(\theta)=\mathbb{P}_\theta(C)$，称为检验的**功效函数**。当 $\theta\in\Theta_0$ 时，拒绝原假设属于**第一类错误**，其概率为 $\pi_C(\theta)$；当 $\theta\in\Theta_1$ 时，不拒绝原假设属于**第二类错误**，其概率为 $1-\pi_C(\theta)$。在备择参数下，$\pi_C(\theta)$ 称为该检验的**功效**。

检验的**实际显著性水平**定义为

$$\mathsf{size}(C)=\sup_{\theta\in\Theta_0}\pi_C(\theta).$$

给定 $0<\alpha<1$，如果 $\mathsf{size}(C)\le\alpha$，就称这个检验**水平不超过** α。上确界表示原假设允许的全部参数中最大的错误风险；它未必在参数空间里取到。名称中的“显著性”并不是数据看起来有多显眼，而是对第一类错误作出的概率保证。

对刚才的硬币检验，为什么计算 $p=1/2$ 就足够？给定十个相互独立的 $U(0,1)$ 随机数 $U_1,\dots,U_{10}$，对任意 p 定义

$$S(p)=\sum_{i=1}^{10}\mathbf{1}_{\{U_i\le p\}}.$$

每个 $S(p)$ 都服从 $\mathsf{Bin}(10,p)$；当 $p\le 1/2$，同一次构造中总有 $S(p)\le S(1/2)$。因此 $\{S(p)\ge 8\}\subseteq\{S(1/2)\ge 8\}$。这个检验的实际水平恰为

$$\pi(1/2)=\frac{\binom{10}{8}+\binom{10}{9}+\binom{10}{10}}{2^{10}}=\frac{7}{128}.$$

于是它是水平不超过 0.06 的检验，却不是水平不超过 0.05 的检验。在备择 $p=0.7$ 下，它的功效是 $\pi(0.7)$，第二类错误概率是 $1-\pi(0.7)$。制定水平时通常先限定第一类错误的最坏概率，再在这一限制下争取较大的功效。

命题 4.1　上尾检验的单调比较.　设 T 是由样本计算出的统计量。若能在同一概率空间内构造一族随机变量 T_θ，分别具有参数 θ 时 T 的分布，并对每个 $\theta \in \Theta_0$ 满足 $T_\theta \le T_*$（概率为 1），则对任意实数 c，

$$\mathbb{P}_\theta(T > c) \le \mathbb{P}(T_* > c) \qquad (\theta \in \Theta_0).$$

如果 T_* 恰好是某个原假设参数 $\theta_* \in \Theta_0$ 下的统计量，那么规则 $T > c$ 的实际水平就是 $\mathbb{P}_{\theta_*}(T > c)$。

证明.　在上述构造中，$\{T_\theta > c\} \subseteq \{T_* > c\}$。取概率得到不等式。右边若来自允许的 θ_*，就既是统一上界又是实际可取的拒绝概率，所以等于上确界。

同样的想法可用于正态模型：若 $X_1, \dots, X_n$ 独立服从 $N(\mu, 1)$，检验 $\mu \le 0$ 对 $\mu > 0$，写 $X_i = \mu + Z_i$，其中 Z_i 独立服从 $N(0,1)$，便有

$$\sqrt{n}\,\overline{X} = \sqrt{n}\mu + \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Z_i.$$

所以对规则 $\sqrt{n}\,\overline{X} > c$，零假设内拒绝概率随 μ 增大，在 $\mu = 0$ 处最大，实际水平为 $1 - \Phi(c)$。这里 Φ、ϕ 分别表示标准正态分布函数、密度，Φ^{-1} 表示 Φ 的反函数。

4.2　根据数据选方向，必须重新计算拒绝概率

单侧检验的临界值通常是在检验方向已经确定的前提下选取的。例如 $Z \sim N(0,1)$、$c = \Phi^{-1}(1-\alpha)$，则 $\mathbb{P}(Z > c) = \alpha$。但如果看见 Z 为正就考察上尾，看见 Z 为负就考察下尾，并在相应一侧超过 c 时拒绝，那么真正的拒绝事件是 $|Z| > c$。当 $0 < \alpha < 1/2$ 时，它的概率为 2α。同一个 Z 的边缘分布并未改变；改变的是利用数据选方向后，整个规则的拒绝事件。

有时选方向使用另一份数据。有无问题就取决于两份数据之间的关系：若方向由与检验统计量独立的随机数决定，错误率可以保持原样；如果两者相关，就必须计算它们的联合概率。下面的例题研究从独立选方向逐渐过渡到完全使用同一份数据的情形。

例 4.1.　在原假设成立时，设 X, Y 相互独立，均服从 $N(0,1)$。对 $0 \le \rho \le 1$，令

$$Z_\rho = \rho X + \sqrt{1-\rho^2}\,Y.$$

观察 X 后按以下规则决定是否拒绝原假设：若 $X > 0$，在 $Z_\rho > d$ 时拒绝；若 $X \le 0$，在 $Z_\rho < -d$ 时拒绝，其中 $d > 0$。

1. 固定 $0 < \alpha < 1/2$，取 $c = \Phi^{-1}(1-\alpha)$。证明以 $d = c$ 为临界值时，实际拒绝概率随 ρ 严格增大，并求两端的概率。

2. 为使实际拒绝概率恰为 α，证明每个 ρ 对应唯一的 $d = d_\rho > 0$，且 d_ρ 随 ρ 严格增大。分别求 $d_0, d_{1/\sqrt{2}}, d_1$。

解.　令 $s = \sqrt{1-\rho^2}$，先考虑 $0 \le \rho < 1$。作正交变换

$$Z = \rho X + sY, \qquad V = sX - \rho Y.$$

它把二维标准正态密度变成 $\phi(z)\phi(v)$，故 Z, V 独立且均为标准正态，并且 $X = \rho Z + sV$。对 $z \in \mathbb{R}$，

$$\mathbb{P}(X > 0 \mid Z = z) = \Phi\Big(\frac{\rho z}{s}\Big).$$

因为 (X,Z) 与 $(-X,-Z)$ 同分布，两个拒绝分支概率相等，故最终规则的实际拒绝概率为

$$R_\rho(d)=2\int_d^\infty \phi(z)\Phi\left(\frac{\rho z}{\sqrt{1-\rho^2}}\right)\,\mathrm{d}z \qquad (0\le\rho<1). \tag{1}$$

当 $\rho=1$ 时 $Z_1=X$，拒绝事件就是 $|X|>d$，因此

$$R_1(d)=2[1-\Phi(d)]. \tag{2}$$

这也与 (1) 在 $\rho\uparrow 1$ 时的极限一致：积分区间 $z\ge d>0$，被积因子 $\Phi(\rho z/s)$ 趋于 1，且它由 1 控制。

(1) 由于 $c>0$, 对任意 $z\ge c$, 函数 $\rho\mapsto\Phi(\rho z/\sqrt{1-\rho^2})$ 在 $[0,1)$ 上严格递增。因 $\phi(z)>0$, 积分 (1) 严格递增；再由极限和式 (2)，严格性也包含右端点 $\rho=1$。$\rho=0$ 时方向来自独立的 X 而检验仅用 Y，所以

$$\boxed{R_0(c)=\alpha,\qquad R_1(c)=2\alpha,\qquad R_\rho(c)\text{ 随}\rho\text{ 严格递增.}}$$

(2) 对每个 $\rho\in[0,1]$，$R_\rho(d)$ 在 $d>0$ 上连续、严格递减，且 $d\to\infty$ 时趋于 0。由 (1) 及 $\Phi(\rho z/s)\ge 1/2$，$\rho<1$ 时 $R_\rho(0)\ge 1/2$，而 $R_1(0)=1$。由于 $0<\alpha<1/2$，介值定理给出唯一的 $d_\rho>0$ 使 $R_\rho(d_\rho)=\alpha$。

若 $\rho_1<\rho_2$，在 $d_{\rho_1}>0$ 处由第一问的严格单调性有 $R_{\rho_2}(d_{\rho_1})>\alpha$；而 R_{ρ_2} 随 d 严格下降，故 $d_{\rho_2}>d_{\rho_1}$。

由 (1) 在 $\rho=0$ 时得 $R_0(d)=1-\Phi(d)$；由 (2) 得 $R_1(d)=2[1-\Phi(d)]$。当 $\rho=1/\sqrt{2}$ 时，$\rho/s=1$，于是

$$R_{1/\sqrt{2}}(d)=2\int_d^\infty \phi(z)\Phi(z)\,\mathrm{d}z=1-\Phi(d)^2.$$

分别令三式等于 α，得到

$$\boxed{d_0=\Phi^{-1}(1-\alpha),\qquad d_{1/\sqrt{2}}=\Phi^{-1}(\sqrt{1-\alpha}),\qquad d_1=\Phi^{-1}(1-\alpha/2).}$$

这些阈值确为正数，且严格递增。此处校准的是经过选方向和数据复用后的完整规则；仅知道 Z_ρ 单独服从标准正态，并不足以用 $\Phi^{-1}(1-\alpha)$ 直接控制第一类错误。

4.3 复合假设与不同参数下的样本范围

复合原假设要求对多个可能的参数同时控制错误概率，而有些模型还会随着参数改变样本的可能取值。以 $X\sim U(0,\theta)$、$\theta>0$ 为例，考虑 $H_0:\theta\ge 1$ 对 $H_1:\theta<1$。规则“$X<1/4$ 时拒绝”在任意 $\theta\ge 1$ 下的拒绝概率都是 $1/(4\theta)$，因此水平为 $1/4$；在 $\theta<1/4$ 下则一定拒绝。这一简单比较已经说明，原假设中最不利的参数可能恰在边界。

对于 n 个独立的 $U(0,\theta)$ 样本，联合密度在立方体 $(0,\theta)^n$ 内等于 θ^{-n}。因此，任给由样本决定的拒绝事件 C，只要其概率有定义，便有（$0<\theta<1$）

$$\mathbb{P}_\theta(C)=\frac{\mathbb{P}_1\big(C\cap\{\max_i X_i<\theta\}\big)}{\theta^n}.$$

右边可以把所有拒绝规则放到同一个 $U(0,1)$ 参考分布下比较，不必先猜它应当是哪种几何形状。这正是下一题构造最优检验的关键。

例 4.2. 设 $n \geq 1$，$X_1, \ldots, X_n$ 独立服从 $U(0,\theta)$，其中 $\theta > 0$ 未知。检验 $H_0 : \theta \geq 1$ 对 $H_1 : \theta < 1$。给定 $0 < \alpha < 1$，在所有水平不超过 α、由完整样本决定且拒绝概率有定义的非随机化检验中，构造一个对每个 $\theta < 1$ 都具有最大功效的规则。证明任何同样对所有备择参数达到最大功效的规则，在 $\theta = 1$ 下几乎必然与它作出相同决定。

解. 令 $A_t = \{\max_{1\leq i\leq n} X_i < t\}$，其中 $0 < t \leq 1$。对任意拒绝事件 C，只要它在各参数下的概率有定义，当 $0 < \theta < 1$ 时，联合密度的比较给出

$$\mathbb{P}_\theta(C) = \frac{\mathbb{P}_1(C \cap A_\theta)}{\theta^n}. \tag{1}$$

这一步没有对 C 的形状作任何限制：在 $\theta = 1$ 的模型下，落入 $(0,\theta)^n$ 的概率是 θ^n，而落入其中某个拒绝部分的概率正是 θ^n 乘以参数 θ 下的拒绝概率。

因为 $\theta = 1$ 属于原假设，水平不超过 α 必须满足 $\mathbb{P}_1(C) \leq \alpha$。由 (1) 与概率的单调性，对任意 $0 < \theta < 1$，

$$\mathbb{P}_\theta(C) = \frac{\mathbb{P}_1(C \cap A_\theta)}{\theta^n} \leq \frac{\min\{\mathbb{P}_1(C), \mathbb{P}_1(A_\theta)\}}{\theta^n} \leq \min\left\{1, \frac{\alpha}{\theta^n}\right\}. \tag{2}$$

因此这是所有合格检验的功效上界，而不只是对某种阈值规则的估计。

令 $c = \alpha^{1/n}$，取

$$\boxed{C_* = A_c = \left\{\max_i X_i < c\right\}.}$$

若 $\theta \geq 1$，其拒绝概率为 $(c/\theta)^n \leq \alpha$，且在 $\theta = 1$ 时等于 α。若 $\theta < 1$，功效为

$$\mathbb{P}_\theta(C_*) = \begin{cases} 1, & 0 < \theta \leq c, \\ (c/\theta)^n = \alpha/\theta^n, & c < \theta < 1. \end{cases}$$

这恰好在每个备择参数下达到 (2)，故完成构造。

再证唯一性。若另一个合格拒绝事件 C 在每个 $0 < \theta < 1$ 下都达到 (2)，那么对于任何 $\theta < c$，它必须在参数 θ 下以概率 1 拒绝。由 (1)，

$$\mathbb{P}_1(A_\theta \setminus C) = \theta^n \mathbb{P}_\theta(A_\theta \setminus C) = 0.$$

取一列 $\theta_j \uparrow c$，事件 A_{θ_j} 递增，且其并恰为 A_c。由概率的连续性，因此

$$\mathbb{P}_1(A_c \setminus C) = 0.$$

另一方面 $\mathbb{P}_1(A_c) = \alpha$，且 $\mathbb{P}_1(C) \leq \alpha$。将 C 分成 $C \cap A_c$ 与 $C \setminus A_c$ 两个互不相交的部分，就有

$$\mathbb{P}_1(C \setminus A_c) = 0.$$

所以在 $\theta = 1$ 的分布下，C 与 C_* 作出不同决定的概率为零。反之，在 $(0,1)^n$ 外改动规则并不一定仍保持对所有 $\theta \geq 1$ 的水平约束，因此唯一性只针对题目指定的 $\theta = 1$ 概率意义。

4.4 用尾概率表示证据：p 值

指定一个拒绝域能完成一次检验，但我们常常希望从已观察的统计量直接看出：需要把名义水平设到多大，才会拒绝？对“统计量越大越支持备择”的问题，很自然地计算原假设下取得不小于观测值的概率，这便引出上尾 p 值。

例如独立抛四次硬币，检验 $H_0: p \le 1/2$ 对 $H_1: p > 1/2$，以正面次数 S 为统计量。对观测 $S = k$，在边界参数 $p = 1/2$ 下计算

$$p(k) = \mathbb{P}_{1/2}(S \ge k).$$

当 $k = 0, 1, 2, 3, 4$，它们依次为 $1, 15/16, 11/16, 5/16, 1/16$。于是若实际观察到四次全为正面，$p$ 值是 $1/16$；若事先规定在 p 值不超过 0.1 时拒绝，实际拒绝事件就只有 $S = 4$。在 $p = 1/2$ 下，这个事件的概率为 $1/16$，小于名义水平 0.1。这就是离散检验常见的保守性。

定义 4.3　合法的 p 值.　对原假设 $H_0: \theta \in \Theta_0$，设 P 是根据观测数据计算出的、取值于 $[0, 1]$ 的统计量。如果对任意 $\theta \in \Theta_0$ 和任意 $0 \le u \le 1$ 都有

$$\mathbb{P}_\theta(P \le u) \le u, \tag{4.1}$$

就称 P 是该原假设的**合法 p 值**。由定义可知，对预先指定的 $0 < \alpha < 1$，规则 $P \le \alpha$ 的水平不超过 α。p 值刻画的是在原假设规定的分布下数据有多极端，并不是原假设本身为真的概率。

命题 4.2　有限离散分布的上尾 p 值.　设在一个完全指定的参考分布下，统计量 T 的可能值为 $t_1 < \cdots < t_m$，且 $a_j = \mathbb{P}(T = t_j) > 0$、$\sum_{j=1}^m a_j = 1$。令

$$p(t_j) = \mathbb{P}(T \ge t_j) = \sum_{\ell=j}^{m} a_\ell.$$

则 $p(T)$ 是该参考分布下的合法 p 值。

证明.　因为 $a_j > 0$，$p(t_j)$ 随 j 严格下降。固定 $0 \le u \le 1$：若所有 $p(t_j) > u$，则 $\{p(T) \le u\}$ 不可能发生；否则取满足 $p(t_j) \le u$ 的最小指标 j_u，那么

$$\mathbb{P}\{p(T) \le u\} = \mathbb{P}(T \ge t_{j_u}) = p(t_{j_u}) \le u.$$

两种情况均符合定义。证明也表明了为什么应当把与观测值相等的那部分概率计入尾部。

只有在整个原假设下满足 (4.1)，这个值才可以用于复合假设。若原假设为 $p \le 1/2$，上面的四次抛币公式之所以仍有效，是因为在同一组独立均匀随机数下，$S(p) \le S(1/2)$，从而任何上尾事件在 $p \le 1/2$ 下的概率都不超过边界参数下的概率。

命题 4.3　复合原假设的上尾校准.　设检验统计量 T 和参考统计量 T_* 都取值于同一个有限有序集合 $t_1 < \cdots < t_m$。若对每个 $\theta \in \Theta_0$、每个 j 都有

$$\mathbb{P}_\theta(T \ge t_j) \le \mathbb{P}_*(T_* \ge t_j), \tag{4.2}$$

则将观测值 T 代入参考分布的上尾函数 $p_*(t_j) = \mathbb{P}_*(T_* \ge t_j)$，得到的 $p_*(T)$ 在整个原假设下合法。

证明.　固定 $0 \le u < 1$。若参考尾概率中没有不超过 u 的值，结论立即成立。否则取最小的 j_u，使 $p_*(t_{j_u}) \le u$。尾概率随 j 非增，所以

$$\{p_*(T) \le u\} = \{T \ge t_{j_u}\}.$$

据此

$$\mathbb{P}_\theta\{p_*(T) \le u\} \le \mathbb{P}_*(T_* \ge t_{j_u}) = p_*(t_{j_u}) \le u.$$

当 $u = 1$ 时结论显然成立。

这个命题把检验分成了清楚的两步：先找一个能控制全部原假设参数上尾概率的参考分布，再用参考分布的尾概率把观测统计量换成 p 值。参考分布并不总是通过独立性得到：如果两组数据之间可能有关联，计算它们的最大值所需的联合分布也可能改变。下一题比较已知独立和未知组间关系这两种情况。

例 4.3. 两组各进行 $n \ge 1$ 次 Bernoulli(p) 试验，每组内部相互独立，只公布两组成功次数中的较大者 M。检验 $H_0 : p \le p_0$，其中 $0 < p_0 < 1$。

1. 若两组也相互独立, 求只依赖 M 的精确上尾 p 值, 并说明为什么直接使用一次 $\mathrm{Bin}(n, p_0)$ 的上尾会失效。

2. 若不再假定两组之间独立，求对所有这样的联合方式都有效、且随 M 非增的逐点最小 p 值，证明它不能再减小。

解. 设 $B \sim \mathrm{Bin}(n, p_0)$，对整数 $0 \le k \le n$ 记

$$u_k = \mathbb{P}(B \ge k), \qquad u_0 = 1.$$

由于 $0 < p_0 < 1$，u_k 随 k 严格下降，且 $0 < u_k < 1$（$1 \le k \le n$）。对任意 $p \le p_0$，把每组的 Bernoulli 变量用独立的均匀随机数与阈值 p 耦合，就知道该组的成功次数随 p 逐点不减。因此，每组在零假设下的上尾概率不超过 u_k；这个结论不需要两组之间独立。

(1) 若两组独立，在 $p = p_0$ 时两组成功次数 S_1, S_2 独立且均服从 B 的分布。因而

$$\mathbb{P}_{p_0}(M \ge k) = 1 - (1 - u_k)^2 = 2u_k - u_k^2.$$

于是仅依赖观测 M 的精确上尾 p 值是

$$\boxed{P_{\mathrm{ind}}(M) = 2u_M - u_M^2.}$$

这个量在整个 H_0 下有效：两组独立时用同一批独立均匀随机数随参数 p 单调耦合，可得 $M(p) \le M(p_0)$；再对离散上尾用最小拒绝阈值证明超均匀性即可。若错把 M 当成一次二项观测，使用 u_M，则取名义水平 u_k（$k \ge 1$）时实际拒绝概率为 $2u_k - u_k^2 > u_k$；超出量为 $u_k(1 - u_k) > 0$。

(2) 当组间联合方式未知时，独立公式不能使用。但对每个 k，并事件上界给出

$$\mathbb{P}_p(M \ge k) = \mathbb{P}_p(S_1 \ge k \text{ 或 } S_2 \ge k) \le \min\{1,\, 2u_k\} \qquad (p \le p_0).$$

故

$$\boxed{P_{\mathrm{rob}}(M) = \min\{1,\, 2u_M\}}$$

是一个合法的 p 值。事实上，任给 $0 \le \alpha < 1$，若不存在 k 使 $\min(1, 2u_k) \le \alpha$，拒绝事件为空；否则取满足条件的最小 k。由于 u_k 递减，事件 $\{P_{\mathrm{rob}}(M) \le \alpha\}$ 恰是 $\{M \ge k\}$，其概率不超过 $2u_k \le \alpha$。$\alpha = 1$ 时结论自明。

证明常数 2 的校准在每个可能的 M 上都不可减小，不能只用并事件上界。先固定任意 $k \ge 1$，在 $p = p_0$ 处构造一种允许的组间依赖。记 $F(j) = \mathbb{P}(B \le j)$，令 $Q(v) = \min\{j : F(j) \ge v\}$ 为二项分布的分位数函数。取 $U \sim U(0, 1)$，并令

$$S_1 = Q(U), \qquad S_2 = Q\big((U + 1/2) \bmod 1\big).$$

这里把 $U+1/2$ 取小数部分，端点取值不影响概率。两个计数分别服从 $\mathrm{Bin}(n,p_0)$；对于任何给定计数 $S_i=s$，在该组的 $\binom{n}{s}$ 个成功位置集合中独立地均匀选取一个。如此构造的每一组内部仍是独立 $\mathrm{Bernoulli}(p_0)$ 试验，因为任一含 s 个成功的位置序列的概率为

$$\frac{\binom{n}{s}p_0^s(1-p_0)^{n-s}}{\binom{n}{s}}=p_0^s(1-p_0)^{n-s}.$$

所以该构造确属题目允许的联合方式。

在这个耦合中，事件 $S_1\ge k$ 对应圆周上的一个长度为 u_k 的区间；事件 $S_2\ge k$ 则是它平移半圈的像。若 $u_k\le 1/2$，两区间除端点外不相交；若 $u_k\ge 1/2$，两区间的并覆盖整个圆周。因此

$$\boxed{\mathbb{P}_{p_0}(M\ge k)=\min\{1,2u_k\}} \tag{*}$$

对所有 k 同时成立。这给出了最坏依赖关系的真正取等构造。

最后设 $g(M)\in[0,1]$ 是另一种随 M 非增，且对所有允许的 p 与组间联合方式均有效的 p 值规则。假设某个 k 满足 $g(k)<\min(1,2u_k)$，则可取 $g(k)<\alpha<\min(1,2u_k)$。由单调性，$\{M\ge k\}\subseteq\{g(M)\le\alpha\}$；在上面的耦合及 $p=p_0$ 下，由 $(*)$ 得

$$\mathbb{P}(g(M)\le\alpha)\ge\min(1,2u_k)>\alpha,$$

与有效性矛盾。$k=0$ 时合法性直接迫使 $g(0)=1$，因为 $M\ge 0$ 恒成立；亦与公式一致。故 P_{rob} 在题目要求的整个单调规则类中逐点最小。

两组独立时的校准为 $2u-u^2$，不知组间关系时须用 $\min(1,2u)$，后者对 $0<u<1$ 严格更大。这里的“逐点最小”仅指由 M 决定、随 M 非增、对所有组间依赖有效的 p 值，不能扩张为任意使用更丰富记录或预先规定其他检验形状的规则。

4.5 离散检验为何有时需要随机化

离散统计量的尾概率是一档一档跳变的。以两次独立抛公平硬币为例，若见到两次正面才拒绝，那么拒绝概率为 $1/4$；若再将“一次正面”全部列入拒绝域，概率一下子变为 $3/4$。因此用非随机规则不可能把实际水平调整到两者之间的任意数。

允许在边界记录出现时按一个事先规定的概率拒绝，就可以控制这种跳变。例如希望水平恰为 0.3，我们可以在 $S=2$ 时必定拒绝，在 $S=1$ 时以概率 0.1 拒绝，在 $S=0$ 时不拒绝。公平硬币下的拒绝概率恰为 $1/4+0.1\times 1/2=0.3$。这一规则随成功次数单调，因此对于 $H_0:p\le 1/2$ 也具有相同的实际水平。

定义 4.4　随机化检验.　对每份可能的观测数据 r，预先指定一个拒绝概率 $\varphi(r)\in[0,1]$；得到数据后，再独立产生 $U\sim U(0,1)$，当 $U\le\varphi(r)$ 时拒绝原假设。这样的规则称为**随机化检验**。它在参数 θ 下的拒绝概率为

$$\pi_\varphi(\theta)=\mathbb{E}_\theta\varphi(R),\qquad \mathrm{size}(\varphi)=\sup_{\theta\in\Theta_0}\mathbb{E}_\theta\varphi(R),$$

其中 R 表示实际观测数据。第一个等式来自：给定 $R=r$，独立均匀随机数满足 $U\le\varphi(r)$ 的概率正好是 $\varphi(r)$，再对所有数据取平均。若 φ 只取 0 或 1，便回到非随机化检验。

前面的例子说明随机化可以把水平补到指定数值，但还没有说明这样的补法是否具有最大功效。对伯努利试验，成功次数越多越支持 $p>p_0$；在限制原假设拒绝概率的前提下，先把拒绝机会安排给成功次数大的记录，才可能获得最大功效。下一题要求证明这种直觉，而且允许竞争检验使用完整的逐次试验序列。

例 4.4. 独立进行 $n \geq 1$ 次 Bernoulli(p) 试验，检验 $H_0 : p \leq p_0$ 对 $H_1 : p > p_0$，其中 $0 < p_0 < 1$。给定 $0 < \alpha < 1$，允许用与样本独立的随机数决定是否拒绝。

1. 构造一个只依赖成功次数 S、显著性水平恰为 α 的检验。
2. 证明它对每个 $p > p_0$ 的功效，在所有可以使用完整试验序列的水平不超过 α 的检验中均为最大；并刻画全部达到相同功效的检验。

解. 记 $T(j) = \mathbb{P}_{p_0}(S \geq j)$（$0 \leq j \leq n$），$T(n+1) = 0$。由于 $0 < p_0 < 1$，存在唯一 $k \in \{1, \dots, n+1\}$ 满足

$$T(k) \leq \alpha < T(k-1).$$

设

$$\gamma = \frac{\alpha - T(k)}{\mathbb{P}_{p_0}(S = k-1)} \in [0, 1), \qquad \varphi_*(s) = \begin{cases} 0, & s \leq k-2, \\ \gamma, & s = k-1, \\ 1, & s \geq k. \end{cases}$$

规则为：观测到 $S = s$ 时以概率 $\varphi_*(s)$ 拒绝。特别地，$k = n+1$ 时仅在 $S = n$ 上随机拒绝，$k = 1$ 时可在 $S = 0$ 上随机拒绝。在 $p = p_0$ 时，拒绝概率为 $T(k) + \gamma \mathbb{P}_{p_0}(S = k-1) = \alpha$。取独立的 $U_1, \dots, U_n \sim U(0,1)$，令 $S(p) = \sum_i \mathbf{1}_{\{U_i \leq p\}}$。当 $p \leq p_0$ 时逐样本有 $S(p) \leq S(p_0)$，而 φ_* 单调不减，故

$$\mathbb{E}_p \varphi_*(S) \leq \mathbb{E}_{p_0} \varphi_*(S) = \alpha.$$

因此该检验的显著性水平恰为 α。

证明第二问时，不能预先假定竞争检验只依赖 S。任取一个允许随机化的检验，把对完整序列 $x = (x_1, \dots, x_n) \in \{0,1\}^n$ 的拒绝概率记为 $\psi(x) \in [0,1]$。设 $s(x) = \sum_i x_i$，并定义

$$\overline{\psi}(s) = \frac{1}{\binom{n}{s}} \sum_{x:\, s(x) = s} \psi(x), \qquad 0 \leq s \leq n.$$

对 $0 < p < 1$，给定 $S = s$ 后，所有有 s 个正面的序列等可能，其概率均为 $\binom{n}{s}^{-1}$。故

$$\mathbb{E}_p \psi(X_1, \dots, X_n) = \mathbb{E}_p \overline{\psi}(S).$$

$p = 1$ 时此等式也成立, 因为仅有全成功序列。由于原检验水平不超过 α, 特别有 $\mathbb{E}_{p_0} \overline{\psi}(S) \leq \alpha$。

固定任意 $p_1 \in (p_0, 1)$。成功次数为 s 时的两种概率之比为

$$L(s) = \frac{p_1^s (1-p_1)^{n-s}}{p_0^s (1-p_0)^{n-s}}, \qquad \frac{L(s+1)}{L(s)} = \frac{p_1(1-p_0)}{p_0(1-p_1)} > 1.$$

由于 $L(s)$ 随 s 严格增大，在给定 p_0 下，每份拒绝机会放在较大的 s 上，会换来更大的 p_1 下的功效。临界处需要随机化，故把 $s = k-1$ 的概率比作为比较基准，令 $c = L(k-1) > 0$。将 $\mathbb{E}_{p_1} f(S) = \mathbb{E}_{p_0}[L(S) f(S)]$ 用于 $f = \varphi_* - \overline{\psi}$，得到恒等式

$$\begin{aligned} &\mathbb{E}_{p_1} \varphi_*(S) - \mathbb{E}_{p_1} \overline{\psi}(S) \\ &\quad = c\big(\alpha - \mathbb{E}_{p_0} \overline{\psi}(S)\big) + \mathbb{E}_{p_0}\big[(L(S) - c)(\varphi_*(S) - \overline{\psi}(S))\big]. \end{aligned}$$

第一项非负。第二项在 $s \leq k-2$ 时，两个因子都非正；在 $s \geq k$ 时，两个因子都非负；在 $s = k-1$ 时第一因子为零。因此第二项也非负，证明了对每个 $p_1 \in (p_0, 1)$ 的功效最优性。对

$p_1 = 1$，由有限状态下拒绝概率关于 p 的连续性取极限，同样成立。这一论证直接比较了任意完整记录规则，未调用一般最强检验定理。

最后刻画等号。固定任意 $p_1 \in (p_0, 1)$，因 L 严格递增，且二项分布在 $s = 0, \dots, n$ 的各点均有正概率，上式取等当且仅当

$$\mathbb{E}_{p_0}\overline{\psi}(S) = \alpha, \qquad \overline{\psi}(s) = \varphi_*(s) \quad (s \neq k-1).$$

再由第一式和 $\mathbb{E}_{p_0}\varphi_*(S) = \alpha$ 得 $\overline{\psi}(k-1) = \gamma$。反之，只要对所有 s 都有 $\overline{\psi}(s) = \varphi_*(s)$，两检验在每个参数下的拒绝概率就完全相同，必为最优。因此全部最优规则恰由下述条件刻画：

$$\begin{cases} \psi(x) = 0, & s(x) \le k-2, \\ \psi(x) = 1, & s(x) \ge k, \\ \dfrac{1}{\binom{n}{k-1}} \displaystyle\sum_{x:\, s(x)=k-1} \psi(x) = \gamma. \end{cases}$$

特别地，对仅依赖 S 的检验，最优规则唯一；允许利用完整序列时，若 $0 < \gamma < 1$ 且 $1 \le k-1 \le n-1$，边界层中的不同序列可以分配不同的拒绝概率，只需平均为 γ，所以最优规则并不唯一。若没有这样的边界自由度，则逐序列规则唯一。这个区别来自条件等可能性，而非两个不同的最优功效值。

4.6 条件检验与置信界的反演

有时数据分析分两步进行：先按一项已经观察到的信息分组，再在各组内计算各自的检验概率。此时需要说明：每组内的规则都有效，能否保证把各组混合起来以后仍然有效？答案直接来自已经学过的全概率公式。

命题 4.4　分组后的有效性可以合并。　设 S 是根据试验得到的一个统计量，只有有限个或可数多个可能值。对于每个 $\theta \in \Theta_0$、每个 $0 \le u \le 1$，假设每当 $\mathbb{P}_\theta(S = s) > 0$ 时都有

$$\mathbb{P}_\theta(P \le u \mid S = s) \le u.$$

那么 P 在整个原假设下是合法的 p 值。

证明.　固定 $\theta \in \Theta_0$ 和 u。只对概率为正的组使用条件概率，全概率公式给出

$$\begin{aligned} \mathbb{P}_\theta(P \le u) &= \sum_{s:\, \mathbb{P}_\theta(S=s)>0} \mathbb{P}_\theta(P \le u \mid S = s)\mathbb{P}_\theta(S = s) \\ &\le u \sum_{s:\, \mathbb{P}_\theta(S=s)>0} \mathbb{P}_\theta(S = s) = u. \end{aligned}$$

所需结论随之成立。

例如先独立抛一枚公平硬币，正面时继续做两次伯努利试验，反面时继续做三次；新的试验成功概率为未知 p，要检验 $H_0 : p \le 1/2$。设 $N \in \{2, 3\}$ 为事先随机决定的试验次数，K 为继续试验的成功数。给定 $N = n$，有 $K \sim \mathrm{Bin}(n, p)$，故用 $\mathrm{Bin}(n, 1/2)$ 的上尾概率计算 P，在两组内分别有效。上面的命题说明即使不固定 N，合并后的 P 仍有效。关键在于给定分组信息后的成功数分布已经算对，而不是分组信息必须与参数无关。

另一个常见目标不是拒绝某个固定假设，而是根据数据给未知参数划出一个可信的范围。若对每个整数 m 都能检验“参数不超过 m”，那么数据越支持参数较大，就会拒绝越多的较小上界。把那些没有被拒绝的上界排列起来，便能得到参数的下置信界。

命题 4.5 有限整数参数的单侧置信界. 设真实参数 $M \in \{0,1,\dots,N\}$。对每个 $m = 0,1,\dots,N$，已构造检验 $H_{0,m} : M \le m$ 的合法 p 值 $P_m = P_m(R)$。假设对每份可能的记录 r，$P_m(r)$ 随 m 非递减，并且 $P_N(r) = 1$。固定 $0 < \alpha < 1$，定义

$$L_\alpha(r) = \min\{m \in \{0,\dots,N\} : P_m(r) > \alpha\}.$$

则对于每个真实值 M，

$$\mathbb{P}_M\{L_\alpha(R) \le M\} \ge 1 - \alpha.$$

因此 $L_\alpha(R)$ 是一个置信水平至少为 $1-\alpha$ 的**下置信界**。

证明. 因为 $P_N(r) = 1 > \alpha$，定义中的集合不为空。固定真实参数 M。由 $P_m(r)$ 对 m 非递减，逐份记录都有

$$L_\alpha(r) > M \quad \Longleftrightarrow \quad P_M(r) \le \alpha.$$

而 P_M 对原假设 $M \le M$ 合法，所以

$$\mathbb{P}_M\{L_\alpha(R) > M\} = \mathbb{P}_M\{P_M(R) \le \alpha\} \le \alpha.$$

取补事件即得覆盖概率的结论。这里“至少”很重要：离散分布造成的尾概率跳变可能使实际覆盖率高于 $1-\alpha$。

条件检验与置信界反演都只是在已有概率知识上多走一步：前者对不同分组计算条件概率，再用全概率公式合并；后者对一系列假设计算 p 值，再把拒绝与不拒绝的结果转化为参数界。后面的习题会分别处理非平局样本、无放回抽样、两项 p 值的组合，以及数据中部分结果没有被记录的情形。所有这些问题都需要先弄清真实观察到了什么，再写相应的概率分布。

习题

习题 4.1. 独立投掷两枚硬币，各自直到第一次正面才停止，所用次数为 R_1, R_2，正面概率为 $p_1, p_2 \in (0,1)$。检验 $H_0 : p_1 \le p_2$ 对 $H_1 : p_1 > p_2$。

1. 证明 $P = R_1/(R_1 + R_2 - 1)$ 是合法 p 值。
2. 独立重复上述成对实验 m 次，对于两枚硬币同一次出现正面的平局不再记录胜负，只汇总非平局的次数 M 及其中第一枚先出现正面的次数 W。仅用 (M, W) 构造一个合法 p 值，并证明其有效性。

习题 4.2. 已知一个容量为 N 的总体中有 M 个红色单位，$0 \le M \le N$ 未知。等概率地无放回抽取 n 个单位，只记录红色数 K，其中 $1 \le n \le N$。固定 $0 < \alpha < 1$。

1. 对每个整数 $0 \le m \le N$，给出检验 $H_0 : M \le m$ 的合法单侧 p 值。
2. 要求整数函数 $L : \{0,\dots,n\} \to \{0,\dots,N\}$ 非递减，且对每个 M 都满足

$$\mathbb{P}_M\{L(K) \le M\} \ge 1 - \alpha.$$

求逐点最大的 L，并证明最优性。

习题 4.3. P_1, P_2 是同一零假设的两个合法 p 值。

1. 若二者独立且均服从 $U(0,1)$，求 $Q = P_1P_2$ 的分布，并把 Q 变为均匀分布的 p 值。
2. 不再假设二者独立或均匀。给定 $0 < w < 1$，求最小常数 c_w，使

$$P_w = \min\{1, c_w P_1^w P_2^{1-w}\}$$

对所有这样的 P_1, P_2 均是合法 p 值，并证明常数不能减小。

习题 4.4. 设 $X_1, \dots, X_n$ 独立服从 $N(\mu, 1)$, 检验 $H_0 : \mu \le 0$ 对 $H_1 : \mu > 0$, 固定 $0 < \alpha < 1$, 记 $c = \Phi^{-1}(1-\alpha)$。比较两个检验

$$A_n : \sqrt{n}\,\overline{X} > c, \qquad B_n : \frac{2(K - n/2)}{\sqrt{n}} > c, \qquad K = \sum_{i=1}^{n} \mathbf{1}_{\{X_i > 0\}}.$$

1. 证明 A_n 的显著性水平恰为 α，而 B_n 的显著性水平趋于 α。
2. 对固定 $\delta > 0$ 取局部备择 $\mu_n = \delta/\sqrt{n}$，求两个检验功效的极限并比较。

习题 4.5. X_1, X_2 独立服从 $U(0,\theta)$, $\theta > 0$。检验 $H_0 : \theta \le 1$ 对 $H_1 : \theta > 1$, 固定 $0 < \alpha < 1/2$。

1. 证明任何显著性水平不超过 α 的非随机化检验, 在 $\theta > 1$ 时的功效不超过 $1 - (1-\alpha)/\theta^2$。
2. 构造两个不同的拒绝域，同时对每个 $\theta > 1$ 达到上述上界：一个只看 $\max(X_1, X_2)$；另一个在每个 $0 < \theta \le 1$ 下的拒绝概率都恰为 α。

习题 4.6. 独立抛一枚正面概率为 p 的硬币五次，检验 $H_0 : 1/6 \le p \le 5/6$。若五次中恰有一次与其余四次不同面，则拒绝；若五次同面，则以概率 γ 拒绝；其余情况不拒绝，其中 $0 \le \gamma \le 1$，随机化与抛掷独立。给定名义水平 $0 < \alpha < 1$，求使这一检验水平不超过 α 的全部 γ（若不存在，说明原因）；当取允许的最大 γ 时，求全部最坏零假设参数。

习题 4.7. 设 $X_1, \dots, X_n$ 独立服从 Bernoulli(p)。每次试验结束后，该次结果可能没有被记录：出现成功时，被记录的概率为 a；出现失败时，被记录的概率为 b。给定全部试验结果后，各次是否被记录相互独立。已知

$$0 < b \le a \le 1, \qquad \frac{a}{b} \le c,$$

其中 $c \ge 1$ 已知，而 a, b 未知。最终只知道被记录的试验总数 M，以及其中成功的次数 K。检验 $H_0 : p \le p_0$，其中 $0 < p_0 < 1$。

1. 构造一个对所有允许的 (p, a, b) 都合法、且只依赖 (M, K) 的单侧 p 值。
2. 如果还要求对每个有正概率的 $M = m$，条件于 $M = m$ 后的 p 值仍合法，并且它随 K 非增，证明你的构造在这类规则中逐点最小。

第五章　合法对称性与精确检验

5.1　什么样的重新排列可以用来计算概率

第四章用统计量的零假设分布计算 p 值。实际问题中，统计量的分布往往不好直接写出，但如果零假设使若干种完整数据记录等可能，就可以在这些记录上逐一计算统计量，得到精确的尾概率。

例如独立抛两枚公平硬币，用 1、-1 表示正反面，取统计量 $T = U + 2V$。四种有顺序的记录及其统计量是

(U,V)	$(-1,-1)$	$(1,-1)$	$(-1,1)$	$(1,1)$
T	-3	-1	1	3

若观察到 $(-1,1)$，则 $T=1$，四种等可能记录中有两种满足 $T \geq 1$，所以单侧上尾概率为 $2/4 = 1/2$。这里的计算单位是四种有编号的完整记录，而不是统计量出现过的不同数值。

定义 5.1　有限等可能记录的精确上尾 p 值.　设在零假设下，有限个有编号的完整记录 $\omega_1, \dots, \omega_M$ 等可能，其中 $M \geq 1$。事先确定统计量 T，若观察到记录 ω，定义

$$P(\omega) = \frac{\#\{j : T(\omega_j) \geq T(\omega)\}}{M}.$$

不同记录即使算出相同的统计量，也应分别计数。若统计量包含从数据中选择某个位置、方向或区间的步骤，那么在每份候选记录上都必须重新进行相同选择。

命题 5.1　等可能记录给出的上尾概率有效.　在上述零假设下，对于任意 $0 \leq u \leq 1$，有

$$\mathbb{P}(P \leq u) \leq u.$$

证明.　把 T 的不同取值由大到小排列为 $t_1 > \cdots > t_s$，对应记录数为 $a_1, \dots, a_s$，其中 $a_j \geq 1$ 且 $\sum_{j=1}^{s} a_j = M$。若观察到 $T = t_j$，则

$$P = \frac{a_1 + \cdots + a_j}{M}.$$

这些分数严格递增。若其中没有一个不超过 u，拒绝概率为零；否则设不超过 u 的最大下标为 j_*，则

$$\mathbb{P}(P \leq u) = \frac{a_1 + \cdots + a_{j_*}}{M} \leq u.$$

这也包括 $u = 0, 1$ 的情况。证毕。

我们将在下面找到三类真正等可能的记录：独立对称差值的符号、可交换配对的方向，以及均匀随机分组后的组别标签。它们的共同点是整个联合分布在相应变化下保持不变。单凭每个坐标的分布相同，无法确定若干坐标可以独立地翻转或交换。

5.2 独立对称差值与符号秩

定义 5.2 联合符号翻转对称性. 设 $D=(D_1,\dots,D_n)$ 为随机向量。如果任取 $\varepsilon_i\in\{-1,1\}$，都有

$$(D_1,\dots,D_n)\overset{d}{=}(\varepsilon_1 D_1,\dots,\varepsilon_n D_n),$$

就称 D 具有逐坐标联合符号翻转对称性。这表示可以任意指定若干坐标改变正负号而不改变联合分布。若 D_i 独立且分别关于零对称，则这个条件成立；只有各个 D_i 分别对称却不一定成立。

命题 5.2 独立对称差值的符号分布. 设 $D_1,\dots,D_n$ 相互独立，各自关于零对称，且 $\mathbb{P}(D_i=0)=0$。记 $A_i=|D_i|$，$B_i=\mathbf{1}_{\{D_i>0\}}$。则 $B_1,\dots,B_n$ 相互独立，且各以 $1/2$ 的概率取 0、1；整个符号向量 $B=(B_1,\dots,B_n)$ 与绝对值向量 $A=(A_1,\dots,A_n)$ 独立。

证明. 由于各 D_i 独立且各自关于零对称，将任意若干个 D_i 同时改成 $-D_i$，整个随机向量的联合分布不变。任取一个只由 $A_1,\dots,A_n$ 决定的事件 C。改变符号不会改变 C，却能把任何一种指定的正负号配置变成另外任意一种。因此 C 与全部 2^n 种符号配置同时发生的概率相同。

又因为 $\mathbb{P}(D_i=0)=0$，这 2^n 种配置两两不交，而且它们的并在概率为 1 的意义下包含全部结果。所以对每一种 $b\in\{0,1\}^n$，

$$\mathbb{P}(A\text{ 满足}C,\ B=b)=2^{-n}\mathbb{P}(C).$$

取 C 为必然事件，就知道各符号配置的概率都是 2^{-n}，即 B_i 相互独立且公平；一般的 C 又给出 B 与 A 的独立性。证毕。

因此，按差值的绝对值大小选择下标或给下标分组，并不会改变各个符号独立且公平的性质。以三个独立且绝对值互不相等的对称差值为例，先把它们按绝对值从小到大排在第 $1,2,3$ 位。已知恰有两个差值为正时，正号占据的两个位次可以是 $\{1,2\}$、$\{1,3\}$、$\{2,3\}$，三种情况的条件概率各为 $1/3$。若记正号位次之和为 W，则 W 等可能地取 $3,4,5$；例如实际算出 $W=4$，其单侧上尾概率为 $\mathbb{P}(W\ge 4\mid\text{恰有两个正号})=2/3$。

这里还要分清两个条件：$\mathbb{P}(D_i=0)=0$ 保证符号的正负二分；若要使绝对值的秩恰为 $1,\dots,n$，还需排除不同绝对值相等的情况。例如各 D_i 有连续密度并相互独立时，这两项都成立。若实际数据有并列，可规定统一的随机打破并列规则，或直接使用原来有编号的配置计数，不能暗中删去并列记录。

例 5.1. 设 $D_1,\dots,D_n$ 相互独立，各有关于 0 对称的连续密度，$n\ge 2$。记 R_i 为 $|D_i|$ 的升序秩，令

$$K=\#\{i:D_i>0\},\qquad W=\sum_{i:D_i>0}R_i.$$

给定全部绝对值，再给定 $K=k$（$0\le k\le n$）。

1. 求 W 的全部可能取值，并指出两个端点各在什么配置下出现。

2. 求 W 的条件均值、方差，并证明其分布关于 $k(n+1)/2$ 对称。

解. 记 $\mathbf{A}=(|D_1|,\dots,|D_n|)$。给定 $\mathbf{A}$ 后，秩恰为 $1,\dots,n$，而正号集合是独立公平符号构成的随机子集。再给定 $K=k$，每个 k 元秩子集的概率均为 $\binom{n}{k}^{-1}$；$k=0,n$ 时该子集退化为唯一配置。

(1) 若选中的秩是 $1\le i_1<\cdots<i_k\le n$，则

$$\frac{k(k+1)}{2}\le W=\sum_{j=1}^{k}i_j\le\frac{k(2n-k+1)}{2}.$$

左端仅当选 $1,\dots,k$ 时取得，右端仅当选 $n-k+1,\dots,n$ 时取得。实际上这两个端点之间的每个整数都能取到：写 $i_j = j + b_j$，其中

$$0 \le b_1 \le \cdots \le b_k \le n-k, \qquad W = \frac{k(k+1)}{2} + \sum_j b_j.$$

当 $k=0$ 或 $k=n$ 时只有一个值。其余情况令 $d = n-k \ge 1$，任取 $0 \le t \le kd$，写 $t = qd + r$，其中 $0 \le r < d$。从右往左取 q 个 $b_j = d$；若 $r > 0$，再把紧邻它们的一个 b_j 取成 r，剩余各项取 0。所得非降序列实现 $\sum_j b_j = t$，故 W 恰取上述闭区间内的每一个整数。

(2) 设 I_r 指示秩 r 是否为正。由均匀选取 k 元子集，

$$\mathbb{E} I_r = \frac{k}{n}, \qquad \mathrm{Cov}(I_r, I_s) = -\frac{k(n-k)}{n^2(n-1)} \quad (r \ne s).$$

后式可由 $\mathbb{P}(I_r = I_s = 1) = k(k-1)/[n(n-1)]$ 相减得到。于是

$$\boxed{\mathbb{E}(W \mid K=k, \mathbf{A}) = \frac{k(n+1)}{2}}, \qquad \boxed{\mathrm{Var}(W \mid K=k, \mathbf{A}) = \frac{k(n-k)(n+1)}{12}}.$$

具体地，令 $c_r = r - (n+1)/2$。因为正好选出 k 个秩，$W - \frac{k(n+1)}{2} = \sum_r c_r I_r$，且 $\sum_r c_r = 0$，所以

$$\begin{aligned} \mathrm{Var}(W \mid K=k, \mathbf{A}) &= \sum_r c_r^2 \,\mathrm{Var}(I_r) + 2\sum_{r<s} c_r c_s \,\mathrm{Cov}(I_r, I_s) \\ &= \frac{k(n-k)}{n(n-1)} \sum_{r=1}^{n} c_r^2 \\ &= \frac{k(n-k)(n+1)}{12}, \end{aligned}$$

其中 $2\sum_{r<s} c_r c_s = -\sum_r c_r^2$，$\sum_r c_r^2 = n(n^2-1)/12$。这也覆盖 $k = 0, n$ 时的零方差。

最后将每个入选秩 r 送到 $n+1-r$。这是全部 k 元子集上的双射，使 W 变为 $k(n+1)-W$，而每个子集仍等可能。故 W 与 $k(n+1)-W$ 条件同分布，结论成立。

5.3 可交换配对与重复观测

定义 5.3 配对交换性. 一对随机变量 (A, B) 若满足

$$(A, B) \overset{d}{=} (B, A),$$

就称它们可交换。这要求两者的联合分布对调后不变，不要求一对内部相互独立，也允许 $A = B$。

命题 5.3 独立可交换配对的随机方向. 设 (A_i, B_i) $(1 \le i \le n)$ 是相互独立的随机变量对，并且每对都可交换。给定各对的较小值和较大值后，对于所有 $A_i \ne B_i$ 的配对，哪一个数放在前面是相互独立的公平选择。若 $A_i = B_i$，该对没有可交换出的第二种记录。

证明. 先固定一对，记 $L = \min(A, B)$、$H = \max(A, B)$。对由 (L, H) 决定的任意事件 C，交换两项时事件 C 不变，而事件

$$C \cap \{L < H, A = H\} \quad \text{与} \quad C \cap \{L < H, B = H\}$$

彼此对换。由可交换性，它们的概率相等。因此在 $L < H$ 的条件下，前后方向是公平的，并与无序数值无关。对于不同配对，独立性又使这些方向及其无序数值的联合概率按配对分解，

因而不同的非并列方向相互独立。相等的两个数交换后仍是一份记录，不能产生新的符号。证毕。

例如三对数据的无序值分别为 $\{2,5\}$、$\{1,4\}$、$\{4,4\}$。若前两对的方向公平且独立，第三对始终相等，那么真正的随机化记录只有 $2^2=4$ 种，不是 $2^3=8$ 种。将第三对也算作一次独立交换，只会把原来每份记录重复写两遍，不会增加信息。

逐对可交换性与联合可交换性还应区分：如果所有配对都由同一个随机符号决定方向，每一对单独看可以交换，逐对独立交换却未必保持整个联合分布。这时必须以共同符号为随机化单位。

5.4 均匀随机分组与标签置换

有些比较两组数据的试验，本身就采用随机分组。设有 $N=m+n$ 个带编号的单位，其观测值 $z_1,\dots,z_N$ 已经固定，随机选择其中 m 个单位标为 X 组，其余 n 个标为 Y 组。若每个 m 元子集被选择的概率均为 $\binom{N}{m}^{-1}$，那么这种随机化提供了精确计算检验概率的依据，而不必知道这些观测值服从什么分布。

这里的等可能性来自随机分组规则本身。观测值可以互不相同，也可以出现并列；位置的编号使不同的分组始终能够区分。固定这些数值以后，把每一种合法标签配置代入事先确定的统计量 T，得到 $\binom{N}{m}$ 个统计量值，再计算不小于实际观测值的比例，就是一个精确上尾 p 值。第一节的有限等可能记录命题已经证明这样的 p 值有效。

定义 5.4　随机分组的标签分布.　固定 N 个有编号的位置，等可能选择其中 m 个放置 X 标签，其余 $n=N-m$ 个放置 Y 标签。任意给定位置 i 放置 X 的概率为 m/N；任意两个不同位置 i,j 都放置 X 的概率为 $m(m-1)/[N(N-1)]$。这两个公式由组合数直接得到，例如前一个等于 $\binom{N-1}{m-1}/\binom{N}{m}$。

对同一组数值，改变分组会使两组均值之差发生怎样的变化？如果其中一个数据允许重新测量或修改，应优先选择哪一个？这些都是在有限个等可能的分组方案上可以严格回答的问题。

例 5.2.　给定 $N=m+n\ge 3$ 个实数 $z_1,\dots,z_N$，其中 $m,n\ge 1$。在这 N 个有编号的位置中等可能选取 m 个标为 X，其余标为 Y；记两组数的均值之差为 $T=\bar X-\bar Y$。

1. 求 T 的期望和方差。

2. 允许选取其中一个位置，将该位置的数改成任意实数，再按同一规则随机分组。求修改后 T 的方差的最小值，并刻画所有能够达到这一最小值的修改方法。

解.　(1) 记 $\bar z=N^{-1}\sum_{i=1}^N z_i$，$c_i=z_i-\bar z$，并以 I_i 表示第 i 个位置被标为 X。因为恰有 m 个位置等可能被选中，

$$\mathbb{E}I_i=\frac{m}{N},\qquad \mathrm{Var}(I_i)=\frac{mn}{N^2},\qquad \mathrm{Cov}(I_i,I_j)=-\frac{mn}{N^2(N-1)}\quad (i\neq j).$$

最后一式可由 $\mathbb{P}(I_i=I_j=1)=m(m-1)/[N(N-1)]$ 减去 $(m/N)^2$ 得到。注意 $\sum_i c_i=0$，而

$$T=\frac{1}{m}\sum_i I_i z_i-\frac{1}{n}\sum_i (1-I_i)z_i=\frac{N}{mn}\sum_{i=1}^N I_i c_i.$$

因此 $\mathbb{E}T=0$。展开方差，再用 $2\sum_{i<j}c_ic_j=-\sum_i c_i^2$，得

$$\begin{aligned}\mathsf{Var}\left(\sum_i I_i c_i\right) &= \frac{mn}{N^2}\sum_i c_i^2 - \frac{2mn}{N^2(N-1)}\sum_{i<j}c_ic_j \\ &= \frac{mn}{N(N-1)}\sum_i c_i^2.\end{aligned}$$

从而

$$\boxed{\mathbb{E}T=0,\qquad \mathsf{Var}(T)=\frac{N}{mn(N-1)}\sum_{i=1}^{N}(z_i-\bar z)^2.}$$

(2) 由第一问，只需使修改后 N 个数的离差平方和最小。先固定要修改的位置 k，将其他 $N-1$ 个数的均值记为

$$b_k=\frac{1}{N-1}\sum_{j\neq k}z_j.$$

把第 k 个数改为 x 后，新均值为 $[x+(N-1)b_k]/N$。围绕 b_k 展开其余 $N-1$ 个数的平方和，交叉项因 $\sum_{j\neq k}(z_j-b_k)=0$ 而消失，得到

$$\sum_{j\neq k}(z_j-\bar z')^2+(x-\bar z')^2=\sum_{j\neq k}(z_j-b_k)^2+\frac{N-1}{N}(x-b_k)^2.$$

故对固定的 k，唯一最优修改是 $x=b_k$。

为了决定修改哪个位置，仍对原来未修改的数据使用同一恒等式，得

$$\sum_{j\neq k}(z_j-b_k)^2=\sum_{i=1}^{N}(z_i-\bar z)^2-\frac{N}{N-1}(z_k-\bar z)^2,$$

这里用到了 $z_k-b_k=N(z_k-\bar z)/(N-1)$。所以应选择距原始均值最远的位置。记 $S=\sum_i(z_i-\bar z)^2$，$M=\max_i|z_i-\bar z|$，最终最小方差为

$$\boxed{\frac{N}{mn(N-1)}\left(S-\frac{N}{N-1}M^2\right).}$$

所有最优方法恰为：选择任意一个满足 $|z_k-\bar z|=M$ 的位置 k，把 z_k 改为其余 $N-1$ 个数的均值 b_k。若有多个最远位置，它们都可选；所有原数相等时任取一个位置且保持原值即可。

例如固定四个有序观测值 $1,2,4,8$，在四个位置上等可能选两个标为 X 组。若实际 X 组占第 $1,4$ 个位置，则 $\overline{X}-\overline{Y}=(1+8-2-4)/2=3/2$。六种等可能的二元位置子集给出的两数之和分别为 $3,5,9,6,10,12$；其中和不小于实际的 9 有三种，所以按两组均值差计算的精确上尾 p 值为 $3/6=1/2$。

这里对标签的随机化建立在分组方案确实等可能这一条件上。如果原始组别并非随机产生，则不能仅因两组观测各自的边缘分布相同，就把组别对调视为合法的随机试验。下一道题说明这个区别。

例 5.3. 设 $q \geq 3$，一对记录 A, B 的边缘分布都在 $\{1, \dots, q\}$ 上均匀，但不假设二者独立。某分析者据此误认为两标签可交换，对 $T = B - A$ 用两种标签顺序计算上尾 p 值，并在 $p \leq 1/2$ 时拒绝。

1. 证明该规则的实际拒绝概率不超过 $1 - 1/q$。

2. 求使这一上界取到的全部联合分布。

解. (1) 固定记录 (a, b)，两种换标签统计量是 $b - a$ 和 $a - b$。严格 $b > a$ 时观测统计量较大，错误上尾 $p = 1/2$；当 $b \leq a$ 时（含相等），$p = 1$。因此拒绝事件恰为 $\{B > A\}$。因 $A = q$ 时不可能有 $B > A$，

$$\mathbb{P}(B > A) \leq \mathbb{P}(A < q) = \frac{q-1}{q}.$$

(2) 若上界取到，必有 $\mathbb{P}(B > A \mid A = i) = 1$ 对每个 $i < q$ 成立，因为每个 $\mathbb{P}(A = i) = 1/q > 0$。当 $A = q - 1$ 时，$B > A$ 迫使 $B = q$，故该行的概率质量 $1/q$ 已经用完 $B = q$ 的全部边缘质量。再看 $A = q - 2$：它只能取 $B = q - 1$ 或 q，但 $B = q$ 已无剩余质量，故必为 $B = q - 1$。从 $q - 2$ 递降到 1，依次得到

$$B = A + 1 \quad \text{只要} A < q.$$

这已用尽 $B = 2, \dots, q$ 的全部边缘质量，因此 $A = q$ 时必须 $B = 1$。反过来，令 A 均匀，规定

$$B = \begin{cases} A + 1, & 1 \leq A < q, \\ 1, & A = q, \end{cases}$$

就使 B 也均匀，且 $\mathbb{P}(B > A) = (q-1)/q$。故这是唯一达到上界的联合分布。它是依次前进一格、到端点再绕回的循环配对；当 q 增加时，误把边缘相同当成标签交换性可以使错误率无限接近 1。

5.5 分组条件、事后选择与游程

等可能标签还可以在知道一些标签计数后继续使用。例如仍在 $N = m + n$ 个有编号的位置上等可能放置 m 个 X 标签和 n 个 Y 标签。现在额外知道前 r 个位置恰有 a 个 X 标签，其中 $1 \leq r < N$ 且 $\max\{0, r - n\} \leq a \leq \min\{m, r\}$。

在这个条件下，前 r 个位置中有 $\binom{r}{a}$ 种合法排列，后 $N - r$ 个位置中有 $\binom{N-r}{m-a}$ 种合法排列，二者任意组合恰好得到全部

$$\binom{r}{a}\binom{N-r}{m-a}$$

种条件标签序列。每一种组合在原随机分组规则下概率相同，因而条件于这一个计数后，前后两段各自均匀排列，而且两段的标签排列相互独立。注意这是给定段内标签数以后的独立性，并不表示原来两段的标签数独立。习题 5.6 将用同样的条件独立性研究两端标签位置的跨度。

检验有时还会从数据中选择一个最有利的位置。例如合并序列为 $XXYXY$ 时，连续 X 标签的最长段长度为 2。如果统计量是“最长连续 X 段长度”，那么在每一种合法置换中都必须重新寻找最长段；不能观察到原数据中的前两个位置恰为 XX，就假装这一位置在看数据前已经固定。对于三个 X、两个 Y 的全部 $\binom{5}{3} = 10$ 种标签序列，只有 $XYXYX$ 不含相邻 X，所以本例的实际精确上尾概率为 $9/10$。

这种连续相同标签组成的一段称为游程。游程总数和最长游程长度分别反映两种不同的排序结构；它们的零分布都能通过有编号标签的组合计数求出，而不依赖具体总体分布的形状。习题 5.7、5.8 将分别研究这两个统计量。

习题

习题 5.1. 设 $n \geq 2$，随机变量 $D_1, \dots, D_n$ 相互独立，且各自的分布连续、关于 0 对称。观察到全部差值后，从下标中选一个非空集合 I，记

$$m = |I|, \qquad S = \#\{i \in I : D_i > 0\}, \qquad P = \mathbb{P}\{\mathrm{Bin}(m, 1/2) \geq S\}.$$

1. 若 I 只能由 $|D_1|, \dots, |D_n|$ 决定，证明 P 是合法的 p 值。
2. 若允许根据全部差值任意选择 I，对给定的 $0 < \alpha < 1$，求所有选取规则下 $\mathbb{P}(P \leq \alpha)$ 的最大值。

习题 5.2. U, V 是独立公平符号（各以概率 $1/2$ 取 ± 1），记录三个差值

$$(D_1, D_2, D_3) = (U, V, UV).$$

1. 证明三个差值两两独立，且各自关于 0 对称，却不能分别独立翻转符号。
2. 对 $T = D_1 + D_2 + D_3$ 错按全部八种翻转计算上尾 p 值，求其真实分布；再用真正合法的翻转求正确的精确 p 值。

习题 5.3. 给定 $N = m + n$ 个有编号的实数 $z_1, \dots, z_N$（允许并列），等概率选择其中 m 个标为 X 组，其余标为 Y 组，其中 $m, n \geq 1$。以 $T = \overline{X} - \overline{Y}$ 作单侧上尾标签置换检验。求在全部可能的观测标签中，p 值能取得的最小值，并刻画所有取得最小值的标签配置。

习题 5.4. X, Y 相互独立且可积。某检验只假定 $H_0 : \mathbb{E}X = \mathbb{E}Y$，却把 (X, Y) 与 (Y, X) 当成两个等可能的标签，使用统计量 $T = Y - X$，并在交换上尾 $p \leq 1/2$ 时拒绝。

1. 写出该规则真正的拒绝事件。
2. 在 $\mathbb{E}X = \mathbb{E}Y = 0$ 的全部这样的分布中，求实际拒绝概率的上确界，并判断能否取到。

习题 5.5. 有 $b \geq 1$ 个独立区组，第 j 组有 r_j 条差值 $D_{j\ell} = a_{j\ell} Z_j$，其中 $a_{j\ell} > 0$ 已知，Z_j 为独立公平符号。以所有差值之和 T 作单侧上尾检验。

1. 已观察全部差值，求精确 p 值，并解释合法的符号翻转单位。

2. 特别地，设 b 为奇数，各组都有 r 条完全相同的记录 $D_{j\ell} = Z_j$。若误将 br 条记录分别独立翻转，得到上尾 p 值 P_r。对固定 $0 < \alpha < 1/2$，求 $r \to \infty$ 时 $\mathbb{P}(P_r \leq \alpha)$ 的极限；再比较观察到全部记录为正时的正确和错误 p 值。

习题 5.6. 在 $N = m + n$ 个有编号的位置上，等可能放置 $m \geq 2$ 个 X 标签与 $n \geq 1$ 个 Y 标签。记第一个与最后一个 X 标签的位置分别为 J, K。给定整数 $1 \leq r < N$，已知前 r 个位置恰有 a 个 X，其中

$$\max\{1, r - n\} \leq a \leq \min\{m - 1, r\}.$$

求 $K - J$ 在这个条件下的期望和方差。

习题 5.7. 在 $N = m + n$ 个有编号的位置上，等可能放置 m 个 X 标签和 n 个 Y 标签，其中 $m, n \geq 2$。一段连续相同的标签称为一个游程，记游程总数为 R。

1. 求 R 的精确分布。

2. 不使用第一问的分布求和，求 $\mathbb{E}R$ 和 $\mathrm{Var}(R)$。

习题 5.8. 在 $N = m + n$ 个有编号的位置上，等可能放置 m 个 X 标签和 n 个 Y 标签，其中 $m, n \geq 1$。记 L 为最长连续 X 标签段的长度。观察到 $L = \ell$，求以 L 为统计量的精确单侧上尾 p 值和最小可达 p 值，并证明该检验有效。

第六章　单样本与双样本

6.1　从样本均值到精确的 t 分布

先考虑最熟悉的估计问题：独立观测 $X_1,\dots,X_n$，希望通过样本均值 $\bar X$ 判断总体均值 μ。如果每次观测都服从 $N(\mu,\sigma^2)$，其中 $\sigma>0$，则

$$\bar X\sim N\!\left(\mu,\frac{\sigma^2}{n}\right),\qquad Z=\frac{\sqrt{n}(\bar X-\mu)}{\sigma}\sim N(0,1).$$

当 σ 已知时，可以直接利用标准正态分布判断 $\bar X$ 与某个假定的均值相差是否过大。但实际问题中，σ 往往也未知。第一章已经介绍了样本方差

$$S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar X)^2\qquad (n\ge 2),$$

并证明只要观测独立同分布且具有有限方差，就有 $\mathbb{E}S^2=\sigma^2$。用 S 代替未知的 σ 后，分母本身也成为随机量，因而新的统计量不再是标准正态变量。

这个变化可以先在只有两个观测时看清楚。令 $Z_i=(X_i-\mu)/\sigma$，则 Z_1,Z_2 独立且均服从 $N(0,1)$。把它们换成

$$W_1=\frac{Z_1+Z_2}{\sqrt{2}},\qquad W_2=\frac{Z_1-Z_2}{\sqrt{2}}.$$

因为 $Z_1^2+Z_2^2=W_1^2+W_2^2$，而上述变换的雅可比行列式的绝对值为 1，换元后联合密度仍为两个标准正态密度之积。所以 W_1,W_2 独立，且

$$W_1=\frac{\sqrt{2}(\bar X-\mu)}{\sigma},\qquad W_2^2=\frac{(X_1-\bar X)^2+(X_2-\bar X)^2}{\sigma^2}.$$

因此，用于估计均值的随机起伏，与用来估计方差的随机起伏恰好独立。一般 n 的情形也是如此，只不过后者由 $n-1$ 个相互独立的标准正态变量共同决定。

定义 6.1　卡方分布与 t 分布.　设 $Z_1,\dots,Z_\nu$ 是 ν 个相互独立的标准正态变量（ν 为正整数）。称随机变量

$$U=Z_1^2+\cdots+Z_\nu^2$$

服从自由度为 ν 的**卡方分布**，记为 $U\sim\chi^2_\nu$。如果 $Z\sim N(0,1)$、$U\sim\chi^2_\nu$ 且 Z 与 U 独立，则称

$$T=\frac{Z}{\sqrt{U/\nu}}$$

服从自由度为 ν 的 t **分布**，记为 $T\sim t_\nu$。

由于每个标准正态变量取值为 0 的概率都为 0，$U>0$ 几乎必然成立，上述分式因而有定义。t_ν 分布关于 0 对称，并有连续、严格递增的分布函数：在给定 $U=u>0$ 后，T 是一个非退化的正态变量；对这些条件分布取平均即可得到上述性质。用 $t_{\nu,q}$ 表示其分布函数的 q 分位数（$0<q<1$），例如当 $0<\alpha<1$ 时，$t_{\nu,1-\alpha/2}>0$。

卡方分布的均值和方差也容易求出。若 $Z\sim N(0,1)$，其密度 ϕ 满足 $\phi'(z)=-z\phi(z)$。分部积分（无穷远处的边界项为零）得到

$$\mathbb{E}Z^4=-\int_{-\infty}^{\infty}z^3\phi'(z)\,\mathrm{d}z=3\int_{-\infty}^{\infty}z^2\phi(z)\,\mathrm{d}z=3.$$

所以 $\operatorname{Var}(Z^2)=3-1=2$。利用独立性可得

$$\mathbb{E}U=\nu,\qquad \operatorname{Var}U=2\nu\qquad (U\sim\chi^2_\nu).$$

命题 6.1 正态样本均值与样本方差的独立分解. 设 $X_1,\dots,X_n$ 相互独立且均服从 $N(\mu,\sigma^2)$，$n\ge 2$、$\sigma>0$。则

$$Z_0=\frac{\sqrt{n}(\bar X-\mu)}{\sigma}\sim N(0,1),\qquad U=\frac{(n-1)S^2}{\sigma^2}\sim\chi^2_{n-1},$$

并且 Z_0 与 U 相互独立。

证明. 令 $Z_i=(X_i-\mu)/\sigma$，把 $(Z_1,\dots,Z_n)$ 看作一个 n 维向量。取第一行为 $\frac{1}{\sqrt{n}}(1,\dots,1)$ 的正交矩阵 Q：这个行向量的长度是 1；例如其余第 j 行（$2\le j\le n$）可以明确取为

$$\frac{1}{\sqrt{j(j-1)}}(\underbrace{1,\dots,1}_{j-1\text{ 个}},-(j-1),0,\dots,0).$$

每一行长度都是 1, 任意两行的内积都是 0, 所以这确实构成正交矩阵。令 $W=Q(Z_1,\dots,Z_n)^{\mathsf T}$。正交变换保持平方和，雅可比行列式的绝对值为 1，因此 W 的联合密度为

$$(2\pi)^{-n/2}\exp\!\left(-\frac{w_1^2+\cdots+w_n^2}{2}\right)=\prod_{j=1}^{n}\frac{e^{-w_j^2/2}}{\sqrt{2\pi}}.$$

这说明 $W_1,\dots,W_n$ 仍是相互独立的标准正态变量。由于 Q 的第一行已作上述选择,

$$W_1=\frac{Z_1+\cdots+Z_n}{\sqrt{n}}=Z_0.$$

另一方面，展开平方并利用 $\sum_i(X_i-\bar X)=0$，得到

$$\sum_{i=1}^{n}(X_i-\mu)^2=\sum_{i=1}^{n}(X_i-\bar X)^2+n(\bar X-\mu)^2.$$

因此

$$W_2^2+\cdots+W_n^2=\sum_{i=1}^{n}Z_i^2-W_1^2=\frac{\sum_i(X_i-\bar X)^2}{\sigma^2}=\frac{(n-1)S^2}{\sigma^2}.$$

后式由 $n-1$ 个相互独立的标准正态变量的平方相加而成，并且只使用 $W_2,\dots,W_n$；它与 W_1 独立，命题得证。

从平方和分解也可以理解为何自由度是 $n-1$：一旦用数据确定了 $\bar X$，所有离差便满足 $\sum_i(X_i-\bar X)=0$，只剩 $n-1$ 个独立变化的方向。这里的“自由度”并不是单纯数一数样本个数，而是在正态模型中确实对应 $n-1$ 个独立的标准正态平方项。

命题 6.2 单样本均值的精确 t 检验与置信区间. 在上一命题的条件下，$S>0$ 几乎必然，且对任意固定的真实均值 μ,

$$T(\mu)=\frac{\sqrt{n}(\bar X-\mu)}{S}\sim t_{n-1}.$$

检验 $H_0:\mu=\mu_0$ 时，统计量

$$T(\mu_0)=\frac{\sqrt{n}(\bar X-\mu_0)}{S}$$

在 H_0 下服从 t_{n-1}。令 $c=t_{n-1,1-\alpha/2}$（$0<\alpha<1$），则以 $|T(\mu_0)|>c$ 为拒绝条件，第一类错误概率恰为 α；区间

$$\left[\bar X-c\frac{S}{\sqrt{n}},\ \bar X+c\frac{S}{\sqrt{n}}\right]$$

对任意 $\mu\in\mathbb{R}$、$\sigma>0$ 的覆盖概率恰为 $1-\alpha$。

证明. 由于 X_1,X_2 独立并有连续密度，$\mathbb{P}(X_1=X_2)=0$。事件 $S=0$ 要求所有观测都相等，故其概率也为 0。在 $S>0$ 时，由前一命题

$$T(\mu)=\frac{Z_0}{\sqrt{U/(n-1)}}\sim t_{n-1}.$$

t 分布连续且关于 0 对称，因而 $\mathbb{P}(|T(\mu)|>c)=\alpha$。检验零假设时把真值换成 μ_0 即得第一项。另一方面，随机区间包含固定数 μ，当且仅当 $|T(\mu)|\le c$，所以覆盖概率为 $1-\alpha$。

在一次实际观测中，先计算 $\bar x$ 和 s，再把它们代入上面的区间端点。区间的随机性来自重复抽样时数据会改变；参数 μ 在这个模型中始终是固定的未知数。

例如，若 $n=5$，测得 $\bar x=10$、$s=2$，要检验 $\mu=9$，先计算 $T=\sqrt{5}(10-9)/2$，再与自由度为 4 的 t 分布双侧临界值比较。不能在计算出 T 之后再把自由度改为 5，也不能把 $s=2$ 当作已知的总体标准差直接套标准正态临界值。

这里的精确 t 结论依赖正态分布和事先确定的取样规则。第一章证明的样本方差无偏性适用于更一般的总体，但方差无偏并不足以保证上述 t 分布。第六章习题将进一步检验这一差别。

6.2 配对观测：先求差，再做推断

同一个人用两种方法测量，或同一对象在处理前后各测量一次，得到的通常是成对数据 (A_i,B_i)。两列数字看起来像两个样本，但同一对的观测往往相关：体质、仪器位置或对象的固有水平可能同时影响 A_i 和 B_i。若研究的是两种处理的平均差，直接对每对作差

$$D_i=A_i-B_i$$

往往更自然。配对以后，真正独立的基本单位是各对差值，而不是把 $2n$ 个读数当成两批相互独立的观测。

对有限二阶矩的成对变量，有

$$\operatorname{Var}D_i=\operatorname{Var}A_i+\operatorname{Var}B_i-2\operatorname{Cov}(A_i,B_i).$$

若两列的方差均为 σ^2，相关系数为 ρ，并且不同的配对彼此独立，则

$$\operatorname{Var}(\bar A-\bar B)=\operatorname{Var}\left(\frac{1}{n}\sum_{i=1}^{n}D_i\right)=\frac{2\sigma^2(1-\rho)}{n}.$$

当同一个体的两次测量正相关时，差值中的随机波动比两列分别独立的情形小；若相关系数为负，差值反而可能更不稳定。配对的价值来自同一对的联系，而非记录表格的排列方式。

若第 i 个人的固定基线同时进入前后两次读数，作差就可以消去这一基线。如果不同人的差值 $D_1,\dots,D_n$ 相互独立，并且都服从 $N(\delta,\tau^2)$（$\tau>0$），那么第一节的单样本 t 定理便可以原样用于这一列差值：记

$$\bar D=\frac{1}{n}\sum_i D_i,\qquad S_D^2=\frac{1}{n-1}\sum_i(D_i-\bar D)^2,$$

则在 $H_0:\delta=\delta_0$ 下，$\sqrt{n}(\bar D-\delta_0)/S_D\sim t_{n-1}$。这并不要求 A_i 与 B_i 在每一对内部独立。下面的正式例题将研究一个更微妙的现象：同一份成对记录，如果无视配对关系，检验统计量甚至可以发生怎样的改变。

例 6.1. 设 $n \geq 2$，$A_i = \beta_i + \delta + \varepsilon_i$，$B_i = \beta_i + \eta_i$，其中 β_i 为任意未知常数，ε_i, η_i 全部相互独立且服从 $N(0, \sigma^2)$，$\sigma > 0$ 未知。

1. 构造检验 $H_0 : \delta = 0$ 的精确双侧水平 α 检验，给出 δ 的 $1-\alpha$ 置信区间（$0 < \alpha < 1$）。
2. 给定一份差值不全相同的观测，证明存在同时加在每对两个读数上的偏移，使配对 t 统计量不变，而忽略配对得到的等方差两独立样本 t 统计量趋于 0。

解. 作差可以消去每一对的未知基线:

$$D_i = A_i - B_i = \delta + \varepsilon_i - \eta_i.$$

因为题设中全部误差相互独立，$D_1, \ldots, D_n$ 彼此独立，且都服从 $N(\delta, 2\sigma^2)$。记它们的样本均值、标准差为 $\bar{D}, S_D$。

(1) 在 H_0 下，$\sqrt{n}\,\bar{D}/S_D \sim t_{n-1}$，其中 $S_D > 0$ 几乎必然。令 $c = t_{n-1,1-\alpha/2}$，所求精确双侧检验为

$$\left| \frac{\sqrt{n}\,\bar{D}}{S_D} \right| > c.$$

把假定的均值 0 改为任意待判断的 δ_0，同一分布结论给出

$$\boxed{\delta \in \left[\bar{D} - c\frac{S_D}{\sqrt{n}}, \quad \bar{D} + c\frac{S_D}{\sqrt{n}} \right]}$$

的覆盖概率为 $1-\alpha$，对每个 $\delta \in \mathbb{R}, \sigma > 0$ 都成立。

(2) 给定数据 (a_i, b_i)，写 $d_i = a_i - b_i$。题设保证差值不全相同，故配对统计量 $\sqrt{n}\,\bar{d}/S_d$ 有定义。要保持所有差值不变，只需给每对的两个数同时加上同一个数。取

$$r_1 = 1, \qquad r_2 = -1, \qquad r_3 = \cdots = r_n = 0,$$

并对实数 M 令 $a_i(M) = a_i + M r_i$、$b_i(M) = b_i + M r_i$。于是每个差值依旧为 d_i，且由 $\sum_i r_i = 0$，两组各自的均值也不变。

记忽略配对后使用的组内总平方和为 $W(M)$。将离均差展开，得

$$\begin{aligned} W(M) &= \sum_i \big(a_i(M) - \bar{a}\big)^2 + \sum_i \big(b_i(M) - \bar{b}\big)^2 \\ &= 2M^2 \sum_i r_i^2 + 2M \sum_i r_i \big[(a_i - \bar{a}) + (b_i - \bar{b})\big] + W(0). \end{aligned}$$

由于 $\sum_i r_i^2 = 2$，这是一个首项系数严格为正的二次函数，因而 $W(M) \to \infty$（$|M| \to \infty$）。将两列错误地当作独立样本而计算的合并标准差满足 $S_p(M)^2 = W(M)/(2n-2) \to \infty$，同时分子 $\bar{a} - \bar{b}$ 不变，于是

$$\frac{\bar{a} - \bar{b}}{S_p(M)\sqrt{2/n}} \longrightarrow 0.$$

相比之下，配对统计量在整个变化过程中完全相同。关键是同一对的共同偏移会被差值消去，却会增大两列各自的离均平方和。

6.3 两个独立正态样本：为什么合并方差有条件

现在换成两个真正独立的样本：$X_1,\dots,X_m$ 来自 $N(\mu_1,\sigma^2)$，$Y_1,\dots,Y_n$ 来自 $N(\mu_2,\sigma^2)$，两组内部及组间均相互独立，$m,n\ge 2$。暂时假设两个总体具有相同但未知的方差 $\sigma^2>0$。于是

$$\bar X-\bar Y\sim N\!\left(\mu_1-\mu_2,\ \sigma^2\left(\frac{1}{m}+\frac{1}{n}\right)\right).$$

若两个总体方差相同，两组用于估计 σ^2 的平方和自然应当放在一起。但每组平方和要分别除以它自己的自由度，不是把两个样本标准差直接取平均。

定义 6.2　合并样本方差.　对于上述两个独立且具有共同方差的正态样本，定义

$$S_p^2=\frac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2},$$

其中 S_X^2,S_Y^2 是两组各自的无偏样本方差。分子就是两组组内离差平方和的总和，分母是两组自由度之和 $(m-1)+(n-1)$。

例如两组数据分别为 $(2,4,6)$ 与 $(1,3,5)$，它们的均值为 4 和 3，各组离差平方和均为 8。所以 $S_p^2=(8+8)/(2+2)=4$，而 $\bar X-\bar Y=1$。这里的数字只展示统计量怎样计算；是否采用 t 分布作精确检验，仍须核对原来的抽样模型。

命题 6.3　独立两样本的合并 t 分布.　设 $X_1,\dots,X_m$、$Y_1,\dots,Y_n$ 满足本节开头的正态、共同方差与相互独立条件。则

$$U=\frac{(m+n-2)S_p^2}{\sigma^2}\sim\chi^2_{m+n-2},$$

并且 U 与 $\bar X-\bar Y$ 相互独立。因此

$$\frac{(\bar X-\bar Y)-(\mu_1-\mu_2)}{S_p\sqrt{1/m+1/n}}\sim t_{m+n-2},$$

特别地，在 $H_0:\mu_1=\mu_2$ 下，$T_p=(\bar X-\bar Y)/(S_p\sqrt{1/m+1/n})\sim t_{m+n-2}$。

证明.　第一节的正态样本分解可分别用于两组，给出

$$U_X=\frac{(m-1)S_X^2}{\sigma^2}\sim\chi^2_{m-1},\qquad U_Y=\frac{(n-1)S_Y^2}{\sigma^2}\sim\chi^2_{n-1}.$$

每一组的均值与本组平方和独立，而两组随机变量整体独立。因此 U_X,U_Y 相互独立，且都与 $(\bar X,\bar Y)$ 独立。由卡方分布定义，可将构成 U_X,U_Y 的独立标准正态平方项合起来，得到 $U_X+U_Y=U\sim\chi^2_{m+n-2}$。另一方面，

$$Z=\frac{(\bar X-\bar Y)-(\mu_1-\mu_2)}{\sigma\sqrt{1/m+1/n}}\sim N(0,1)$$

且 Z 与 U 独立。把分子、分母同时写成 Z 与 U，原比值恰等于 $Z/\sqrt{U/(m+n-2)}$，故服从 t_{m+n-2}。同样可知 $S_p>0$ 几乎必然。

我们在两个样本中一共估计了两个均值，留下 $m+n-2$ 个自由度；这就是合并检验的自由度来源。

如果两组方差分别为 σ_1^2 与 σ_2^2，而且事先没有理由认为它们相等，则

$$\operatorname{Var}(\bar X-\bar Y)=\frac{\sigma_1^2}{m}+\frac{\sigma_2^2}{n}.$$

此时 $S_X^2/m + S_Y^2/n$ 是该方差的一个无偏估计，但把它开平方后放进统计量的分母，一般不能声称其服从某个自由度为 $m+n-2$ 的精确 t 分布。不同方差对应两种尺度的平方和，无法像前面那样直接合成一个共同尺度的卡方量。习题 6.3 将让我们精确比较这两种情况。

本节命题不仅适用于保留所有读数的资料。如果知道两组样本量、两组均值与各自组内离差平方和，就已经能够计算检验统计量，而不必逐个恢复原始观测。这里哪些统计量需要保留，是由公式本身决定的。

6.4 两组比例：先找出真正的随机量

对于两组互相独立的伯努利观测，设第一组成功 K 次、样本量 m，第二组成功 L 次、样本量 n，则

$$K \sim \mathrm{Bin}(m, p_1), \qquad L \sim \mathrm{Bin}(n, p_2), \qquad \widehat{p}_1 = \frac{K}{m}, \quad \widehat{p}_2 = \frac{L}{n}.$$

由期望和独立方差公式，

$$\mathbb{E}(\widehat{p}_1 - \widehat{p}_2) = p_1 - p_2, \qquad \mathrm{Var}(\widehat{p}_1 - \widehat{p}_2) = \frac{p_1(1-p_1)}{m} + \frac{p_2(1-p_2)}{n}.$$

例如在 $p_1 = p_2 = 1/2$、$m = n = 20$ 时，两个样本比例之差的方差为 $\frac{1}{4}(1/20 + 1/20) = 1/40$。这里的方差是比例差的抽样方差，不是 40 个伯努利观测本身的方差。

在比较两组成功次数时，除了计算比例差，有时还可以直接研究哪一组成功次数较多。若两组的试验次数相同，交换两组的成功次数，会使概率产生一个简单的比例关系。即使不求出成功次数之差的完整分布，也能借此比较两组谁更可能获胜。习题 6.4 将利用这一关系得到严格的概率界。

在大样本比较中，还要区分两种规模：观测次数的增长决定估计误差的大小，而真实成功概率之差可能随预算变化。若预算为 B，两组样本量都与 B 同阶，则样本比例的随机误差通常是 $B^{-1/2}$ 量级。因此，研究 $p_1 = p + \Delta/\sqrt{B}$、$p_2 = p$，恰好能同时看到系统性差别与随机波动。下一道正式例题还将考虑两组观测成本不同的情形。

例 6.2. 两组独立 Bernoulli 观测，每次成本分别为 $c_1, c_2 > 0$，预算为 $B \to \infty$。样本量 m_B, n_B 满足

$$c_1 m_B + c_2 n_B = B + o(B), \qquad m_B/B \to a > 0, \quad n_B/B \to b > 0.$$

固定 $p \in (0,1)$、$\Delta \in \mathbb{R}$，第一组成功概率为 $p+\Delta/\sqrt{B}$，第二组为 p（B 足够大）。求 $\sqrt{B}(\hat{p}_1 - \hat{p}_2)$ 的极限分布，并求使渐近方差最小的 m_B/n_B 极限。

解. 记两组成功比例为 $\widehat{p}_1, \widehat{p}_2$，并令 $q_B = p + \Delta/\sqrt{B}$。因 $p \in (0,1)$，当 B 足够大时 $q_B \in (0,1)$。最直接的想法是对两组比例使用中心极限定理，不过第一组的成功概率随 B 改变；下面先把这一变化化成一个均方趋零的误差。

给第一组每次观测取独立 $U_i \sim U(0,1)$，同时定义

$$X_i = \mathbf{1}_{\{U_i \le q_B\}}, \qquad X_i^0 = \mathbf{1}_{\{U_i \le p\}}.$$

这样 X_i 具有原题所需的伯努利分布，而 X_i^0 的参数始终为 p。令 $H_i = X_i - X_i^0$。有 $\mathbb{E}H_i = \Delta/\sqrt{B}$，且 H_i^2 只在 U_i 落入长度为 $|\Delta|/\sqrt{B}$ 的小区间时取值 1，故

$$\mathrm{Var}\, H_i \le \mathbb{E}H_i^2 = \frac{|\Delta|}{\sqrt{B}}.$$

H_i 在不同 i 之间相互独立，因此

$$\mathbb{E}\left[\sqrt{B}\left\{\frac{1}{m_B}\sum_i H_i - \frac{\Delta}{\sqrt{B}}\right\}\right]^2 = \frac{B}{m_B}\operatorname{Var} H_1 \le \frac{B|\Delta|}{m_B\sqrt{B}} \longrightarrow 0.$$

对成功概率固定为 p 的两组独立样本，中心极限定理给出

$$\sqrt{B}(\bar{X}^0 - p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{a}\right), \qquad \sqrt{B}(\bar{Y} - p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{b}\right).$$

两极限相互独立；前面均方趋零的项在概率意义下也趋于零。结合 $\sqrt{B}(q_B - p) = \Delta$，得到

$$\boxed{\sqrt{B}(\widehat{p}_1 - \widehat{p}_2) \xrightarrow{d} N\left(\Delta, p(1-p)\left(\frac{1}{a} + \frac{1}{b}\right)\right).}$$

把预算条件除以 B 再取极限，得 $c_1 a + c_2 b = 1$。渐近方差只需极小化 $1/a + 1/b$。利用预算关系，

$$\frac{1}{a} + \frac{1}{b} = (c_1 a + c_2 b)\left(\frac{1}{a} + \frac{1}{b}\right) = c_1 + c_2 + c_1\frac{a}{b} + c_2\frac{b}{a}.$$

由基本不等式，$c_1 a/b + c_2 b/a \ge 2\sqrt{c_1 c_2}$，等号当且仅当 $a/b = \sqrt{c_2/c_1}$。此比例可以通过选择满足预算关系的正 a, b 实现（整数样本量取整不改变极限），故唯一最优分配比例为

$$\boxed{\lim_{B\to\infty} \frac{m_B}{n_B} = \sqrt{\frac{c_2}{c_1}}.}$$

这里优化的是题设极限方案的渐近方差，未要求每个有限预算下的整数样本量也恰好达到同一比例。

6.5 两组标签丢失以后

前面一直知道每个观测属于哪一组。现在设两组数据的数值都保存下来了，但不再知道哪个数字来自第一组、哪个来自第二组。数学上，能够使用的只是合并后的无标签多重集合：重复出现的数要保留重复次数，原来的组别却无法恢复。

从这种记录可以算出全部观测的总和、总均值、相对于总均值的平方和等量；它们在交换两组时保持不变。至于涉及两组之间比较的参数，能否仅由合并数据估计，就不能再根据原始的组别公式直接判断了。重要的是从实际可见的数据出发，而不是在推导中暗中使用已经丢失的标签。

下面的例题从一个简单的正态模型出发，研究两种看起来相近、但面对标签丢失会表现得不同的估计目标。

例 6.3. 两组相互独立的正态样本各有 $n \ge 2$ 个观测，分别来自 $N(\mu_1, \sigma^2)$ 与 $N(\mu_2, \sigma^2)$，其中 $\sigma^2 > 0$ 已知。仪器只保留全部 $2n$ 个数的无标签多重集合。

1. 证明不存在只由该记录计算、且对每个 (μ_1, μ_2) 都可积并无偏估计 $\mu_1 - \mu_2$ 的统计量。

2. 构造仅依赖该记录的 $(\mu_1 - \mu_2)^2$ 的无偏估计量。

解. (1) 记 R 为合并后所有 $2n$ 个观测值组成的无标签多重集合。把两组参数由 (μ_1, μ_2) 互换为 (μ_2, μ_1)，相当于将产生原来第一组的随机数与产生第二组的随机数对调，R 的分布并未变化。

因此任何只由 R 算出且可积的统计量 T，都满足

$$\mathbb{E}_{\mu_1,\mu_2}T=\mathbb{E}_{\mu_2,\mu_1}T.$$

若它对每一对参数都无偏估计 $\mu_1-\mu_2$，则上式两端又必须分别等于 $\mu_1-\mu_2$ 与 $\mu_2-\mu_1$。取 $\mu_1\neq\mu_2$ 即得矛盾。

(2) 虽然不能从无标签数据区分两组的方向,全部数字的总均值 $Z=(\sum_i X_i+\sum_j Y_j)/(2n)$ 及总离均平方和

$$Q=\sum_i (X_i-Z)^2+\sum_j (Y_j-Z)^2$$

都可以直接计算。暂时在证明中利用两组原始记号，把平方和分成组内及组间两部分:

$$Q=\sum_i (X_i-\bar X)^2+\sum_j (Y_j-\bar Y)^2+\frac{n}{2}(\bar X-\bar Y)^2.$$

这里 $Z=(\bar X+\bar Y)/2$，把 $X_i-Z=(X_i-\bar X)+(\bar X-Z)$ 展开后，交叉项因 $\sum_i(X_i-\bar X)=0$ 消失，另一组也一样。

令 $\delta=\mu_1-\mu_2$。每组样本方差无偏，故两组组内平方和的期望各为 $(n-1)\sigma^2$；同时两组均值独立,

$$\mathbb{E}(\bar X-\bar Y)^2=\mathsf{Var}(\bar X-\bar Y)+\delta^2=\frac{2\sigma^2}{n}+\delta^2.$$

所以 $\mathbb{E}Q=(2n-1)\sigma^2+\frac{n}{2}\delta^2$，整理得到

$$\boxed{\widehat{\delta^2}=\frac{2}{n}\Big[Q-(2n-1)\sigma^2\Big].}$$

此量仅由实际保留的 R 与已知 σ^2 决定，期望恰为 δ^2。它在某些记录下可以为负值；无偏估计要求的是每个参数下的期望正确，并不要求每一次估计结果都与目标同号。

习题

习题 6.1. 两批相互独立的样本各有 $n\geq 2$ 个观测，均来自 $N(\mu,\sigma^2)$，$\sigma>0$ 未知。比较两批样本标准差后，选择标准差较小（或较大）的一批，仅用其 $T=\sqrt{n}(\bar X_J-\mu_0)/S_J$，按 t_{n-1} 的双侧临界值检验 $H_0:\mu=\mu_0$。证明选较小标准差时真实第一类错误概率严格大于 α，选较大时严格小于 α，其中 $0<\alpha<1$。

习题 6.2. 给定 $a_1<\cdots<a_n$ 与 $b_1<\cdots<b_n$（$n\geq 2$），可任意把 a_i 和 $b_{\pi(i)}$ 配成 n 对。记差值的无偏样本方差为 S_π^2。求 S_π^2 的最小、最大值及全部取等配对，并证明差值均值与配对无关。

习题 6.3. 独立正态样本分别有 $m,n\geq 2$ 个，方差为 $\sigma_1^2,\sigma_2^2>0$，不预设相等。令

$$S_p^2=\frac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2},\qquad V=S_p^2\left(\frac{1}{m}+\frac{1}{n}\right).$$

1. 求 $\mathbb{E}V-\mathsf{Var}(\bar X-\bar Y)$，给出 V 无偏估计后者的充要条件。

2. 若 $m=n=r$ 而 $\sigma_1^2\neq\sigma_2^2$，证明把合并方差按真实均值差方差归一化后，不服从 χ^2_{2r-2}。

习题 6.4. 两组试验各独立进行 $n \ge 2$ 次，成功概率分别为 $0 < q < p < 1$。记两组的成功次数为 K, L，令

$$R = \frac{p(1-q)}{q(1-p)}.$$

1. 对每个整数 $1 \le d \le n$，证明

$$\mathbb{P}(K - L = d) = R^d \, \mathbb{P}(K - L = -d).$$

2. 已知两组的成功次数不相等，证明

$$\frac{R}{1+R} < \mathbb{P}(K > L \mid K \ne L) < \frac{R^n}{1+R^n}.$$

习题 6.5. $X \sim N(\mu, 1)$、$Y \sim N(\mu, 4)$ 相互独立，$\mu \in \mathbb{R}$ 未知。仪器只保留无标签集合 $\{X, Y\}$。

1. 在所有平方可积、全参数无偏且满足 $T(\{x+t, y+t\}) = T(\{x, y\}) + t$ 的无标签估计量中，求最小方差及全部取等估计量。

2. 若保留通道标签，求最小方差线性无偏估计量并比较。

习题 6.6. 设 $n \ge 2$，$X_1, \dots, X_n$ 独立同分布，$\bar{X} = n^{-1}\sum_i X_i$、$S^2 = (n-1)^{-1}\sum_i (X_i - \bar{X})^2$。对任意有限 $c > 0$，证明

$$\sup_{\substack{F \text{ 具有连续密度} \\ \mathbb{E}_F X = 0,\ \mathrm{Var}_F X = 1}} \mathbb{P}_F\left(\left| \frac{\sqrt{n}\,\bar{X}}{S} \right| > c \right) = 1.$$

在上述分布类中，$S > 0$ 几乎必然。

习题 6.7. 每招募一名受试者花费 $c > 0$，每次测量再花费 1。每人测量 $k \ge 1$ 次，总经费为 B，人数为 $m_B = \lfloor B/(c+k) \rfloor$。第 j 人第 ℓ 次观测为 $Y_{j\ell} = \mu + U_j + \varepsilon_{j\ell}$，其中各 U_j 独立、均值 0、方差 $\tau^2 > 0$；各 $\varepsilon_{j\ell}$ 彼此独立、均值 0、方差 $\sigma^2 > 0$，并与全部 U_j 独立。以所有读数的平均估计 μ。

1. 固定整数 k，求 $\lim_{B \to \infty} B \, \mathrm{Var}(\hat{\mu}_{B,k})$。

2. 求使该极限最小的全部正整数 k，包括并列最优情形。

习题 6.8. 两组实数 $X_1, \dots, X_m$、$Y_1, \dots, Y_n$，$m, n \ge 2$。把它们看成 $N = m + n$ 个点：第一组横坐标为 $x = 0$、纵坐标为 X_i，第二组为 $x = 1$、纵坐标为 Y_j。对拟合直线 $z = a + bx$，一个点的纵坐标减去它在直线上的拟合值称为该点的残差。

1. 直接极小化所有残差的平方和 $\sum (z - a - bx)^2$，求最小二乘 $\hat{a}, \hat{b}$ 和最小残差平方和 W。

2. 若两组独立服从 $N(\mu_1, \sigma^2)$、$N(\mu_2, \sigma^2)$，证明以残差方差 $\hat{s}^2 = W/(N-2)$、$S_{xx} = \sum (x - \bar{x})^2$ 定义的斜率统计量 $\hat{b}/(\hat{s}/\sqrt{S_{xx}})$，与独立两样本合并 t 统计量只差符号。

第七章　一元线性回归

7.1　最小二乘直线、拟合值与残差

现在研究一组带有两个数值的观测 (x_i, Y_i)：x_i 是第 i 次观测时预先选定的横坐标，Y_i 是所观测的响应。例如，在事先规定的不同温度下测量一种材料的长度，温度可以作为 x_i，长度作为 Y_i。我们暂时不假定响应一定沿直线变化，只问：**哪一条直线最贴近已经观察到的数据?**

定义 7.1　最小二乘直线、拟合值与残差.　设 $n \geq 2$，$x_1, \ldots, x_n$ 是不全相等的固定实数，$Y_1, \ldots, Y_n$ 是实值观测变量。对任意 $a, b \in \mathbb{R}$，记

$$Q(a,b) = \sum_{i=1}^{n} (Y_i - a - bx_i)^2.$$

使 Q 最小的直线 $y = \widehat{a} + \widehat{b}x$ 称为**带截距的最小二乘拟合直线**，$\widehat{a}, \widehat{b}$ 分别是拟合截距和拟合斜率。第 i 个点在这条直线上的**拟合值**与**残差**分别为

$$\widehat{Y}_i = \widehat{a} + \widehat{b}x_i, \qquad e_i = Y_i - \widehat{Y}_i.$$

所有残差的平方和记为

$$R = \sum_{i=1}^{n} e_i^2,$$

称为**残差平方和**，也常记作 SSE。

对一次实际测量，数据记为 y_i，相应的拟合值与残差则是确定的数。残差带有正负号：数据点在拟合直线上方时为正，在下方时为负；它不是点到直线的最短距离，而是两者的竖直差。

先把横坐标和响应各自减去平均数：

$$\bar{x} = \frac{1}{n}\sum_i x_i, \quad \bar{Y} = \frac{1}{n}\sum_i Y_i, \quad t_i = x_i - \bar{x}.$$

由此有 $\sum_i t_i = 0$。再记

$$S_{xx} = \sum_i t_i^2 > 0, \quad S_{xy} = \sum_i t_i(Y_i - \bar{Y}) = \sum_i t_i Y_i, \quad S_{yy} = \sum_i (Y_i - \bar{Y})^2.$$

用中心化后的横坐标表示斜率，可以同时化简最小二乘计算和后面的概率公式。

命题 7.1　最小二乘解与残差的两个恒等式.　上述最小二乘直线存在且唯一，并且

$$\widehat{b} = \frac{S_{xy}}{S_{xx}}, \qquad \widehat{a} = \bar{Y} - \widehat{b}\bar{x}.$$

它的残差满足

$$\sum_i e_i = 0, \qquad \sum_i (x_i - \bar{x}) e_i = 0, \qquad R = S_{yy} - \frac{S_{xy}^2}{S_{xx}} \geq 0.$$

证明. 对任意候选直线，写成

$$Y_i - a - bx_i = (Y_i - \bar{Y}) - bt_i + (\bar{Y} - a - b\bar{x}).$$

前两项对 i 求和都是零，因此最后一项与它们的交叉项在平方和中消失。于是

$$Q(a,b) = S_{yy} - 2bS_{xy} + b^2 S_{xx} + n(\bar{Y} - a - b\bar{x})^2.$$

将关于 b 的二次式配方，得到

$$Q(a,b) = S_{yy} - \frac{S_{xy}^2}{S_{xx}} + S_{xx}\left(b - \frac{S_{xy}}{S_{xx}}\right)^2 + n(\bar{Y} - a - b\bar{x})^2.$$

因为 $S_{xx} > 0$，后两个平方项同时为零，当且仅当 $b = S_{xy}/S_{xx}$ 且 $a = \bar{Y} - b\bar{x}$。这证明了存在唯一最小二乘解，也给出了 R 的表达式。

再把求得的直线代入残差的定义，得到

$$e_i = (Y_i - \bar{Y}) - \widehat{b}t_i.$$

直接求和，利用 $\sum_i (Y_i - \bar{Y}) = \sum_i t_i = 0$ 及 $\sum_i t_i(Y_i - \bar{Y}) = \widehat{b}S_{xx}$，便得到两个残差恒等式。$R \geq 0$ 则来自它是平方和。

例如, 三次观测的横坐标为 $-1, 0, 1$, 响应值为 $0, 2, 1$。这时 $\bar{x} = 0$、$\bar{y} = 1$、$S_{xx} = 2$、$S_{xy} = 1$, 拟合直线是

$$y = 1 + \frac{x}{2}.$$

三个拟合值是 $1/2, 1, 3/2$, 对应残差是 $-1/2, 1, -1/2$。它们的和为零，与中心化横坐标相乘再求和也为零，而残差平方和为 $3/2$。这个小计算说明，残差恒等式描述的是最小二乘求得的直线，与数据是否真的来自线性关系无关。

当 $n = 2$ 且横坐标不同，拟合直线必经过两点，所以 $R = 0$。即使 $n \geq 3$，某份数据也可能恰好落在一条直线上。因而仅凭残差平方和的大小，尚不能判断随机误差的大小；这需要对数据如何产生作出进一步假设。

7.2 加入一个新观测

原有拟合直线求出后，如果又加入一个点，新的拟合直线可能上移或下移，也可能改变斜率。为了比较这种变化，必须说清新点相对于哪一条直线的位置：在旧直线上方 r 个单位，是说新点纵坐标为 $\ell(u) + r$；重新拟合以后，它相对于新直线的残差通常已不再等于 r。

下面的问题要求选择新点的横坐标，使拟合直线在给定位置的变化最大。这比机械地分别计算新截距与新斜率更能体现中心化的好处。

例 7.1. 已有 $n \geq 2$ 个数据点 (x_i, y_i)，其中 x_i 不全相等，最小二乘直线为 $y = \ell(x)$。现加入一个新点

$$(u, \ell(u) + r), \qquad r \neq 0,$$

其横坐标 u 可任意选择。记新拟合直线为 $\ell_u(x)$。给定位置 $z \in \mathbb{R}$，求

$$\max_{u \in \mathbb{R}} |\ell_u(z) - \ell(z)|$$

及所有达到最大值的 u。

解. 记原数据的均值为 $\bar{x},\bar{y}$，中心平方和为 $S=\sum_i(x_i-\bar{x})^2>0$，原拟合斜率为 $\widehat{b}$。新点横坐标为 u，令

$$t=u-\bar{x},\quad d=z-\bar{x},\quad A=\frac{n+1}{n}S>0,\quad B=\frac{S}{n}>0.$$

因为 $\ell(u)=\bar{y}+\widehat{b}t$，新增响应为 $\bar{y}+\widehat{b}t+r$。由中心平方和的更新公式，

$$S'_{xx}=S+\frac{n}{n+1}t^2,\qquad S'_{xy}=\widehat{b}S+\frac{n}{n+1}t(\widehat{b}t+r).$$

所以新旧斜率之差为 $\widehat{b}_u-\widehat{b}=rt/(A+t^2)$。又因为两份数据的中心分别为

$$\bar{x}'=\bar{x}+\frac{t}{n+1},\qquad \bar{y}'=\bar{y}+\frac{\widehat{b}t+r}{n+1},$$

在给定位置 z 的两条拟合直线之差便是

$$\begin{aligned}\ell_u(z)-\ell(z)&=\frac{r}{n+1}+\frac{rt}{A+t^2}\left(d-\frac{t}{n+1}\right)\\&=r\,\frac{B+dt}{A+t^2}.\end{aligned}\tag{1}$$

因此只需在 $t\in\mathbb{R}$ 上求 $|B+dt|/(A+t^2)$ 的最大值。

先设 $d\neq0$，**以分子为新变量**，令 $s=B+dt$，则

$$\frac{|B+dt|}{A+t^2}=\frac{d^2|s|}{Ad^2+(s-B)^2}.$$

若 $s<0$，改取 $-s>0$，分子绝对值不变，但分母由 $(s-B)^2$ 变为 $(-s-B)^2$，且后者严格更小。$s=0$ 时分式为零，显然不会达到最大值。因此只需考察 $s>0$。

对这样的 s，除以 s 后得到

$$\frac{d^2s}{Ad^2+(s-B)^2}=\frac{d^2}{s-2B+\dfrac{B^2+Ad^2}{s}}.$$

由基本不等式，

$$s+\frac{B^2+Ad^2}{s}\geq2\sqrt{B^2+Ad^2},$$

且等号当且仅当 $s=\sqrt{B^2+Ad^2}$。由于 $d\neq0$，有 $\sqrt{B^2+Ad^2}>B$，所以上式给出的分母下界严格为正。于是最大值唯一地在这个 s 处取得，等于

$$\frac{d^2}{2(\sqrt{B^2+Ad^2}-B)}=\frac{B+\sqrt{B^2+Ad^2}}{2A},$$

相应

$$t=\frac{\sqrt{B^2+Ad^2}-B}{d}=\frac{Ad}{B+\sqrt{B^2+Ad^2}}.$$

当 $d=0$,式 (1) 直接变为 $rB/(A+t^2)$,绝对值仅在 $t=0$ 处最大,值为 $|r|B/A=|r|/(n+1)$;上述两个通式在 $d=0$ 时也给出同样答案。故对所有给定的 z,

$$\boxed{\max_{u\in\mathbb{R}}|\ell_u(z)-\ell(z)|=\frac{|r|}{2A}\left(B+\sqrt{B^2+Ad^2}\right)}$$

且**唯**一达到最大值的横坐标为

$$\boxed{u=\bar{x}+\frac{Ad}{B+\sqrt{B^2+Ad^2}}},\quad A=\frac{n+1}{n}S,\ B=\frac{S}{n},\ d=z-\bar{x}.$$

这里固定的 r 是新点相对于旧拟合直线的竖直偏差。加入新点后，该点的实际残差一般已改变。

7.3 随机误差、回归参数与估计精度

前面一直只研究一份数据的最小二乘计算。要解释为什么斜率可以用于估计总体关系，需要说明响应 Y_i 的随机来源。

定义 7.2 一元固定设计线性回归模型. 横坐标 $x_1,\dots,x_n$ 仍是预先确定且不全相等的实数。假设存在未知常数 a,b，使

$$Y_i=a+bx_i+\varepsilon_i,\qquad 1\le i\le n,$$

其中每个 ε_i 的期望为零且二阶矩有限。称 a,b 为**真实回归参数**，ε_i 为第 i 次观测的**随机误差**。于是 $\mathbb{E}Y_i=a+bx_i$。

这里的随机误差与前面的残差不同：随机误差是响应减去未知的真实均值 $a+bx_i$，残差是响应减去用同一组数据算出来的拟合值 $\widehat{a}+\widehat{b}x_i$。一般说来，$\varepsilon_i\neq e_i$。此前的最小二乘公式没有使用这个模型，现在才把它用于统计推断。

把 $Y_i=a+bx_i+\varepsilon_i$ 代入第一节的斜率公式，利用 $\sum_i t_i=0$、$\sum_i t_ix_i=S_{xx}$，可得

$$\widehat{b}-b=\frac{\sum_i t_i\varepsilon_i}{S_{xx}},\qquad \widehat{a}-a=\bar{\varepsilon}-\bar{x}(\widehat{b}-b),\quad \bar{\varepsilon}=\frac{1}{n}\sum_i\varepsilon_i.$$

因此只要误差均值为零，就有 $\mathbb{E}\widehat{a}=a$、$\mathbb{E}\widehat{b}=b$：即使误差不服从正态分布，最小二乘截距与斜率依然无偏。

现在增加一个假设：所有误差的方差都是同一个 $\sigma^2>0$，并且不同观测的误差两两不相关，即

$$\mathrm{Var}(\varepsilon_i)=\sigma^2,\qquad \mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0\quad(i\neq j).$$

两两不相关是方差计算所需的条件；此处尚不要求误差相互独立。因为 $\sum_i t_i=0$，

$$\mathrm{Var}(\widehat{b})=\frac{\sigma^2}{S_{xx}},\quad \mathrm{Var}(\bar{\varepsilon})=\frac{\sigma^2}{n},\quad \mathrm{Cov}(\bar{\varepsilon},\widehat{b}-b)=\frac{\sigma^2}{nS_{xx}}\sum_i t_i=0.$$

所以

$$\mathrm{Var}(\widehat{a})=\sigma^2\left(\frac{1}{n}+\frac{\bar{x}^2}{S_{xx}}\right),\qquad \mathrm{Cov}(\widehat{a},\widehat{b})=-\frac{\sigma^2\bar{x}}{S_{xx}}.$$

定义 7.3 平均响应、拟合均值与新观测. 给定一个在观测前确定的横坐标 x_0，在上述模型中，称

$$m(x_0)=a+bx_0$$

为该位置的**平均响应**。它的估计值为 $\widehat{m}(x_0)=\widehat{a}+\widehat{b}x_0$。如果将来在同一横坐标再测一次，记所得的新响应为 $Y_0=m(x_0)+\varepsilon_0$。平均响应是固定但未知的数，未来观测 Y_0 则仍会受到新的随机误差影响。

命题 7.2　拟合均值的精度和残差方差估计.　在本节共同方差、两两不相关的假设下，对任意预先确定的 x_0，有

$$\mathrm{Var}\{\widehat{m}(x_0)\} = \sigma^2 c(x_0), \qquad c(x_0) = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}.$$

若 $n \geq 3$，则 $s^2 = R/(n-2)$ 对 σ^2 无偏。若新误差 ε_0 也具有均值零、方差 σ^2，并且与全部旧误差不相关，则

$$\mathrm{Var}\{Y_0 - \widehat{m}(x_0)\} = \sigma^2\{1 + c(x_0)\}.$$

证明.　对第一式，写

$$\widehat{m}(x_0) - m(x_0) = \bar{\varepsilon} + (x_0 - \bar{x})(\widehat{b} - b).$$

右端两项不相关，方差可以直接相加，得到所需公式。

再令 $H = \widehat{b} - b$。由残差的定义，

$$e_i = \varepsilon_i - \bar{\varepsilon} - H t_i.$$

将平方和展开，利用 $\sum_i t_i = 0$ 以及 $\sum_i t_i \varepsilon_i = H S_{xx}$，化为

$$R = \sum_i \varepsilon_i^2 - n\bar{\varepsilon}^2 - S_{xx} H^2.$$

右边三项的期望依次为 $n\sigma^2, \sigma^2, \sigma^2$，所以 $\mathbb{E}R = (n-2)\sigma^2$。当 $n \geq 3$ 时除以 $n-2$，便得到无偏估计 s^2。最后，新误差与旧样本的任何固定线性组合都不相关，因此 ε_0 与 $\widehat{m}(x_0) - m(x_0)$ 不相关，两者相减的方差相加即得第三式。

从 $c(x_0)$ 的式子还能直接看出：估计平均响应时，样本横坐标中心 $x_0 = \bar{x}$ 的方差最小，为 σ^2/n；离中心越远，斜率估计的不确定性带来的影响越大。预测新的一次观测时，还要计入它自身的随机波动，故方差比平均响应的估计多一个 σ^2。

命题 7.3　线性无偏斜率估计的方差下界.　在上述共同方差、两两不相关模型中，设 $T = \sum_i w_i Y_i$，各 w_i 只依赖已知的设计点。若它对全部 $a, b \in \mathbb{R}$ 均无偏估计 b，则

$$\mathrm{Var}(T) \geq \frac{\sigma^2}{S_{xx}},$$

等号当且仅当对每个 i 都有 $w_i = t_i / S_{xx}$，亦即 $T = \widehat{b}$。

证明.　由 $\mathbb{E}T = a\sum_i w_i + b\sum_i w_i x_i$，全参数无偏的充要条件是

$$\sum_i w_i = 0, \qquad \sum_i w_i x_i = 1.$$

于是 $\sum_i w_i t_i = 1$。Cauchy 不等式给出

$$1 = \left(\sum_i w_i t_i\right)^2 \leq \left(\sum_i w_i^2\right) S_{xx}.$$

利用误差的共同方差与两两不相关，$\mathrm{Var}(T) = \sigma^2 \sum_i w_i^2$，便得到下界。等号要求 w_i 与 t_i 成比例，两个无偏约束唯一确定比例系数为 $1/S_{xx}$。

这个最优性结论比较的是权重在观测前固定的线性无偏估计量，不必额外假定误差正态。如果误差具有不同方差，公式将变为

$$\mathrm{Var}(\widehat{b}) = \frac{\sum_i t_i^2 \,\mathrm{Var}(\varepsilon_i)}{S_{xx}^2},$$

最优权重也可能变化。下面换一个角度看最小二乘拟合值：把它写成原始响应的加权平均，这些权重之和恒为 1，却未必全都非负。由此可以精确判定：在什么横坐标上，拟合直线总不会超出任何一组原始响应的范围？

例 7.2. 给定 $n \geq 3$ 个不全相等的实数 $x_1, \ldots, x_n$。对任意响应数据 $y_1, \ldots, y_n$，用带截距的最小二乘直线 $y = \ell(x)$ 拟合这些点。

(1) 求所有满足如下性质的实数 z：无论响应数据怎样取，拟合值 $\ell(z)$ 都介于 $y_1, \ldots, y_n$ 的最小值和最大值之间。

(2) 求全部满足如下性质的横坐标配置：对任意响应数据，每个原横坐标处的拟合值 $\ell(x_i)$ 都介于最小和最大响应之间。若配置不满足这一性质，给出只取 $0, 1$ 的一组响应，使某个拟合值超出响应范围。

解. 记

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x})^2 > 0,$$

并设 $a = \min_i x_i$，$b = \max_i x_i$。因横坐标不全相等，$a < \bar{x} < b$。最小二乘直线的斜率为 $\sum_i (x_i - \bar{x})y_i / S_{xx}$，故

$$\ell(z) = \bar{y} + \frac{z - \bar{x}}{S_{xx}} \sum_i (x_i - \bar{x}) y_i = \sum_{i=1}^{n} w_i(z) y_i, \qquad w_i(z) = \frac{1}{n} + \frac{(z - \bar{x})(x_i - \bar{x})}{S_{xx}}. \tag{1}$$

这里 $\sum_i w_i(z) = 1$。对于一组和为 1 的固定权重，$\sum_i w_i y_i$ 对每一组实数 y_i 都介于其最小值与最大值之间，当且仅当所有 $w_i \geq 0$：权重非负时它是凸组合；若 $w_j < 0$，只取 $y_j = 1$、其余 $y_i = 0$ 就得到负值，超出 $[0, 1]$。

(1) 由 (1)，当 $z \geq \bar{x}$ 时，最小权重出现在 $x_i = a$，故全部权重非负等价于

$$\frac{1}{n} - \frac{(z - \bar{x})(\bar{x} - a)}{S_{xx}} \geq 0, \quad \text{即} \quad z \leq \bar{x} + \frac{S_{xx}}{n(\bar{x} - a)}.$$

当 $z \leq \bar{x}$ 时，最小权重出现在 $x_i = b$，同理等价于 $z \geq \bar{x} - S_{xx}/[n(b - \bar{x})]$。因此所求全部实数构成闭区间

$$\boxed{\left[\bar{x} - \frac{S_{xx}}{n(b - \bar{x})},\ \bar{x} + \frac{S_{xx}}{n(\bar{x} - a)}\right]}. \tag{2}$$

两端也取到，因为此时允许某些权重等于 0。

(2) 对每个横坐标都有 $(x_i - a)(b - x_i) \geq 0$。将其展开求和，得到

$$0 \leq \sum_i (x_i - a)(b - x_i) = n(\bar{x} - a)(b - \bar{x}) - S_{xx}. \tag{3}$$

等号成立当且仅当所有 $x_i \in \{a, b\}$，即横坐标恰好只有两种不同取值。

要求在每个原横坐标处都保持响应范围，特别要求 (2) 包含 a, b。由 (2) 可知，这等价于

$$\frac{S_{xx}}{n(b - \bar{x})} \geq \bar{x} - a, \qquad \frac{S_{xx}}{n(\bar{x} - a)} \geq b - \bar{x},$$

两式都等价于 $S_{xx} \geq n(\bar{x} - a)(b - \bar{x})$。结合 (3)，只能取等，因此充要条件是设计点恰有两个不同取值。这时直线在 a 与 b 处的拟合值分别就是对应那组响应的平均数，故确实都介于全部响应的最小值和最大值之间。

若至少有三个不同横坐标，则 (3) 严格不等。任取一个达到 b 的下标 j，令 $y_j = 1$、其余响应全为 0。在任意达到 a 的横坐标处，由 (1) 得到

$$\ell(a) = w_j(a) = \frac{1}{n} - \frac{(\bar{x} - a)(b - \bar{x})}{S_{xx}} < 0.$$

这组响应的范围是 $[0, 1]$，而拟合值已经小于 0，满足题目所求。

7.4 正态误差下的精确推断

前面已由均值、方差与不相关性得到许多结论。如果还想用第六章的 t 分布给斜率建立精确置信区间，则要进一步假定 $n \geq 3$，且 $\varepsilon_1, \ldots, \varepsilon_n$ 相互独立并服从 $N(0, \sigma^2)$，$\sigma > 0$。

把误差向量除以 σ，得到 n 个独立标准正态变量。回忆第一节所使用的两个方向：常数方向 $(1, \ldots, 1)$ 和中心化横坐标方向 $(t_1, \ldots, t_n)$。它们互相正交；对应的单位向量分别为

$$v_1 = \frac{(1, \ldots, 1)}{\sqrt{n}}, \qquad v_2 = \frac{(t_1, \ldots, t_n)}{\sqrt{S_{xx}}}.$$

沿这两个方向的误差分别决定拟合截距与斜率，剩下的 $n-2$ 个正交方向才表现为残差。因此，残差方差估计的分母 $n-2$ 既可由上节的期望计算解释，也可从正态模型中正交方向的个数看出。

命题 7.4　回归的精确 t 分布.　在上述独立同分布正态误差模型中，记 $s^2 = R/(n-2)$，则

$$\frac{R}{\sigma^2} \sim \chi^2_{n-2}, \qquad \frac{\widehat{b} - b}{s/\sqrt{S_{xx}}} \sim t_{n-2}.$$

对任何预先确定的 x_0，还有

$$\frac{\widehat{m}(x_0) - m(x_0)}{s\sqrt{c(x_0)}} \sim t_{n-2}.$$

若新误差 ε_0 与旧样本独立且也服从 $N(0, \sigma^2)$，则

$$\frac{Y_0 - \widehat{m}(x_0)}{s\sqrt{1 + c(x_0)}} \sim t_{n-2}.$$

这些比值在 $s > 0$ 的事件上定义，而在该模型中 $\mathbb{P}(s > 0) = 1$。

证明.　由第六章证明过的正交变换性质，可以把 v_1, v_2 补成 $\mathbb{R}^n$ 的一组标准正交基。标准化误差向量沿这组基的 n 个坐标独立且均服从 $N(0,1)$。第一坐标等于 $\sqrt{n}\,\bar{\varepsilon}/\sigma$，第二坐标为 $\sqrt{S_{xx}}(\widehat{b} - b)/\sigma$。

在其余 $n-2$ 个方向上，平方坐标之和正是 R/σ^2。所以它服从 χ^2_{n-2}，并与前两个标准正态坐标独立；由于 $n - 2 \geq 1$，该平方和以概率一严格为正。用第六章 t 分布的定义，就得到斜率的式子。

平均响应误差 $\bar{\varepsilon} + (x_0 - \bar{x})(\widehat{b} - b)$ 只涉及前两个正态坐标，方差由上一节算得为 $\sigma^2 c(x_0)$，因而标准化后为 $N(0,1)$，并与 R 独立。再用一次 t 分布定义便得第二个比值。新误差独立于全部旧坐标，$Y_0 - \widehat{m}(x_0)$ 同样是与 R 独立的正态变量，方差为 $\sigma^2\{1 + c(x_0)\}$，最后一个比值随之成立。

例如要检验 $H_0 : b = b_0$，记第六章的 $t_{\nu, 1-\alpha/2}$ 为 t_ν 分布的上 $1 - \alpha/2$ 分位数，其中 $0 < \alpha < 1$。精确双侧水平 α 的拒绝条件为

$$\left| \frac{\widehat{b} - b_0}{s/\sqrt{S_{xx}}} \right| > t_{n-2, 1-\alpha/2}.$$

将不等式反过来解 b_0，就得到斜率的 $1 - \alpha$ 置信区间

$$\left[\widehat{b} - t_{n-2,1-\alpha/2} \frac{s}{\sqrt{S_{xx}}}, \quad \widehat{b} + t_{n-2,1-\alpha/2} \frac{s}{\sqrt{S_{xx}}} \right].$$

这里的 $s/\sqrt{S_{xx}}$ 是斜率估计的**估计标准误**。

在 x_0 处，平均响应 $m(x_0)$ 的置信区间只需将半宽换成 $t_{n-2,1-\alpha/2}s\sqrt{c(x_0)}$；若要预测将来的一次新观测 Y_0，则应使用更大的半宽 $t_{n-2,1-\alpha/2}s\sqrt{1+c(x_0)}$。前一个区间用随机区间覆盖固定的均值参数，后一个区间要覆盖尚未观测到的随机值，二者的对象不同。以上精确概率结论依赖独立正态误差；仅凭两两不相关不能直接套用 t 分布。

7.5 真实均值不是直线时

最小二乘直线总能按第一节的公式算出，但真实平均响应不一定恰好具有 $a+bx$ 的形状。例如，如果 $\mathbb{E}Y_i=f(x_i)$，其中 f 是某个非线性函数，那么拟合斜率的期望为

$$\mathbb{E}\widehat{b}=\frac{\sum_i(x_i-\bar{x})f(x_i)}{S_{xx}}.$$

这是给定横坐标处函数值的一个加权和，不一定等于 f 在某个位置的导数。对于二次函数，这两种量之间出现了一个有趣的精确联系；对于三次函数，联系却不再成立。

例 7.3. 固定 $n\geq 2$ 个不全相等的设计点 $x_1,\dots,x_n$，已知 $\mathbb{E}Y_i=f(x_i)$，并用带截距的最小二乘直线拟合 (x_i,Y_i)，斜率记为 $\widehat{b}$。

1. 证明存在唯一只依赖设计点的实数 ξ，使对每个次数不超过 2 的多项式 f，都有 $\mathbb{E}\widehat{b}=f'(\xi)$，并求 ξ。
2. 若允许 f 为任意次数不超过 3 的多项式，证明这样的 ξ 不存在。

解. 记 $\bar{x}=n^{-1}\sum_i x_i$、$t_i=x_i-\bar{x}$，并令

$$S_j=\sum_{i=1}^{n}t_i^j\qquad(j=2,3,4).$$

设计点不全相等，所以 $S_2>0$，且 $S_4>0$。由最小二乘斜率公式，

$$\widehat{b}=\frac{\sum_i t_iY_i}{S_2},\qquad \mathbb{E}\widehat{b}=\frac{\sum_i t_if(x_i)}{S_2}. \tag{1}$$

这里仅使用 Y_i 的有限期望，不需要误差独立、正态或同方差。

(1) 设 $f(x)=a+bx+cx^2$。因为 $\sum_i t_i=0$，而

$$\sum_i t_ix_i=S_2,\qquad \sum_i t_ix_i^2=2\bar{x}S_2+S_3,$$

式 (1) 化为

$$\mathbb{E}\widehat{b}=b+c\left(2\bar{x}+\frac{S_3}{S_2}\right).$$

要求它对每个 c 等于 $f'(\xi)=b+2c\xi$，恰好确定唯一位置

$$\boxed{\xi=\bar{x}+\frac{S_3}{2S_2}=\frac{\sum_i(x_i-\bar{x})x_i^2}{2\sum_i(x_i-\bar{x})^2}.} \tag{2}$$

代回即验证：对于每个二次或更低次数的 f，该位置确实满足要求。

(2) 若存在一个位置对全部三次及以下多项式成立，它尤其须适用于所有二次多项式，故只能是式 (2) 的 ξ。再取 $f(x)=x^3$。一方面

$$\mathbb{E}\widehat{b}=\frac{\sum_i t_ix_i^3}{S_2}=3\bar{x}^2+3\bar{x}\frac{S_3}{S_2}+\frac{S_4}{S_2};$$

另一方面，若在同一位置等于导数，则必须等于

$$3\xi^2 = 3\bar{x}^2 + 3\bar{x}\frac{S_3}{S_2} + \frac{3S_3^2}{4S_2^2}.$$

因此必须有 $S_2 S_4 = 3S_3^2/4$。但由 Cauchy 不等式，

$$S_3^2 = \left(\sum_i t_i\, t_i^2\right)^2 \le \left(\sum_i t_i^2\right)\left(\sum_i t_i^4\right) = S_2 S_4.$$

故上述必要等式将推出

$$0 < S_2 S_4 = \frac{3}{4}S_3^2 \le \frac{3}{4}S_2 S_4,$$

矛盾。即使允许 ξ 位于设计点区间之外，也不可能找到一个对所有三次多项式同时适用的导数位置。

事实上，对 $f(x) = x^3$，在二次情形唯一确定的 ξ 处，斜率期望与导数之差至少为

$$\frac{S_4}{S_2} - \frac{3S_3^2}{4S_2^2} \ge \frac{S_4}{4S_2} > 0.$$

这表明障碍并非来自某种特殊的非对称设计，而是每一组非退化设计都存在的四阶矩约束。

7.6 杠杆量与删点后重新拟合

某个点即使残差不大，也可能对拟合直线产生很大影响。例如三个设计点 $0, 1, 2$ 中，如果删去端点，剩下两个横坐标更靠近，斜率就更容易因观测值的小变化而改变。下面用一个只由横坐标决定的量刻画这种影响。

定义 7.4　杠杆量.　对第 k 个设计点，定义

$$h_k = \frac{1}{n} + \frac{(x_k - \bar{x})^2}{S_{xx}},$$

称为该点的**杠杆量**。它不使用响应 Y_i，只由设计决定。

这个公式也可以从拟合值的计算中读出。事实上

$$\widehat{Y}_k = \bar{Y} + t_k \widehat{b} = \sum_{i=1}^{n}\left(\frac{1}{n} + \frac{t_k t_i}{S_{xx}}\right) Y_i.$$

其中 Y_k 自己的系数恰为 h_k。它衡量的是第 k 次观测对自己那个位置的拟合值的权重。例如 $x = (0, 1, 2)$ 时，三个杠杆量分别为 $5/6, 1/3, 5/6$；两端的观测比正中的观测对自身拟合值影响更大。

命题 7.5　杠杆量的范围与删点的可行性.　对 $n \ge 2$ 且 $S_{xx} > 0$ 的设计，$0 < h_k \le 1$。并且 $h_k < 1$ 当且仅当删去第 k 个点后，其余横坐标仍不全相等。

证明.　记 $t_k = x_k - \bar{x}$。删去第 k 个点以后，剩余横坐标的均值是

$$\bar{x}_{(-k)} = \frac{n\bar{x} - x_k}{n-1} = \bar{x} - \frac{t_k}{n-1}.$$

代入中心平方和，利用 $\sum_i t_i = 0$，得到

$$\begin{aligned} S_{xx,(-k)} &= \sum_{i \ne k}\left(t_i + \frac{t_k}{n-1}\right)^2 \\ &= S_{xx} - \frac{n}{n-1}t_k^2 = \frac{n}{n-1}S_{xx}(1 - h_k). \end{aligned}$$

左边非负，且为零恰好表示删点后所有剩余横坐标相同。因为 $S_{xx}>0$ 且 $h_k\geq 1/n>0$，所以 $h_k\leq 1$，并得到严格不等式成立的充要条件。

如果 $h_k=1$，删去第 k 个点以后不能唯一确定带截距的拟合斜率。特别地，当 $n=2$ 时删点后只剩一个点，因此两个杠杆量都是 1。当 $h_k<1$ 时，重新拟合才有唯一解。杠杆量在判断删点后的拟合是否唯一、分析单点影响时很有用。

7.7 两组数据合并后的线性趋势

分别给两组数据拟合直线，得到的斜率都为正，并不能保证把两组合并后，斜率仍为正。原因在于每组内部点的相对位置与两组中心的相对位置是两件不同的事。下面的例题中，每组数据内部的形状保持不变，只通过平移其中一组，就能精确研究合并拟合斜率何时改变符号。

例 7.4. 第一组数据为 (x_i,y_i) $(1\leq i\leq m)$，第二组为 (x'_j,y'_j) $(1\leq j\leq n)$，其中 $m,n\geq 2$。每组的横、纵坐标平均值都为 0，且各组的横坐标均不全相等。分别对两组数据作带截距的最小二乘拟合，得到的斜率都严格为正。现在将第二组的所有点同时平移向量 (u,v)，再把两组合并，拟合一条新的最小二乘直线。

记

$$C=\sum_{i=1}^{m}x_iy_i+\sum_{j=1}^{n}x'_jy'_j.$$

求使合并后拟合斜率不大于 0 的最小平移距离 $\sqrt{u^2+v^2}$，并求达到这一最小值的全部平移向量。

解. 因为每组的横、纵坐标平均值都为 0，各组的最小二乘斜率分别是

$$\frac{\sum_{i=1}^{m}x_iy_i}{\sum_{i=1}^{m}x_i^2},\qquad \frac{\sum_{j=1}^{n}x'_jy'_j}{\sum_{j=1}^{n}(x'_j)^2}.$$

两组横坐标的中心平方和都正，两条斜率也正，所以题目中的 $C>0$。

平移后，第二组的点为 (x'_j+u,y'_j+v)。记 $N=m+n$。合并数据的横、纵坐标平均值变为

$$\bar{x}=\frac{n}{N}u,\qquad \bar{y}=\frac{n}{N}v.$$

计算合并数据的中心乘积和时，先注意两组原数据各自的横、纵坐标之和均为 0，从而

$$\begin{aligned}S_{xy}&=\sum_{i=1}^{m}x_iy_i+\sum_{j=1}^{n}(x'_j+u)(y'_j+v)-N\bar{x}\bar{y}\\&=C+nuv-\frac{n^2}{N}uv=C+\frac{mn}{m+n}uv.\end{aligned}\tag{1}$$

同样，若 $A=\sum_i x_i^2+\sum_j(x'_j)^2>0$，则

$$S_{xx}=A+\frac{mn}{m+n}u^2>0.$$

因此合并拟合斜率的正负完全由式 (1) 决定。它不大于 0，当且仅当

$$uv\leq -\frac{m+n}{mn}C.\tag{2}$$

现在不必直接去求斜率的极值。由

$$u^2+v^2\ge 2|uv|\ge \frac{2(m+n)}{mn}C,$$

可知平移距离至少为 $\sqrt{2(m+n)C/(mn)}$。

要达到这一最小距离，两处不等式都必须取等：第一处要求 $|u|=|v|$，第二处要求 $uv=-(m+n)C/(mn)$。由于 $C>0$，它们恰好给出两个平移向量

$$\boxed{(u,v)=(t,-t)\ \text{或}\ (-t,t)\,,\quad t=\sqrt{\frac{(m+n)C}{mn}}.}$$

此时 $S_{xy}=0$，合并拟合斜率正好为 0。所以最小平移距离为

$$\boxed{\sqrt{\frac{2(m+n)C}{mn}}}.$$

若要求斜率严格为负，上述数仍是平移距离的下确界，但没有达到下确界的平移向量。

习题

习题 7.1. 横坐标固定为 $0,1,3$。设 $g:\mathbb{R}\to\mathbb{R}$ 连续。要求对任意实数 y_1,y_2,y_3，把三个响应同时替换为 $g(y_1),g(y_2),g(y_3)$ 后，带截距的最小二乘斜率为零，当且仅当原斜率为零。求全部这样的 g。

习题 7.2. 给定 $n\ge 3$ 个互异的实数 $x_1,\dots,x_n$. 观测

$$Y_i=a+bx_i+cx_i^2+\varepsilon_i,$$

其中 $a,b,c\in\mathbb{R}$ 均未知; 误差均值为 0, 方差均为已知的 $\sigma^2>0$, 且两两不相关.

1. 在所有权重仅依赖设计点的线性估计量 $T=\sum_i w_iY_i$ 中, 求对全部 (a,b,c) 都无偏估计 b 且方差最小的唯一估计量.
2. 若忽略二次项, 直接使用带截距的普通最小二乘斜率 $\widehat{b}$, 求它对每个 (a,b,c) 仍无偏的充要条件; 满足该条件时, 比较两种估计的方差.

习题 7.3. 固定 $n\ge 4$ 个两两不同的 x_i。一组响应的原始记录已丢失, 只保存了 $\bar{Y}$、$V=S_{yy}$ 和 $R=\mathrm{SSE}$，这些量确实来自某组数据。

1. 求全部可能的拟合斜率。
2. 若又找回第 k 个响应 $Y_k=z$，求全部仍与记录相容的拟合直线，并给出直线能被唯一恢复的充要条件。

习题 7.4. 在 $x=(-3,-1,1,3)$ 处观测 $Y_i=a+bx_i+\varepsilon_i$。误差均值为 0 且两两不相关，四个方差恰为 $1,1,r,r$，其中 $r\ge 1$ 已知。估计量取 $T=\sum_i w_iY_i$，权重须在观测前确定，并对每个 a,b 都无偏估计 b。

1. 若已知两个方差 r 对应于 $x=\pm 3$，求方差最小的权重。
2. 若不知道四个方差与观测的对应关系，求使六种安排中最大方差最小的权重及该最小值。

习题 7.5. 固定不全相等的 $x_1,\dots,x_n$，观测 $Y_i=a+bx_i+\varepsilon_i$。误差均值为 0、方差为已知的 $\sigma^2>0$ 且两两不相关。只知道 $|a|\le A$，其中 $A\ge 0$ 已知，而 $b\in\mathbb{R}$ 任意。在所有固定线性估计量 $T=\sum_i w_iY_i$ 中，求使

$$\sup_{|a|\le A,\ b\in\mathbb{R}} \mathbb{E}_{a,b}(T-b)^2$$

最小的权重及最小值。

习题 7.6. 设 $Y_i=a+bi+\varepsilon_i$，$1\le i\le n$，误差均值为 0、方差为 $\sigma^2>0$ 且两两不相关。给定 $2\le k\le n$，须在观测前选定恰好 k 个下标，只保留这些响应。在所有选取方式及其固定线性估计量中，求对每个 a,b 都无偏估计 b 的最小方差，并求出全部最优下标集合及权重。

习题 7.7. 固定不全相等的 $x_1,\dots,x_n$ 及实数 $y_1,\dots,y_n$，$n\ge 2$。均匀随机排列响应标签，所得斜率记为 B_Π。

1. 求 $\mathbb{E}_\Pi B_\Pi$ 与 $\mathrm{Var}_\Pi(B_\Pi)$。
2. 设 $Y_i=a+\varepsilon_i$，误差独立同分布且连续。观察数据后，在 n 组设计 $x_i^{(j)}=\mathbf{1}_{\{i=j\}}$ 中选取拟合斜率最大的一组，再把该组设计固定下来，计算上尾排列 p 值。求所报 p 值及在水平 $\alpha=1/n$ 时的实际拒绝概率。若每次排列都重新选择最大斜率，所报 p 值又是多少？

新领军计划

数理统计

自学讲义

抽样　估计　检验　回归

习题完整解答

目录

第一章抽样、数据与信息 **2**

第二章参数估计 **10**

第三章无偏构造与估计量比较 **20**

第四章假设检验的概率逻辑 **28**

第五章合法对称性与精确检验 **36**

第六章单样本与双样本 **43**

第七章一元线性回归 **49**

第一章　抽样、数据与信息

习题完整解答

习题 1.1.　设 $a_1 < a_2 < \cdots < a_{2m}$, $m \geq 2$. 将这些数分成 m 对, 从每对中独立等概率抽一个, 用所得 m 个数的平均值估计总体均值. 求使估计量方差最小的全部配对及最小方差, 并证明这个最小方差严格小于从 $2m$ 个数中简单随机抽取 m 个所得均值的方差.

解.　一对数 u, v 中等可能取一个, 其均值为 $(u+v)/2$, 方差为 $(u-v)^2/4$. 因此题给估计量的期望总是总体均值. 不同对的抽样独立, 故对配对 $\mathcal{P}$, 估计量的方差为

$$V(\mathcal{P}) = \frac{1}{4m^2} \sum_{\{i,j\}\in\mathcal{P}} (a_i - a_j)^2.$$

先证明最小配对必须把 a_1, a_2 放在一起. 若 a_1 与 a_j、a_2 与 a_k 配对, 且 $j, k > 2$, 将这两对改成 $\{a_1, a_2\}, \{a_j, a_k\}$, 平方距离之和减少

$$(a_j - a_1)^2 + (a_k - a_2)^2 - (a_2 - a_1)^2 - (a_j - a_k)^2 = 2(a_j - a_2)(a_k - a_1) > 0.$$

所以最小配对必须包含 $\{a_1, a_2\}$. 去掉这一对, 剩下的仍是严格递增的偶数个数. 依次应用同一交换关系, 便得到唯一最小配对

$$\{a_1, a_2\}, \{a_3, a_4\}, \ldots, \{a_{2m-1}, a_{2m}\},$$

其中不区分各对的先后及每对内部顺序. 最小方差为

$$\boxed{V_{\min} = \frac{1}{4m^2} \sum_{j=1}^{m} (a_{2j} - a_{2j-1})^2}.$$

为与简单随机抽样比较, 对所有配对等概率取平均. 固定 i, 交换其余两个编号, 会把以其中一个为伙伴的配对与以另一个为伙伴的配对一一对应. 因此 i 的伙伴在其余 $2m-1$ 个位置中等可能, 一对指定编号 $\{i, j\}$ 被配在一起的概率为 $1/(2m-1)$. 于是

$$\mathbb{E}_{\mathcal{P}} V(\mathcal{P}) = \frac{1}{4m^2(2m-1)} \sum_{1\leq i<j\leq 2m} (a_i - a_j)^2.$$

记总体均值为 μ、分母为 $2m$ 的总体方差为 σ^2. 将有序对的平方差合并,

$$\begin{aligned} \sum_{1\leq i<j\leq 2m} (a_i - a_j)^2 &= \frac{1}{2} \sum_{i=1}^{2m} \sum_{j=1}^{2m} (a_i - a_j)^2 \\ &= 2m \sum_{i=1}^{2m} a_i^2 - \left(\sum_{i=1}^{2m} a_i \right)^2 = 4m^2\sigma^2, \end{aligned}$$

所以平均方差等于 $\sigma^2/(2m-1)$. 这也正是容量 m 的简单随机样本均值的方差:

$$\frac{2m-m}{2m-1} \frac{\sigma^2}{m} = \frac{\sigma^2}{2m-1}.$$

$m \geq 2$ 时存在不止一种配对, 而最小配对唯一, 故最小值严格小于所有配对的平均值. 所需严格不等式成立.

习题 1.2. 数据只取 $0,1,2,3$. 每次只保留数据个数 n、总和 S 和平方和 Q. 求所有函数 $h:\{0,1,2,3\}\to\mathbb{R}$, 使对任意 $n\ge 1$ 和任意这样的数据, $\sum_{i=1}^{n} h(x_i)$ 都能由 (n,S,Q) 唯一确定.

解. 先看四个取值的频数能怎样变化而不改变记录. 若频数变化为 d_0,d_1,d_2,d_3, 则须满足

$$d_0+d_1+d_2+d_3=0,\quad d_1+2d_2+3d_3=0,\quad d_1+4d_2+9d_3=0.$$

后两式相减, 得 $d_2=-3d_3$; 代回得 $d_1=3d_3, d_0=-d_3$. 取 $d_3=-1$, 便得到两组允许的数据

$$(0,2,2,2),\qquad (1,1,1,3),$$

它们都给出 $n=4,S=6,Q=12$. 因此所求函数必须满足

$$h(0)-3h(1)+3h(2)-h(3)=0. \tag{1}$$

前三个函数值确定一个二次多项式: 令

$$A=h(0),\qquad C=\frac{h(2)-2h(1)+h(0)}{2},\qquad B=h(1)-h(0)-C.$$

则 $A+Bx+Cx^2$ 在 $0,1,2$ 处分别等于 $h(0),h(1),h(2)$; 在 3 处的值是 $h(0)-3h(1)+3h(2)$, 由 (1) 也等于 $h(3)$.

故全部答案为

$$\boxed{h(x)=A+Bx+Cx^2\quad(x\in\{0,1,2,3\}),\qquad A,B,C\in\mathbb{R}.}$$

反过来, 每一个这样的函数都有

$$\sum_{i=1}^{n} h(x_i)=An+BS+CQ,$$

确能由记录恢复. 这证明了必要性与充分性.

习题 1.3. 从六个有编号的单位中选取三个. 预先指定若干个不同的三元子集, 抽样时在这些子集中等概率选一个. 所选子集的数值平均记为 T, 要求对任意实数总体, T 的期望和方差都与简单随机抽样相同. 求至少需要指定多少个子集, 并给出达到最少数量的全部方案, 其中仅由重新编号得到的方案视为相同.

解. “对任意总体”允许逐个探查单位及单位对. 设共指定 k 个子集, 单位 i 在其中出现 r_i 次, 单位对 $\{i,j\}$ 出现 λ_{ij} 次.

令总体只在第 i 个位置取 1, 其余取 0. 均值条件给出 $r_i/(3k)=1/6$, 故 $r_i=k/2$. 再令第 i,j 两个位置都取 1, 其余取 0. 由于期望已经相同, 方差相同等价于二阶矩相同. 简单随机抽样时, 一对指定单位同时入选的概率为

$$\frac{\binom{4}{1}}{\binom{6}{3}}=\frac{1}{5}.$$

在这个总体上 $T=(I_i+I_j)/3$, 故

$$\mathbb{E}T^2=\frac{1}{9}\big(\mathbb{E}I_i+\mathbb{E}I_j+2\mathbb{E}(I_iI_j)\big)=\frac{1}{9}\left(1+\frac{2\lambda_{ij}}{k}\right).$$

简单随机抽样则将右侧的 λ_{ij}/k 换成 $1/5$. 二阶矩相同, 便得 $\lambda_{ij}/k = 1/5$. 所以

$$r_i = k/2, \qquad \lambda_{ij} = k/5. \tag{2}$$

这也充分: 对任意 $x_1, \dots, x_6$,

$$\mathbb{E}T = \frac{1}{3}\sum_{i=1}^{6} x_i \mathbb{E}I_i, \qquad \mathbb{E}T^2 = \frac{1}{9}\left(\sum_{i=1}^{6} x_i^2 \mathbb{E}I_i + 2\sum_{1\le i<j\le 6} x_i x_j \mathbb{E}(I_i I_j)\right).$$

(2) 使这两个式子中的系数与简单随机抽样一致, 因而期望和方差都一致.

r_i, λ_{ij} 为整数, 因此 k 同时被 2 和 5 整除, 至少为 10. 下面刻画 $k = 10$ 的情形, 此时每个单位出现 5 次, 每对单位出现 2 次.

把单位 6 单独提出. 包含 6 的五个子集删去 6 后, 成为其余五个单位间的五条边. 每个单位与 6 共同出现两次, 因此每个顶点恰连两条边. 这些边互不重复, 每点恰连两条边. 从任一点沿边前进, 每次沿另一条边继续, 有限步后必回到已到过的点, 形成一个圈; 圈上各点的两条边已经用完, 不能再接圈外的点. 因此所有点被分成若干个圈, 每圈至少含三个点. 这里只有五个点, 不可能分成两个圈, 因而只能组成一个五边形. 重新编号后, 可令包含 6 的子集为

$$126,\ 236,\ 346,\ 456,\ 156.$$

这里 126 表示 $\{1, 2, 6\}$.

另五个子集全在 $\{1, \dots, 5\}$ 内. 用每个子集所遗漏的两个单位作一条边, 得到图 H. 每个单位在这五个子集中出现 3 次、被遗漏 2 次, 所以 H 中每个顶点也恰与两条边相接. 此边数称为顶点的度数.

固定 $i, j \in \{1, \dots, 5\}$. 另五个子集中同时含 i, j 的个数等于 H 中与这两个顶点均不相接的边数, 为

$$5 - 2 - 2 + \mathbf{1}_{\{ij\text{是}H\text{的边}\}} = 1 + \mathbf{1}_{\{ij\text{是}H\text{的边}\}}.$$

五边形上相邻的一对在含 6 的子集中出现 1 次, 非相邻的一对出现 0 次. 要使每对总共出现 2 次, H 的边必须恰为五边形的五条对角线. 这唯一确定了另五个子集:

$$245,\ 235,\ 135,\ 134,\ 124.$$

反向检查, 这两组各有五个不同子集, 并因是否包含 6 而互不重复. 单位 6 出现 5 次; 其余每个单位在第一组出现 2 次、在第二组出现 3 次. 含 6 的单位对各出现 2 次. 其余单位对中, 五边形的边在两组中各出现 1 次, 对角线在第一组出现 0 次、在第二组出现 2 次. 因此每对都出现 2 次, (2) 确实成立.

所以最少数量为 $\boxed{10}$; 不计重新编号, 达到最少数量的方案恰有 $\boxed{1}$ 种, 由上列十个子集给出.

这个最小方案并非简单随机抽样, 却保留了任意总体下抽样均值的前两阶矩. 例如令单位 1、2、3 的数值为 1, 其余为 0, 上列方案从不选 123, 所以 $\mathbb{P}(T = 1) = 0$; 简单随机抽样却有 $\mathbb{P}(T = 1) = 1/20$. 期望和方差相同, 并不意味着抽样分布相同.

习题 1.4. 九个实数的五数概括为 $(-2,-1,0,1,2)$, 四分位数沿用本章约定. 求以 9 为分母的数据方差的全部可能值, 并给出取到两端值的全部数据, 忽略排列.

解. 设 $x_1 \le \cdots \le x_9$, 均值为 u. 题设精确地给出

$$x_1 = -2, \quad x_2 + x_3 = -2, \quad x_5 = 0, \quad x_7 + x_8 = 2, \quad x_9 = 2.$$

为求下界, 对已知和的两组分别使用平方和不等式, 并保留两端及中间数:

$$\begin{aligned} 9v &= \sum_{i=1}^{9} (x_i - u)^2 \\ &\ge (-2-u)^2 + (2-u)^2 + u^2 + \frac{(-2-2u)^2}{2} + \frac{(2-2u)^2}{2} \\ &= 12 + 7u^2 \ge 12. \end{aligned}$$

等号要求 $u = 0$、$x_2 = x_3 = -1$、$x_7 = x_8 = 1$, 以及先前舍去的 $x_4 - u, x_6 - u$ 均为 0. 因此最小值为 $4/3$, 唯一数据为

$$(-2,-1,-1,0,0,0,1,1,2).$$

上界不能只用极差, 而要用四分位数限制. 令 $t = x_3$, 则 $-1 \le t \le 0$, $x_2 = -2-t$ 且 $t \le x_4 \le 0$, 所以

$$x_1^2 + x_2^2 + x_3^2 + x_4^2 \le 4 + (-2-t)^2 + 2t^2 = 8 + t(4+3t) \le 8.$$

由于 $4 + 3t > 0$, 最后等号只能在 $t = 0$ 成立, 此时前四项为 $(-2,-2,0,0)$. 将上半组取负并反序, 得到后四项的平方和也不超过 8, 等号只能为 $(0,0,2,2)$. 因而

$$v = \frac{1}{9}\sum_{i=1}^{9} x_i^2 - u^2 \le \frac{16}{9},$$

等号的唯一数据是 $(-2,-2,0,0,0,0,0,2,2)$, 其均值确为 0.

最后, 将取到下界、上界的两组数据分别记为 $(a_1,\ldots,a_9)$ 和 $(b_1,\ldots,b_9)$. 对 $0 \le s \le 1$, 令 $x_i(s) = (1-s)a_i + sb_i$. 两组都已排序, 故

$$x_{i+1}(s) - x_i(s) = (1-s)(a_{i+1} - a_i) + s(b_{i+1} - b_i) \ge 0.$$

两端值、中位数及两条四分位数和式也都保持. 方差是 s 的连续函数, 在 $s = 0, 1$ 处分别取 $4/3, 16/9$. 由介值定理, 每个中间值也能取得. 因此所求集合恰为

$$\boxed{[4/3,\ 16/9].}$$

习题 1.5. $n \ge 4$ 个有编号的位置排成圆圈, 从中简单随机选 k 个涂黑, $1 \le k < n$. 相邻的黑色位置连成黑段, 记黑段数为 R. 求 R 的分布和标准误.

解. 记白色位置数为 $\ell = n - k$. 若有 r 个黑段, 就有 r 个白段; 先把各段长度排成正整数列, 故 $1 \le r \le \min(k, \ell)$.

给一种着色额外标出一个黑段的起点. 从这一点顺时针读出黑段长度和白段长度. 起点有 n 种选择, 两个正整数分拆分别有 $\binom{k-1}{r-1}$ 和 $\binom{\ell-1}{r-1}$ 种; 例如把 k 写成 r 个正整数之和, 就是在 k 个连续符号的 $k-1$ 个间隙中选 $r-1$ 处隔开; 白段的计数相同. 每一种原着色却有 r 种标法, 因而

$$\boxed{\mathbb{P}(R = r) = \frac{n}{r\binom{n}{k}} \binom{k-1}{r-1}\binom{n-k-1}{r-1}, \quad 1 \le r \le \min(k, n-k).}$$

求方差时不直接对这个分布作长和. 令 I_i 表示第 i 个位置为黑、它前一个位置为白的事件指示量, 下标按圆周解释. 每个黑段恰有一个起点, 所以 $R=\sum_{i=1}^{n} I_i$. 由固定编号的包含概率,

$$\mathbb{E}I_i=\frac{k\ell}{n(n-1)},\qquad \mathbb{E}R=\frac{k\ell}{n-1}.$$

相邻两个位置不可能同时成为黑段起点. 对非相邻的两个位置, 需要指定的两个位置为黑、它们各自的前驱为白, 四个位置互异; 其概率为

$$\frac{k(k-1)\ell(\ell-1)}{n(n-1)(n-2)(n-3)}.$$

非相邻有序位置对共有 $n(n-3)$ 个, 因此

$$\mathbb{E}[R(R-1)]=\frac{k(k-1)\ell(\ell-1)}{(n-1)(n-2)}.$$

用 $k+\ell=n$ 整理 $\mathbb{E}R^2-(\mathbb{E}R)^2$, 得到

$$\mathrm{Var}(R)=\frac{k\ell(k-1)(\ell-1)}{(n-1)^2(n-2)},\qquad \boxed{\mathrm{SE}(R)=\frac{\sqrt{k(n-k)(k-1)(n-k-1)}}{(n-1)\sqrt{n-2}}.}$$

$k=1$ 或 $n-k=1$ 时 $R=1$ 恒定, 公式也给出标准误 0.

习题 1.6. 从整数总体 $\{1,2,\dots,N\}$ 中简单随机抽取 n 个, $3\le n<N$. 样本只留下最小值 A 和最大值 B. 证明 $(A+B)/2$ 以总体均值为期望, 求其标准误, 并与完整样本均值的标准误比较.

解. 把抽中的数排为 $X_{(1)}<\cdots<X_{(n)}$, 用没有抽中的位置数描述间隔:

$$G_0=X_{(1)}-1,\quad G_i=X_{(i+1)}-X_{(i)}-1\ (1\le i<n),\quad G_n=N-X_{(n)}.$$

它们为非负整数, 和为 $M=N-n$. 每个抽样子集与一个这样的间隔向量一一对应, 所以所有把 M 分成 $q=n+1$ 个非负整数的向量等可能. 对称性给出 $\mathbb{E}G_i=M/q$.

求二阶矩时, 对间隔向量连同标记一起计数. 把 M 个相同符号分入 q 个位置, 可排成 M 个符号与 $q-1$ 条分隔线的序列, 因而向量总数为 $\binom{M+q-1}{q-1}$.

先设 $M\ge 2$. 给定一个间隔向量, 在第 0 个间隔的 G_0 个符号中标出两个, 有 $\binom{G_0}{2}$ 种方法. 删掉这两个标记符号, 原间隔被分成三个可为空的小段. 加上其他 $q-1$ 个间隔, 恰好得到 $q+2$ 个非负整数, 总和为 $M-2$; 反过来可以唯一放回两个标记符号. 所以

$$\sum_{\substack{g_0+\cdots+g_n=M\\ g_0,\dots,g_n\ge 0}}\binom{g_0}{2}=\binom{M+q-1}{q+1}.$$

若改成在第 0 个与第 n 个间隔中各标一个符号, 给定向量有 G_0G_n 种标法. 删去两标记符号后, 两个间隔各分成两小段, 同样对应 $q+2$ 个非负整数且总和为 $M-2$. 因而

$$\sum_{\substack{g_0+\cdots+g_n=M\\ g_0,\dots,g_n\ge 0}} g_0g_n=\binom{M+q-1}{q+1}.$$

分别除以向量总数, 并在第一式乘 2, 得

$$\mathbb{E}[G_0(G_0-1)]=\frac{2M(M-1)}{q(q+1)},\qquad \mathbb{E}(G_0G_n)=\frac{M(M-1)}{q(q+1)}.$$

这里 $M=1$ 时两个阶乘矩均为 0, 仍与公式一致. 又 G_0, G_n 同分布, 故

$$\mathbb{E}(G_0-G_n)^2 = 2\left[\frac{2M(M-1)}{q(q+1)} + \frac{M}{q} - \frac{M(M-1)}{q(q+1)}\right] = \frac{2M(M+q)}{q(q+1)}.$$

由于

$$\frac{A+B}{2} = \frac{N+1}{2} + \frac{G_0-G_n}{2},$$

其期望为 $(N+1)/2$, 且

$$\boxed{\mathrm{SE}\left(\frac{A+B}{2}\right) = \sqrt{\frac{(N-n)(N+1)}{2(n+1)(n+2)}}.}$$

总体方差为 $(N^2-1)/12$; 由有限总体修正, 完整样本均值的方差为 $(N-n)(N+1)/(12n)$. 两标准误的比为

$$\boxed{\sqrt{\frac{6n}{(n+1)(n+2)}} < 1},$$

因为 $(n+1)(n+2) - 6n = (n-1)(n-2) > 0$.

这里比较的是两个具体估计量; 保留完整样本时同样可以计算 $(A+B)/2$, 所以不能把结论解释为删除信息能提高所有方法的精度.

习题 1.7. 一个由 $N \geq 2$ 个单位组成的有限总体, 均值为 μ, 以 N 为分母的方差为 $\sigma^2 > 0$. 先随机决定样本量 $K \in \{1, \dots, N\}$, 随后在给定 $K=k$ 时, 从总体中简单随机抽取 k 个单位. 已知 $\mathbb{E}K = \tau \in [1, N]$, 以所抽单位的均值 T 估计 μ. 求 $\mathrm{Var}(T)$ 的**全部可能值**, 并刻画达到两端值的全部 K 的分布.

解. 设 $p_k = \mathbb{P}(K=k)$. 对 $p_k > 0$ 的 k, 给定 $K=k$ 后应用有限总体抽样公式, 得

$$\mathbb{E}(T \mid K=k) = \mu, \qquad \mathrm{Var}(T \mid K=k) = \frac{N-k}{N-1}\frac{\sigma^2}{k}.$$

由全期望公式, $\mathbb{E}T = \mu$. 各个条件均值都为 μ, 因而

$$\begin{aligned} \mathrm{Var}(T) = \mathbb{E}(T-\mu)^2 &= \sum_{k:p_k>0} p_k \mathbb{E}[(T-\mu)^2 \mid K=k] \\ &= \sum_{k:p_k>0} p_k \frac{N-k}{N-1}\frac{\sigma^2}{k} = \frac{\sigma^2}{N-1}\left(N\mathbb{E}\frac{1}{K} - 1\right). \end{aligned} \tag{1}$$

因此只需求 $\mathbb{E}(1/K)$ 在 $\mathbb{E}K = \tau$ 时的取值范围.

先设 $1 \leq \tau < N$, 记 $k = \lfloor \tau \rfloor$, $\theta = \tau - k \in [0, 1)$. 为求下界, 连接平面上的 $(k, 1/k)$ 和 $(k+1, 1/(k+1))$. 这条直线在横坐标 j 处的值为

$$L(j) = \frac{1}{k} - \frac{j-k}{k(k+1)}.$$

对每个正整数 j, 计算曲线上对应点与直线的高度差:

$$\frac{1}{j} - L(j) = \frac{(j-k)(j-k-1)}{jk(k+1)} \geq 0.$$

不等式来自 $j-k$ 为整数: 它不可能严格介于 0 和 1 之间. 等号恰在 $j = k, k+1$ 时成立.

令 $j=K$ 并取期望. 因为 L 是一次函数且 $\mathbb{E}K=\tau$, 得到

$$\mathbb{E}\frac{1}{K}\geq L(\tau)=\frac{1-\theta}{k}+\frac{\theta}{k+1}. \tag{2}$$

等号要求 K 以概率 1 取值于 $\{k,k+1\}$. 再由平均值为 τ, 得到唯一的分布

$$\mathbb{P}(K=k)=1-\theta,\qquad \mathbb{P}(K=k+1)=\theta. \tag{3}$$

当 $\theta=0$ 时, 这个分布就是 $\mathbb{P}(K=\tau)=1$.

求上界时, 改用连接 $(1,1)$ 与 $(N,1/N)$ 的直线. 它在横坐标 j 处的值为 $(N+1-j)/N$, 并且对 $1\leq j\leq N$,

$$\frac{N+1-j}{N}-\frac{1}{j}=\frac{(j-1)(N-j)}{Nj}\geq 0.$$

等号恰在 $j=1,N$ 时成立. 于是

$$\mathbb{E}\frac{1}{K}\leq\frac{N+1-\tau}{N}. \tag{4}$$

由等号条件和 $\mathbb{E}K=\tau$, 取等分布唯一为

$$\mathbb{P}(K=1)=\frac{N-\tau}{N-1},\qquad \mathbb{P}(K=N)=\frac{\tau-1}{N-1}. \tag{5}$$

将 (2)、(4) 代入 (1), 得到 $1\leq\tau<N$ 时的全部方差必须位于

$$\boxed{\left[\frac{\sigma^2}{N-1}\left\{N\left(\frac{1-\theta}{k}+\frac{\theta}{k+1}\right)-1\right\},\quad\frac{\sigma^2(N-\tau)}{N-1}\right]}. \tag{6}$$

下端由 (3) 取到, 上端由 (5) 取到. 因为 $\sigma^2>0$, (1) 随 $\mathbb{E}(1/K)$ 严格增加, 所以上述等号条件也正是方差取到两端的全部条件.

还要验证区间内的每个数都能取得. 任取 $s\in[0,1]$, 先以概率 s 选择分布 (3), 以概率 $1-s$ 选择分布 (5), 再按所选分布产生 K. 两个分布的均值都是 τ, 混合后的均值仍为 τ; $\mathbb{E}(1/K)$ 则是两端值的同权重平均. 由 (1), 方差也遍历 (6) 中的整个区间.

若 $\tau=N$, 因为 $N-K\geq 0$ 且期望为 0, 必有 $\mathbb{P}(K=N)=1$, 方差唯一为 0. $\tau=1$ 时同理有 $\mathbb{P}(K=1)=1$, 方差为 σ^2, 已包含在 (6) 中. 当 $N=2$ 时, 平均值条件已经唯一确定 K 的分布, 上下两端相同.

习题 1.8. 总体分成 $k\geq 2$ 个等大的层, 第 i 层的总体方差为 $i(i+1)$. 在各层有放回独立等概率抽样, 第 i 层抽 $n_i\geq 1$ 次, 用各层样本均值的平均估计总体均值. 总次数为 $k(k+1)/2+s$, 其中 $s\in\{0,1,\ldots,k\}$. 求最小方差及全部最优整数分配.

解. 各层等大, 所以每层的权重都是 $1/k$. 层内有放回独立抽样, 不同层之间也独立, 因而估计量的方差为

$$V=\frac{1}{k^2}\sum_{i=1}^{k}\frac{i(i+1)}{n_i}.$$

第 i 项在 $n_i=i$ 和 $n_i=i+1$ 处的值分别是 $i+1$ 和 i. 通过这两点的一次函数为 $2i+1-n_i$. 将原式与它相减, 得

$$\frac{i(i+1)}{n_i}-(2i+1-n_i)=\frac{(n_i-i)(n_i-i-1)}{n_i}\geq 0,$$

因为 $n_i - i$ 为整数. 等号当且仅当 $n_i = i$ 或 $i+1$.

逐层相加并代入总次数, 得

$$\begin{aligned} k^2 V &\geq \sum_{i=1}^{k}(2i+1) - \sum_{i=1}^{k} n_i \\ &= k(k+2) - \left(\frac{k(k+1)}{2} + s\right) = \frac{k(k+3)}{2} - s. \end{aligned}$$

任选 s 层, 在这些层取 $n_i = i+1$, 其余各层取 $n_i = i$. 总次数恰好符合要求, 每项也都取等. 因而

$$\boxed{V_{\min} = \frac{k(k+3) - 2s}{2k^2}}.$$

反过来, 总和达到下界时, 各项的非负差都必须为 0, 所以每层只能取 $n_i = i$ 或 $i+1$. 总次数又要求恰有 s 层取后一个值. 因此全部最优方案正是上述 $\binom{k}{s}$ 种, 包括 $s=0$ 和 $s=k$ 时各自唯一的方案.

第二章　参数估计

习题完整解答

习题 2.1.　设 $X_1,\dots,X_n$ 独立服从 $U(0,\theta)$（$n\ge 2,\theta>0$），记乘积 $P=\prod_{i=1}^n X_i$ 与最大值 $M=\max_i X_i$。

1. 分别求仅根据 P、仅根据 M 的极大似然估计。
2. 若估计量 $A(P)$、$B(M)$ 分别满足 $A(c^n p)=cA(p)$、$B(cm)=cB(m)$（任意 $c,p,m>0$），求各自唯一的无偏形式，并证明 $\mathbb{E}_\theta[A(P)\mid M]=B(M)$，比较二者的方差。

解. (1) 先求乘积的实际分布。令 $U_i=X_i/\theta$，$Z_i=-\log U_i$，则 U_i 独立服从 $U(0,1)$，Z_i 独立服从参数为 1 的指数分布。卷积归纳：$W=\sum_{i=1}^n Z_i$ 的密度为

$$f_W(w)=\frac{e^{-w}w^{n-1}}{(n-1)!},\qquad w>0.$$

确实，$n=1$ 时直接成立；若 $n-1$ 时成立，和另一个独立指数变量卷积给出

$$\int_0^w \frac{e^{-u}u^{n-2}}{(n-2)!}e^{-(w-u)}\,\mathrm{d}u=\frac{e^{-w}w^{n-1}}{(n-1)!}.$$

由于 $P=\theta^n e^{-W}$，一次换元得到实际记录 P 的密度

$$f_{P,\theta}(p)=\frac{[\log(\theta^n/p)]^{n-1}}{(n-1)!\,\theta^n}\quad(0<p<\theta^n),$$

其余 p 处取 0。对几乎必然出现的记录 $p>0$，在正似然区域令 $z=\log(\theta^n/p)>0$，则似然与 $z^{n-1}e^{-z}$ 成正比。其对数导数为 $(n-1)/z-1$，所以唯一最大点为 $z=n-1$，即

$$\boxed{\widehat{\theta}_P=e^{(n-1)/n}P^{1/n}}.$$

另一方面，最大值的分布函数为 $\mathbb{P}_\theta(M\le m)=(m/\theta)^n$（$0\le m\le\theta$），故其密度取为

$$f_{M,\theta}(m)=\frac{nm^{n-1}}{\theta^n}\,\mathbf{1}_{\{0<m\le\theta\}}.$$

固定 $m>0$ 后，似然在 $\theta\ge m$ 上严格递减，因而

$$\boxed{\widehat{\theta}_M=M}.$$

(2) 缩放条件先决定了估计量的形式：在第一个条件中取 $p=1,c=u^{1/n}$，在第二个条件中取 $m=1,c=u$，得到 $A(u)=a_n u^{1/n}$、$B(u)=b_n u$，其中常数与未知参数无关。对任意 $r>0$，由独立性，

$$\mathbb{E}_\theta P^{r/n}=\theta^r\left(\int_0^1 v^{r/n}\,\mathrm{d}v\right)^n=\theta^r\left(\frac{n}{n+r}\right)^n.$$

同时 $\mathbb{E}_\theta M=n\theta/(n+1)$。令期望等于 θ，唯一确定

$$\boxed{A(P)=\left(\frac{n+1}{n}\right)^n P^{1/n}},\qquad \boxed{B(M)=\frac{n+1}{n}M}.$$

下面证明条件期望关系. 固定哪个观测为最大值, 并记该最大值为 $m \in (0,\theta)$. 由于各个 X_i 独立且密度均为 $1/\theta$, 指定第 i 个观测落在 $(m, m+\mathrm{d}m)$ 而其余 $n-1$ 个均小于 m 的联合密度为

$$\frac{1}{\theta^n}\mathbf{1}_{\{0<x_j<m\ (j\neq i)\}}.$$

对其他变量积分后, $(M,$最大值的编号$)$ 的密度为 m^{n-1}/θ^n. 二者相除, 就得到在给定最大值 m 及其编号后, 其余 $n-1$ 个观测的条件联合密度

$$\frac{1}{m^{n-1}}\mathbf{1}_{\{0<x_j<m\ (j\neq i)\}}.$$

因此这些剩余观测相互独立, 且均匀分布在 $(0,m)$ 上. 令它们分别为 $mV_1,\dots,mV_{n-1}$, 其中 V_j 独立服从 $U(0,1)$. 则

$$P^{1/n} = m\prod_{j=1}^{n-1} V_j^{1/n}, \qquad \mathbb{E}(P^{1/n}\mid M=m) = m\left(\int_0^1 u^{1/n}\,\mathrm{d}u\right)^{n-1} = m\left(\frac{n}{n+1}\right)^{n-1}.$$

这个结果不依赖达到最大值的编号. 因为连续型独立观测以概率 1 有唯一最大值, 所以

$$\mathbb{E}_\theta[P^{1/n}\mid M] = M\left(\frac{n}{n+1}\right)^{n-1}, \qquad \boxed{\mathbb{E}_\theta[A(P)\mid M] = B(M)}.$$

这说明对甲的无偏估计作条件平均，恰好得到乙的无偏估计，而不是反过来。

两种估计量均有有限二阶矩。利用 $r=2$ 的乘积矩和 $\mathbb{E}M^2 = n\theta^2/(n+2)$，得

$$\mathrm{Var}_\theta(A(P)) = \theta^2\left[\left(1+\frac{1}{n(n+2)}\right)^n - 1\right], \qquad \mathrm{Var}_\theta(B(M)) = \frac{\theta^2}{n(n+2)}.$$

记 $x = 1/[n(n+2)] > 0$。由于 $n\ge 2$，$(1+x)^n > 1+x$，因此

$$\boxed{\mathrm{Var}_\theta(B(M)) < \mathrm{Var}_\theta(A(P)) \qquad (n\ge 2)}.$$

这个严格改进也可从条件方差恒等式看出：给定 $M=m>0$ 时，其余 $n-1$ 个观测仍有随机性，所以 $A(P)$ 的条件方差为正。特别地，两种无偏估计的方差都随 $n\to\infty$ 趋于 0，由 Chebyshev 不等式可知它们都一致。

习题 2.2. 设 $X_1,\dots,X_n$ 独立服从 $U(0,\theta)$，$\theta>0$，仪器只能记录整数部分 $Y_i = \lfloor X_i\rfloor$。记 $M_n = \max_i Y_i$，并令 $R_n = \#\{i : Y_i = M_n\}$。

1. 已知完整的整数记录，求 θ 的全部极大似然估计。
2. 若仪器只保存 M_n，重新求极大似然估计。对每个固定的 $\theta>1$，分别判断两种估计能否在 $n\to\infty$ 时一致，并说明理由。

解. 记本次观测的最大整数为 m、它出现的次数为 r。若 $m=0$，全部观测均为零；此时 $0<\theta\le 1$ 下发生该记录的概率均为 1，而 $\theta>1$ 下为 $\theta^{-n}<1$。因此两种记录方式的极大似然估计集合都是 $(0,1]$。

下面设 $m\ge 1$。对 $y<m$, 若 $\theta>m$, 都有 $\mathbb{P}_\theta(Y_i=y)=1/\theta$; 对 $y=m$, 当 $m<\theta<m+1$ 时其概率为 $(\theta-m)/\theta$，当 $\theta\ge m+1$ 时为 $1/\theta$。由独立性，完整整数记录的似然为

$$L(\theta) = \begin{cases} 0, & 0<\theta\le m,\\ (\theta-m)^r/\theta^n, & m<\theta<m+1,\\ \theta^{-n}, & \theta\ge m+1. \end{cases}$$

在中间区间有

$$\frac{\mathrm{d}}{\mathrm{d}\theta}\log L(\theta)=\frac{r}{\theta-m}-\frac{n}{\theta}=\frac{nm-(n-r)\theta}{\theta(\theta-m)}.$$

在 $\theta\geq m+1$ 区间，似然严格递减。若 $r(m+1)<n$，则 $r<n$ 且 $nm/(n-r)\in(m,m+1)$；导数在此点前正后负，因而它是唯一最大点。若 $r(m+1)\geq n$，导数在 $(m,m+1)$ 上非负，结合右侧的严格递减性，唯一最大点为 $m+1$。所以

$$\boxed{\widehat{\theta}_{\text{full}}=\begin{cases}\dfrac{nm}{n-r}, & r(m+1)<n,\\ m+1, & r(m+1)\geq n.\end{cases}}$$

这里 $r=n$ 自动落在第二种情形，无须对零分母作额外约定。尽管保留了全部 Y_i，其似然实际上只依赖 (M_n,R_n)。

只保留 $M_n=m$ 时，不能再直接使用上述似然。由 $\{M_n\leq m\}=\{X_i<m+1\text{ 对所有}i\}$，得

$$\mathbb{P}_\theta(M_n=m)=\begin{cases}0, & 0<\theta\leq m,\\ 1-(m/\theta)^n, & m<\theta<m+1,\\ \dfrac{(m+1)^n-m^n}{\theta^n}, & \theta\geq m+1.\end{cases}$$

第一段正值随 θ 严格增大，第二段随 θ 严格减小，两段在 $m+1$ 连续衔接。因此

$$\boxed{\widehat{\theta}_{\max}=m+1}\qquad(m\geq 1).$$

完整记录中最大整数出现的次数 r 可以把估计从 $m+1$ 推向内部，而只保留 m 时这部分信息丢失了。

最后固定真实参数 $\theta>1$。令

$$j=\lceil\theta\rceil-1\geq 1,\qquad \delta=\theta-j\in(0,1],\qquad q=\frac{\delta}{\theta}.$$

观测的整数部分只能取 $0,\dots,j$，其中

$$\mathbb{P}_\theta(Y_i=j)=q,\qquad \mathbb{P}_\theta(Y_i<j)=\frac{j}{\theta}<1.$$

因此

$$\mathbb{P}_\theta(M_n=j)=1-\left(\frac{j}{\theta}\right)^n\longrightarrow 1.$$

再记 $H_n=\#\{i:Y_i=j\}$。它服从 $\mathrm{Bin}(n,q)$，且

$$\mathbb{E}\left(\frac{H_n}{n}\right)=q,\qquad \mathrm{Var}\left(\frac{H_n}{n}\right)=\frac{q(1-q)}{n}\longrightarrow 0.$$

由 Chebyshev 不等式，$H_n/n\to q$ 依概率成立。在事件 $M_n=j$ 上，$R_n=H_n$，第一问的估计可统一写为

$$\widehat{\theta}_{\text{full}}=\min\left\{j+1,\ \frac{j}{1-H_n/n}\right\},$$

其中 $H_n=n$ 时将第二项理解为 $+\infty$。由于 $q<1$，右侧在 q 附近连续，故

$$\widehat{\theta}_{\text{full}}\ \xrightarrow{\mathbb{P}}\ \min\left\{j+1,\frac{j}{1-q}\right\}=\min\{j+1,\theta\}=\theta.$$

这里 $\delta = 1$（即 θ 为整数）的临界情况也已包含，无须排除。

另一方面，$\widehat{\theta}_{\max} = M_n + 1$（当 $M_n = 0$ 时可任取前述估计集合中的值，例如 1），所以

$$\widehat{\theta}_{\max} \xrightarrow{\mathbb{P}} j + 1 = \lceil \theta \rceil.$$

它仅当 θ 为整数时一致；当 $\theta > 1$ 非整数时，即使样本量无限增大，只知道最大整数也无法消除量化误差。事实上 $0 < \theta \le 1$ 时全部 Y_i 恒为零，不同参数产生完全相同的记录分布，因此在这一参数范围内也不可能构造对所有 θ 一致的整数记录估计列。

习题 2.3. 给定不全相等的实数 $x_1, \dots, x_n$，记 $M_j = n^{-1} \sum_{i=1}^n x_i^j$。

(1) 求唯一的两点分布 $\mathbb{P}(Y = a) = p$、$\mathbb{P}(Y = b) = 1 - p$，其中 $a < b$、$0 < p < 1$，使 $\mathbb{E}Y^j = M_j$（$j = 1, 2, 3$），并证明 $a, b \in [\min_i x_i, \max_i x_i]$。

(2) 比较 $\mathbb{E}Y^4$ 与 M_4，并确定等号成立的全部情形。

解. (1) 先消去位置参数。记

$$\mu = \frac{1}{n}\sum_{i=1}^n x_i, \qquad y_i = x_i - \mu, \qquad v = \frac{1}{n}\sum_{i=1}^n y_i^2 > 0, \qquad t = \frac{1}{n}\sum_{i=1}^n y_i^3.$$

令 $\alpha = a - \mu, \beta = b - \mu$。匹配原点前三阶矩，等价于匹配中心化后的前三阶矩：

$$p\alpha + (1-p)\beta = 0, \quad p\alpha^2 + (1-p)\beta^2 = v, \quad p\alpha^3 + (1-p)\beta^3 = t. \tag{4}$$

两点 α, β 都满足 $z^2 - (\alpha + \beta)z + \alpha\beta = 0$。按权重 $p, 1-p$ 平均此式及其乘以 z 后的式子，由 (4) 得到

$$\alpha\beta = -v, \qquad (\alpha + \beta)v = t.$$

这使三个未知数的方程变成一个二次方程。记 $s = t/v$、$d = \sqrt{s^2 + 4v} > |s|$，则唯一可能为

$$\alpha = \frac{s - d}{2} < 0 < \frac{s + d}{2} = \beta, \qquad p = \frac{\beta}{\beta - \alpha} = \frac{s + d}{2d}.$$

于是

$$\boxed{a = \mu + \frac{s - d}{2}, \quad b = \mu + \frac{s + d}{2}, \quad p = \frac{s + d}{2d}, \qquad s = \frac{t}{v},\ d = \sqrt{s^2 + 4v}.}$$

由 $\alpha < 0 < \beta$ 可知 $0 < p < 1$。代回第一矩为 0；再利用 $\alpha\beta = -v$ 及 $\alpha + \beta = s$，第二、第三矩依次为 $v, sv = t$。因此这唯一候选确实满足全部方程。

最后证明两支点没有跑到原始数据之外。令

$$P(z) = (z - \alpha)(z - \beta) = z^2 - sz - v.$$

按已知样本矩，

$$\frac{1}{n}\sum_{i=1}^n P(y_i) = 0, \qquad \frac{1}{n}\sum_{i=1}^n y_i P(y_i) = t - sv = 0.$$

所以

$$\sum_{i=1}^n (y_i - \alpha)(y_i - \beta)^2 = 0, \qquad \sum_{i=1}^n (y_i - \beta)(y_i - \alpha)^2 = 0. \tag{5}$$

若 $\alpha < \min_i y_i$，第一式每项非负，而且因样本不全相同，至少有一个 $y_i \neq \beta$，对应项严格为正，与 (5) 矛盾。故 $\alpha \ge \min_i y_i$。若 $\beta > \max_i y_i$，第二式每项非正且至少一项严格为负，同样矛盾，故 $\beta \le \max_i y_i$。加回 μ 即得所需区间约束。

(2) 直接展开四次根式会掩盖三矩匹配的作用。取第一问中已确定的 $q(x)=(x-a)(x-b)$。多项式 $q(x)^2$ 的最高次项为 x^4；其余各项次数不超过 3，故这部分在原样本平均与 Y 的期望下相同。又 $q(Y)=0$，于是

$$\boxed{M_4-\mathbb{E}Y^4=\frac{1}{n}\sum_{i=1}^{n}(x_i-a)^2(x_i-b)^2\geq 0}.$$

等号当且仅当每个 x_i 都属于 $\{a,b\}$。原数据不全相等，所以等号恰在数据仅取两个不同值时成立；此时 a,b 就是这两个值，概率为它们的经验频率。若数据至少有三个不同值，则和式中至少一项为正，不等式严格。

习题 2.4. 设 $n\geq 2$，$X_1,\ldots,X_n$ 独立服从 $U(0,\theta)$，其中 $\theta>0$ 未知。只记录最大的两个观测值之差 $D_n=X_{(n)}-X_{(n-1)}$。

1. 求 θ 的极大似然估计和形如 c_nD_n 的无偏估计量。

2. 当 $n\to\infty$ 时，判断这两个估计量是否一致。

解. 以概率 1 有 $0<D_n<\theta$。对 $0<s<t<\theta$，第二大值 s 和最大值 t 的联合密度为

$$f_{n-1,n}(s,t)=\frac{n(n-1)}{\theta^n}s^{n-2}.$$

这里的 $n(n-1)$ 选择这两个观测的原始编号，其余 $n-2$ 个都须小于 s。于是对 $0<d<\theta$，由 $t=s+d$ 并对 $0<s<\theta-d$ 积分，

$$f_{D_n}(d)=\int_0^{\theta-d}\frac{n(n-1)}{\theta^n}s^{n-2}\,\mathrm{d}s=\frac{n(\theta-d)^{n-1}}{\theta^n}.$$

给定实际记录 $d>0$，应最大化这一记录的密度。把 d 固定，令 $u=d/\theta$。由于似然为正时 $\theta>d$，故 $0<u<1$，而

$$f_{D_n,\theta}(d)=\frac{n}{d}\,u(1-u)^{n-1}.$$

这里的关键是 u 与 $1-u$ 之和为 1。对 n 个正数

$$u,\quad \underbrace{\frac{1-u}{n-1},\ldots,\frac{1-u}{n-1}}_{n-1\text{ 个}}$$

用基本不等式，它们的算术平均数为 $1/n$，因而

$$u\left(\frac{1-u}{n-1}\right)^{n-1}\leq\frac{1}{n^n}.$$

等号当且仅当这 n 个数全相等，即 $u=1/n$。这给出了密度在参数空间内的唯一最大点 $\theta=nd$。因此

$$\boxed{\widehat{\theta}_n=nD_n}.$$

这一做法利用了记录密度的比例结构，无须对含参数的分式求导。

另一方面，把密度积分得到准确尾概率

$$\mathbb{P}_\theta(D_n>d)=\left(1-\frac{d}{\theta}\right)^n\qquad(0\leq d\leq\theta).$$

对非负随机变量用尾和积分,

$$\mathbb{E}_\theta D_n = \int_0^\theta \left(1-\frac{d}{\theta}\right)^n \mathrm{d}d = \frac{\theta}{n+1}.$$

因此 c_nD_n 对每个 $\theta>0$ 无偏，当且仅当 $c_n=n+1$；唯一无偏比例估计为 $\boxed{\widetilde{\theta}_n=(n+1)D_n}$。

(2) 增大样本量并不使这一个间距拥有越来越小的相对误差。对固定 $a>0$ 和充分大的 n,

$$\mathbb{P}_\theta\left(\frac{nD_n}{\theta}>a\right)=\left(1-\frac{a}{n}\right)^n \longrightarrow e^{-a}.$$

特别地，取 $a=2$,

$$\mathbb{P}_\theta(\widehat{\theta}_n>2\theta)\longrightarrow e^{-2}>0.$$

若 $\widehat{\theta}_n$ 依概率收敛到 θ，左侧必趋于 0，故它不一致。把 n 换成 $n+1$ 后,

$$\mathbb{P}_\theta(\widetilde{\theta}_n>2\theta)=\left(1-\frac{2}{n+1}\right)^n\longrightarrow e^{-2}>0;$$

它也不一致。两个估计虽然分别具有似然最大与无偏的性质，但只保存极端观测之间一个间距，仍不能保证精度随样本量提高。

习题 2.5. 每轮独立取 $X\sim\mathrm{Exp}(\theta)$、$Y\sim\mathrm{Exp}(1)$，只记录 $K=\lfloor X/Y\rfloor$，其中 $\theta>0$ 未知，不同轮相互独立。

1. 一轮记录为 $K=k\geq 0$ 时，求 θ 的全部极大似然估计。
2. 对任意固定的 $n\geq 1$，证明只根据 n 轮记录 $K_1,\dots,K_n$ 不可能构造 θ 的无偏估计量；但 $1/(1+\theta)$ 可以无偏估计。

解. 先求单轮记录分布. 对 $u\geq 0$, 利用 X,Y 独立以及指数尾概率,

$$\mathbb{P}_\theta(X/Y\geq u)=\int_0^\infty e^{-\theta uy}e^{-y}\,\mathrm{d}y=\frac{1}{1+\theta u}.$$

由于 X/Y 为连续随机变量, 对每个整数 $k\geq 0$ 有

$$p_\theta(k)=\mathbb{P}_\theta(K=k)=\frac{1}{1+k\theta}-\frac{1}{1+(k+1)\theta}=\frac{\theta}{(1+k\theta)(1+(k+1)\theta)}. \tag{1}$$

(1) 若 $k=0$, 则 $p_\theta(0)=\theta/(1+\theta)$ 随 $\theta>0$ 严格增大, 上确界为 1 而不取到, 因而 MLE 不存在. 若 $k\geq 1$, 则

$$\frac{1}{p_\theta(k)}=\frac{1}{\theta}+(2k+1)+k(k+1)\theta\geq 2k+1+2\sqrt{k(k+1)}.$$

由 AM–GM 不等式, 等号仅在 $\theta=1/\sqrt{k(k+1)}$ 成立, 故这是唯一 MLE.

(2) 固定 $n\geq 1$, 假设某实值统计量 $T=T(K_1,\dots,K_n)$ 对每个 $\theta>0$ 可积并无偏估计 θ. 对 $k\geq 1$, 在 $\theta\geq 1$ 时,

$$\frac{\mathrm{d}}{\mathrm{d}\theta}\frac{1}{p_\theta(k)}=-\frac{1}{\theta^2}+k(k+1)>0,$$

所以 $p_\theta(k)\leq p_1(k)$. 同时 $p_\theta(0)\leq 1=2p_1(0)$. 各轮独立, 对任何记录向量 $\boldsymbol{k}$ 得到

$$\mathbb{P}_\theta(\boldsymbol{K}=\boldsymbol{k})\leq 2^n\mathbb{P}_1(\boldsymbol{K}=\boldsymbol{k})\quad(\theta\geq 1).$$

用非负级数逐项比较, 不需要交换极限与期望, 立即有

$$|\mathbb{E}_\theta T| \le \mathbb{E}_\theta |T| \le 2^n \mathbb{E}_1 |T| < \infty \qquad (\theta \ge 1). \tag{2}$$

右侧与 θ 无关, 但若 T 无偏估计 θ, 则 $|\mathbb{E}_\theta T| = \theta$ 可任意大, 与 (2) 矛盾. 这已排除全部在每个参数处可积的统计量, 而不只是某个矩估计公式.

另一方面, 由 (1) 或最初的尾概率,

$$\mathbb{E}_\theta \mathbf{1}_{\{K \ge 1\}} = \mathbb{P}_\theta(X \ge Y) = \frac{1}{1+\theta}.$$

故 $\mathbf{1}_{\{K_1 \ge 1\}}$ 与 $n^{-1}\sum_i \mathbf{1}_{\{K_i \ge 1\}}$ 均无偏估计 $1/(1+\theta)$, 且有界可积.

习题 2.6. 一枚正面概率为 $p \in (0,1)$ 的硬币反复抛掷，直到首次出现与第一面不同的结果。记此前连续相同的次数为 R，但不记录正反面。各轮试验独立重复。令 $t = p(1-p)$。

1. 证明：无论独立观察多少个 R，都不能无偏估计 p；但只观察一次 R 就能无偏估计 t。
2. 若每轮只保留 R 的奇偶性, 证明固定任意轮数都不能无偏估计 t, 但可以一致估计它。若允许借助独立的公平硬币随机决定观测何时结束，构造一个有界的 t 的无偏估计量，并证明平均所用轮数不超过 $3/2$。

解. 先求完整记录的分布。若 $R = r \ge 1$，则在首次变面之前，要么连续出现 r 次正面再出现反面，要么连续出现 r 次反面再出现正面。因此

$$\mathbb{P}_p(R = r) = p^r(1-p) + (1-p)^r p. \tag{1}$$

由于 $0 < p < 1$, 两种无限不变面的概率均为零, R 几乎必然有限。式 (1) 在 p 与 $1-p$ 交换时不变，所以任意固定 n 轮的完整记录 $(R_1, \dots, R_n)$，在参数 p 与 $1-p$ 下有相同分布。若存在对所有 p 可积且无偏估计 p 的统计量 T，便同时有 $\mathbb{E}_p T = p$ 与 $\mathbb{E}_{1-p} T = 1-p$，这在 $p \ne 1/2$ 时矛盾。即使观察到每个 R 的精确数值，也只能区分与 $p(1-p)$ 有关的信息，而不能区分正反面互换的两个参数。

另一方面，$R = 1$ 恰在前两次抛掷不同面时发生，故

$$\mathbb{P}_p(R = 1) = 2p(1-p) = 2t.$$

因此

$$\boxed{T_1 = \frac{1}{2}\mathbf{1}_{\{R=1\}}}$$

对每个 $0 < p < 1$ 都是 t 的有界无偏估计量，第一问得证。

(2) 记 $B = \mathbf{1}_{\{R \text{ 为偶数}\}}$。由式 (1) 及绝对收敛的几何级数,

$$\begin{aligned} q := \mathbb{P}(B = 1) &= \sum_{j=1}^{\infty} \left[p^{2j}(1-p) + (1-p)^{2j} p\right] \\ &= \frac{p^2}{1+p} + \frac{(1-p)^2}{2-p} = \frac{1-t}{2+t}. \end{aligned} \tag{2}$$

当 $0 < p < 1$ 时，$0 < t \le 1/4$，从而 $q \in [1/3, 1/2)$；反解得到

$$\boxed{t = \frac{1-2q}{1+q}.} \tag{3}$$

这说明奇偶记录在分布上仍能辨识 t，但有限样本的无偏性需要另行判断。

固定 $n \geq 1$，只观察独立的 $B_1, \ldots, B_n$。对于任意实值且对所有参数可积的统计量 $H(B_1, \ldots, B_n)$，其期望必为 q 的一个次数不超过 n 的多项式：

$$F(q) = \sum_{b \in \{0,1\}^n} H(b) q^{\sum b_i} (1-q)^{n - \sum b_i}. \tag{4}$$

这里每个记录向量在 $1/3 < q < 1/2$ 下都有正概率，因此可积性保证式中的 $H(b)$ 全部为有限实数。若 H 对所有 p 都无偏估计 t，则由式 (3)，

$$(1+q)F(q) = 1 - 2q \qquad (1/3 < q < 1/2).$$

两侧均为多项式，在一个开区间上相等便是恒等多项式。代入 $q = -1$，左边为零而右边为 3，矛盾。因此对每一个固定 n 都不存在这样的无偏估计。这个论证不要求 H 只依赖奇偶次数之和；它已覆盖所有依赖完整奇偶序列的统计量。

但一致估计可以构造。令 $K_n = \sum_{i=1}^{n} B_i$，先把经验比例截到合法参数区间：

$$\widetilde{q}_n = \min\left\{\frac{1}{2}, \max\left\{\frac{1}{3}, \frac{K_n}{n}\right\}\right\}, \qquad \widehat{t}_n = \frac{1 - 2\widetilde{q}_n}{1 + \widetilde{q}_n}.$$

由于 $q \in [1/3, 1/2)$，截断不会增大与 q 的距离，即 $|\widetilde{q}_n - q| \leq |K_n/n - q|$。函数 $h(u) = (1-2u)/(1+u)$ 在 $[1/3, 1/2]$ 上满足

$$|h'(u)| = \frac{3}{(1+u)^2} \leq \frac{27}{16} < 2.$$

于是由独立性与 Bernoulli 方差公式，

$$\mathbb{E}_p(\widehat{t}_n - t)^2 \leq 4\mathbb{E}_p\left(\frac{K_n}{n} - q\right)^2 = \frac{4q(1-q)}{n} \leq \frac{1}{n}.$$

右端趋零。再用 $\mathbb{P}(|\widehat{t}_n - t| > \varepsilon) \leq \mathbb{E}_p(\widehat{t}_n - t)^2/\varepsilon^2$，对每个固定 $p \in (0,1)$ 都有 $\widehat{t}_n \xrightarrow{\mathbb{P}} t$。实际上均方误差上界对全部 p 一致有效。故奇偶化会破坏固定样本的无偏可估性，却不妨碍随着样本量增加而一致估计同一参数函数。

还有一种不同于固定样本量的办法：允许用奇偶记录决定是否继续观测，并且可使用与所有实验独立的公平硬币。每轮由奇偶记录 B_i 和一枚新的公平硬币 U_i 共同决定：若 $U_i = 1$，立即结束并记 $Y = 1$；若 $U_i = 0, B_i = 1$，结束并记 $Y = 0$；若 $U_i = 0, B_i = 0$，再观察下一轮。这个停止规则只用已知的公平概率与已获得的记录，不依赖未知参数。

每轮继续的概率为 $r = (1-q)/2$，其中 $0 < r \leq 1/3$。各轮独立，所以观测轮数 τ 满足

$$\mathbb{P}(\tau > j) = r^j \quad (j = 0, 1, 2, \ldots), \qquad \mathbb{E}\tau = \sum_{j=0}^{\infty} r^j = \frac{2}{1+q} \leq \frac{3}{2}.$$

特别地，$\mathbb{P}(\tau = \infty) = \lim_{j\to\infty} r^j = 0$。事件 $Y = 1$ 是若干轮连续后首次遇到 $U_i = 1$，故

$$\mathbb{P}(Y = 1) = \sum_{j=0}^{\infty} r^j \frac{1}{2} = \frac{1}{1+q}.$$

于是停止时给出

$$\boxed{\widetilde{T} = 3Y - 2 \in \{-2, 1\}}, \qquad \mathbb{E}_p\widetilde{T} = \frac{3}{1+q} - 2 = \frac{1-2q}{1+q} = t.$$

这便是只用奇偶记录及独立公平硬币的有界无偏估计量。$q=1/3$（即 $p=1/2$）时，$\mathbb{E}\tau=3/2$，因此平均轮数界还是尖锐的。它可以取负值，但无偏估计量不要求逐次落在参数范围内。

固定 n 时统计量期望一定是 q 的多项式；上述估计量的观测轮数随机，$\mathbb{P}(Y=1)$ 来自无穷几何级数，故没有违反先前的多项式障碍。即使固定 n 时额外加入独立随机数，先在每个奇偶序列上对这些随机数取条件期望，仍会得到同一个有限多项式限制。

习题 2.7. 设 $n\ge 2$，$X_1,\dots,X_n$ 独立服从密度 $\mathbf{1}_{\{\theta\le x\le\theta+1\}}$，$\theta\in\mathbb{R}$。记 $m_n=\min_i X_i$、$M_n=\max_i X_i$。

(1) 在所有 $T_{n,c}=cm_n+(1-c)(M_n-1)$（$0\le c\le 1$，$c$ 不依赖样本或 θ）中，求对每个 θ 均使均方误差最小的 c 及最小值，并证明所选估计量是一致的 MLE。

(2) 求所选估计误差乘以 n 后的极限分布，并与一阶矩估计 $\bar X-1/2$ 的收敛尺度比较。

解. (1) 似然为 $\mathbf{1}_{\{M_n-1\le\theta\le m_n\}}$。在模型产生的样本上，$M_n-m_n\le 1$，故所有 $T_{n,c}$ 均在 MLE 区间内。似然本身不能区分这些选择。

令 $U_i=X_i-\theta$，并记 $A=\min_i U_i$、$B=1-\max_i U_i$。则

$$T_{n,c}-\theta=cA-(1-c)B=\frac{A-B}{2}+\left(c-\frac12\right)(A+B).$$

这里先利用对称性，就能确定最优权重：把所有 U_i 同时换成 $1-U_i$，样本分布不变，而 A,B 的位置互换。因此 $\mathbb{E}A^2=\mathbb{E}B^2$，交叉项满足

$$\mathbb{E}[(A-B)(A+B)]=\mathbb{E}A^2-\mathbb{E}B^2=0.$$

于是

$$\mathbb{E}_\theta(T_{n,c}-\theta)^2=\frac14\mathbb{E}(A-B)^2+\left(c-\frac12\right)^2\mathbb{E}(A+B)^2. \tag{1}$$

因为 $A+B>0$ 以概率 1 成立，第二项只在 $c=1/2$ 时为零；这已经证明最优系数唯一。下面计算其风险。

先求两端间隔的联合矩。对 $0<u<v<1$，

$$\mathbb{P}(\min U_i>u,\max U_i\le v)=(v-u)^n.$$

先对 v 求导，再对 u 求导并变号，得到最小值、最大值的联合密度 $n(n-1)(v-u)^{n-2}$。令 $a=u,b=1-v$，Jacobian 绝对值为 1，从而

$$f_{A,B}(a,b)=n(n-1)(1-a-b)^{n-2},\qquad a,b>0,\ a+b<1.$$

又 $\mathbb{P}(A>t)=(1-t)^n$（$0<t<1$），A,B 同分布，尾积分公式给出

$$\mathbb{E}A=\mathbb{E}B=\frac{1}{n+1},\qquad \mathbb{E}A^2=\mathbb{E}B^2=\frac{2}{(n+1)(n+2)}.$$

为求交叉矩，令 $s=a+b$，先在 $0<a<s$ 上积分：

$$\begin{aligned}\mathbb{E}AB&=n(n-1)\int_0^1(1-s)^{n-2}\left[\int_0^s a(s-a)\,\mathrm{d}a\right]\mathrm{d}s\\&=\frac{n(n-1)}{6}\int_0^1 s^3(1-s)^{n-2}\,\mathrm{d}s=\frac{1}{(n+1)(n+2)}.\end{aligned}$$

最后一个等式可连续分部积分三次验证。将这些矩代入 (1)，得到

$$\mathbb{E}_\theta(T_{n,c}-\theta)^2=\frac{1/2+6(c-1/2)^2}{(n+1)(n+2)}.$$

所以唯一最优估计量及最小均方误差为

$$\boxed{T_n=\frac{m_n+M_n-1}{2}},\qquad \boxed{\mathbb{E}_\theta(T_n-\theta)^2=\frac{1}{2(n+1)(n+2)}}.$$

右端随 $n\to\infty$ 趋于零。由 $\mathbb{P}_\theta(|T_n-\theta|>\varepsilon)\le\mathbb{E}_\theta(T_n-\theta)^2/\varepsilon^2$，对每个固定的 θ 和 $\varepsilon>0$，T_n 依概率收敛于 θ，即它是一致的 MLE。

(2) 只看方差的阶还不足以识别极限分布。令 $D=(A-B)/2=T_n-\theta$、$S=A+B$。反解 $a=S/2+D, b=S/2-D$，Jacobian 绝对值为 1；积分域为 $2|D|<S<1$。因此 D 的密度为

$$f_D(d)=n(n-1)\int_{2|d|}^1(1-s)^{n-2}\,\mathrm{d}s=n(1-2|d|)^{n-1},\quad |d|<1/2.$$

分布对称。固定 $x<0$，当 $n>-2x$ 时，$\mathbb{P}(nD\le x)=\frac12(1+2x/n)^n\to\frac12e^{2x}$；固定 $x\ge0$，当 $n>2x$ 时，$\mathbb{P}(nD\le x)=1-\frac12(1-2x/n)^n\to1-\frac12e^{-2x}$。所以

$$\boxed{n(T_n-\theta)\xrightarrow{d}Z,\qquad f_Z(z)=e^{-2|z|},\ z\in\mathbb{R}.}$$

另一方面，$\mathbb{E}(X_i-1/2)=\theta$、$\mathrm{Var}(X_i)=1/12$，故 $\sqrt{n}(\bar X-1/2-\theta)\xrightarrow{d}N(0,1/12)$。前者的非退化尺度是 n，后者是 $\sqrt{n}$。精确 MSE 之比为

$$\frac{\mathbb{E}(T_n-\theta)^2}{\mathbb{E}(\bar X-1/2-\theta)^2}=\frac{6n}{(n+1)(n+2)}\longrightarrow0.$$

$n=2$ 时两个估计量本来相同；$n\ge3$ 时前者 MSE 严格较小。这一比较来自精确矩计算，并非仅凭依分布收敛。

第三章　无偏构造与估计量比较

习题完整解答

习题 3.1.　设 $N=2m\ge 4$，$X_1,\dots,X_N$ 独立服从 $U(0,1)$。观察全部数据后，独立地将 N 个有编号的位置等可能地分成 m 对。每对取两个数中较小的那个，记这些较小数的平均值为 T。再令 T_* 为固定原数据后，对全部可能配对所得 T 的平均值。

(1) 只用次序统计量 $X_{(1)}\le\cdots\le X_{(N)}$ 表示 T_*。

(2) 求 $\mathrm{Var}(T)$ 与 $\mathrm{Var}(T_*)$，证明 T_* 的方差严格小于 T 的方差。

解.　(1) 记 $h_{ij}=\min(X_i,X_j)$ $(i<j)$。固定原数据后，由位置的对称性，下标 i 与指定的 $j\ne i$ 配成一对的概率为 $1/(N-1)$。由于每次配对包含 $m=N/2$ 对，

$$T=\frac{2}{N}\sum_{\{i,j\}\text{属于本次配对}} h_{ij},$$

所以对随机配对求平均，得到

$$T_*=\frac{2}{N(N-1)}\sum_{i<j}h_{ij}=\frac{1}{\binom{N}{2}}\sum_{i<j}\min(X_i,X_j).$$

把原数据从小到大排列，第 k 小的数恰在与后面 $N-k$ 个数配对时成为较小数（并列时直接按排序位置计数，结论仍成立）。因此

$$\boxed{T_*=\frac{1}{\binom{N}{2}}\sum_{k=1}^{N}(N-k)X_{(k)}.}$$

(2) 先考虑两个独立的 $U(0,1)$ 随机变量 X,Y，记 $H=\min(X,Y)$。在 $0<t<1$ 上，

$$\mathbb{P}(H>t)=(1-t)^2.$$

利用尾积分公式可得

$$\mathbb{E}H=\int_0^1(1-t)^2\,\mathrm{d}t=\frac{1}{3},\qquad \mathbb{E}H^2=\int_0^1 2t(1-t)^2\,\mathrm{d}t=\frac{1}{6},$$

故 $\mathrm{Var}(H)=1/18$。每次实际配对后的 m 个较小数来自互不相交的独立观测，故它们相互独立且与 H 同分布。即使先随机选配对，上述条件均值与方差也不依赖具体配对，所以

$$\boxed{\mathrm{Var}(T)=\frac{1}{18m}=\frac{1}{9N}.}$$

下面计算 T_* 的方差。不同的 h_{ij} 若没有共同下标，则相互独立；若恰好共用一个下标，例如 h_{12} 与 h_{13}，可先固定 $X_1=x$。此时 h_{12},h_{13} 条件独立，而且

$$\mathbb{E}\big[\min(x,X_2)\big]=\int_0^x t\,\mathrm{d}t+x(1-x)=x-\frac{x^2}{2}.$$

于是

$$\begin{aligned}\mathrm{Cov}(h_{12},h_{13}) &= \mathbb{E}\left(X_1-\frac{X_1^2}{2}\right)^2-\left(\frac{1}{3}\right)^2\\ &= \int_0^1\left(x-\frac{x^2}{2}\right)^2\mathrm{d}x-\frac{1}{9}=\frac{1}{45}.\end{aligned}$$

共有 $M=\binom{N}{2}$ 个 h_{ij}。每个 h_{ij} 的方差为 $1/18$；在方差展开的有序交叉项中，共有 $N(N-1)(N-2)$ 对不同的 h_{ij} 恰好共享一个下标，其协方差均为 $1/45$，余下的交叉项协方差为零。因而

$$\begin{aligned}\mathrm{Var}(T_*) &= \frac{1}{M^2}\left(\frac{M}{18}+\frac{N(N-1)(N-2)}{45}\right)\\ &= \boxed{\frac{4N-3}{45N(N-1)}}.\end{aligned}$$

最终

$$\boxed{\mathrm{Var}(T)-\mathrm{Var}(T_*)=\frac{N-2}{45N(N-1)}>0,\qquad N=2m\geq 4.}$$

随机配对虽然不影响无偏性，却引入了额外波动。固定样本后先对所有配对取平均，能够消去这种波动；而精确方差的差别来自有共同观测位置的两对最小值之间的协方差。

习题 3.2. (X_i,Y_i)（$1\leq i\leq n$，$n\geq 3$）为独立同分布样本，且 $\mathbb{E}(X_1^4+Y_1^4)<\infty$。从所有无固定点置换中等概率抽取 Π，独立于样本。只保留

$$C=\sum_i X_iY_i,\qquad D=\sum_i X_iY_{\Pi(i)}.$$

(1) 只用 C,D 构造 $\mathrm{Cov}(X_1,Y_1)$ 的无偏估计量。(2) 若可以读取完整样本，对全部无固定点置换作平均，证明新估计量方差不会增大，并写出其显式形式。

解. 记 $\mu=\mathbb{E}X_1$、$\nu=\mathbb{E}Y_1$、$c=\mathrm{Cov}(X_1,Y_1)$。四阶矩条件保证下面统计量都具有有限二阶矩。对于每个 i，因 $\Pi(i)\neq i$，X_i 和 $Y_{\Pi(i)}$ 来自两组不同的独立样本对，故

$$\mathbb{E}(X_iY_{\Pi(i)}\mid\Pi)=\mu\nu.$$

因此 $\mathbb{E}C=n(\mu\nu+c)$，$\mathbb{E}D=n\mu\nu$。第 (1) 问的估计量可以取

$$\boxed{U_\Pi=\frac{C-D}{n}},\qquad \mathbb{E}U_\Pi=c.$$

对第 (2) 问，令 $A=\sum_i X_i$、$B=\sum_i Y_i$。均匀随机的无固定点置换满足

$$\mathbb{P}(\Pi(i)=j)=\frac{1}{n-1}\quad(j\neq i).$$

这是因为在无固定点置换集合中，把除 i 外的标号重新排列可把条件 $\Pi(i)=j$ 对应的置换一一映到条件 $\Pi(i)=j'$ 对应的置换。于是对已经实现的数据取有限平均，

$$\overline{U}:=\mathbb{E}_\Pi(U_\Pi\mid X_1,Y_1,\dots,X_n,Y_n)=\frac{1}{n}\left(C-\frac{AB-C}{n-1}\right)=\frac{nC-AB}{n(n-1)}.$$

展开中心化乘积，得到

$$\boxed{\overline{U}=\frac{1}{n-1}\sum_{i=1}^n(X_i-\bar X)(Y_i-\bar Y)}.$$

它仍无偏，因为 $\mathbb{E}\overline{U} = \mathbb{E}U_{\Pi} = c$。对每一份固定的样本，有限个数的平方满足平均平方不小于平方的平均；以 $U_\pi - c$ 代入，再对样本取期望，得到

$$\mathbb{E}(\overline{U} - c)^2 \le \mathbb{E}(U_{\Pi} - c)^2.$$

两者均无偏，故

$$\boxed{\mathsf{Var}(\overline{U}) \le \mathsf{Var}(U_{\Pi})}.$$

更精确地说，等号成立当且仅当几乎每份样本中，$\sum_i X_i Y_{\pi(i)}$ 在全部无固定点置换 π 下都相同；这是有限平均平方不等式的全部等号条件。第二问能够这样平均，是因为已经取得完整样本，可以对每一种无固定点置换算出相应的数值；第一问只给 C, D，并不具备这些数据。

习题 3.3. 一个容量为 N 的总体中有 M 个“成功”单位，$N \ge n \ge 2$ 已知，M 未知。无放回简单随机抽取 n 个单位，记样本中的成功数为 K，并记 $p = M/N$。

(1) 只用 K 构造 p^2 的无偏估计量。

(2) 求 $(K/n)^2$ 估计 p^2 的偏差，并指出何时偏差为 0。

解. (1) 按有序位置计数。任意一个样本位置成功的概率为 M/N，故

$$\mathbb{E}K = \frac{nM}{N}.$$

任意两个不同有序样本位置同时成功的概率为 $M(M-1)/[N(N-1)]$，因此

$$\mathbb{E}[K(K-1)] = n(n-1)\frac{M(M-1)}{N(N-1)}.$$

而

$$p^2 = \frac{M^2}{N^2} = \frac{M(M-1) + M}{N^2}.$$

分别用上面两个无偏量替换 $M(M-1)$ 和 M，得到

$$\boxed{T = \frac{N-1}{Nn(n-1)}K(K-1) + \frac{K}{Nn}}$$

满足 $\mathbb{E}T = p^2$。

(2) 由 $\mathbb{E}(K/n) = p$,

$$\mathbb{E}\left(\frac{K}{n}\right)^2 - p^2 = \mathsf{Var}\left(\frac{K}{n}\right).$$

利用刚才的前两阶阶乘矩,

$$\begin{aligned}\mathsf{Var}(K) &= \mathbb{E}[K(K-1)] + \mathbb{E}K - (\mathbb{E}K)^2 \\ &= np(1-p)\frac{N-n}{N-1}.\end{aligned}$$

所以偏差为

$$\boxed{\frac{p(1-p)(N-n)}{n(N-1)}} \ge 0.$$

它恰在 $M = 0$、$M = N$ 或 $n = N$ 时为 0：前两种总体没有随机成分，后一种抽取了整个总体。其余情形 $(K/n)^2$ 都向上偏。

习题 3.4. $X_1,\dots,X_n$ 独立服从 $U(a,a+\theta)$，$n\ge 2$，其中 $a\in\mathbb{R}$ 与 $\theta>0$ 均未知。只保留 $L=\min_i X_i$ 与 $H=\max_i X_i$。(1) 在所有 $uH+vL+w$（系数只能依赖 n）中，求对 θ 无偏的全部估计量，并求其方差。(2) 若 a 已知，只用 H 构造 θ 的无偏估计量；比较两种观测要求下的方差。

解. 记 $R=H-L$。由均匀样本的次序统计量分布，

$$\mathbb{E}L=a+\frac{\theta}{n+1},\qquad \mathbb{E}H=a+\frac{n\theta}{n+1}.$$

这些式子也可由 $\P(H\le a+t)=(t/\theta)^n$ 以及 $L-a\overset{d}{=}\theta-(H-a)$ 积分得到。若 $T=uH+vL+w$ 对每个 $a\in\mathbb{R}$ 和 $\theta>0$ 都无偏估计 θ，则

$$(u+v)a+\frac{nu+v}{n+1}\theta+w=\theta.$$

分别比较 a,θ 和常数项，必有

$$u+v=0,\quad nu+v=n+1,\quad w=0,$$

故唯一无偏仿射估计量是

$$\boxed{T=\frac{n+1}{n-1}(H-L)}.$$

为求方差，先求极差 R 的密度。在 $a<l<h<a+\theta$ 上，L,H 的联合密度为

$$f_{L,H}(l,h)=\frac{n(n-1)}{\theta^n}(h-l)^{n-2}.$$

这是从 n 个样本中确定最小值与最大值的位置，剩下 $n-2$ 个样本须落在它们之间。令 $r=h-l$ 并对 $l\in(a,a+\theta-r)$ 积分，得到

$$f_R(r)=\frac{n(n-1)}{\theta^n}r^{n-2}(\theta-r),\qquad 0<r<\theta.$$

于是对 $k=1,2$，

$$\mathbb{E}R^k=\frac{n(n-1)\theta^k}{(n-1+k)(n+k)}.$$

特别地，

$$\mathbb{E}R=\frac{n-1}{n+1}\theta,\qquad \mathbf{Var}(R)=\frac{2(n-1)}{(n+1)^2(n+2)}\theta^2.$$

所以第一问唯一无偏估计量的方差为

$$\boxed{\mathbf{Var}(T)=\frac{2\theta^2}{(n-1)(n+2)}}.$$

当 a 已知时，$H-a$ 的密度是 nt^{n-1}/θ^n（$0<t<\theta$），

$$\mathbb{E}(H-a)=\frac{n}{n+1}\theta,\qquad \mathbf{Var}(H-a)=\frac{n\theta^2}{(n+1)^2(n+2)}.$$

因此 $\widehat{\theta}_0=(n+1)(H-a)/n$ 无偏，且

$$\boxed{\mathbf{Var}(\widehat{\theta}_0)=\frac{\theta^2}{n(n+2)}}.$$

两方差之比为 $2n/(n-1)>2$。已知起点 a 时，最大值距离起点就是长度信息；起点未知时必须借助极差消去位置干扰，精度随之下降。比较的是这两个明确构造，并非宣称已证明所有非线性估计量的全局最优性。

习题 3.5. 设 $X_1,\dots,X_n$ 独立服从 Bernoulli(p)，$Y_1,\dots,Y_n$ 独立服从 Bernoulli(q)，两组相互独立，$n\ge 2$，$p,q\in[0,1]$。只保留成功次数 $K=\sum_i X_i$、$L=\sum_i Y_i$。

(1) 构造只依赖 (K,L) 的 $(p-q)^2$ 的无偏估计量。

(2) 证明不存在对所有 $(p,q)\in[0,1]^2$ 都无偏、且在每份可能记录上都非负的估计量。

解. (1) 不同下标对应独立试验，故

$$\mathbb{E}\frac{K(K-1)}{n(n-1)}=p^2,\qquad \mathbb{E}\frac{L(L-1)}{n(n-1)}=q^2.$$

两组独立还给出 $\mathbb{E}(KL/n^2)=pq$。因此

$$T(K,L)=\frac{K(K-1)+L(L-1)}{n(n-1)}-\frac{2KL}{n^2}$$

对每个 $(p,q)\in[0,1]^2$ 无偏估计 $(p-q)^2$。T 在某些记录下可能为负，这与无偏性并不矛盾。

(2) 设 $G(K,L)\ge 0$ 且对全部 (p,q) 无偏。在 $p=q=1/2$ 时目标为零，因而

$$\mathbb{E}_{1/2,1/2}G(K,L)=0.$$

此时 K,L 独立且各服从 Bin$(n,1/2)$；任意 $0\le k,l\le n$ 的联合概率 $\binom{n}{k}\binom{n}{l}2^{-2n}$ 严格为正。对有限个非负数求加权和等于零，只能有 $G(k,l)=0$ 对全部 k,l 成立。于是 G 在任何参数下都恒等于零，但取 $p=1,q=0$ 时目标值为 1，矛盾。因此不存在这样的非负无偏估计量。

习题 3.6. 设 $n\ge 2$. 对每个 $i=1,\dots,n$，有同一批次的两次读数

$$Y_i=\mu+U_i+\varepsilon_i,\qquad Z_i=\mu+U_i+\eta_i.$$

其中 U_i 独立同分布于 $N(0,\tau^2)$，ε_i,η_i 独立同分布于 $N(0,\sigma^2)$，上述全部随机变量相互独立，$\mu\in\mathbb{R}$、$\tau^2>0$、$\sigma^2>0$ 均未知. 记

$$C=\frac{1}{n-1}\sum_{i=1}^{n}(Y_i-\bar Y)(Z_i-\bar Z).$$

(1) 证明 C 对 τ^2 无偏. 利用两次读数的差值具有已知期望 0 这一信息，构造另一个对 τ^2 无偏的估计量 T，使其对所有允许的参数均满足 $\mathrm{Var}(T)<\mathrm{Var}(C)$，并求 $\mathrm{Var}(C)-\mathrm{Var}(T)$ 的精确表达式.

(2) 若每批只保留两次读数的和 $S_i=Y_i+Z_i$，证明不存在仅依赖 $S_1,\dots,S_n$、对全部参数可积且对 τ^2 无偏的估计量.

解. 两次读数中都含有 U_i，因此可先取平均以保留共同波动，再作差以消去它. 记

$$M_i=\frac{Y_i+Z_i}{2},\qquad D_i=Y_i-Z_i.$$

则

$$M_i=\mu+U_i+\frac{\varepsilon_i+\eta_i}{2},\qquad D_i=\varepsilon_i-\eta_i.$$

由正态分布在线性组合下封闭以及题设独立性，

$$M_i\sim N(\mu,v),\quad v=\tau^2+\frac{\sigma^2}{2},\qquad D_i\sim N(0,2\sigma^2).$$

在同一批次内，$\mathrm{Cov}(M_i, D_i) = \frac{1}{2}(\sigma^2 - \sigma^2) = 0$；由于 (M_i, D_i) 联合服从正态分布，所以 M_i, D_i 独立. 各批次又相互独立，故整组 (M_i) 与整组 (D_i) 独立.

对任何 $n \geq 2$ 个数 $W_1, \ldots, W_n$，记 $S_W^2 = (n-1)^{-1} \sum_i (W_i - \bar{W})^2$. 将 $Y_i = M_i + D_i/2$ 及 $Z_i = M_i - D_i/2$ 代入样本协方差，交叉乘积逐项抵消，得到

$$C = S_M^2 - \frac{1}{4} S_D^2.$$

样本方差的无偏性给出 $\mathbb{E}S_M^2 = v$ 及 $\mathbb{E}S_D^2 = 2\sigma^2$，因此 $\mathbb{E}C = \tau^2$.

区别在于 D_i 的总体均值已知为 0，没必要再从数据估计这个均值. 于是令

$$\boxed{T = S_M^2 - \frac{1}{4n} \sum_{i=1}^{n} D_i^2}.$$

由于 $\mathbb{E}D_i^2 = 2\sigma^2$，也有 $\mathbb{E}T = \tau^2$.

为比较方差，先证明一个所需的正态样本方差公式. 若 W_i 独立同分布于 $N(a, w^2)$ 且 $n \geq 2$，记 $V_i = W_i - a$，$A = \sum_i V_i^2$ 及 $B = (\sum_i V_i)^2/n$. 则 $(n-1)S_W^2 = A - B$. 正态变量的二、四阶矩分别为 $\mathbb{E}V_i^2 = w^2$、$\mathbb{E}V_i^4 = 3w^4$，所以

$$\mathrm{Var}(A) = 2nw^4, \qquad \mathrm{Var}(B) = 2w^4.$$

又因不同下标的奇数次因子具有零期望，展开 $\mathbb{E}(AB)$ 时只留下 $\mathbb{E}(V_i^4)$ 和 $\mathbb{E}(V_i^2 V_j^2)$，即

$$\mathbb{E}(AB) = \frac{1}{n}\left(3nw^4 + n(n-1)w^4\right) = (n+2)w^4.$$

而 $\mathbb{E}A = nw^2$、$\mathbb{E}B = w^2$，故 $\mathrm{Cov}(A, B) = 2w^4$，从而

$$\boxed{\mathrm{Var}(S_W^2) = \frac{2w^4}{n-1}}.$$

另外，对独立 $N(0, d^2)$ 变量，直接用 $\mathrm{Var}(D_i^2) = 2d^4$ 可得 $\mathrm{Var}(n^{-1}\sum_i D_i^2) = 2d^4/n$.

现在利用 (M_i) 与 (D_i) 独立，并代入其各自的方差参数，得到

$$\mathrm{Var}(C) = \frac{2v^2}{n-1} + \frac{\sigma^4}{2(n-1)}, \qquad \mathrm{Var}(T) = \frac{2v^2}{n-1} + \frac{\sigma^4}{2n}.$$

所以

$$\boxed{\mathrm{Var}(C) - \mathrm{Var}(T) = \frac{\sigma^4}{2n(n-1)} > 0}.$$

这里 T 降低方差的原因不是增添数据，而是没有再估计一个事先已知等于 0 的均值.

(2) 只观察和时，$S_i = 2M_i$ 独立同分布于

$$N(2\mu,\ 4\tau^2 + 2\sigma^2).$$

取同一个 μ，比较 $(\tau^2, \sigma^2) = (1/4, 3/2)$ 与 $(1/2, 1)$：两种参数下，全部 S_i 的联合分布完全相同，都是独立 $N(2\mu, 4)$，但要估计的 τ^2 分别为 $1/4$ 与 $1/2$. 因此任何仅依赖这些和且在两种参数下可积的统计量，其期望必定相等，不可能同时等于这两个不同的目标值. 所以不存在题设要求的无偏估计量.

习题 3.7. 设 $X_1,\dots,X_n$ 独立服从均值为 $\theta>0$ 的指数分布，即密度为 $\theta^{-1}e^{-x/\theta}$（$x>0$），$n\ge 2$。比较下面两个 θ^2 的无偏估计量的方差：

$$A_n=\frac{1}{2n}\sum_{i=1}^{n}X_i^2,\qquad B_n=\frac{1}{n(n-1)}\sum_{i\neq j}X_iX_j.$$

确定哪一个更好，并说明样本量为何会改变答案。

解. 指数分布的整数阶矩为 $\mathbb{E}X^k=k!\theta^k$；可由密度积分分部积分递推得到。因此 $\mathbb{E}(X_i^2/2)=\theta^2$，而 $i\neq j$ 时独立性给 $\mathbb{E}(X_iX_j)=\theta^2$，二者确实都无偏。

对 A_n，

$$\mathrm{Var}(X_i^2/2)=\frac{1}{4}\mathbb{E}X_i^4-\theta^4=6\theta^4-\theta^4=5\theta^4,$$

所以

$$\boxed{\mathrm{Var}(A_n)=\frac{5\theta^4}{n}}.$$

把 B_n 写成所有无序对乘积 $H_{ij}=X_iX_j$ 的平均。共有 $m=\binom{n}{2}$ 项。每项

$$\mathrm{Var}(H_{ij})=(\mathbb{E}X^2)^2-\theta^4=3\theta^4.$$

两对指标不相交时相互独立；若只共享一个指标，例如 (12) 与 (13)，则

$$\mathrm{Cov}(H_{12},H_{13})=\mathbb{E}X_1^2\mathbb{E}X_2\mathbb{E}X_3-\theta^4=\theta^4.$$

三个不同指标能组成 3 对“共享一个端点”的无序边对，所以这样的协方差对共有 $3\binom{n}{3}$ 个。于是

$$\begin{aligned}\mathrm{Var}(B_n)&=\frac{m\cdot 3\theta^4+2\cdot 3\binom{n}{3}\theta^4}{m^2}\\&=\boxed{\frac{2(2n-1)}{n(n-1)}\theta^4}.\end{aligned}$$

比较两式，

$$\mathrm{Var}(B_n)<\mathrm{Var}(A_n)\iff 2(2n-1)<5(n-1)\iff n>3.$$

所以 $n=2$ 时 A_n 较好，$n=3$ 时二者相同，$n\ge 4$ 时 B_n 较好。原因是 B_n 虽然使用了 $\binom{n}{2}$ 个乘积，但这些乘积大量共享样本而相关；小 n 时这种相关性抵消了平均的优势，样本量增大后跨指标平均才占优。

习题 3.8. $X_i=\mu+\sigma Z_i$（$1\le i\le n$，$n\ge 2$），其中 Z_i 独立同分布，$\mathbb{E}Z_i=0$、$\mathrm{Var}(Z_i)=1$，$\mu\in\mathbb{R},\sigma>0$ 未知。假设只观察到 $D_i=X_i-X_1$（$2\le i\le n$）与 $W=X_1+\varepsilon$，其中 ε 独立于样本，均值为 0，方差为已知的 $\tau^2>0$。(1) 在所有系数不依赖未知参数的线性仿射估计量 $T=aW+\sum_{i=2}^{n}b_iD_i+c$ 中，求对每个 (μ,σ) 无偏且方差最小的全部估计量。(2) 如果 W 也被删除，证明任一仅依赖差值的可积估计量都不可能对所有 μ 无偏。

解. 差值的期望为 0，$\mathbb{E}W=\mu$。由于估计量须对所有 $\mu\in\mathbb{R}$ 无偏，

$$\mathbb{E}T=a\mu+c=\mu$$

迫使 $a=1,c=0$；b_i 没有无偏性约束。将估计量改写成原样本的加权和：

$$T=W+\sum_{i=2}^{n}b_i(X_i-X_1)=\varepsilon+\sum_{i=1}^{n}w_iX_i,\quad w_1=1-\sum_{i=2}^{n}b_i,\quad w_i=b_i\ (i\ge 2).$$

这些权重恰满足 $\sum_i w_i = 1$。独立性与方差标准化给出

$$\mathrm{Var}(T) = \tau^2 + \sigma^2 \sum_{i=1}^{n} w_i^2 \geq \tau^2 + \frac{\sigma^2}{n},$$

其中不等式由 $\left(\sum_i w_i\right)^2 \leq n \sum_i w_i^2$ 得出。因为 $\sigma > 0$，等号当且仅当 $w_i = 1/n$ 对全部 i 成立，所以唯一最优估计量为

$$\boxed{T_* = W + \frac{1}{n}\sum_{i=2}^{n} D_i}, \qquad \boxed{\mathrm{Var}(T_*) = \tau^2 + \frac{\sigma^2}{n}}.$$

代入记录的定义，$T_* = \bar{X} + \varepsilon$：差值将锚点对应的单个观测恢复为样本均值，但噪声 ε 并未因平均差值而消失。

若删去 W，则记录 $D_i = \sigma(Z_i - Z_1)$ 的联合分布在固定 σ 时与 μ 完全无关。任何只依赖这些差值且在全部参数下可积的统计量 G，其期望对 μ 为常数，不可能对所有 μ 同时等于 μ。第 (2) 问不仅否定线性估计量，而是否定所有这样的可积估计量。这是因为差值的分布本身不随位置参数 μ 变化。

第四章　假设检验的概率逻辑

习题完整解答

习题 4.1.　独立投掷两枚硬币，各自直到第一次正面才停止，所用次数为 R_1, R_2，正面概率为 $p_1, p_2 \in (0,1)$。检验 $H_0 : p_1 \le p_2$ 对 $H_1 : p_1 > p_2$。

1. 证明 $P = R_1/(R_1 + R_2 - 1)$ 是合法 p 值。
2. 独立重复上述成对实验 m 次，对于两枚硬币同一次出现正面的平局不再记录胜负，只汇总非平局的次数 M 及其中第一枚先出现正面的次数 W。仅用 (M, W) 构造一个合法 p 值，并证明其有效性。

解.　(1) 记 $S = R_1 + R_2$，$q_i = 1 - p_i$。给定 $S = s \ge 2$，R_1 可取 $1, \dots, s-1$，其条件概率正比于

$$p_1 p_2 q_1^{r-1} q_2^{s-r-1} \;\propto\; \rho^{r-1}, \qquad \rho = q_1/q_2.$$

在 H_0 下 $\rho \ge 1$，这些权重随 r 不减。因此对 $0 \le k \le s-1$，前 k 项的平均权重不超过全部 $s-1$ 项的平均权重，得到

$$\mathbb{P}_{p_1,p_2}(R_1 \le k \mid S = s) = \frac{\sum_{r=1}^{k} \rho^{r-1}}{\sum_{r=1}^{s-1} \rho^{r-1}} \le \frac{k}{s-1}.$$

空和按零处理；$k = s-1$ 时等号成立。当 $p_1 = p_2$ 时，所有条件权重相同。固定 $0 < u < 1$，在 $S = s$ 条件下，$\{P \le u\} = \{R_1 \le \lfloor u(s-1) \rfloor\}$。于是

$$\mathbb{P}(P \le u \mid S = s) \le \frac{\lfloor u(s-1) \rfloor}{s-1} \le u.$$

再对 $s = 2, 3, \dots$ 用全概率公式求和，得到对每个 $p_1 \le p_2$ 都有 $\mathbb{P}(P \le u) \le u$。当 $s = 2$ 时 $P = 1$，已包含在证明中。

(2) 对单次成对实验，

$$A := \mathbb{P}(R_1 < R_2) = \sum_{r=1}^{\infty} p_1 q_1^{r-1} q_2^{r} = \frac{p_1 q_2}{1 - q_1 q_2},$$
$$B := \mathbb{P}(R_2 < R_1) = \frac{p_2 q_1}{1 - q_1 q_2}.$$

两级数绝对收敛，且 $A, B > 0$。条件于非平局，第一枚先成功的概率为

$$\eta = \frac{A}{A+B} = \frac{p_1(1-p_2)}{p_1(1-p_2) + p_2(1-p_1)}.$$

直接相减可知 $\eta \le 1/2$ 当且仅当 $p_1 \le p_2$。m 次实验相互独立。指定其中哪些实验不是平局后，这些实验的胜负仍相互独立，各以概率 η 由第一枚获胜；该条件分布只依赖非平局个数。故

$$W \mid M = j \sim \mathrm{Bin}(j, \eta).$$

可取

$$P_* = \begin{cases} 1, & M = 0, \\ \displaystyle\sum_{\ell=W}^{M} \binom{M}{\ell} 2^{-M}, & M > 0. \end{cases}$$

对每个 $j>0$，例 4.4 在 $\eta\le 1/2$ 下给出 $\mathbb{P}(P_*\le u\mid M=j)\le u$；$j=0$ 时同样成立。对 M 平均即得有效性。删除平局确实依赖结果，但经过条件化，留下的胜负仍有可校准的零分布；因此不能把“与结果独立”误当作所有合法删选的必要条件。

习题 4.2. 已知一个容量为 N 的总体中有 M 个红色单位，$0\le M\le N$ 未知。等概率地无放回抽取 n 个单位，只记录红色数 K，其中 $1\le n\le N$。固定 $0<\alpha<1$。

1. 对每个整数 $0\le m\le N$，给出检验 $H_0: M\le m$ 的合法单侧 p 值。

2. 要求整数函数 $L:\{0,\dots,n\}\to\{0,\dots,N\}$ 非递减，且对每个 M 都满足

$$\mathbb{P}_M\{L(K)\le M\}\ge 1-\alpha.$$

求逐点最大的 L，并证明最优性。

解. 记

$$T_m(k)=\mathbb{P}_m(K\ge k)=\frac{1}{\binom{N}{n}}\sum_{j=k}^{n}\binom{m}{j}\binom{N-m}{n-j}\qquad(0\le m\le N,\ 0\le k\le n),\tag{1}$$

其中越界的二项式系数取零。特别地 $T_m(0)=1$，且 $T_N(k)=1$。给 N 个单位编号，令 A 为均匀选择的 n 元子集，在同一个 A 上定义

$$K_m=\#\big(A\cap\{1,\dots,m\}\big).$$

于是 K_m 具有参数为 m 的超几何分布，且 $m\le m'$ 时逐点有 $K_m\le K_{m'}$。因此 $T_m(k)$ 随 m 不减、随 k 不增。

(1) 对 $H_0: M\le m$ 取

$$\boxed{P_m=T_m(K).}\tag{2}$$

证明合法性时，固定 $0<u<1$。若 $\{k: T_m(k)\le u\}$ 为空，则拒绝事件为空；否则设 k_u 为其中最小的整数。由 $T_m(k)$ 对 k 不增，

$$\{P_m\le u\}=\{K\ge k_u\}.$$

因而对任意 $M\le m$，由上述耦合及 (1) 得

$$\mathbb{P}_M(P_m\le u)=T_M(k_u)\le T_m(k_u)\le u.$$

故 (2) 对整个复合零假设有效，而不是只在 $M=m$ 时有效。

(2) 对每个可能的观察值 k 定义

$$\boxed{L_\alpha(k)=\min\{m\in\{0,\dots,N\}: T_m(k)>\alpha\}.}\tag{3}$$

由于 $T_N(k)=1>\alpha$，最小值一定存在；$k=0$ 时 $L_\alpha(0)=0$。又因 $T_m(k)$ 对 k 不增，$L_\alpha(k)$ 对 k 非递减，确实属于题设的函数类。

固定真实参数 M。由 $T_m(k)$ 对 m 不减及 (3)，逐个 k 都有

$$L_\alpha(k)>M\quad\Longleftrightarrow\quad T_M(k)\le\alpha.$$

故第 (1) 问的合法性给出

$$\mathbb{P}_M\{L_\alpha(K)>M\}=\mathbb{P}_M\{T_M(K)\le\alpha\}\le\alpha,$$

即 $L_\alpha(K)$ 是覆盖概率至少为 $1-\alpha$ 的单侧下置信界。

最后证明它是逐点最大的。设另一非递减整数函数 B 也满足题设覆盖要求，却在某个 k 处有 $B(k) > L_\alpha(k)$。记 $m = L_\alpha(k)$。一旦观察到 $K \geq k$，非递减性给出 $B(K) \geq B(k) > m$；而由 (3)，$T_m(k) > \alpha$。所以在参数 $M = m$ 下，

$$\mathbb{P}_m\{B(K) > m\} \geq \mathbb{P}_m(K \geq k) = T_m(k) > \alpha,$$

与覆盖要求矛盾。因此任何合法的非递减 B 都必须逐点满足 $B(k) \leq L_\alpha(k)$，而 (3) 本身合法，所以它就是唯一的逐点最大函数。

这不是将一个 p 值代入未知参数的估计量，而是逐个检验假设边界，再反演全部未被拒绝的参数。例如 $n = N$ 时 $K = M$ 恒成立，式 (3) 给出 $L_\alpha(K) = K$；当 $n = 1$ 时上述构造也不需要任何连续近似。

习题 4.3. P_1, P_2 是同一零假设的两个合法 p 值。

1. 若二者独立且均服从 $U(0,1)$，求 $Q = P_1P_2$ 的分布，并把 Q 变为均匀分布的 p 值。

2. 不再假设二者独立或均匀。给定 $0 < w < 1$，求最小常数 c_w，使

$$P_w = \min\{1, c_w P_1^w P_2^{1-w}\}$$

对所有这样的 P_1, P_2 均是合法 p 值，并证明常数不能减小。

解. (1) 独立均匀时，对 $0 < t < 1$ 按 $P_1 = x$ 积分，得到

$$\mathbb{P}(Q \leq t) = \int_0^t 1 \,\mathrm{d}x + \int_t^1 \frac{t}{x} \,\mathrm{d}x = t(1 - \log t).$$

在 $t \leq 0$ 和 $t \geq 1$ 时，分布函数分别为 0 和 1。因为该函数在 $(0,1)$ 上连续、严格递增，并且两端极限为 $0, 1$，所以

$$\boxed{Q(1 - \log Q) \sim U(0,1).}$$

这里确实用到了独立和均匀分布两个条件；只有“合法 p 值”还不够。

(2) 记 $d_w = w^w(1-w)^{1-w}$，证明最小常数是

$$\boxed{c_w = \frac{1}{d_w}}.$$

固定 $0 < u < 1$。如果同时有 $P_1 > wu$、$P_2 > (1-w)u$，则

$$P_1^w P_2^{1-w} > (wu)^w((1-w)u)^{1-w} = d_w u.$$

因此

$$\{c_w P_1^w P_2^{1-w} \leq u\} \subseteq \{P_1 \leq wu\} \cup \{P_2 \leq (1-w)u\}.$$

两边缘 p 值各自有效，故

$$\mathbb{P}(P_w \leq u) \leq wu + (1-w)u = u.$$

$u = 0$ 时合法性给出 $\mathbb{P}(P_i = 0) = 0$，$u \geq 1$ 时结论直接成立。由此所给常数确实有效，不需要假定两者独立。

常数的尖锐性由一个具体的相关结构给出。任取 $0<s<1$，令 $U\sim U(0,1)$，取

$$P_1=U,\qquad P_2=\begin{cases}s-U, & 0<U<s,\\ U, & s\le U<1.\end{cases}$$

这是把 $(0,s)$ 内的数关于中点反射,区间外保持不变,因此 P_1,P_2 都服从均匀分布。在 $0<U<s$ 时写 $v=U/s$，便有

$$P_1^{w}P_2^{1-w}=s\,v^{w}(1-v)^{1-w}.$$

这里不必求导。由加权基本不等式,

$$\Big(\frac{v}{w}\Big)^{w}\Big(\frac{1-v}{1-w}\Big)^{1-w}\le w\frac{v}{w}+(1-w)\frac{1-v}{1-w}=1,$$

所以

$$v^{w}(1-v)^{1-w}\le w^{w}(1-w)^{1-w}=d_w,$$

等号仅在 $v=w$ 时成立。另一方面，$U\ge s$ 时两 p 值都等于 U，乘积的加权几何平均为 $U\ge s>sd_w$。因此

$$\mathbb{P}(P_1^{w}P_2^{1-w}\le sd_w)=s.$$

若 $0<c<1/d_w$，取 $u=csd_w\in(0,1)$，则

$$\mathbb{P}\{\min(1,cP_1^{w}P_2^{1-w})\le u\}\ge s>u,$$

违反 p 值的有效性。故 c_w 确为最小常数；$w=1/2$ 时它等于 2。

习题 4.4. 设 $X_1,\dots,X_n$ 独立服从 $N(\mu,1)$, 检验 $H_0:\mu\le 0$ 对 $H_1:\mu>0$, 固定 $0<\alpha<1$, 记 $c=\Phi^{-1}(1-\alpha)$。比较两个检验

$$A_n:\sqrt{n}\,\overline{X}>c,\qquad B_n:\frac{2(K-n/2)}{\sqrt{n}}>c,\qquad K=\sum_{i=1}^{n}\mathbf{1}_{\{X_i>0\}}.$$

1. 证明 A_n 的显著性水平恰为 α，而 B_n 的显著性水平趋于 α。

2. 对固定 $\delta>0$ 取局部备择 $\mu_n=\delta/\sqrt{n}$，求两个检验功效的极限并比较。

解. (1) $\sqrt{n}\,\overline{X}\sim N(\sqrt{n}\mu,1)$，所以 A_n 的拒绝概率为 $1-\Phi(c-\sqrt{n}\mu)$，在 $\mu\le 0$ 上的最大值恰为 $1-\Phi(c)=\alpha$。对 B_n，有 $K\sim\mathsf{Bin}(n,\Phi(\mu))$。由共同均匀变量的耦合，其上尾随 μ 不减，最坏参数仍为 $\mu=0$。此时 $K\sim\mathsf{Bin}(n,1/2)$，通常的独立同分布中心极限定理给出

$$\frac{2(K-n/2)}{\sqrt{n}}\xrightarrow{d}N(0,1),$$

故拒绝概率趋于 α。

(2) 在 $\mu_n=\delta/\sqrt{n}$ 下，A_n 的功效对每个 n 都是

$$\pi_{A,n}=1-\Phi(c-\delta).$$

令 $p_n=\Phi(\delta/\sqrt{n})$、$d_n=p_n-1/2$。在一组独立 $U_i\sim U(0,1)$ 上构造

$$K_n=\sum_{i=1}^{n}\mathbf{1}_{\{U_i\le p_n\}},\qquad K_n^{0}=\sum_{i=1}^{n}\mathbf{1}_{\{U_i\le 1/2\}},\qquad D_n=K_n-K_n^{0}.$$

D_n 是 n 个参数 d_n 的独立 Bernoulli 变量之和，因而

$$\mathbb{E}D_n = nd_n, \qquad \mathrm{Var}\left(\frac{2(D_n - nd_n)}{\sqrt{n}}\right) = 4d_n(1-d_n) \longrightarrow 0.$$

Chebyshev 不等式说明这个中心化差趋于零（依概率）。另一方面，$\Phi'(0) = 1/\sqrt{2\pi}$ 给出

$$2\sqrt{n}\, d_n \longrightarrow \sqrt{\frac{2}{\pi}}\,\delta.$$

于是

$$\frac{2(K_n - n/2)}{\sqrt{n}} = \frac{2(K_n^0 - n/2)}{\sqrt{n}} + \frac{2(D_n - nd_n)}{\sqrt{n}} + 2\sqrt{n}\, d_n \xrightarrow{d} N\left(\sqrt{2/\pi}\,\delta, 1\right).$$

这里没有假设 D_n 与 K_n^0 独立，也没有调用随 n 变化的三角阵中心极限定理。所需的扰动步骤也可直接验证：若 A_n 已趋于连续分布、B_n 依概率趋于零，则对任意 $\varepsilon > 0$，

$$\mathbb{P}(A_n \le t - \varepsilon) - \mathbb{P}(|B_n| > \varepsilon) \le \mathbb{P}(A_n + B_n \le t) \le \mathbb{P}(A_n \le t + \varepsilon) + \mathbb{P}(|B_n| > \varepsilon).$$

先令 $n \to \infty$，再令 $\varepsilon \downarrow 0$ 即可；确定性趋于常数的第三项只造成平移。因此

$$\boxed{\lim_{n\to\infty} \pi_{B,n} = 1 - \Phi\left(c - \sqrt{2/\pi}\,\delta\right) < 1 - \Phi(c - \delta) = \lim_{n\to\infty} \pi_{A,n}.}$$

严格不等式来自 $\delta > 0$、$0 < \sqrt{2/\pi} < 1$ 和 Φ 严格递增。

习题 4.5. X_1, X_2 独立服从 $U(0,\theta)$, $\theta > 0$。检验 $H_0 : \theta \le 1$ 对 $H_1 : \theta > 1$, 固定 $0 < \alpha < 1/2$。

1. 证明任何显著性水平不超过 α 的非随机化检验, 在 $\theta > 1$ 时的功效不超过 $1 - (1-\alpha)/\theta^2$。
2. 构造两个不同的拒绝域，同时对每个 $\theta > 1$ 达到上述上界：一个只看 $\max(X_1, X_2)$；另一个在每个 $0 < \theta \le 1$ 下的拒绝概率都恰为 α。

解. (1) 记 $A = (0,1)^2$，任取合法拒绝域 C。当 $\theta > 1$ 时，联合密度在 $(0,\theta)^2$ 上恒为 θ^{-2}，故

$$\mathbb{P}_\theta(C \cap A) = \theta^{-2}\mathbb{P}_1(C), \qquad \mathbb{P}_\theta(A^c) = 1 - \theta^{-2}.$$

于是

$$\mathbb{P}_\theta(C) \le \theta^{-2}\alpha + 1 - \theta^{-2} = 1 - \frac{1-\alpha}{\theta^2}.$$

第一步只使用零假设中的 $\theta = 1$ 来推出一个上界；随后构造检验时，仍须验证全部 $\theta \le 1$。

(2) 令 $b = \sqrt{1-\alpha}$。第一个拒绝域可取

$$C_1 = \{\max(X_1, X_2) > b\}.$$

当 $\theta \le b$ 时拒绝概率为零；当 $b < \theta \le 1$ 时为 $1 - b^2/\theta^2 \le \alpha$，在 $\theta = 1$ 取等。当 $\theta > 1$ 时功效正是第 (1) 问的上界。

第二个拒绝域取为

$$\boxed{C_2 = \{\max(X_1, X_2) > 1\} \cup \{X_1 < 2\alpha X_2\}.}$$

因 $0 < 2\alpha < 1$，对每个 $0 < \theta \le 1$,

$$\mathbb{P}_\theta(C_2) = \frac{1}{\theta^2}\int_0^\theta 2\alpha y \,\mathrm{d}y = \alpha.$$

当 $\theta > 1$ 时，它包括整个 A^c（在样本支持内），而它在 A 内的三角区域面积为 α，所以

$$\mathbb{P}_\theta(C_2) = 1 - \theta^{-2} + \alpha\theta^{-2} = 1 - \frac{1-\alpha}{\theta^2}.$$

两检验不仅书写形式不同。区域 $0 < x_2 < b/2$、$0 < x_1 < 2\alpha x_2$ 具有正面积，属于 C_2 而不属于 C_1。因此，最优功效曲线在这个模型中并不唯一确定拒绝域。

习题 4.6. 独立抛一枚正面概率为 p 的硬币五次，检验 $H_0 : 1/6 \le p \le 5/6$。若五次中恰有一次与其余四次不同面，则拒绝；若五次同面，则以概率 γ 拒绝；其余情况不拒绝，其中 $0 \le \gamma \le 1$，随机化与抛掷独立。给定名义水平 $0 < \alpha < 1$，求使这一检验水平不超过 α 的全部 γ（若不存在，说明原因）；当取允许的最大 γ 时，求全部最坏零假设参数。

解. 记 $s = p(1-p)$。零假设等价于 $5/36 \le s \le 1/4$；不同的 p 可能对应同一个 s。四次同面、一次异面的概率和五次同面的概率分别为

$$5p(1-p)\big(p^3 + (1-p)^3\big) = 5s(1-3s), \qquad p^5 + (1-p)^5 = 1 - 5s + 5s^2.$$

故给定参数 s 的拒绝概率为

$$f_\gamma(s) = \gamma + 5(1-\gamma)s - 5(3-\gamma)s^2. \tag{1}$$

这里关于 s 严格凹，顶点位于

$$s_\gamma = \frac{1-\gamma}{2(3-\gamma)} \le \frac{1}{6} < \frac{1}{4}.$$

而 $s_\gamma \ge 5/36$ 当且仅当 $\gamma \le 3/13$。因此实际显著性水平是

$$A(\gamma) = \max_{p \in [1/6,5/6]} \mathbb{P}_p(\text{拒绝}) = \begin{cases} \gamma + \dfrac{5(1-\gamma)^2}{4(3-\gamma)}, & 0 \le \gamma \le 3/13, \\ \dfrac{525 + 521\gamma}{1296}, & 3/13 \le \gamma \le 1. \end{cases} \tag{2}$$

两式在 $\gamma = 3/13$ 相等。由于 γ 每增加一点，拒绝概率恰好增加该增量乘以五次同面概率，而后者对所有 $p \in [1/6, 5/6]$ 均严格为正，故 $A(\gamma)$ 在 $[0,1]$ 上连续且严格递增。其起点、转折点、终点分别为

$$A(0) = \frac{5}{12}, \qquad A\left(\frac{3}{13}\right) = \frac{233}{468}, \qquad A(1) = \frac{523}{648}. \tag{3}$$

所以 $\alpha < 5/12$ 时根本没有可行的 γ：即使永不在五次同面时拒绝，检验水平仍为 $5/12$。

若 $\alpha \ge 5/12$，全部允许的随机化概率恰为 $0 \le \gamma \le \gamma_{\max}(\alpha)$，其中

$$\boxed{\gamma_{\max}(\alpha) = \begin{cases} -1 - 2\alpha + 2\sqrt{\alpha^2 + 4\alpha - 1}, & \dfrac{5}{12} \le \alpha \le \dfrac{233}{468}, \\ \dfrac{1296\alpha - 525}{521}, & \dfrac{233}{468} \le \alpha \le \dfrac{523}{648}, \\ 1, & \dfrac{523}{648} \le \alpha < 1. \end{cases}} \tag{4}$$

为核实第一段的反演，令 $A(\gamma) = \alpha$ 并乘以 $4(3-\gamma)$，整理得到

$$\gamma^2 + (2 + 4\alpha)\gamma + 5 - 12\alpha = 0.$$

所取的根是 $-1 - 2\alpha + 2\sqrt{\alpha^2 + 4\alpha - 1}$；另一根为负，不在 $[0,1]$。第二段直接由 (2) 解出。第三段的水平约束已允许 $\gamma = 1$。这些端点均相互接合，因而不存在遗漏或双重取值。

最后找最坏参数。若 $5/12 \le \alpha < 233/468$，则 $\gamma_{\max} < 3/13$，唯一使 s 取到顶点的两个 p 为

$$\boxed{p = \frac{1}{2}\left(1 \pm \sqrt{\frac{1 + \gamma_{\max}}{3 - \gamma_{\max}}}\right).}$$

这两个参数均位于零假设区间内部。若 $233/468 \le \alpha < 1$, 则 $\gamma_{\max} \ge 3/13$, 最大值只在 $s = 5/36$ 取得，全部最坏参数恰为 $\boxed{p = 1/6,\ 5/6}$。在转折水平 $\alpha = 233/468$ 时，顶点正好移到两个区间端点，结论仍成立。

这里先对整个复合零假设求最大拒绝概率, 再反演为允许的随机化范围; 直接只检查 $p = 1/2$ 或区间端点，会在第一段得到错误的校准。

习题 4.7. 设 $X_1, \dots, X_n$ 独立服从 Bernoulli(p)。每次试验结束后，该次结果可能没有被记录：出现成功时，被记录的概率为 a；出现失败时，被记录的概率为 b。给定全部试验结果后，各次是否被记录相互独立。已知

$$0 < b \le a \le 1, \qquad \frac{a}{b} \le c,$$

其中 $c \ge 1$ 已知，而 a, b 未知。最终只知道被记录的试验总数 M，以及其中成功的次数 K。检验 $H_0 : p \le p_0$，其中 $0 < p_0 < 1$。

1. 构造一个对所有允许的 (p, a, b) 都合法、且只依赖 (M, K) 的单侧 p 值。
2. 如果还要求对每个有正概率的 $M = m$，条件于 $M = m$ 后的 p 值仍合法，并且它随 K 非增，证明你的构造在这类规则中逐点最小。

解. (1) 记保留指示为 R_i。每次试验只有三种记录状态: 记录成功、记录失败、未被记录, 其概率依次为

$$pa, \qquad (1-p)b, \qquad 1 - pa - (1-p)b.$$

写 $\rho = pa + (1-p)b > 0$。给定恰好哪些试验被记录，这些位置上的试验结果仍相互独立，而且每一个为成功的条件概率是

$$q = \frac{pa}{pa + (1-p)b} = \frac{p(a/b)}{1 - p + p(a/b)}.$$

因此，只要 $\mathbb{P}(M = m) > 0$，就有

$$\boxed{K \mid M = m \sim \mathsf{Bin}(m, q).} \tag{1}$$

对 $0 \le p \le p_0$ 和 $1 \le a/b \le c$，上式中的 q 分别随 p 和 a/b 非减，故

$$q \le q_* := \frac{cp_0}{1 - p_0 + cp_0} \in (0, 1).$$

取

$$\boxed{P_*(M, K) = \sum_{j=K}^{M} \binom{M}{j} q_*^j (1 - q_*)^{M-j},} \tag{2}$$

其中 $M = 0$ 时和式为 1。给定 $M = m$，二项上尾概率随成功数 K 非增，且其在参数 q_* 下是合法的离散上尾 p 值。再用同一组均匀随机数耦合参数 $q \le q_*$ 的二项变量，得到对任意 $0 < u < 1$,

$$\mathbb{P}(P_* \le u \mid M = m) \le u. \tag{3}$$

对所有具有正概率的 m 用全概率公式求和，即得 P_* 在整个复合零假设下有效。这里 M 本身的分布可以依赖未知的 a, b；条件校准并未假定 M 与参数无关。

(2) 需证明式 (2) 不仅有效, 而且不能在任何一个 (m,k) 上下降。固定 $0 \le m \le n$。考虑零假设参数 $p = p_0$、$a = 1/2$、$b = 1/(2c)$。它们满足题设约束, 而且 $\rho \in (0,1)$, 所以 $\mathbb{P}(M = m) > 0$ 对所有 $m = 0, \dots, n$ 都成立。此时式 (1) 的参数恰为 q_*。

设 $G_m(k) \in [0,1]$ 是任意另一规则：对于每个允许的零假设参数，在条件 $M = m$ 下都满足 $\mathbb{P}\{G_m(K) \le u \mid M = m\} \le u$，并且 $G_m(k)$ 随 k 非增。若在某个 k 上有

$$G_m(k) < \mathbb{P}_{q_*}\{\mathsf{Bin}(m, q_*) \ge k\} = P_*(m,k),$$

可取严格介于两边的 $u \in (0,1)$。由于 G_m 非增，在上述边界零假设参数下,

$$\{K \ge k\} \subseteq \{G_m(K) \le u\},$$

于是

$$\mathbb{P}\{G_m(K) \le u \mid M = m\} \ge \mathbb{P}_{q_*}\{\mathsf{Bin}(m, q_*) \ge k\} > u,$$

与条件有效性矛盾。$m = 0$ 也包含在此证明中：此时只有 $k = 0$，合法常数 p 值必为 1。因此所有这样的规则都满足

$$\boxed{G_m(k) \ge P_*(m,k) \quad (0 \le k \le m \le n),}$$

而式 (2) 自身满足全部约束, 故它是唯一逐点最小的条件有效、随成功数非增的校准规则。注意最优性限定于题设的每一保留数条件下有效的规则类；并未声称它在不要求条件有效的全部无条件检验中最优。

第五章　合法对称性与精确检验

习题完整解答

习题 5.1.　设 $n \geq 2$，随机变量 $D_1, \ldots, D_n$ 相互独立，且各自的分布连续、关于 0 对称。观察到全部差值后，从下标中选一个非空集合 I，记

$$m = |I|, \qquad S = \#\{i \in I : D_i > 0\}, \qquad P = \mathbb{P}\{\mathrm{Bin}(m, 1/2) \geq S\}.$$

1. 若 I 只能由 $|D_1|, \ldots, |D_n|$ 决定，证明 P 是合法的 p 值。
2. 若允许根据全部差值任意选择 I，对给定的 $0 < \alpha < 1$，求所有选取规则下 $\mathbb{P}(P \leq \alpha)$ 的最大值。

解. (1) 记 $A = (|D_1|, \ldots, |D_n|)$、$B_i = \mathbf{1}_{\{D_i > 0\}}$。由独立性和逐个坐标关于零对称，改变任意一组 D_i 的符号都不改变联合分布。对任何仅由 A 决定的事件 C，所有 2^n 种指定符号与 C 同时发生的概率相同；由于 $\mathbb{P}(D_i = 0) = 0$，它们的概率均为 $2^{-n}\mathbb{P}(C)$。故整个符号向量与绝对值向量独立，而且各符号独立公平。

若 I 仅由绝对值决定，则在给定全部绝对值后，$m = |I|$ 已固定，

$$S \sim \mathrm{Bin}(m, 1/2).$$

写 $h_m(s) = \mathbb{P}\{\mathrm{Bin}(m, 1/2) \geq s\}$，$0 \leq s \leq m$。对于 $0 \leq u < 1$，如果没有整数 s 满足 $h_m(s) \leq u$，则 $\mathbb{P}(h_m(S) \leq u \mid |D_1|, \ldots, |D_n|) = 0$；否则取满足该不等式的最小整数 s_u。因 h_m 单调不增，

$$\mathbb{P}(P \leq u \mid |D_1|, \ldots, |D_n|) = \mathbb{P}(S \geq s_u \mid |D_1|, \ldots, |D_n|) = h_m(s_u) \leq u.$$

对绝对值向量取平均即得 $\mathbb{P}(P \leq u) \leq u$。$u = 1$ 时结论也成立。因此在按绝对值选择下，这确是合法的 p 值。

(2) 现在 I 可依赖符号。记全部 n 个差值中的正号数为

$$K = \#\{i : D_i > 0\} \sim \mathrm{Bin}(n, 1/2).$$

无论怎样选择非空 I，其中的正号数 S 总满足 $S \leq K$。在定义 P 的参照二项分布中，指定前 S 次试验全部成功的概率为 2^{-S}，故

$$P = \mathbb{P}\{\mathrm{Bin}(m, 1/2) \geq S\} \geq 2^{-S} \geq 2^{-K}.$$

这里 $S = 0$ 时 $P = 1$，同样满足该式。

这一逐次观测的下界能够达到: 如果 $K \geq 1$, 就选取所有正差值的下标, 此时 $m = S = K$, 故 $P = 2^{-K}$；若 $K = 0$，任取一个下标，则 $P = 1 = 2^{-K}$。于是对每一份已观测数据，任意选取规则所能得到的最小 p 值恰为 2^{-K}。特别地，任何规则都满足事件包含关系

$$\{P \leq \alpha\} \subseteq \{2^{-K} \leq \alpha\},$$

而刚才的规则使两事件相等。

令 $r = \lceil \log_2(1/\alpha) \rceil$。由于 $0 < \alpha < 1$，有 $r \geq 1$；当 $r > n$ 时下面的和约定为 0。由 K 的二项分布，所求最大值为

$$\boxed{\sup_I \mathbb{P}(P \leq \alpha) = \mathbb{P}(K \geq r) = \frac{1}{2^n} \sum_{j=r}^{n} \binom{n}{j}.}$$

例如 $\alpha = 1/2$ 时，这个最大值为 $1 - 2^{-n} > 1/2$。按绝对值挑选不会破坏公平符号；看过正负再挑选，却可把本来保守的检验变成严重超水平的规则。

习题 5.2. U, V 是独立公平符号（各以概率 $1/2$ 取 ± 1），记录三个差值

$$(D_1, D_2, D_3) = (U, V, UV).$$

1. 证明三个差值两两独立，且各自关于 0 对称，却不能分别独立翻转符号。

2. 对 $T = D_1 + D_2 + D_3$ 错按全部八种翻转计算上尾 p 值，求其真实分布；再用真正合法的翻转求正确的精确 p 值。

解. (1) (U, V) 在 $\{-1, 1\}^2$ 上等可能。给定 U，乘积 UV 仍是公平符号，因此 U 与 UV 独立；同样 V 与 UV 独立。三个差值每个都是公平符号，所以两两独立且边缘对称。然而恒有

$$D_1 D_2 D_3 = U\,V\,(UV) = 1.$$

只翻转任意一个坐标会使乘积变为 -1，所得向量在原模型中根本不可能出现。合法的符号向量只有乘积为 1 的四种配置，它们等概率；可用乘积为 1 的四个翻转向量整体作用。

(2) 真实统计量 T 在 $(1, 1, 1)$ 时为 3（概率 $1/4$），在其余三个合法配置时均为 -1（概率 $3/4$）。错误地使用全部八个独立翻转会给出统计量列表 3 一次、1 三次、-1 三次、-3 一次。因此错误 p 值为

$$P_{\text{wrong}} = \begin{cases} 1/8, & T = 3, \\ 7/8, & T = -1. \end{cases}$$

真实零分布为 $\mathbb{P}(P_{\text{wrong}} = 1/8) = 1/4$、$\mathbb{P}(P_{\text{wrong}} = 7/8) = 3/4$；在阈值 $1/8$ 下真实错误率 $1/4 > 1/8$。

若只用四种合法翻转，统计量列表为 $3, -1, -1, -1$，正确的上尾 p 值为

$$P_{\text{true}} = \begin{cases} 1/4, & T = 3, \\ 1, & T = -1. \end{cases}$$

于是当 $u < 1/4$ 时拒绝概率为零，当 $1/4 \le u < 1$ 时为 $1/4 \le u$，确实合法。这里甚至两两独立也不足以替代全向量的独立翻转对称性。

习题 5.3. 给定 $N = m + n$ 个有编号的实数 $z_1, \dots, z_N$（允许并列），等概率选择其中 m 个标为 X 组，其余标为 Y 组，其中 $m, n \ge 1$。以 $T = \overline{X} - \overline{Y}$ 作单侧上尾标签置换检验。求在全部可能的观测标签中，p 值能取得的最小值，并刻画所有取得最小值的标签配置。

解. 固定合并数据。设 t 为第 m 大的数，严格大于 t 的位置有 a 个，等于 t 的位置有 b 个；于是 $0 \le a < m$，且 $r = m - a$ 满足 $1 \le r \le b$。

令 A 为标成 X 组的 m 元位置集合。由于

$$T(A) = \frac{1}{m}\sum_{i \in A} z_i - \frac{1}{n}\sum_{i \notin A} z_i = \left(\frac{1}{m} + \frac{1}{n}\right)\sum_{i \in A} z_i - \frac{1}{n}\sum_{i=1}^{N} z_i,$$

最大化 T 等价于最大化所选的 m 个数之和。若某个被选位置的值比某个未选位置的值严格小，把这两个标签交换，就使该和严格增大。因此，且仅因此，极大配置必须选中所有严格大于 t 的 a 个位置，从值等于 t 的 b 个位置中再任取 r 个。

这些最大配置共有 $\binom{b}{r}$ 种。每种标签配置在零假设下都以 $\binom{N}{m}^{-1}$ 的概率出现。当观测本身最大时，上尾 p 值恰为最大配置总数所占的比例；若观测不是最大，除上述所有最大配置以外还须把观测配置计入上尾，因此比例严格更大。故

$$\boxed{p_{\min} = \frac{\binom{b}{r}}{\binom{N}{m}}},$$

全部且仅有刚才刻画的 $\binom{b}{r}$ 个标签配置取得这个值。特别地，当截断处没有跨组并列，即第 m 大数严格大于第 $m+1$ 大数时，$r=b$，最小 p 值为 $\binom{N}{m}^{-1}$；若全部数都相等，则 $a=0, b=N, r=m$，最小值变为 1。不能把并列标签配置去重后等概率计算。

习题 5.4. X, Y 相互独立且可积。某检验只假定 $H_0 : \mathbb{E}X = \mathbb{E}Y$，却把 (X,Y) 与 (Y,X) 当成两个等可能的标签，使用统计量 $T = Y - X$，并在交换上尾 $p \le 1/2$ 时拒绝。

1. 写出该规则真正的拒绝事件。

2. 在 $\mathbb{E}X = \mathbb{E}Y = 0$ 的全部这样的分布中，求实际拒绝概率的上确界，并判断能否取到。

解. (1) 固定记录 (x,y)，两个置换统计量分别为 $y-x$ 与 $x-y$。若 $y > x$，实测统计量严格较大，上尾 $p = 1/2$；若 $y = x$，两者并列，上尾 $p = 1$；若 $y < x$，实测统计量较小，上尾 $p = 1$。故拒绝事件恰为 $\{Y > X\}$，其真实第一类错误概率就是 $\mathbb{P}(Y > X)$。

(2) 拒绝概率不超过 1。下面构造使它任意接近 1 的分布。取 $0 < \varepsilon < 1/2$，使

$$\mathbb{P}(X = -1) = 1 - \varepsilon, \qquad \mathbb{P}\left(X = \frac{1-\varepsilon}{\varepsilon}\right) = \varepsilon,$$

$$\mathbb{P}(Y = 1) = 1 - \varepsilon, \qquad \mathbb{P}\left(Y = -\frac{1-\varepsilon}{\varepsilon}\right) = \varepsilon,$$

并令 X, Y 独立。两者期望都为 0，且当 $X = -1, Y = 1$ 时必有 $Y > X$，故

$$\mathbb{P}(Y > X) \ge (1-\varepsilon)^2 \longrightarrow 1.$$

于是所求上确界为 1。但没有任何可积且均值相同的联合分布能使 $\mathbb{P}(Y > X) = 1$：否则非负随机变量 $Y - X$ 几乎处处严格正，而其期望必严格大于 0（由 $\{Y - X \ge 1/k\}$ 的可数并覆盖该事件即可证明），与 $\mathbb{E}(Y - X) = 0$ 矛盾。故上确界不能取到。这不仅是某个特定数字的反例：把均值相等误当成标签可交换，实际拒绝概率可以无限接近 1。

习题 5.5. 有 $b \ge 1$ 个独立区组，第 j 组有 r_j 条差值 $D_{j\ell} = a_{j\ell} Z_j$，其中 $a_{j\ell} > 0$ 已知，Z_j 为独立公平符号。以所有差值之和 T 作单侧上尾检验。

1. 已观察全部差值，求精确 p 值，并解释合法的符号翻转单位。

2. 特别地，设 b 为奇数，各组都有 r 条完全相同的记录 $D_{j\ell} = Z_j$。若误将 br 条记录分别独立翻转，得到上尾 p 值 P_r。对固定 $0 < \alpha < 1/2$，求 $r \to \infty$ 时 $\mathbb{P}(P_r \le \alpha)$ 的极限；再比较观察到全部记录为正时的正确和错误 p 值。

解. (1) 令 $c_j = \sum_{\ell=1}^{r_j} a_{j\ell} > 0$，观察到的符号为 $z_j \in \{-1, 1\}$。在零假设下，真正的统计量是 $T = \sum_{j=1}^{b} c_j Z_j$。由于只有 b 个独立公平符号，精确上尾概率为

$$\boxed{P_{\text{block}} = 2^{-b} \#\left\{ \varepsilon \in \{-1,1\}^b : \sum_{j=1}^{b} c_j \varepsilon_j \ge \sum_{j=1}^{b} c_j z_j \right\}.}$$

它是有限等可能零分布的上尾概率，所以对一切 $0 \le u \le 1$，均有 $\mathbb{P}(P_{\text{block}} \le u) \le u$。一个区组内的记录共用同一个 Z_j；只翻动该组的部分记录，将得到零假设下根本不可能出现的观测向量，因而不能用来校准检验。

(2) 记 $J = \#\{j : Z_j = -1\}$，则 $J \sim \mathsf{Bin}(b, 1/2)$，观察统计量为

$$T = r(b - 2J).$$

真正按组翻转的上尾 p 值为

$$P_{\text{block}} = 2^{-b}\sum_{k=0}^{J}\binom{b}{k}.$$

若错误地假设 br 条记录各有独立公平符号，便相当于比较 br 次公平抛掷中的负号数，所得错误上尾 p 值是

$$\boxed{P_r = 2^{-br}\sum_{k=0}^{rJ}\binom{br}{k} = \mathbb{P}\{H_r \le rJ\}, \qquad H_r \sim \mathsf{Bin}(br, 1/2).} \tag{1}$$

这里 H_r 只用于计算分析者臆造的零分布，并不等于真实数据的独立负号数。

固定整数 $j < b/2$。因为 $\mathbb{E}H_r = br/2$、$\mathsf{Var}(H_r) = br/4$，由切比雪夫不等式，

$$\mathbb{P}(H_r \le rj) \le \frac{b}{4r(b/2-j)^2} \longrightarrow 0.$$

类似地，若 $j > b/2$，

$$\mathbb{P}(H_r \le rj) \ge 1 - \frac{b}{4r(j-b/2)^2} \longrightarrow 1.$$

b 为奇数，J 不可能等于 $b/2$。因此对任何固定 $0 < \alpha < 1/2$，在条件 $J = j$ 下，$\mathbf{1}_{\{P_r \le \alpha\}}$ 对 $j < b/2$ 最终等于 1，对 $j > b/2$ 最终等于 0。将有限个 j 的概率相加，利用公平二项分布的对称性，得到

$$\boxed{\lim_{r\to\infty}\mathbb{P}(P_r \le \alpha) = \mathbb{P}\left(J < \frac{b}{2}\right) = \frac{1}{2}.}$$

这是在真实零假设下的拒绝概率，而不是错误独立模型的名义概率。当同一个随机符号被重复记录很多次时，错误分析者会把重复记录误认为不断增加的独立证据，使任意固定的名义显著性水平 $0 < \alpha < 1/2$ 最终出现 $1/2$ 的第一类错误率。

若观察到全部记录为正，则 $J = 0$，真正的上尾 p 值是 2^{-b}，错误独立翻转却给出 2^{-br}；当 $r = 1$ 两者相同，而当 $r > 1$ 后者会随着重复测量次数指数缩小。上述极限并不违背合法 p 值的超均匀性，因为 P_r 对应的独立翻转模型本来就不是数据的真实联合零分布。

习题 5.6. 在 $N = m + n$ 个有编号的位置上，等可能放置 $m \ge 2$ 个 X 标签与 $n \ge 1$ 个 Y 标签。记第一个与最后一个 X 标签的位置分别为 J, K。给定整数 $1 \le r < N$，已知前 r 个位置恰有 a 个 X，其中

$$\max\{1, r-n\} \le a \le \min\{m-1, r\}.$$

求 $K - J$ 在这个条件下的期望和方差。

解. 记 $L = N - r$，$b = m - a$。条件事件使前 r 位含 a 个 X，后 L 位含 b 个 X。每个前段标签排列可与每个后段排列配成完整记录，故给定题设条件后，前后两段相互独立，分别在 $\binom{r}{a}$ 和 $\binom{L}{b}$ 种放法中等可能。由于 $a \ge 1$、$b \ge 1$，第一个 X 必在前段，最后一个 X 必在后段。

先计算一个通用的间隙。把 $k \ge 1$ 个 X 等可能放在 $M \ge k$ 个位置，记最左边 X 前面的 Y 个数为 G。固定 $G \ge t$，等价于前 t 位全是 Y，所以对于整数 $1 \le t \le M - k$，

$$\mathbb{P}(G \ge t) = \frac{\binom{M-t}{k}}{\binom{M}{k}}.$$

利用非负整数变量的尾和公式及组合恒等式 $\sum_{s=k}^{M-1}\binom{s}{k} = \binom{M}{k+1}$，

$$\mathbb{E}G = \sum_{t=1}^{M-k}\mathbb{P}(G \ge t) = \frac{\binom{M}{k+1}}{\binom{M}{k}} = \frac{M-k}{k+1}.$$

为了求方差，对非负整数 g 有 $g(g-1)=2\sum_{t=2}^{g}(t-1)$。由两次组合数求和，

$$\sum_{t=2}^{M-k}(t-1)\binom{M-t}{k}=\sum_{s=1}^{M-k-1}\binom{M-s}{k+1}=\binom{M}{k+2}.$$

因此（当求和范围为空时两边同为零），

$$\mathbb{E}[G(G-1)]=\frac{2\binom{M}{k+2}}{\binom{M}{k}}=\frac{2(M-k)(M-k-1)}{(k+1)(k+2)}.$$

代入 $\mathsf{Var}(G)=\mathbb{E}[G(G-1)]+\mathbb{E}G-(\mathbb{E}G)^2$，整理得

$$\boxed{\mathsf{Var}(G)=\frac{k(M-k)(M+1)}{(k+1)^2(k+2)}.}$$

这些公式在 $M=k$ 时仍成立，此时 $G=0$。

回到原问题，记前段第一个 X 之前的 Y 个数为 G_1，后段最后一个 X 之后的 Y 个数为 G_2。反向排列后，G_2 与上述通用间隙有同样的分布。由前后两段的条件独立性，G_1,G_2 独立，而且

$$J=G_1+1,\qquad K=N-G_2,\qquad K-J=N-1-G_1-G_2.$$

对 G_1 取 $(M,k)=(r,a)$，对 G_2 取 $(M,k)=(L,b)$，得到

$$\boxed{\mathbb{E}(K-J\mid A_r=a)=N-1-\frac{r-a}{a+1}-\frac{L-b}{b+1},}$$

$$\boxed{\mathsf{Var}(K-J\mid A_r=a)=\frac{a(r-a)(r+1)}{(a+1)^2(a+2)}+\frac{b(L-b)(L+1)}{(b+1)^2(b+2)}.}$$

其中 A_r 表示前 r 个位置恰含 a 个 X。令 $L=N-r$、$b=m-a$ 即得到只含题给 m,n,r,a 的答案。

习题 5.7. 在 $N=m+n$ 个有编号的位置上，等可能放置 m 个 X 标签和 n 个 Y 标签，其中 $m,n\geq 2$。一段连续相同的标签称为一个游程，记游程总数为 R。

1. 求 R 的精确分布。

2. 不使用第一问的分布求和，求 $\mathbb{E}R$ 和 $\mathsf{Var}(R)$。

解. 记 $N=m+n$。由题设的等可能分组规则，每一种含 m 个 X、n 个 Y 的完整标签序列的概率都是 $\binom{N}{m}^{-1}$。下面直接计数这些有编号位置上的标签序列。

先数游程。把正整数 s 写成 r 个正整数之和的方案数为 $\binom{s-1}{r-1}$：在连续排列的 s 个单位之间的 $s-1$ 处空隙选 $r-1$ 处分隔即可。

当 $R=2r$ 时，两端标签必不同，X 和 Y 各有 r 个游程。起始标签有两种选择；给定起始标签后，各个同类游程的长度分别是一组正整数分拆。因此

$$\boxed{\mathbb{P}(R=2r)=\frac{2\binom{m-1}{r-1}\binom{n-1}{r-1}}{\binom{N}{m}}.}$$

当 $R=2r+1$ 时，两端标签相同。若两端均为 X，则 X 有 $r+1$ 个游程，Y 有 r 个；反之交换两组。故

$$\boxed{\mathbb{P}(R=2r+1)=\frac{\binom{m-1}{r}\binom{n-1}{r-1}+\binom{m-1}{r-1}\binom{n-1}{r}}{\binom{N}{m}}.}$$

这里 $r \ge 1$，超出 $0 \le b \le a$ 的组合数 $\binom{a}{b}$ 约定为零；由于两组都非空，$R = 1$ 不可能。每一种标签序列都有唯一游程分解，以上计数既无重复又无遗漏，故给出完整分布。

再直接计算矩。对 $1 \le i < N$，令 I_i 表示排序后的第 i、$i+1$ 个标签不同，则

$$R = 1 + S, \qquad S = \sum_{i=1}^{N-1} I_i.$$

对任意相邻两个位置，依次抽到 XY 或 YX 的概率相加，得

$$p := \mathbb{E} I_i = \frac{2mn}{N(N-1)}, \qquad \boxed{\mathbb{E}R = 1 + \frac{2mn}{N}}.$$

求二阶矩时，必须区分两条边是否共用一个位置。若 $j = i+1$，两个边界同时变号只能出现 XYX 或 YXY，所以

$$\mathbb{E}(I_i I_{i+1}) = \frac{m(m-1)n + mn(n-1)}{N(N-1)(N-2)} = \frac{mn}{N(N-1)} = \frac{p}{2}.$$

若两条边没有公共位置，要让每一条边两端不同，四个指定位置必须各有两个 X、两个 Y，且每条边内一正一反；四种定向均可，因而

$$\mathbb{E}(I_i I_j) = \frac{4m(m-1)n(n-1)}{N(N-1)(N-2)(N-3)} \qquad (|i-j| \ge 2).$$

$N-1$ 条边中，相邻边对有 $N-2$ 对，不相邻边对有 $(N-2)(N-3)/2$ 对。展开 $S(S-1)$ 并把无序边对计两次，得到

$$\mathbb{E}[S(S-1)] = (N-2)p + \frac{4m(m-1)n(n-1)}{N(N-1)}.$$

由 $\mathbb{E}S = (N-1)p = 2mn/N$ 及恒等式 $\mathsf{Var}(S) = \mathbb{E}[S(S-1)] + \mathbb{E}S - (\mathbb{E}S)^2$，整理得

$$\boxed{\mathsf{Var}(R) = \mathsf{Var}(S) = \frac{2mn(2mn-m-n)}{(m+n)^2(m+n-1)}}.$$

这两个矩来自相邻标签的局部关系，不必对第一问的组合数分布求和。第二问也说明：虽然每条边变号的概率相同，相邻边的指示量却不独立。

习题 5.8. 在 $N = m+n$ 个有编号的位置上，等可能放置 m 个 X 标签和 n 个 Y 标签，其中 $m, n \ge 1$。记 L 为最长连续 X 标签段的长度。观察到 $L = \ell$，求以 L 为统计量的精确单侧上尾 p 值和最小可达 p 值，并证明该检验有效。

解. 按照题设的均匀标签分组规则，所有含 m 个 X 与 n 个 Y 的标签序列等可能，每种概率为 $\binom{m+n}{m}^{-1}$。每次重新分配标签后都须重新寻找最长的连续 X 段。

把 n 个 Y 标签看成隔板。记第一个 Y 前、相邻两个 Y 之间、最后一个 Y 后的 X 个数依次为

$$g_0, g_1, \dots, g_n \ge 0, \qquad g_0 + \cdots + g_n = m.$$

每个标签序列唯一对应一个这样的非负整数组合，反之也可由组合唯一还原标签序列。故这 $\binom{m+n}{n}$ 个组合全部等可能，且

$$L = \max_{0 \le i \le n} g_i.$$

这说明选取最长的那段不是选择一个事先指定的位置，而是从 $n+1$ 个可能的间隔中取最大值。

固定 $1 \le h \le m$。对某 j 个指定的间隔同时要求 $g_i \ge h$，从这些间隔各减去 h，便得到总和为 $m - jh$ 的 $n+1$ 个非负整数。当 $jh \le m$ 时，这样的组合恰有

$$\binom{m - jh + n}{n}$$

个；当 $jh > m$ 时一个也没有。对 $n+1$ 个事件 $\{g_i \ge h\}$ 用容斥原理（约定 $\binom{n+1}{j} = 0$ 当 $j > n+1$），得到

$$\boxed{T(h) := \mathbb{P}(L \ge h) = \frac{1}{\binom{m+n}{m}} \sum_{j=1}^{\lfloor m/h \rfloor} (-1)^{j+1} \binom{n+1}{j} \binom{m+n-jh}{n}.}$$

故观察到 $L = \ell$ 时，精确单侧置换 p 值就是 $\boxed{P = T(\ell)}$。这个表达式已把事后选取最长区段的所有可能位置及其重叠计算在内。

再证合法性。$T(h)$ 随整数 h 单调不增。对任意 $0 \le u < 1$，若不存在可能的 h 满足 $T(h) \le u$，则 $\mathbb{P}(P \le u) = 0$；否则取满足条件的最小可能值 h_u。因 L 为整数且 T 单调，

$$\mathbb{P}(P \le u) = \mathbb{P}(L \ge h_u) = T(h_u) \le u.$$

$u = 1$ 时也成立，因此 P 对每个显著性阈值都有效，并未把所选中的那段错误地视为预先固定。

最后，$L \le m$ 恒成立，而 $L = m$ 当且仅当所有 m 个 X 排成一个连续区段。这个区段可以放在 n 个 Y 的前面、最后面或相邻 Y 之间，恰有 $n+1$ 种标签序列。因此

$$\boxed{P_{\min} = T(m) = \frac{n+1}{\binom{m+n}{m}}.}$$

这确实能取到，并且由于 $T(h) \ge T(m)$，它就是最小可达值。当 $m = 1$ 时上式给出 $P \equiv 1$，仍然正确。作为对照，在某个事先指定的长度为 m 的位置区间内全部出现 X 的概率仅为 $\binom{m+n}{m}^{-1}$；若看过数据才选到该区间却沿用这个概率，就会把实际的最小尾概率低估 $n+1$ 倍。

第六章　单样本与双样本

习题完整解答

习题 6.1.　两批相互独立的样本各有 $n \geq 2$ 个观测，均来自 $N(\mu, \sigma^2)$，$\sigma > 0$ 未知。比较两批样本标准差后，选择标准差较小（或较大）的一批，仅用其 $T = \sqrt{n}(\bar{X}_J - \mu_0)/S_J$，按 t_{n-1} 的双侧临界值检验 $H_0 : \mu = \mu_0$。证明选较小标准差时真实第一类错误概率严格大于 α，选较大时严格小于 α，其中 $0 < \alpha < 1$。

解.　在 H_0 下记 $\nu = n - 1$，

$$Z_j = \frac{\sqrt{n}(\bar{X}_j - \mu_0)}{\sigma}, \quad U_j = \frac{\nu S_j^2}{\sigma^2} \qquad (j = 1, 2).$$

由两批相互独立和正态样本分解，Z_1, Z_2 为独立标准正态，U_1, U_2 为独立 χ^2_ν，而整个 Z 向量与整个 U 向量独立。记 $c = t_{\nu, 1-\alpha/2} > 0$。选择规则 J 只由 (U_1, U_2) 决定，所以条件于此二元向量，Z_J 仍为标准正态。被选中样本的条件拒绝概率为

$$h(U_J), \qquad h(u) = 2\Phi\Big(-c\sqrt{u/\nu}\Big), \quad u > 0.$$

h 严格递减。令 $U_- = \min(U_1, U_2)$、$U_+ = \max(U_1, U_2)$。对预先固定的第一批，$\mathbb{E}h(U_1) = \alpha$。但 $U_- \leq U_1 \leq U_+$，两个严格不等式均以正概率成立，因为独立卡方变量非退化且分布连续。因此

$$\mathbb{P}_{H_0}(|T_{\text{small}}| > c) = \mathbb{E}h(U_-) > \alpha > \mathbb{E}h(U_+) = \mathbb{P}_{H_0}(|T_{\text{large}}| > c).$$

这说明分别看每批时均为合法的 t 统计量，不代表看数据挑选后仍保持同一零分布。

习题 6.2.　给定 $a_1 < \cdots < a_n$ 与 $b_1 < \cdots < b_n$（$n \geq 2$），可任意把 a_i 和 $b_{\pi(i)}$ 配成 n 对。记差值的无偏样本方差为 S_π^2。求 S_π^2 的最小、最大值及全部取等配对，并证明差值均值与配对无关。

解.　无论排列 π 如何，差值均值都等于 $\bar{a} - \bar{b}$。置 $u_i = a_i - \bar{a}$、$v_i = b_i - \bar{b}$，则

$$(n-1)S_\pi^2 = \sum_i u_i^2 + \sum_i v_i^2 - 2\sum_i u_i v_{\pi(i)}.$$

前两项不随 π 改变，故最小方差对应内积 $C_\pi = \sum_i a_i b_{\pi(i)}$ 最大。若 $i < j$ 而 $\pi(i) > \pi(j)$，交换相应两个 b 后内积增加

$$(a_j - a_i)(b_{\pi(i)} - b_{\pi(j)}) > 0.$$

不断交换逆序对最终到达恒等排列，而任何非恒等排列都存在逆序对，所以唯一最大内积对应 $\pi(i) = i$。把 b 由小到大的顺序反转，同理唯一最小内积对应 $\pi(i) = n + 1 - i$。因此

$$\boxed{\min_\pi S_\pi^2 = \frac{1}{n-1}\sum_{i=1}^{n}[(a_i - b_i) - (\bar{a} - \bar{b})]^2},$$

$$\boxed{\max_\pi S_\pi^2 = \frac{1}{n-1}\sum_{i=1}^{n}[(a_i - b_{n+1-i}) - (\bar{a} - \bar{b})]^2}.$$

两列数均严格递增，故等号配对各自唯一。

习题 6.3. 独立正态样本分别有 $m,n\ge 2$ 个，方差为 $\sigma_1^2,\sigma_2^2>0$，不预设相等。令

$$S_p^2=\frac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2},\qquad V=S_p^2\left(\frac{1}{m}+\frac{1}{n}\right).$$

1. 求 $\mathbb{E}V-\mathrm{Var}(\bar X-\bar Y)$，给出 V 无偏估计后者的充要条件。

2. 若 $m=n=r$ 而 $\sigma_1^2\neq\sigma_2^2$，证明把合并方差按真实均值差方差归一化后，不服从 χ^2_{2r-2}。

解. 令 $a=\sigma_1^2>0$、$b=\sigma_2^2>0$，并记 $N=m+n$。

(1) 由独立性和两组样本方差的无偏性，

$$\mathrm{Var}(\bar X-\bar Y)=\frac{a}{m}+\frac{b}{n},\qquad \mathbb{E}V=\frac{N}{mn(N-2)}\big[(m-1)a+(n-1)b\big].$$

通分以后分别收集 a,b 的系数，得到

$$\begin{aligned}\mathbb{E}V-\mathrm{Var}(\bar X-\bar Y)&=\frac{N[(m-1)a+(n-1)b]-(N-2)(na+mb)}{mn(N-2)}\\&=\boxed{\frac{(m-n)(m+n-1)(a-b)}{mn(m+n-2)}}.\end{aligned}$$

分母严格为正，$m+n-1>0$，所以 V 无偏的充要条件是 $\boxed{m=n\text{ 或 }\sigma_1^2=\sigma_2^2}$。

(2) 当 $m=n=r$ 时，第一部分说明 V 虽然无偏，但需要检验它的完整分布。设

$$U=\frac{(r-1)S_X^2}{a},\qquad H=\frac{(r-1)S_Y^2}{b}.$$

由正态样本分解与组间独立性，U,H 独立且都服从 χ^2_{r-1}。用真实的方差 $\mathrm{Var}(\bar X-\bar Y)=(a+b)/r$ 作尺度，得到

$$W=\frac{(2r-2)V}{(a+b)/r}=\frac{2(aU+bH)}{a+b}.$$

它的期望确实是 $2r-2$，但方差为

$$\mathrm{Var}\,W=\frac{4}{(a+b)^2}\left(a^2\cdot 2(r-1)+b^2\cdot 2(r-1)\right)=\frac{8(r-1)(a^2+b^2)}{(a+b)^2}.$$

如果 $W\sim\chi^2_{2r-2}$，按照卡方分布的方差公式，上式应等于 $4(r-1)$。这等价于 $2(a^2+b^2)=(a+b)^2$，即 $(a-b)^2=0$，与 $a\neq b$ 矛盾。因而即使 $m=n$ 保证了方差估计无偏，也不能得到共同方差模型里的精确 t 分布。

习题 6.4. 两组试验各独立进行 $n\ge 2$ 次，成功概率分别为 $0<q<p<1$。记两组的成功次数为 K,L，令

$$R=\frac{p(1-q)}{q(1-p)}.$$

1. 对每个整数 $1\le d\le n$，证明

$$\mathbb{P}(K-L=d)=R^d\,\mathbb{P}(K-L=-d).$$

2. 已知两组的成功次数不相等，证明

$$\frac{R}{1+R}<\mathbb{P}(K>L\mid K\neq L)<\frac{R^n}{1+R^n}.$$

解. 由 $0<q<p<1$，有 $R>1$。对 $0\le \ell \le n-d$，两组成功次数分别为 $\ell+d$ 和 ℓ 时的概率为

$$a_{\ell,d}=\binom{n}{\ell+d}\binom{n}{\ell}p^{\ell+d}(1-p)^{n-\ell-d}q^{\ell}(1-q)^{n-\ell}.$$

若交换两组的成功次数，即取 $K=\ell, L=\ell+d$，其概率为

$$b_{\ell,d}=\binom{n}{\ell}\binom{n}{\ell+d}p^{\ell}(1-p)^{n-\ell}q^{\ell+d}(1-q)^{n-\ell-d}.$$

比较这两个概率，组合数恰好相同，而

$$\frac{a_{\ell,d}}{b_{\ell,d}}=\left(\frac{p(1-q)}{q(1-p)}\right)^{d}=R^{d}.$$

在所有满足 $K-L=d$ 的数对上求和，右边交换 K,L 后恰遍历 $K-L=-d$ 的所有数对。因此

$$\boxed{\mathbb{P}(K-L=d)=R^{d}\mathbb{P}(K-L=-d)}\qquad (1\le d\le n).$$

现在记 $c_d=\mathbb{P}(K-L=-d)$。由于 $0<p,q<1$，对于 $1\le d\le n$，事件 $K=0,L=d$ 的概率严格为正，故 $c_d>0$。由第一问，

$$\frac{\mathbb{P}(K>L)}{\mathbb{P}(K<L)}=\frac{\sum_{d=1}^{n}R^{d}c_d}{\sum_{d=1}^{n}c_d}.$$

这个比值是 $R,R^2,\dots,R^n$ 以正权重 c_d 所作的加权平均。因为 $n\ge 2$ 且 $R>1$，所有权重均为正，且 R 与 R^n 是两个不同的端点值，都以正权重出现，于是严格有

$$R<\frac{\mathbb{P}(K>L)}{\mathbb{P}(K<L)}<R^{n}.$$

把中间的比值记为 $u>0$。在 $K\neq L$ 的条件下，

$$\mathbb{P}(K>L\mid K\neq L)=\frac{\mathbb{P}(K>L)}{\mathbb{P}(K>L)+\mathbb{P}(K<L)}=\frac{u}{1+u}.$$

由于 $u/(1+u)$ 严格递增，得到

$$\boxed{\frac{R}{1+R}<\mathbb{P}(K>L\mid K\neq L)<\frac{R^{n}}{1+R^{n}}}.$$

严格性依赖于 $n\ge 2$ 和 $0<q<p<1$；若只有一轮试验 $n=1$，两端相同，条件获胜概率恰为 $R/(1+R)$。

习题 6.5. $X\sim N(\mu,1)$、$Y\sim N(\mu,4)$ 相互独立，$\mu\in\mathbb{R}$ 未知。仪器只保留无标签集合 $\{X,Y\}$。

1. 在所有平方可积、全参数无偏且满足 $T(\{x+t,y+t\})=T(\{x,y\})+t$ 的无标签估计量中，求最小方差及全部取等估计量。

2. 若保留通道标签，求最小方差线性无偏估计量并比较。

解. (1) 对任何无标签的平移等变统计量，设 $z=(x+y)/2$、$r=|x-y|$。将两数同时减去 z，所剩无标签集合仅由 r 确定，因此一定存在函数 g，使

$$T(\{x,y\})=\frac{x+y}{2}+g(|x-y|).$$

记 $Z=(X+Y)/2$、$R=|X-Y|$。R 的分布与 μ 无关，而 $\mathbb{E}Z=\mu$，故全参数无偏当且仅当 $\mathbb{E}g(R)=0$。中心化的 $(X-\mu,Y-\mu)$ 与其同时取负的向量同分布。在此变换下 $Z-\mu$ 变号、R 不变，因此平方可积保证乘积可积，且 $\mathbb{E}[(Z-\mu)g(R)]=0$。于是

$$\mathsf{Var}(T)=\mathsf{Var}(Z)+\mathbb{E}[g(R)^2]=\frac{5}{4}+\mathbb{E}[g(R)^2]\geq\frac{5}{4}.$$

等号当且仅当 $g(R)=0$ 几乎必然。故按每个 μ 下几乎处处相等来判断，唯一最优估计量为 $T_*=(X+Y)/2$，方差 $5/4$。

(2) 保留标签后，所有线性无偏估计量为 $wX+(1-w)Y$，其方差

$$w^2+4(1-w)^2=5\left(w-\frac{4}{5}\right)^2+\frac{4}{5}.$$

唯一最优选择是 $(4X+Y)/5$，最小方差为 $4/5<5/4$。

习题 6.6. 设 $n\geq 2$，$X_1,\dots,X_n$ 独立同分布，$\bar X=n^{-1}\sum_i X_i$、$S^2=(n-1)^{-1}\sum_i(X_i-\bar X)^2$。对任意有限 $c>0$，证明

$$\sup_{\substack{F\text{ 具有连续密度}\\ \mathbb{E}_F X=0,\ \mathsf{Var}_F X=1}}\mathbb{P}_F\left(\left|\frac{\sqrt{n}\,\bar X}{S}\right|>c\right)=1.$$

在上述分布类中，$S>0$ 几乎必然。

解. 先想象一种总体：它绝大部分时间给出几乎相同的正数，极少数时候给出一个很大的负数，使总体均值恰好为 0。如果一个样本恰好全部来自第一类结果，那么样本均值为正且样本标准差非常小，t 统计量就会非常大。下面用连续密度严格实现这一想法。

取 $0<\varepsilon<1/2$、$0<\delta<1$，令

$$h_\delta(u)=\frac{(\delta-|u|)_+}{\delta^2},\qquad f(z)=(1-\varepsilon)h_\delta(z-1)+\varepsilon h_\delta\left(z+\frac{1-\varepsilon}{\varepsilon}\right).$$

h_δ 是以 0 为中心、支撑于 $[-\delta,\delta]$ 的对称三角形连续密度（底为 2δ、高为 $1/\delta$，面积为 1）。因此 f 也是连续密度。若 Z 服从 f，则

$$\mathbb{E}Z=(1-\varepsilon)\cdot 1+\varepsilon\left(-\frac{1-\varepsilon}{\varepsilon}\right)=0.$$

其方差 $v=\mathsf{Var}\,Z$ 有限且大于 0。令 $X=Z/\sqrt{v}$，得到具有连续密度、均值 0、方差 1 的总体。因为正倍数缩放不改变 $\sqrt{n}\,\bar X/S_X$，以下直接在 Z 的尺度上估算。

n 个观测独立抽取。设 E 为它们全部来自中心位于 1 的三角形密度的事件，$\mathbb{P}(E)=(1-\varepsilon)^n$。在 E 上，每个 $Z_i\in[1-\delta,1+\delta]$，因而 $\bar Z\geq 1-\delta$。又由于 $\bar Z$ 是使离差平方和最小的常数，

$$(n-1)S_Z^2=\sum_i(Z_i-\bar Z)^2\leq\sum_i(Z_i-1)^2\leq n\delta^2.$$

在 $S_Z>0$ 时便有

$$\frac{\sqrt{n}\,\bar Z}{S_Z}\geq\frac{\sqrt{n-1}(1-\delta)}{\delta}.$$

给定任意 $c>0$，先将 δ 取到足够小，使右端大于 c；再让 ε 足够小，使 $(1-\varepsilon)^n>1-\eta$，其中 $\eta>0$ 可任意指定。于是

$$\mathbb{P}\left(\left|\frac{\sqrt{n}\,\bar X}{S_X}\right|>c\right)>1-\eta.$$

由于概率不超过 1，令 $\eta\downarrow 0$ 即得题中的上确界为 1。

最后，连续密度与观测独立性保证 $\mathbb{P}(X_1=X_2)=0$，而 $S_X=0$ 必须有 $X_1=X_2$，故 $S_X>0$ 几乎必然。证明中所有除以 S 的式子因而合法。

习题 6.7. 每招募一名受试者花费 $c>0$，每次测量再花费 1。每人测量 $k\ge 1$ 次，总经费为 B，人数为 $m_B=\lfloor B/(c+k)\rfloor$。第 j 人第 ℓ 次观测为 $Y_{j\ell}=\mu+U_j+\varepsilon_{j\ell}$，其中各 U_j 独立、均值 0、方差 $\tau^2>0$；各 $\varepsilon_{j\ell}$ 彼此独立、均值 0、方差 $\sigma^2>0$，并与全部 U_j 独立。以所有读数的平均估计 μ。

1. 固定整数 k，求 $\lim_{B\to\infty} B\,\mathrm{Var}(\hat\mu_{B,k})$。
2. 求使该极限最小的全部正整数 k，包括并列最优情形。

解. (1) 第 j 人的均值 $\bar Y_j=k^{-1}\sum_{\ell=1}^{k}Y_{j\ell}$ 满足 $\mathbb{E}\bar Y_j=\mu$、$\mathrm{Var}(\bar Y_j)=\tau^2+\sigma^2/k$。不同受试者独立。总均值是 m_B 个 $\bar Y_j$ 的平均，故

$$\mathrm{Var}(\hat\mu_{B,k})=\frac{\tau^2+\sigma^2/k}{\lfloor B/(c+k)\rfloor}$$

（当 B 足够大使 $m_B\ge 1$ 时）。固定 k，$m_B/B\to 1/(c+k)$，因此

$$F(k):=\lim_{B\to\infty}B\,\mathrm{Var}(\hat\mu_{B,k})=(c+k)\left(\tau^2+\frac{\sigma^2}{k}\right).$$

(2) 分离常数并比较相邻项：

$$F(k)=c\tau^2+\sigma^2+\tau^2k+\frac{c\sigma^2}{k},\quad F(k+1)-F(k)=\tau^2-\frac{c\sigma^2}{k(k+1)}.$$

置 $R=c\sigma^2/\tau^2>0$。相邻差严格递增，且 $F(k)\to\infty$。一个正整数 k 为最优解当且仅当

$$k(k-1)\le R\le k(k+1).$$

若 $R=j(j+1)$（j 为正整数），恰有 $j,j+1$ 两个最优整数；其他 R 下最优整数唯一。这个条件也包括 $0<R<2$ 时 $k=1$ 唯一最优的边界情况。

习题 6.8. 两组实数 $X_1,\dots,X_m$、$Y_1,\dots,Y_n$，$m,n\ge 2$。把它们看成 $N=m+n$ 个点：第一组横坐标为 $x=0$、纵坐标为 X_i，第二组为 $x=1$、纵坐标为 Y_j。对拟合直线 $z=a+bx$，一个点的纵坐标减去它在直线上的拟合值称为该点的残差。

1. 直接极小化所有残差的平方和 $\sum(z-a-bx)^2$，求最小二乘 $\hat a,\hat b$ 和最小残差平方和 W。
2. 若两组独立服从 $N(\mu_1,\sigma^2)$、$N(\mu_2,\sigma^2)$，证明以残差方差 $\hat s^2=W/(N-2)$、$S_{xx}=\sum(x-\bar x)^2$ 定义的斜率统计量 $\hat b/(\hat s/\sqrt{S_{xx}})$，与独立两样本合并 t 统计量只差符号。

解. (1) 把横坐标为 0 与 1 的点分别求和，待极小化的平方和为

$$Q(a,b)=\sum_{i=1}^{m}(X_i-a)^2+\sum_{j=1}^{n}(Y_j-a-b)^2.$$

对每组使用恒等式 $\sum_i(u_i-c)^2=\sum_i(u_i-\bar u)^2+r(c-\bar u)^2$（$r$ 为这一组的个数），得到

$$\begin{aligned}Q(a,b)=&\sum_i(X_i-\bar X)^2+\sum_j(Y_j-\bar Y)^2\\&+m(a-\bar X)^2+n(a+b-\bar Y)^2.\end{aligned}$$

最后两项非负，并且同时为零恰当 $a=\bar X$、$a+b=\bar Y$。因此唯一的最小二乘直线满足

$$\boxed{\hat a=\bar X,\qquad \hat b=\bar Y-\bar X},$$

而最小残差平方和为 $\boxed{W=\sum_i (X_i-\bar X)^2+\sum_j (Y_j-\bar Y)^2}$。

(2) 横坐标共有 m 个 0、n 个 1，所以

$$\bar x=\frac{n}{m+n},\qquad S_{xx}=m\left(\frac{n}{m+n}\right)^2+n\left(\frac{m}{m+n}\right)^2=\frac{mn}{m+n}.$$

由第一问，$\hat s^2=W/(m+n-2)$，而第六章定义的合并方差也恰为 $S_p^2=W/(m+n-2)$。因此

$$\frac{\hat b}{\hat s/\sqrt{S_{xx}}}=\frac{\bar Y-\bar X}{S_p\sqrt{1/m+1/n}}=\boxed{-T_p}.$$

在题设的正态模型中，$S_p>0$ 几乎必然，所以这两个统计量都有定义，并且在每一份分母非零的数据上恒相差一个负号。对检验 $H_0:\mu_1=\mu_2$ 而言，由独立正态样本的合并方差定理，$T_p\sim t_{m+n-2}$；两个统计量取绝对值后完全相同，因此具有相同的双侧拒绝域与准确的零假设拒绝概率。这里的中心 t 分布结论只在零假设下适用于未中心化的 T_p。

一般 $\mu_1\neq\mu_2$ 时，具有中心 t 分布的是

$$\frac{(\bar X-\bar Y)-(\mu_1-\mu_2)}{S_p\sqrt{1/m+1/n}},$$

而不是 T_p 本身。事实上，因为分母严格为正，

$$\mathbb{P}(T_p>0)=\mathbb{P}(\bar X-\bar Y>0)=\Phi\left(\frac{\mu_1-\mu_2}{\sigma\sqrt{1/m+1/n}}\right),$$

当两组总体均值不同时，这个概率不等于 $1/2$，所以 T_p 不可能具有关于零对称的中心 t 分布。两统计量相差负号则对所有参数值都成立；负号来自把第一组编码为 0、第二组编码为 1 时斜率取 $\bar Y-\bar X$，而 T_p 的分子取 $\bar X-\bar Y$。

第七章　一元线性回归

习题完整解答

习题 7.1.　横坐标固定为 $0,1,3$。设 $g:\mathbb{R}\to\mathbb{R}$ 连续。要求对任意实数 y_1,y_2,y_3，把三个响应同时替换为 $g(y_1),g(y_2),g(y_3)$ 后，带截距的最小二乘斜率为零，当且仅当原斜率为零。求全部这样的 g。

解.　原斜率为 $(-4y_1-y_2+5y_3)/14$。取 $y_1=u, y_2=v, y_3=(4u+v)/5$，题设要求

$$5g\left(\frac{4u+v}{5}\right)=4g(u)+g(v)\qquad(u,v\in\mathbb{R}).$$

令 $h(x)=g(x)-g(0)$。它也满足此式且 $h(0)=0$。先取 $u=0$，得到 $h(v/5)=h(v)/5$，故上式又给出

$$h(4u+v)=4h(u)+h(v).$$

再取 $v=0$，有 $h(4u)=4h(u)$。令 $A=4u$，可得

$$h(A+v)=h(A)+h(v)\qquad(A,v\in\mathbb{R}).$$

由加法性，$h(q)=qh(1)$ 对所有有理数 q 成立；用有理数列趋近任意实数并利用连续性，得到 $h(x)=cx$。所以 $g(x)=d+cx$。

若 $c=0$，变换后的斜率总为零，与题设的反向蕴含矛盾。若 $c\neq0$，变换后的斜率等于原斜率的 c 倍，确实满足等价关系。因此

$$\boxed{g(x)=d+cx,\qquad d\in\mathbb{R},\ c\neq0.}$$

习题 7.2.　给定 $n\geq3$ 个互异的实数 $x_1,\dots,x_n$. 观测

$$Y_i=a+bx_i+cx_i^2+\varepsilon_i,$$

其中 $a,b,c\in\mathbb{R}$ 均未知; 误差均值为 0, 方差均为已知的 $\sigma^2>0$, 且两两不相关.

1. 在所有权重仅依赖设计点的线性估计量 $T=\sum_i w_iY_i$ 中, 求对全部 (a,b,c) 都无偏估计 b 且方差最小的唯一估计量.
2. 若忽略二次项, 直接使用带截距的普通最小二乘斜率 $\widehat{b}$, 求它对每个 (a,b,c) 仍无偏的充要条件; 满足该条件时, 比较两种估计的方差.

解.　记

$$\bar{x}=\frac{1}{n}\sum_i x_i,\quad \overline{x^2}=\frac{1}{n}\sum_i x_i^2,\quad s_i=x_i-\bar{x},\quad q_i=x_i^2-\overline{x^2},$$

并置 $U=\sum_i s_i^2$, $V=\sum_i q_i^2$, $C=\sum_i s_iq_i$. 由于至少有三个互异的设计点, $U>0$ 且 $V>0$. 定义

$$r_i=s_i-\frac{C}{V}q_i,\qquad D=\sum_i r_i^2=U-\frac{C^2}{V}.$$

D 严格为正. 否则全部 $r_i=0$, 即 $x_i-\bar{x}=(C/V)(x_i^2-\overline{x^2})$ 对每个 i 成立. 于是同一个次数至多为 2、而一次项系数为 -1 的非零多项式在至少三个互异实数处为零, 矛盾.

(1) 由

$$\mathbb{E}T = a\sum_i w_i + b\sum_i w_i x_i + c\sum_i w_i x_i^2,$$

对全部三个参数无偏的充要条件是

$$\sum_i w_i = 0, \quad \sum_i w_i x_i = 1, \quad \sum_i w_i x_i^2 = 0. \tag{1}$$

由前两式与第三式可得 $\sum_i w_i s_i = 1$, $\sum_i w_i q_i = 0$, 从而 $\sum_i w_i r_i = 1$. Cauchy 不等式给出

$$1 \le \left(\sum_i w_i^2\right)\left(\sum_i r_i^2\right) = D\sum_i w_i^2.$$

误差两两不相关, 故 $\mathrm{Var}(T) = \sigma^2\sum_i w_i^2 \ge \sigma^2/D$. 取 $w_i^* = r_i/D$. 因为 $\sum_i r_i = 0$, $\sum_i r_i q_i = 0$, 而 $\sum_i r_i s_i = \sum_i r_i^2 = D$, 所以这些权重满足 (1), 并使上式取等. 由于 $D > 0$, Cauchy 等号条件还迫使一切最优权重与 r 成比例; (1) 唯一确定比例系数. 因此

$$\boxed{T^* = \frac{\sum_i r_i Y_i}{D}, \qquad \mathrm{Var}(T^*) = \frac{\sigma^2}{D}, \qquad r_i = x_i - \bar{x} - \frac{C}{V}(x_i^2 - \overline{x^2}).}$$

(2) 普通最小二乘斜率为 $\widehat{b} = \sum_i s_i Y_i/U$, 所以

$$\mathbb{E}\widehat{b} = b + c\frac{C}{U}.$$

它对全部 (a, b, c) 无偏当且仅当 $C = 0$, 即

$$\boxed{\sum_i (x_i - \bar{x})(x_i^2 - \overline{x^2}) = 0.}$$

此时 $r_i = s_i$、$D = U$, 故 $T^* = \widehat{b}$, 两者方差均为 σ^2/U. 若 $C \ne 0$, 则普通最小二乘斜率不再对所有 c 无偏; 本题的新估计则通过消去未知二次趋势的影响保持无偏.

习题 7.3. 固定 $n \ge 4$ 个两两不同的 x_i。一组响应的原始记录已丢失, 只保存了 $\bar{Y}$、$V = S_{yy}$ 和 $R = \mathrm{SSE}$，这些量确实来自某组数据。

1. 求全部可能的拟合斜率。
2. 若又找回第 k 个响应 $Y_k = z$，求全部仍与记录相容的拟合直线，并给出直线能被唯一恢复的充要条件。

解. 记 $t_i = x_i - \bar{x}$、$S = S_{xx} > 0$。由第一节的恒等式 $R = V - S_{xy}^2/S$，任何相容数据的斜率 β 必满足

$$\beta^2 = \frac{V - R}{S}.$$

所以候选斜率集合为

$$\mathcal{B} = \left\{-\sqrt{\frac{V-R}{S}},\ \sqrt{\frac{V-R}{S}}\right\}.$$

这里已知保存的数据确实可能来自某组响应，因此 $V \ge R \ge 0$。若 $V > R$，把一组相容数据的每个响应 Y_i 换为 $2\bar{Y} - Y_i$，三个保存的量不变而斜率变号。因此这两个斜率都可能；若 $V = R$，候选集合只有 0。

进一步知道 $Y_k = z$ 后，令

$$h = \frac{1}{n} + \frac{t_k^2}{S}, \qquad d = z - \bar{Y}.$$

因所有 x_i 两两不同且 $n \geq 4$，删去第 k 点后仍有至少两个不同横坐标，故 $0 < h < 1$。现在给定一个候选斜率 $\beta \in \mathcal{B}$，问是否存在一组残差 $e_1, \ldots, e_n$，使

$$Y_i = \bar{Y} + \beta t_i + e_i, \quad \sum_i e_i = \sum_i t_i e_i = 0, \quad \sum_i e_i^2 = R, \quad e_k = d - \beta t_k. \tag{1}$$

先求这些约束下单个残差的可能范围。将只在第 k 个位置等于 1 的向量，分别减去它在常数向量和 $t = (t_i)$ 方向上的投影，得到

$$q_i = \mathbf{1}_{\{i=k\}} - \frac{1}{n} - \frac{t_k t_i}{S}.$$

直接求和可得

$$\sum_i q_i = \sum_i t_i q_i = 0, \quad q_k = \sum_i q_i^2 = 1 - h, \quad e_k = \sum_i e_i q_i.$$

所以 Cauchy 不等式给出 $e_k^2 \leq R(1-h)$。代入式 (1) 最后的等式，得到必要条件

$$\boxed{|d - \beta t_k| \leq \sqrt{(1-h)R}}. \tag{2}$$

这个条件也充分。给定满足式 (2) 的 β，置 $r = d - \beta t_k$。由于 $n \geq 4$，常数向量、t 和 q 互相正交且都非零，可取与这三个向量都正交的单位向量 v。令

$$e_i = \frac{r}{1-h} q_i + \sqrt{R - \frac{r^2}{1-h}}\, v_i.$$

根号内非负；两部分互相正交，故得到的残差向量满足式 (1) 中的两条正交约束，且平方和为 R。又因为 v 与 $\mathbf{1}_{\{i=k\}} = q + n^{-1}\mathbf{1} + (t_k/S)t$ 正交，所以 $v_k = 0$，于是 $e_k = r$，与保存的 $Y_k = z$ 一致。定义 $Y_i = \bar{Y} + \beta t_i + e_i$，其均值为 $\bar{Y}$，$S_{yy} = \beta^2 S + R = V$，拟合斜率为 β，完成构造。即使 $R = 0$，此构造仍成立。

因此**全部可能的拟合直线**恰为

$$\boxed{y = \bar{Y} + \beta(x - \bar{x}), \quad \beta \in \mathcal{B}, \quad |d - \beta t_k| \leq \sqrt{(1-h)R}.}$$

它能被唯一恢复，当且仅当 $\mathcal{B}$ 中恰有一个不同的实数满足最后的不等式。

习题 7.4. 在 $x = (-3, -1, 1, 3)$ 处观测 $Y_i = a + bx_i + \varepsilon_i$。误差均值为 0 且两两不相关，四个方差恰为 $1, 1, r, r$，其中 $r \geq 1$ 已知。估计量取 $T = \sum_i w_i Y_i$，权重须在观测前确定，并对每个 a, b 都无偏估计 b。

1. 若已知两个方差 r 对应于 $x = \pm 3$，求方差最小的权重。

2. 若不知道四个方差与观测的对应关系，求使六种安排中最大方差最小的权重及该最小值。

解. 无偏条件为

$$\sum_{i=1}^4 w_i = 0, \qquad \sum_{i=1}^4 x_i w_i = 1.$$

把权重 (w_1,w_2,w_3,w_4) 变为 $(-w_4,-w_3,-w_2,-w_1)$，两条约束仍成立；题设第一问的方差和第二问的最坏方差均保持不变。两问的目标函数都是严格凸的：每一种方差都是含有 $\sum_i w_i^2$ 的正定二次式，第二问的目标是其中六种二次式的最大值，仍严格凸。因此最优权重存在且唯一，必与自己的反向变号相同，可写为

$$w=(-u,-v,v,u),\qquad 3u+v=\frac{1}{2}. \tag{1}$$

(1) 已知方差 r 落在 $x=\pm3$ 两处，此时

$$\begin{aligned}\operatorname{Var}T&=2ru^2+2v^2=2\big[ru^2+(\tfrac12-3u)^2\big]\\&=2(r+9)\left(u-\frac{3}{2(r+9)}\right)^2+\frac{r}{2(r+9)}.\end{aligned}$$

所以唯一最优权重满足

$$\boxed{u=\frac{3}{2(r+9)},\qquad v=\frac{r}{2(r+9)}},\qquad \boxed{\min\operatorname{Var}T=\frac{r}{2(r+9)}}.$$

(2) 当两个方差 r 可以落在任意两个位置时，最坏安排总把它们放在绝对值最大的两个权重上。因此

$$F(u,v)=2(u^2+v^2)+2(r-1)\max(u^2,v^2). \tag{2}$$

最优解必有 $u,v\ge0$。事实上，若 $u<0$，由 (1) 有 $v>1/2$，改成 $(u,v)=(0,1/2)$ 会同时严格减小两个坐标的绝对值；若 $v<0$，则 $u>1/6$，改成 $(1/6,0)$ 也一样。因而只需考察 $0\le u\le1/6$、$v=1/2-3u$。

最坏安排怎样随权重变化？两种权重的绝对值在 $u=v=1/8$ 处相等。若 $u\le1/8$，则 $v\ge u$，此时

$$F=2\big[u^2+r(\tfrac12-3u)^2\big]=2(1+9r)\left(u-\frac{3r}{2(1+9r)}\right)^2+\frac{r}{2(1+9r)}.$$

由于 $r\ge1$，平方项的中心满足

$$\frac{3r}{2(1+9r)}\ge\frac18.$$

所以这一段上的最小值必在端点 $u=1/8$ 处取得。

若 $u\ge1/8$，则 $u\ge v$，此时

$$F=2\big[ru^2+(\tfrac12-3u)^2\big]=2(r+9)\left(u-\frac{3}{2(r+9)}\right)^2+\frac{r}{2(r+9)}.$$

平方项的中心属于区间 $[1/8,1/6]$ 当且仅当 $1\le r\le3$。若 $r\le3$，右段在此中心处达到最小值，它不大于公共端点的值；若 $r>3$，右段最小值也落在公共端点 $u=1/8$。

于是唯一最优权重仍为 $(-u,-v,v,u)$，其中

$$\boxed{(u,v)=\begin{cases}\left(\dfrac{3}{2(r+9)},\dfrac{r}{2(r+9)}\right), & 1\le r\le3,\\ (1/8,1/8), & r\ge3,\end{cases}}\qquad \boxed{\min F=\begin{cases}\dfrac{r}{2(r+9)}, & 1\le r\le3,\\ \dfrac{r+1}{32}, & r\ge3.\end{cases}}$$

在 $r=3$ 处，两种表达式完全一致。这个临界值并非计算巧合：它恰好是第一问的最优权重达到 $u=v$ 的时刻。在此之后，若仍让外侧与内侧权重大小不同，最坏安排就会把大方差放到权重较大的位置；四个权重绝对值相等才是最优平衡。

习题 7.5. 固定不全相等的 $x_1,\dots,x_n$，观测 $Y_i=a+bx_i+\varepsilon_i$。误差均值为 0、方差为已知的 $\sigma^2>0$ 且两两不相关。只知道 $|a|\le A$，其中 $A\ge 0$ 已知，而 $b\in\mathbb{R}$ 任意。在所有固定线性估计量 $T=\sum_i w_iY_i$ 中，求使

$$\sup_{|a|\le A,\ b\in\mathbb{R}} \mathbb{E}_{a,b}(T-b)^2$$

最小的权重及最小值。

解. 若 $\sum_i w_ix_i\neq 1$，偏差中含有非零的 b 倍数，上确界为无穷。因此必须 $\sum_i w_ix_i=1$。在此条件下，令 $s=\sum_i w_i$，最大均方误差恰为

$$Q(w)=\sigma^2\sum_i w_i^2+A^2s^2.$$

它包含偏差代价，不等同于最小方差问题。

写 $\mu=\bar{x}$、$t_i=x_i-\mu$、$S=S_{xx}>0$。约束可改写成

$$1=\sum_i\left(w_i-\frac{s}{n}\right)t_i+s\mu.$$

对这两种相互分开的成分使用加权 Cauchy 不等式，得

$$1\le\left[\sigma^2\sum_i\left(w_i-\frac{s}{n}\right)^2+\left(A^2+\frac{\sigma^2}{n}\right)s^2\right]\left[\frac{S}{\sigma^2}+\frac{\mu^2}{A^2+\sigma^2/n}\right].$$

第一个方括号就是 $Q(w)$。令

$$\rho=\frac{\sigma^2}{\sigma^2+nA^2},\qquad D=S+n\rho\mu^2.$$

得到 $Q(w)\ge\sigma^2/D$。等号要求存在共同常数 c，使

$$w_i-\frac{s}{n}=\frac{c}{\sigma^2}t_i,\qquad s=\frac{c\mu}{A^2+\sigma^2/n}.$$

再代入约束，确定 $c=\sigma^2/D$，所以唯一最优解为

$$\boxed{w_i=\frac{x_i-\bar{x}+\rho\bar{x}}{S_{xx}+n\rho\bar{x}^2}},\qquad \boxed{\min Q=\frac{\sigma^2}{S_{xx}+n\rho\bar{x}^2}}.$$

这些权重确实满足 $\sum_i w_ix_i=1$；代入也直接得到所列目标值。$A=0$ 时 $\rho=1$，这就是已知零截距的过原点估计；A 越大，权重越接近带截距最小二乘，且在 $A\to\infty$ 时趋于它。若 $\bar{x}=0$，两种估计从一开始就相同。

习题 7.6. 设 $Y_i=a+bi+\varepsilon_i$，$1\le i\le n$，误差均值为 0、方差为 $\sigma^2>0$ 且两两不相关。给定 $2\le k\le n$，须在观测前选定恰好 k 个下标，只保留这些响应。在所有选取方式及其固定线性估计量中，求对每个 a,b 都无偏估计 b 的最小方差，并求出全部最优下标集合及权重。

解. 先固定保留的下标集合 I，记其均值为 $\bar{i}_I$。对全部截距 a、斜率 b 无偏的充要条件是 $\sum_{i\in I}w_i=0$、$\sum_{i\in I}iw_i=1$。于是

$$1=\left(\sum_{i\in I}w_i(i-\bar{i}_I)\right)^2\le\left(\sum_{i\in I}w_i^2\right)\underbrace{\sum_{i\in I}(i-\bar{i}_I)^2}_{S_I}.$$

因此，固定 I 时唯一的最优权重为

$$w_i = \frac{i - \bar{i}_I}{S_I}, \qquad \min \mathrm{Var}(T) = \frac{\sigma^2}{S_I}.$$

剩下的任务只是在 $1, \dots, n$ 中挑 k 个数，使它们的中心平方和 S_I 尽可能大。

若 $n = k$，下标没有选择余地。以下设 $d = n - k > 0$，将选择的下标排列为 $i_1 < \cdots < i_k$。写 $i_j = j + z_j$，则

$$0 \le z_1 \le z_2 \le \cdots \le z_k \le d.$$

可以把 d 理解为删去的下标个数，把

$$g_0 = z_1, \quad g_a = z_{a+1} - z_a \ (1 \le a < k), \quad g_k = d - z_k$$

理解为分别放在保留下标之前、相邻保留下标之间、之后的空缺数。这些数都非负且 $\sum_{a=0}^{k} g_a = d$。

若把全部 d 个空缺集中在某一处 a，就得到一个只保留左端 a 个与右端 $k-a$ 个的下标向量

$$v_j^{(a)} = \begin{cases} j, & j \le a, \\ j + d, & j > a. \end{cases} \qquad (0 \le a \le k).$$

一般下标向量正是这些极端向量的加权平均：取 $\lambda_a = g_a/d$，则 $\lambda_a \ge 0$、$\sum_a \lambda_a = 1$，而对每个 j 都有 $i_j = \sum_a \lambda_a v_j^{(a)}$。中心化不会破坏这个加权平均关系。对每个坐标使用平方函数的凸性并求和，便得

$$S_I \le \sum_{a=0}^{k} \lambda_a S(v^{(a)}) \le \max_{0 \le a \le k} S(v^{(a)}). \tag{1}$$

这说明：总能把分散在各处的空缺移到同一个间隔，而不减小中心平方和。

对 $v^{(a)}$，前 a 个下标为 $1, \dots, a$，后 $k-a$ 个为 $n-k+a+1, \dots, n$。它是 $1, \dots, k$ 的后 $k-a$ 个元素共同增加 d 所得，直接展开中心平方和，

$$\begin{aligned} S(v^{(a)}) &= \frac{k(k^2-1)}{12} + a(k-a)d + \frac{a(k-a)}{k} d^2 \\ &= \frac{k(k^2-1)}{12} + \frac{n(n-k)}{k} a(k-a). \end{aligned}$$

这只需最大化二次式 $a(k-a)$。其最大值为 $\lfloor k^2/4 \rfloor$，恰好在 $a = \lfloor k/2 \rfloor$ 或 $a = \lceil k/2 \rceil$ 达到。因此最大中心平方和为

$$S_* = \frac{k(k^2-1)}{12} + \frac{n(n-k)}{k} \left\lfloor \frac{k^2}{4} \right\rfloor.$$

还需确认没有其他最优集合。因为 $d > 0$，上述两个可能最优的端点向量若不同，其中心化向量也不同。平方函数的凸性在非平凡混合时严格成立；式 (1) 要取等，λ_a 只能集中在某一个最优端点向量上。故所有最优集合恰为

$$\boxed{I = \{1, \dots, a\} \cup \{n-k+a+1, \dots, n\}, \quad a \in \left\{ \left\lfloor \frac{k}{2} \right\rfloor, \left\lceil \frac{k}{2} \right\rceil \right\}.}$$

相应的唯一最优权重是 $w_i = (i - \bar{i}_I)/S_*$，最小方差为 $\boxed{\sigma^2/S_*}$。当 $n = k$ 时，相同公式给出唯一的全体下标集合。

习题 7.7. 固定不全相等的 $x_1,\dots,x_n$ 及实数 $y_1,\dots,y_n$，$n\ge 2$。均匀随机排列响应标签，所得斜率记为 B_Π。

1. 求 $\mathbb{E}_\Pi B_\Pi$ 与 $\mathrm{Var}_\Pi(B_\Pi)$。
2. 设 $Y_i=a+\varepsilon_i$，误差独立同分布且连续。观察数据后，在 n 组设计 $x_i^{(j)}=\mathbf{1}_{\{i=j\}}$ 中选取拟合斜率最大的一组，再把该组设计固定下来，计算上尾排列 p 值。求所报 p 值及在水平 $\alpha=1/n$ 时的实际拒绝概率。若每次排列都重新选择最大斜率，所报 p 值又是多少?

解. 第一问令 $t_i=x_i-\bar{x}$、$z_j=y_j-\bar{y}$，则

$$B_\Pi=\frac{\sum_i t_i z_{\Pi(i)}}{S_{xx}}.$$

固定一个位置，$\mathbb{E}z_{\Pi(i)}=0$，$\mathbb{E}z_{\Pi(i)}^2=S_{yy}/n$。不同位置 $i\ne j$ 对应于不同下标的均匀有序对，所以

$$\mathbb{E}[z_{\Pi(i)}z_{\Pi(j)}]=\frac{\sum_{r\ne s} z_r z_s}{n(n-1)}=-\frac{S_{yy}}{n(n-1)}.$$

又 $2\sum_{i<j}t_it_j=-S_{xx}$，故

$$\boxed{\mathbb{E}_\Pi B_\Pi=0,\qquad \mathrm{Var}_\Pi(B_\Pi)=\frac{S_{yy}}{(n-1)S_{xx}}.}$$

这也包括所有 y_j 相等、方差为零的情形。

第二问，第 j 组设计有 $S_{xx}=(n-1)/n$，拟合斜率为

$$B_j=\frac{n}{n-1}(Y_j-\bar{Y}).$$

因此被选中的恰是最大响应所在位置。连续且独立同分布保证最大值几乎必然唯一。若把这个位置固定后再排列，$n!$ 个排列中恰有 $(n-1)!$ 个把最大响应留在此处，所以

$$\boxed{p=1/n\quad \text{几乎必然.}}$$

按 $p\le\alpha$ 拒绝，在 $\alpha=1/n$ 时实际拒绝概率是 $\boxed{1}$，而不是 $1/n$。

若每次排列都重新选组，比较的统计量是

$$M=\max_j B_j=\frac{n}{n-1}(\max_j Y_j-\bar{Y}).$$

它在任何标签排列下都不变，所以重新计算选择过程得到的上尾排列概率恒为 $\boxed{1}$。原错误不在联合分布的交换性，而在于先用同一份数据挑了设计，却在校准时把这一选择当成预先固定。